# Probabilidad: Tarea 4

Profesor: M. en C. Iván Toledano

Octubre 2025

Escribir el procedimiento completo (ecuaciones y variables utilizadas) para resolver los siguientes problemas:

1. **(10 puntos)** Científicos han determinado que el 90 % de las personas con una enfermedad B tienen el gen A activo, es decir, $P(A|B) = 0.9$. Se estima que, de toda la población, sólo el 5 % tiene la enfermedad B, mientras que 45 % tiene el gen A activo. Si una persona secuencia su genoma y descubre que el gen A se encuentra activo. ¿Cuál es la probabilidad de que desarrolle la enfermedad B?. En otras palabras, ¿cuál es el valor $P(B|A)$?.
2. **(20 puntos)** Una persona utiliza su coche 0.30 del tiempo, camina un 0.30 del tiempo, y toma el camión 0.40 del tiempo al ir a trabajar. Esta persona llega tarde a su trabajo 0.1 del tiempo cuando camina, 0.03 cuando maneja, y 0.07 cuando toma el camión.
   - Si un día llegó tarde a su trabajo, ¿Cuál es la probabilidad de que haya tomado el camión?
   - Si llegó a tiempo. ¿Cuál es la probabilidad de que haya caminado al trabajo?

## 1. Modelo Naive Bayes

Un modelo de Naive Bayes es un clasificador probabilístico fundamentado en el teorema de Bayes, y es uno de los métodos supervisados de clasificación más simples. Uno tiene una colección de N pares entrenados $\{(\vec{x}_i, y_i\})_{i=1}^N$, donde el vector $\vec{x}_i \in \mathcal{R}^D$ son las $D$ variables de entradai (o features) de las $i$ muestras o registros, y $y_i \in \{1, \ldots, C\}$ es la variable dependiente/objetivo (categórica) que denota a cual clase $C$ pertenece cada registro $i$. Dado una nueva muestra $\vec{x}$, el objetivo es determinar cuál sería su clase predicha $\hat{y}$. Esta predicción de la clase se realiza escogiendo la clase con mayor probabilidad *a posteriori* bajo la suposición simple (ingenua, naive), de que cada una de estas variables de entrada $\vec{x}_i$ son independientes una de la otra.

$$\begin{aligned}\hat{y} = \arg\max_{y\in[C]} \mathcal{P}(y|\vec{x}) &= \arg\max_{y\in[C]} \frac{\mathcal{P}(\vec{x}|y)\mathcal{P}(y)}{\mathcal{P}(\vec{x})} \propto \arg\max_{y\in[C]} \mathcal{P}(\vec{x}|y)\mathcal{P}(y) \\ &= \arg\max_{y\in[C]} \mathcal{P}(y)\prod_{j_1}^{D}\mathcal{P}(x_j|y)\end{aligned}$$

donde $\mathcal{P}$ es la probabilidad a posteriori que se busca maximizar. En este ejercicio particular tenemos solamente datos de entrada categóricos. Para cada $X_i$, las probabilidades

$P(X_i|C)$ se estiman a partir de los datos de entrenamiento como la frecuencia relativa de la ocurrencia del valor $X_i$ dado $C$:

$$P(X_i = x|C = c) = \frac{\text{Número de veces que } X_i = x \text{ dado } C = c}{\text{Número total de ocurrencias de } C = c}$$

Por ejemplo, si estamos clasificando correos electrónicos como"spam" o "no spam", y la palabra clave $X_i$ es "gratis", entonces la probabilidad $P(X_i = \text{gratis}|C = \text{spam})$ se calcularía como:

$$P(X_i = \text{gratis}|C = \text{spam}) = \frac{\text{Número de correos con la palabra "gratis" y etiquetados como spam}}{\text{Número total de correos etiquetados como spam}}$$

3. **(40 puntos)** Supongamos que nuestro objetivo es desarrollar un filtro de spam utilizando este modelo. Para esto, se nos proporciona el dataset que se muestra en la Tabla 1, indicando las palabras incluidas en una muestra de emails. Dado un nuevo email que contiene el mensaje "congratulations, you won free gift", el objetivo es determinar si este mensaje es clasificado como spam o no. Para esto, el modelo de Naive Bayes estima la probabilidad total de que un correo sea spam $\hat{\mathcal{P}}(y = 1)$ (spam=1, nospam=0). Uno podría tener un estimado de cuál sería la probabilidad global de que un correo sea spam en toda la población, pero si no se tiene este dato, lo recomendable es utilizar la información del dataset mismo, i. e.,

$$\hat{\mathcal{P}}(y = \text{spam}) = \frac{6}{10} = \frac{3}{5}$$

$$\hat{\mathcal{P}}(y = \text{no spam}) = \frac{4}{10} = \frac{2}{5}$$

De manera similar, uno puede obtener para cada variable de entrada (feature) $x_j$ una probabilidad condicional $\hat{\mathcal{P}}(x_j = 1|y)$ como la fracción correspondiente por cada clase, utilizando la información del dataset. Por ejemplo, la probabilidad de encontrar la palabra "congratulations" en un mensaje de spam sería $\hat{\mathcal{P}}(x = \text{congratulations}|y = \text{spam}) = \frac{5}{6}$, puesto que según los datos, esta palabra se encuentra 5 de cada 6 veces en un mensaje de spam (primer renglón en Tabla 1).

Usando la misma metodología, llenar la Tabla 2 de probabilidades condicionales para todas las palabras, para las dos clases de mensaje. Utilizando el mismo formato del dataset, el mensaje "congratulations, you won free gift" estaría codificado como un vector $\vec{x} = [1, 1, 1, 1, 1, 0, 0, 0]$. Utilizando la información de la tabla de probabilidades creada, calcular la probabilidad condicional de que este mensaje sea spam (y no spam) dado este contenido de palabras,

$$\hat{\mathcal{P}}(y = \text{spam}|\vec{x}) \propto \hat{\mathcal{P}}(y = \text{spam}) \prod_{j=!}^{D} \hat{\mathcal{P}}(x_j|y = \text{spam}) \tag{1}$$

$$\hat{\mathcal{P}}(y = \text{no spam}|\vec{x}) \propto \hat{\mathcal{P}}(y = \text{no spam}) \prod_{j=!}^{D} \hat{\mathcal{P}}(x_j|y = \text{no spam}) \tag{2}$$

Comparar las dos probabilidades condicionales anteriores y escoger la clase asociada con la probabilidad a posteriori más grande. ¿Cómo se clasifica este mensaje?

| Features | | Muestras(emails) | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|
| | | **1** | **2** | **3** | **4** | **5** | **6** | **7** | **8** | **9** | **10** |
| **1** | congratulations | 1 | 1 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 1 |
| **2** | you | 1 | 1 | 1 | 0 | 0 | 0 | 1 | 1 | 0 | 0 |
| **3** | won | 0 | 1 | 1 | 1 | 1 | 1 | 0 | 0 | 0 | 1 |
| **4** | free | 1 | 1 | 1 | 1 | 1 | 1 | 1 | 0 | 0 | 0 |
| **5** | gift | 0 | 0 | 1 | 1 | 1 | 1 | 0 | 1 | 0 | 0 |
| **6** | attached | 0 | 0 | 1 | 0 | 0 | 0 | 1 | 1 | 1 | 0 |
| **7** | sincerely | 1 | 0 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 1 |
| **8** | thanks | 0 | 1 | 0 | 1 | 1 | 0 | 1 | 1 | 0 | 0 |
| **Categoría** | | **Spam** | | | | | | **No Spam** | | | |

Cuadro 1: Muestra de emails.

| | | $P(x_j = 1\|y)$ | |
|---|---|---|---|
| | | **Spam** | **No Spam** |
| **1** | congratulations | 5/6 | |
| **2** | you | | |
| **3** | won | | |
| **4** | free | | |
| **5** | gift | | |
| **6** | attached | | |
| **7** | sincerely | | |
| **8** | thanks | | |

Cuadro 2: Probabilidades condicionales de cada uno de los features del dataset de la Tabla 1.

4. **(30 puntos)** Utilizando el dataset adjunto **emails_spam_sample.csv** referente a los datos de la Tabla 1, genera un script en Python denominado **naive_bayes_comparativo.py** que cumpla con los siguientes objetivos:

   a) Implementar manualmente el modelo de **Naive Bayes** tal como se desarrolló en el ejercicio 3, mostrando en pantalla la **Tabla 2** completa de probabilidades condicionales, así como los valores resultantes de las probabilidades a posteriori y la clasificación final calculada a partir de las Ecuaciones 1 y 2.

   b) Utilizar una paquetería de aprendizaje automático en Python (*por ejemplo,* `scikit-learn`) para entrenar un modelo equivalente de **Naive Bayes** sobre el mismo conjunto de datos. Puede emplearse alguna de las siguientes variantes según el tipo de variables del dataset: `GaussianNB`, `MultinomialNB` o `BernoulliNB`.

   c) Comparar ambos enfoques (implementación manual vs. paquetería) en términos de:
      - Resultado de la clasificación final para cada observación del conjunto de prueba.
      - Probabilidades obtenidas (cuando sean accesibles en el modelo de librería).
      - Diferencias observadas en precisión, simplicidad de implementación y tiempo de ejecución.