Clustering Jerárquico: Tarea 3

Profesor: M. en C. Iván Toledano

Septiembre 2023

En el set de datos adjunto **OnlineRetail.csv** se registraron transacciones ocurridas entre los años 2010 y 2011 para una empresa de e-commerce de Reino Unido. Este set de datos incluye las siguientes variables:

- StockCode (categórico)
- Description (categórico)
- Quantity (numérico Entero)
- InvoiceDate (Fecha)
- UnitPrice (numérico Real)
- CustomerID (categórico)
- Country (categórico)

En el jupyter notebook adjunto se realiza un análisis de tipo RFM (Recency, Frequency, Monetary Value), en el cual se intenta clasificar a los clientes utilizando estos atributos, aplicando un modelo de clustering utilizando dos métodos: *clustering jerárquico* y *k-medias*. Modifiquen a su consideración el código anexado y contestar las siguientes preguntas.

1. Preguntas

1. **(30 puntos)** Desarrollar y explicar el el procedimiento que se siguió para preparar los datos, particularmente en los siguientes apartados:

   - Obtención de las variables Recency, Frequency, y Monetary Value.
   - Tratamiento de valores atípicos.
   - Reescalar los datos numéricos.

   Ayudarse de tablas o figuras para complementar su respuesta, si lo consideran necesario.

2. **(20 puntos)** Explicar brevemente en qué consiste el clustering jerárquico y cómo es aplicado a estos datos. Utilizar tablas y figuras para complementar su explicación y argumentos. Incluir la siguiente información:

   - Elección de tipo de métrica y tipo de enlace entre clusters.
   - Visualización del algoritmo utilizando un dendrograma.

- Selección del número óptimo de clusters.

3. **(10 puntos)** Explicar en qué consiste el clustering por k-medias. ¿Qué diferencias, así como sus ventajas y desventajas se tienen en comparación con la metodología anterior?

4. **(20 puntos)** Mostrar una tabla que muestre estadísticos relevantes de los clusters generados, y exponer en sus palabras cómo es el perfil de cada grupo de clientes obtenido de este set de datos. Mencionar de qué manera se podría utilizar la información obtenida.

5. **(20 puntos)** Generar un gráfico 3D de las variables R, F, M, donde se representen cada uno de los clusters encontrados.