Maestria en Ciencia de los Datos Carlos Pulido Rosas

Actividad 4 - Probabilidad

"Estas respuestas se obtuvieron con el código de Python adjunto"

1. Respuesta

   P(B|A) = 0.10
   Aunque el gen A aparece frecuentemente en quienes sí tienen la enfermedad (90%), en la población general el gen es muy común (45%) y la enfermedad es muy rara (5%). Cuando se combina todo con Bayes, el resultado real es que **solo 1 de cada 10 personas con el gen activo tiene la enfermedad B**.

2. Respuesta

   Probabilidad de que haya tomado el bus dado que llegó tarde:

   P (Bus | Tarde)

   i. Aplicamos Bayes:

   $$P(\text{Bus}|\text{Tarde}) = \frac{P(\text{Tarde}|\text{Bus})\,P(\text{Bus})}{P(\text{Tarde})}$$

   ii. Primero calculamos P(Tarde):

   $$P(Tarde) = 0.03(0.30) + 0.10(0.30) + 0.07(0.40)$$
   $$P(Tarde) = 0.009 + 0.03 + 0.028 = 0.067$$

   iii. Ahora:

   $$P(\text{Bus}|\text{Tarde}) = \frac{0.07(0.40)}{0.067} = 0.4179$$

   iv. **Respuesta: ≈ 0.4179**

   Interpretación: si llegó tarde, hay **41.8%** de probabilidad de que haya ido en bus.

   Probabilidad de que haya caminado dado que llegó a tiempo:

   P (Camina | A tiempo)

   v. Aplicamos Bayes:

   $$P(A\ tiempo) = 1 - P(Tarde) = 1 - 0.067 = 0.933$$

   vi. Probabilidad de llegar a tiempo caminando):

   $$P(A\ tiempo \mid Camina) = 1 - 0.10 = 0.90$$

   vii. Ahora:

   $$P(Camina|A\ tiempo) = 0.9330.90(0.30) = 0.2894$$

viii. **Respuesta: ≈ 0.2894**

Interpretación: si llegó a tiempo, hay **28.9%** de probabilidad de que haya ido caminando.

3. Respuesta

Primero completamos la tabla de acuerdo con nuestro resultado del Código
Tabla 2.

#	Feature	$P(x_j=1\|Spam)$	$P(x_j=1\|No\ Spam)$
1	congratulations	5/6	1/4
2	you	1/2	1/2
3	won	5/6	1/4
4	free	5/6	1/4
5	gift	2/3	1/4
6	attached	1/6	3/4
7	sincerely	1/3	1/2
8	thanks	1/3	1/2

Aplicamos el Teorema de Bayes para el mensaje “Congratulations, you won free gift”

Vector: $\vec{x} = [1, 1, 1, 1, 1, 0, 0, 0]$

Probabilidades a priori:

- P (y = Spam) = 6/10 = 3/5
- P (y = No Spam) = 4/10 = 2/5

Para Spam:

- **$P(\vec{x}|Spam)$** = $P(x_1=1|Spam) \times P(x_2=1|Spam) \times P(x_3=1|Spam) \times P(x_4=1|Spam) \times P(x_5=1|Spam) \times P(x_6=0|Spam) \times P(x_7=0|Spam) \times P(x_8=0|Spam)$
- **$P(\vec{x}|Spam)$** = (5/6) × (1/2) × (5/6) × (5/6) × (2/3) × (5/6) × (2/3) × (2/3)
- **$P(\vec{x}|Spam)$** = (5×1×5×5×2×5×2×2) / (6×2×6×6×3×6×3×3) = 2500/23328 ≈ 0.1072
- **$P(\vec{x}, Spam) = P(\vec{x}|Spam) \times P(Spam)$** = 0.1072 × (3/5) = 0.0643

Para No Spam:

- **$P(\vec{x}|No\ Spam)$** = (1/4) × (1/2) × (1/4) × (1/4) × (1/4) × (1/4) × (1/2) × (1/2)
- **$P(\vec{x}|No\ Spam)$** = (1×1×1×1×1×1×1×1) / (4×2×4×4×4×4×2×2) = 1/16384 ≈ 0.000061
- **$P(\vec{x}, No\ Spam) = P(\vec{x}|No\ Spam) \times P(No\ Spam)$** = 0.000061 × (2/5) = 0.000024

Probabilidades Posteriores

- **P (Spam|$\vec{x}$) = P($\vec{x}$, Spam) / [P($\vec{x}$, Spam) + P($\vec{x}$, No Spam)]**
- **P (Spam|$\vec{x}$)** = 0.0643 / (0.0643 + 0.000024) = 0.0643 / 0.0643 ≈ **0.9996** (99.96%)
- **P (No Spam|$\vec{x}$) = P($\vec{x}$, No Spam) / [P($\vec{x}$, Spam) + P($\vec{x}$, No Spam)]**
- **P (No Spam|$\vec{x}$)** = 0.000024 / 0.0643 ≈ **0.0004** (0.04%)

El mensaje "congratulations, you won free gift" se clasifica como SPAM con una probabilidad posterior del **99.96%**.

Esto tiene sentido porque las palabras "congratulations", "won", "free" y "gift" aparecen con mucha mayor frecuencia en emails de spam que en emails legítimos según el “dataset” de entrenamiento.

4. Respuesta

Utilice BernoulliNB por que los datos son binarios

```
TABLA 2: PROBABILIDADES CONDICIONALES
#   Feature         P(xj=1|Spam)       P(xj=1|No Spam)
------------------------------------------------------------------------------
1   congratulations 1.0000               0.2000
2   you             0.6000               0.4000
3   won             0.8000               0.4000
4   free            1.0000               0.4000
5   gift            0.6000               0.4000
6   attached        0.2000               0.6000
7   sincerely       0.4000               0.6000
8   thanks          0.6000               0.4000

Probabilidades a priori:
  P(Spam) = 0.5000
  P(No Spam) = 0.5000
```

Actividad 4 - Probabilidad

```
RESULTADOS POR EMAIL:
Email    Real       Manual     P(Spam)      Sklearn    P(Spam)
--------------------------------------------------------------------------------
1        Spam       Spam       0.7874         Spam       0.7377
2        Spam       Spam       0.9912         Spam       0.9674
3        Spam       Spam       0.8929         Spam       0.8333
4        Spam       Spam       0.9912         Spam       0.9674
5        Spam       Spam       0.9912         Spam       0.9674
6        No Spam    No Spam    0.0000         No Spam    0.3846
7        No Spam    No Spam    0.0000         No Spam    0.1509
8        No Spam    No Spam    0.0000         No Spam    0.0380
9        No Spam    No Spam    0.0000         No Spam    0.0039
10       No Spam    No Spam    0.0000         No Spam    0.3973

MÉTRICAS:
  Precisión Manual:     1.0000
  Precisión Sklearn:    1.0000
  Tiempo Manual:        0.44 ms
  Tiempo Sklearn:       7.82 ms

MATRIZ DE CONFUSIÓN (Manual):
  VP: 5  FP: 0
  FN: 0  VN: 5
```

La implementación manual da P(Spam)=0.0000 para emails No Spam porque algunas probabilidades condicionales son exactamente 1.0 o 0.0, causando que el producto sea 0. Sklearn usa **suavizado de Laplace** para evitar probabilidades de cero.

Diferencias Observadas

A) PRECISIÓN

- **Manual:** 100% (10/10 correctos)
- **Sklearn:** 100% (10/10 correctos)
- **Diferencia:** 0% - Ambos son perfectos en este dataset