Métodos Estadísticos Básicos: Tarea 5

Maestría en Ciencias de Datos, CUCEA, UdeG

2023
Noviembre

Escribir el procedimiento completo (ecuaciones y variables utilizadas) para resolver los siguientes problemas:

1. **(10 puntos)**: Las calificaciones de una clase están distribuidas de manera normal con una media de 80 y una desviación estándar de 12.

   - Encuentra la calificación x que separa 30 % a la izquierda (menor) y 70 % a la derecha (mayor) de la distribución.
   - Si un estudiante se encuentra en el top 10 % de la clase, al menos cuánto tiene que ser el valor de su calificación?
   - ¿Qué rango de calificaciones constituye el 50 % central (i.e. entre cuartiles Q_1 y Q_2) de esta distribución normal?

   Agregar figuras de la distribución normal y su correspondiente área integrada en cada apartado (puede ser a mano).

2. **(10 puntos)** Una encuesta de opinión quiere estimar las preferencias de los votantes (sí o no) dentro de dos puntos porcentuales como margen de error. ¿Cómo podría decidirse el tamaño de la muestra de encuestados a considerar?

3. **(10 puntos)** Expresar la hipótesis nula (H_0) e hipótesis alternativa (H_1) en términos de los parámetros apropiados (μ, p ó σ) de las siguientes situaciones:

   - El salario promedio inicial de un graduado en ingeniería en sistemas computacionales es mayor a 20,000 mxn.
   - La desviación estándar de la temperatura de un cuerpo humano promedio es de 0.62 F.
   - La proporción de personas que sufren de diabetes en México es menor a 9 %.

4. **(10 puntos)** Una base de datos de los puntos de rating de distintos vinos (1-100) fue obtenida y extraída a partir de una revista y pagina web dedicada a este tema. Se encuentra que estos puntos de rating pueden ser modelados como una curva normal. Considerando esto como una población en el análisis, se tiene una media de 88.44 puntos y una desviación estándar de 3.03 puntos. Supongamos que de una muestra de $n = 10$ vinos se obtuvo una media muestral de puntos de 90.2. ¿Salió esta muestra de la población de vinos anterior? Escribir la prueba de hipótesis y llegar a una conclusión con un nivel de significancia del 5 % (decir si se realiza una prueba de una o dos colas).

5. **(10 puntos)** En tiempos de campaña, una pequeña encuesta es realizada preguntando si las personas votarían por un candidato de un partido o no. De esta encuesta los resultados son los siguientes: 24 de 80 mujeres encuestadas y 11 de 65 hombres encuestados dicen que no van a votar por el candidato. Realizar una prueba de hipótesis con un nivel de significancia del 10 % para ver las proporciones entre hombres y mujeres es significativamente diferente.

6. **(20 puntos)** En una prueba t de una sola muestra se compara una media muestral con respecto a un valor de la hipótesis nula. De manera similar, en una prueba t para muestras dependientes apareadas se calcula la diferencia entre las observaciones pareadas (ejemplo: observaciones antes y después en una sola muestra) y después se realiza una prueba t de una sola muestra a estas diferencias. En el cuadro 1 se muestran las calificaciones de 20 estudiantes antes y después de llevar un curso de preparación. Se quiere buscar si en general este curso mejoró la capacidad de los estudiantes para realizar este examen. Realizar la prueba t pareada para esta muestra de estudiantes calculando cada uno de los siguiente incisos:

   - Calcular la diferencia d_i entre las dos observaciones de cada para, haciendo la distinción entre diferencias negativas y positivas.
   - Calcular la media de la distribución de estas diferencias, $\bar{d}$.
   - Calcular la desviación estándar de estas diferencias, s_d, y utilizar esto para calcular el error estándar de la distribución muestral asociada, $SE(\bar{d}) = \frac{s_d}{\sqrt{n}}$.
   - En la hipótesis nula se tendría que las diferencias antes y después sean cero. Lo que nosotros queremos estudiar (hipótesis alternativa) es si estas diferencias son mayores (test de una sola cola). En base a esto, la estadística de prueba T se calcula con la ecuación:
   $$T = \frac{\bar{d}}{SE(\bar{d})}$$
   - Esta estadística correspondiente a una distribución T de Student tiene los grados de libertad de la única muestra analizada de 20 alumnos, $n - 1$. Con la estadística de prueba calculada y los grados de libertad, encontrar el p-valor asociado a esta estadística.
   - Escoger un nivel de significancia y concluir si la diferencia entre las notas obtenidas después del curso de preparación son significativamente más altas que aquellas antes del curso.

7. **(20 puntos)** En la parte de distribuciones utilizamos el data set **Babyboom.csv** e hicimos un ajuste con una distribución de Poisson para la probabilidad de tener x número de nacimientos en un lapso de 24 horas, para $n = 44$ bebés. Observamos que las frecuencias esperadas (teóricamente) en un **lapso de 24 horas** sugerían que la distribución de Poisson era un buen ajuste para los datos observados. Para probar que este es un buen ajuste, realizar una prueba de bondad de Chi cuadrada entre lo observado y esperado teóricamente (es importante utilizar lo esperado en todo el rango de 24, para tener unidades de frecuencia y no una probabilidad) **entre los valores x = 0 y x = 6**, y concluir si esto es un buen ajuste con un nivel de significancia del 5 %. La tabla de de frecuencias esperadas y observadas se pueden encontrar en el cuadro 2, o se puede revisar **el notebook de Python adjunto**, .

Número de estudiante	Calificación (antes)	Calificación (después)
1	18	22
2	21	25
3	16	17
4	22	24
5	19	16
6	24	29
7	17	20
8	21	23
9	23	19
10	18	20
11	14	15
12	16	15
13	16	18
14	19	26
15	18	18
16	20	24
17	12	18
18	22	25
19	15	19
20	17	16

Cuadro 1: Calificaciones de 20 estudiantes en un examen antes y después de tomar un curso de preparación.

Número de nacimientos (por hora)	Probabilidad (D. Poisson)	Frecuencia Esperada [# observaciones]	Frecuencia Observada [# observaciones]
0	0.159885	3.837242	3
1	0.293117	7.034815	8
2	0.268686	6.448464	6
3	0.164194	3.940656	4
4	0.075254	1.806101	3
5	0.027593	0.662225	0
> 6	0.011271	0.270497	0
Total	1.0	24	24

Cuadro 2: Observaciones de número de sobrevivientes en el Titanic

8. **(10 puntos)** Suponer que uno compara el tipo de pasajeros (tripulación, 1era, 2da, 3era clase) del viaje el Titanic, y se observa el número de pasajeros que sobrevivieron o no el hundimiento del barco. Las cuentas se muestran en el cuadro 3, y uno se pregunta si algún tipo de pasajero de cierta clase tenía más probabilidad de sobrevivir que los otros. Hacer una prueba de Chi cuadrada para prueba de independencia de variables para decidir si las probabilidades de supervivencia es independiente del status de un pasajero.

	Tripulación	1era Clase	2da Clase	3era Clase	Total
Vivos	212	202	118	178	710
Muertos	673	123	167	528	1491
Total	885	325	285	706	2201

Cuadro 3: Observaciones de número de sobrevivientes en el Titanic