Datos Generales

1. Nombre de la Asignatura	2. Nivel de formación	3. Clave de la Asignatura
Procesamiento de Grandes Bases de Datos	Maestría	IH595
4. Prerrequisitos	5. Área de Formación Formación Particular Obligatoria	6. Departamento Sistemas de Información
7. Modalidad: Mixta	8. Tipo de Asignatura: Curso-Taller	
9. Carga Horaria		
Teoría: ***20 hrs.***	Práctica: ***28 hrs.***	Total: ***48 hrs.*** Créditos: 7
10. Trayectoria de la asignatura		

Contenido del Programa

11. Presentación

12.- Objetivos del programa

Adquirir los conocimientos necesarios en uso del software y hardware para el procesamiento de grandes bases de datos en el contexto de áreas multi-temáticas de diferentes ciencias.

Objetivo General

Implementar soluciones de nube computacional y entonos locales para grandes volúmenes de datos

13.-Contenido

Contenido temático

1. ***Introducción a grandes bases de datos y su vinculación con la nube computacional***
2. ***Arquitecturas de un sistema de grandes bases de datos***
3. ***Procesamiento por lotes (Batch)***
4. ***Procesamiento en flujo (Streaming)***
5. ***Procesamiento de grafos***
6. ***Introducción a almacenamiento de los datos***
7. ***Fiabilidad de los datos***

8. Consistencia de los datos

Contenido desarrollado

Unidad 1. ***Introducción a grandes bases de datos y su vinculación con la nube computacional***

Objetivo particular de la unidad:

Desarrollo

1.1. **Grandes bases de datos**

- ***1.1.1.*** Definición
- ***1.1.2.*** Tipos de datos
- ***1.1.3.*** Características
- ***1.1.4.*** Las Vs de las grandes bases de datos
- ***1.1.5.*** Aprovechamiento de grandes bases de datos
- ***1.1.6.*** Generación de grandes bases de datos
- ***1.1.7.*** Modelo de generación de grandes bases de datos
- ***1.1.8.*** Manejo de grandes bases de datos
- ***1.1.9.*** Valor del análisis de grandes bases de datos
- ***1.1.10.*** Desafíos, Panorama y Tecnologías

1.2. **Nube Computacional**

- ***1.2.1.*** Definición
- ***1.2.2.*** Características esenciales
- ***1.2.3.*** Modelos de servicios
  - ***1.2.3.1.*** Infraestructura como un servicio
  - ***1.2.3.2.*** Plataforma como un servicio
  - ***1.2.3.3.*** Software como un servicio
- ***1.2.4.*** Modelos de implementación en la nube
  - ***1.2.4.1.*** Nube publica
  - ***1.2.4.2.*** Nube privada
  - ***1.2.4.3.*** Nube comunitaria
  - ***1.2.4.4.*** Nube híbrida

1.3. **Soluciones empresariales**

- ***1.3.1.*** Hadoop
- ***1.3.2.*** Plataforma en la nuble de Google

1.3.3. Servicios de la Web de Amazon

1.3.3.1. Consola de administración de AWS

1.3.4. Microsoft Azure

1.4. Caso de uso

Unidad 2 *Arquitecturas de un sistema de grandes bases de datos*

Objetivos particulares de la unidad:

Conocer los Fundamentos tecnológicos de grandes bases de datos.

Identificar Arquitectura de un sistema de grandes bases de datos.

Aprender métodos de procesamiento distribuido.

Desarrollo

2.3. **Fundamentos tecnológicos**

2.3.1. Fundamentos tecnológicos

2.3.2. Sistemas distribuidos

2.3.2.1. Hipervisores

2.3.2.2. Implementación de servicios locales con Linux para soluciones virtuales

2.3.2.3. Contenedores y microservicios

2.3.2.3.1. Dockers y Kubernetes

2.3.3. ¿Como procesamos toda esa información?

2.3.4. Computación científica

2.4. **Arquitectura de un sistema de grandes bases de datos**

2.4.1. Estructura general de un sistema de grandes bases de datos

2.4.2. Sistema de archivos

2.4.3. Sistema de cálculo distribuido

2.4.4. Gestor de recursos

2.4.4.1. DBMS

2.4.4.2. No-SQL

2.4.4.3. Implementación de servicios de Bases de datos bajo estructura DBMS y No-SQL

2.4.5. *Stacks* de *software* para sistemas de grandes bases de datos

2.5. **Escenarios de procesamiento distribuido**

2.5.1. Procesamiento en *batch*

2.5.2. Procesamiento en *stream*

2.5.3. Procesamiento en grafos

2.5.4. Procesamiento en GPU

2.6. Caso de uso

Unidad 3 *Procesamiento por lotes (Batch)*

Objetivos particulares de la unidad:

Conocer métodos de captura y preprocesamiento por lotes.

Aprender métodos de almacenamiento de datos estructurados.

Analizar datos estáticos.

Desarrollo

3.1 **Captura y preprocesamiento por lotes**

3.1.1 Conceptos básicos

3.1.2 Captura de datos estáticos

3.2 **Almacenamiento de datos estructurados**

3.2.1 Almacenamiento de datos masivos

3.2.2 Sistemas de ficheros distribuidos DBMS

3.2.3 Bases de datos *NoSQL*

3.3 **Análisis de datos estáticos**

3.3.1 *Apache Hadoop* y *MapReduce*

3.3.2 *Apache Spark*

3.4 Caso de uso

Unidad 4 Procesamiento en flujo (Streaming)

Objetivo particular de la unidad:

Conocer métodos de captura y preprocesamiento de datos dinámicos.

Aprender métodos de almacenamiento de datos dinámicos.

Analizar datos dinámicos.

Desarrollo

4.1 Captura y preprocesamiento de datos dinámicos

4.1.1 Conceptos básicos
4.1.2 Captura de datos en *streaming*
4.1.3 Arquitectura de datos en *streaming*

4.2 Almacenamiento de datos dinámicos

4.2.1 Almacenamiento de datos dinámicos
4.2.2 Bases de datos en memoria

4.3 Análisis de datos dinámicos

4.3.1 Soluciones basadas en datos y basadas en tareas
4.3.2 Calculo *online* de valores estadísticos
4.3.3 Técnicas de resumen para el procesado aproximado de datos en flujo

4.4 Caso de uso

Unidad 5 *Procesamiento de grafos*

Objetivos particulares de la unidad:

Conocer métodos de Representación y captura de grafos.

Aprender métodos de almacenamiento de grafos.

Analizar datos mediante técnicas de grafos.

Desarrollo:

5.1 Representación y captura de grafos

5.1.1 Conceptos básicos de grafos
5.1.2 Tipos de grafos
5.1.3 Captura de datos en formato de grafos

5.2 Almacenamiento de grafos

5.2.1 Almacenamiento en ficheros
5.2.2 Bases de datos *NoSQL* en grafo

5.3 Análisis de grafos

- ***5.3.1*** Procesamiento de grafos
- ***5.3.2*** Visualización de grafos
- ***5.3.3*** Herramientas para datos masivos
- ***5.4 Caso de uso***

Unidad 6. Introducción a almacenamiento de los datos

Desarrollo:

6.1 Jerarquía de memoria

- ***6.1.1*** ROM
- ***6.1.2*** RAM
- ***6.1.3*** Almacenamiento secundario/respaldo
- ***6.1.4*** Discos duros
  - ***6.1.4.1*** Tipos de almacenamiento
    - *6.1.4.1.1* Mecánicos
    - *6.1.4.1.2* Estado Solido
    - *6.1.4.1.3* Flash M.2
  - ***6.1.4.2*** Grabación longitudinal
  - ***6.1.4.3*** Almacenamiento de bits
  - ***6.1.4.4*** Geometría y estructura
  - ***6.1.4.5*** Acceso
- ***6.1.5*** Discos de estado sólido
- ***6.1.6*** Análisis comparativo HDD contra SSD

6.2 Matriz redundante de discos independientes (RAID)

- ***6.2.1*** Componentes de la matriz
- ***6.2.2*** Técnicas RAID
- ***6.2.3*** Implementaciones

6.3 Caso de uso

7. Fiabilidad de los datos

7.1 Introducción a la replicación

- ***7.1.1*** Problema de confiabilidad de los datos
- ***7.1.2*** Definición de replicación
  - ***7.1.2.1*** Consistencia del sistema de archivos

7.1.2.2 Consistencia de la base de datos

7.1.3 Clasificación (local y remota)

7.1.4 Copia en primer acceso

7.1.5 Seguimiento de cambios en origen y destino

7.2 Introducción a los códigos de borrado (EC)

7.2.1 Bases de codificación de borrado

7.2.2 Códigos horizontales y verticales

7.2.3 Expresando Código con Generador Matriz

7.2.3.1 Codificación: Linux RAID-6

7.2.3.2 Aceleración de la codificación

7.2.3.3 Codificación: RDP

7.2.4 Aritmética para códigos de borrado

7.2.5 Decodificación con matrices generadoras

7.2.5.1 Códigos: Reed Solomon, EVENODD 1995, Código X 199,H y HDP

7.3 Replicación y EC en la nube

7.3.1 Tres dimensiones en el almacenamiento en la nube

7.3.2 Replicación versus Codificación de borrado (RS)

7.3.3 Compensación fundamental

7.3.4 Códigos piramidales

7.3.4.1 Google GFS II y Microsoft Azure

7.3.5 Problema de recuperación en la nube

7.3.5.1 Optimizando la recuperación

7.3.5.2 Códigos Regeneradores

7.3.6 Combinación de dos códigos de borrado

7.4 Caso de uso

8. Consistencia de los datos

8.1. Consistencia de datos y teorema CAP

8.1.1. Los sistemas de intercambio de datos de hoy

8.1.2. Propiedades fundamentales

8.1.2.1. Consistencia, disponibilidad, tolerancia a las particiones de red

8.1.3. Teorema CAP (Consistency, Availability and Partition Tolerance)

8.1.3.1. Definición

8.1.3.2. Perder particiones, perder disponibilidad, perder consistencia.

8.1.3.3. CAP en el Sistema de base de datos

8.1.4. Otro CAP: ACID (Atomicity, Consistency, Integrity, Durability)

8.1.5. Comparativa CAP y ACID

8.2. Protocolo de consenso: 2PC y 3PC

8.2.1. 2PC (Two Phase Commit Protocol): definición y problemática

8.2.2. 3PC (Three Phase Commit Protocol)

8.2.2.1. Definición

8.2.2.2. Solución de bloqueo

8.2.2.3. Especificaciones de manejo de tiempo de espera

8.2.2.4. Gestión de particiones y con particiones de red

8.2.2.5. Seguridad contra vivacidad.

8.3. Paxos

8.3.1. Definición, propiedades y desafíos

8.3.2. Mecanismos diferenciadores centrales e implementación

8.4. Chubby y Zookeeper

8.4.1. Chubby

8.4.1.1. Definición, estructura del sistema, lista de control de acceso, cerraduras y secuencias, eventos, Apis, almacenamiento en caché

8.4.2. Zookeeper

8.4.2.1. Definición, ecosistema *Hadoop*, servicio, cliente API, garantías, implementación, ambiente, ejemplo, aplicación

8.5. Caso de uso

14. Actividades Prácticas

El curso está diseñado con una visión de aprender haciendo, basado en un enfoque de enseñanza basada en problemas, tomando en cuenta que el grupo esta integrados con alumnos con diferentes habilidades y destrezas derivadas de su formación profesional diversa.

Se estimula el proceso de aprendizaje mediante las lecturas del texto de referencia fuera del aula y la resolución de tareas en el aula virtual del curso, complementándose con ejercicios prácticos (manos a la obra) en entornos en la nube *(Cloud computing)*.

15.- Metodología

El curso taller tiene un enfoque práctico para facilitar el proceso de enseñanza aprendizaje, complementando las lecturas y actividades del libro de texto, con ejercicios prácticos durante las sesiones practicas semanales.

16.- Evaluación

- *Reportes de actividades, ejercicios semanales e investigación en aula virtual 30%.*
- *Evaluación 1 15%.*
- *Evaluación 2 15%*
- *Actividades presenciales en el aula durante talleres presenciales 20%.*
- *Proyecto final con entregable de articulo corto 20%.*

17.- Bibliografía

1. *Big Data Analytics with Hadoop 3, Sridhar Alla, Packt, 2018, Birmingham UK. ISBN 978-1-78862-884-6*
2. *Artificial Intelligence for Cloud and Edge Computing (Sanjay Misra, Amit Kumar Tyagi, Vincenzo Piuri), Springer, 2022, Edinburgh, UK.ISBN: 978-3-030-80820-4*
3. *Cloud Computing Infrastructure for Enabling Future Technology Advancement (Sitendra Tamrakar), Nova Science Publishers, 2021, New York EUA, ISBN: 978-1-68507-800-3*
4. *MongoDB The Defi nitive Guide Powerful and Scalable Data Storage, Shannon Bradshaw, O.Reilly, 2019, EUA, ISBN: 978-1-491-95446-1.*
5. *Big Data: Análisis de Datos en Entornos Masivos. Autores: Nin Guerrero, Jordi - Casas Roma, Jordi - Julbe López, Francesc. ISBN: 9788491804727, 9788491804734 Editorial: Editorial UOC, Año de Edición: 2019*
6. *Graph Algorithms Practical Examples in Apache Spark and Neo4j, Mark Needham and Amy E. Hodler, O´Really, 2019, EUA, ISBN: 978-1-492-05781-9*

Otros materiales

- *Big Data IEEE Transactions, 2022, https://www.computer.org/csdl/journal/bd*
- *Cloud Computing, IEEE Transactions, 2022, https://www.computer.org/csdl/journal/cc/2022/01*
- *Springer, 2022, https://link.springer.com/search?facet-content-type=%22Book%22&facet-language=%22En%22&sortOrder=newestFirst&query=&facet-sub-discipline=%22Artificial+Intelligence%22&facet-discipline=%22Computer+Science%22*

18.- Perfil del profesor

- ***Doctor en Tecnologías de Información con orientación en la ciencia de los datos.***
- ***Maestro en Ciencia de Datos, Tecnologías de Información, o áreas afines en infraestructura y servicios de nube computacional.***

19.- Nombre de los profesores que imparten la materia

- ***Dr. José Antonio Orizaga Trejo***

20.- Lugar y fecha de su aprobación (incluyendo la última actualización)

- ***27 de junio de 2022***

21.- Instancias que aprobaron el programa:

- ***Junta Académica de la Maestría en Ciencia de los Datos, conformada por:***

Centro Universitario de Ciencias Económico Administrativas
MAESTRÍA EN CIENCIA DE LOS DATOS

Dra. Ana Rosa Jiménez Meza
Presidenta de la Junta Académica y
Coordinadora de la Maestría en Ciencia de los Datos

Dr. Guillermo Sierra Juárez

Dra. Rocío Maciel Arellano

Dr. Jesús Raúl Beltrán Ramírez

Dr. José Antonio Orizaga Trejo

Dr. Pablo Salazar Linares (Externo)