Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Almacenamiento de Grandes Bases de Datos

Actividad: Corrección WordCount y Nube de Palabras

War and Peace - WordCount Corregido (normalizado)

Alumno:	Carlos Pulido Rosas
Fecha:	9 de Marzo de 2026
Entorno:	Linux Mint – Oracle VirtualBox – Hadoop 3.3.6 – YARN Single Node
Archivo:	warandpeace.txt (3,202,320 bytes – 562,488 palabras)
Correccion:	toLowerCase() + replaceAll("[^a-záéíóúüñ]", "")

Correccion del Programa WordCount

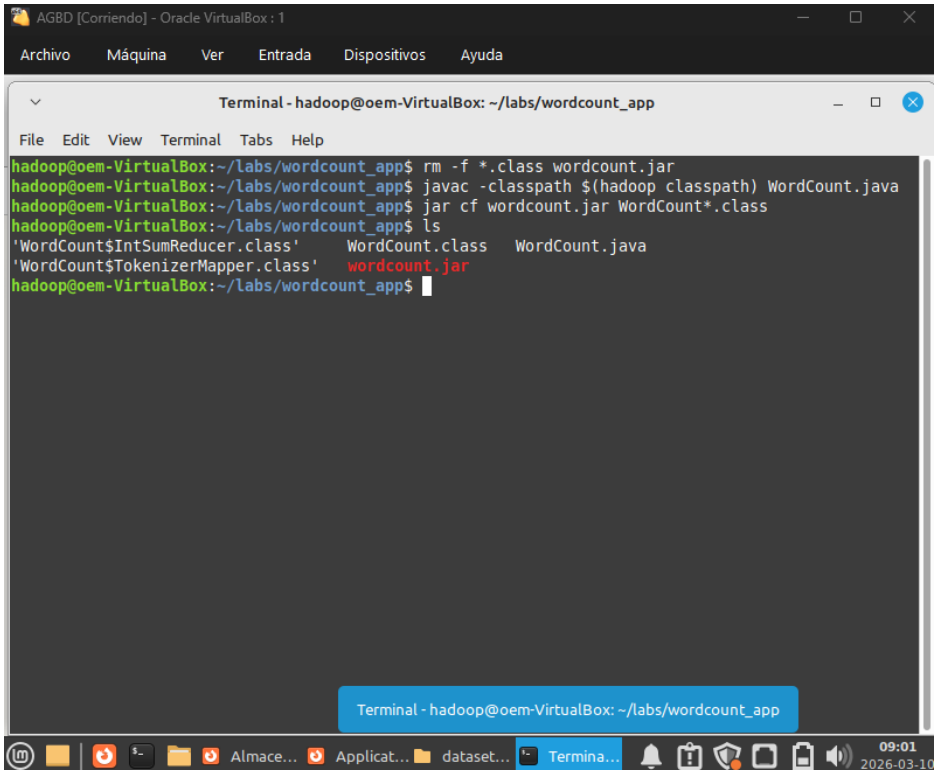
Se modifico el Mapper para normalizar cada token: convertir a lfabético con **toLowerCase()** y eliminar caracteres no alfabéticos con **replaceAll("[^a-z]", "")**. Esto fusiona variantes como "war", "War", "war," y "war." En un solo token.

```
Token = token.toLowerCase()
       .replaceAll("[^a-zaeiouun]", "");
if (!token.isEmpty()) {
    word.set(token);
    context.write(word, one);
}
```

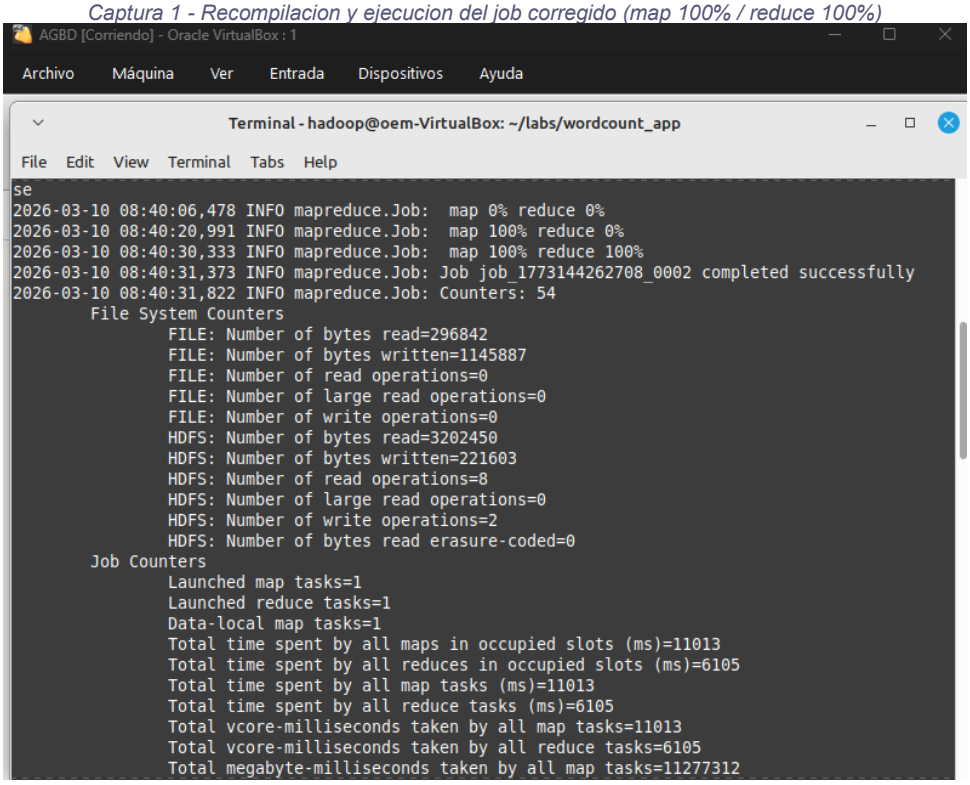
Código de Python utilizado para la creación de la Nube de palabras

```
from wordcloud import WordCloud, STOPWORDS
import matplotlib.pyplot as plt
# Load word frequencies from Hadoop MapReduce output
frequencies = {}
with open('/home/hadoop/datasets/resultado2.txt', 'r') as f:
    for line in f:
        parts = line.strip().split('\t')
        if len(parts) == 2:
            word = parts[0], count = int(parts[1]), frequencies[word] = count
# Remove common stopwords so meaningful words stand out
stopwords = set(STOPWORDS)
# Generate word cloud from frequencies
wc = WordCloud( width=1920, height=1080,background_color='white', max_words=300, colormap='RdYlBu',
    stopwords=stopwords, collocations=False, min_font_size=10, max_font_size=300,
    font_path='/usr/share/fonts/truetype/dejavu/DejaVuSans.ttf'
).generate_from_frequencies(frequencies)
# Plot and save image
fig, ax = plt.subplots(figsize=(19.2, 10.8)), ax.imshow(wc, interpolation='bilinear'), ax.axis('off')
ax.set_title('Word Cloud - War and Peace (Normalized)',
             fontsize=20, fontweight='bold', pad=20)
plt.tight_layout()
plt.savefig('/home/hadoop/datasets/nube_palabras.png',
            dpi=150, bbox_inches='tight')
plt.show()
print("Word cloud saved at: /home/hadoop/datasets/nube_palabras.png")
```

Ejecución del Job MapReduce (Corregido)



Captura 1 - Recompilacion y ejecucion del job corregido (map 100% / reduce 100%)



Captura 2 - YARN Web UI - FinalStatus: SUCCEEDED

Respuestas

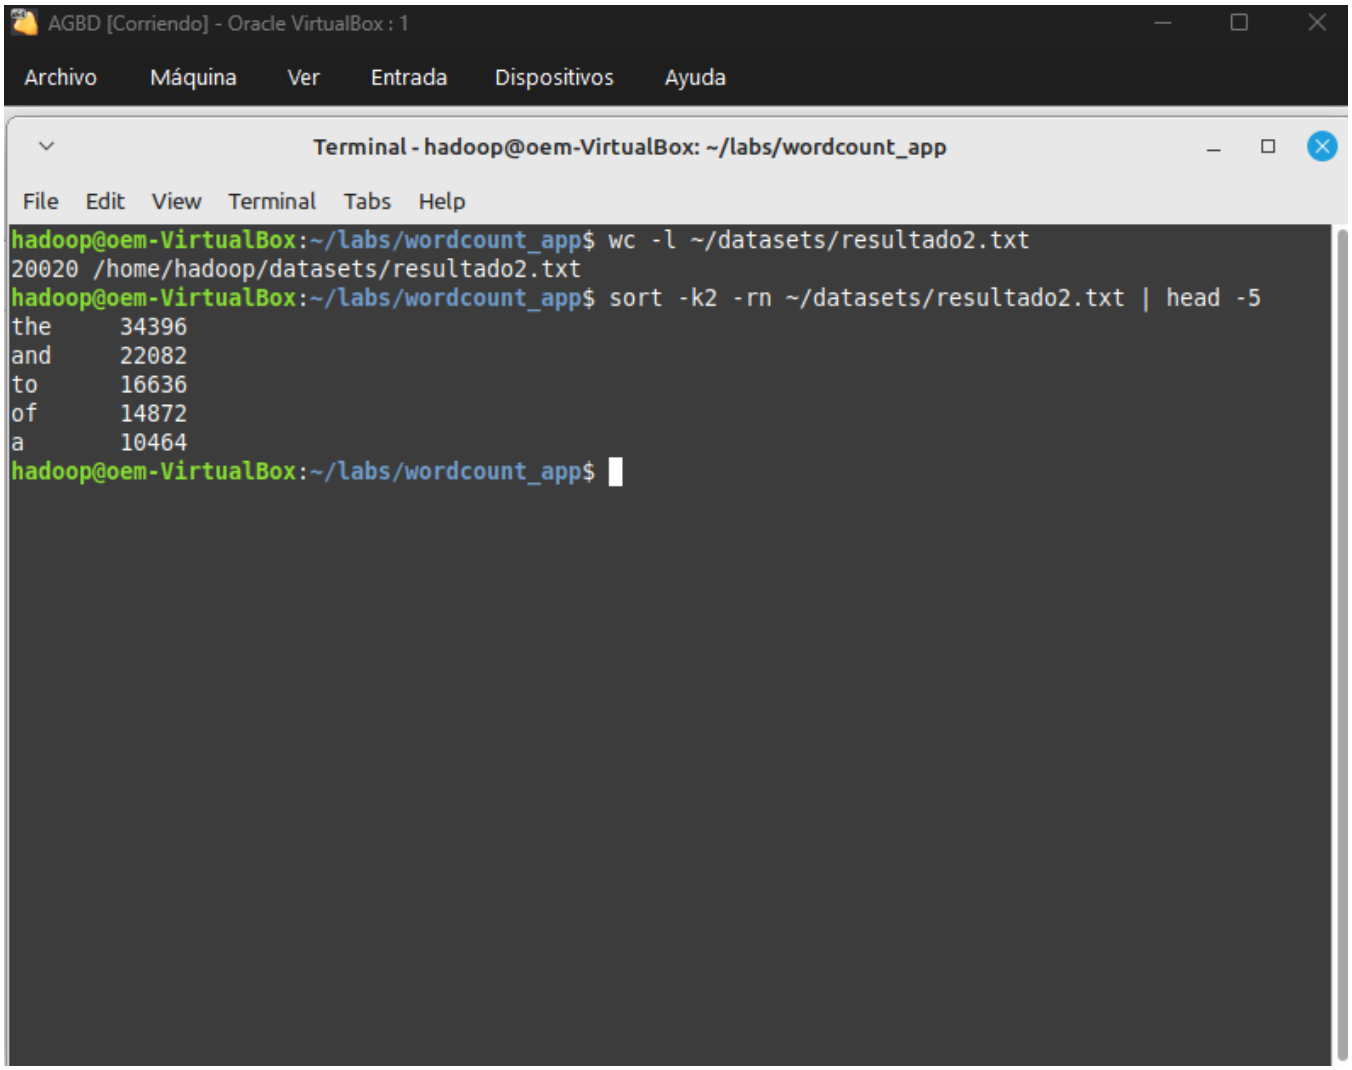
1. Cuantas palabras unicas contabilizo el programa?

El programa contabilizo **20,020** palabras unicas.

Con la version original eran 41,621 - la normalizacion redujo el vocabulario a la mitad al fusionar variantes de puntuacion y capitalizacion.

2. Cuales son las 5 palabras con mayor numero de ocurrencias?

#	Palabra	Ocurrencias
1	the	34,396
2	and	22,082
3	to	16,636
4	of	14,872
5	a	10,464



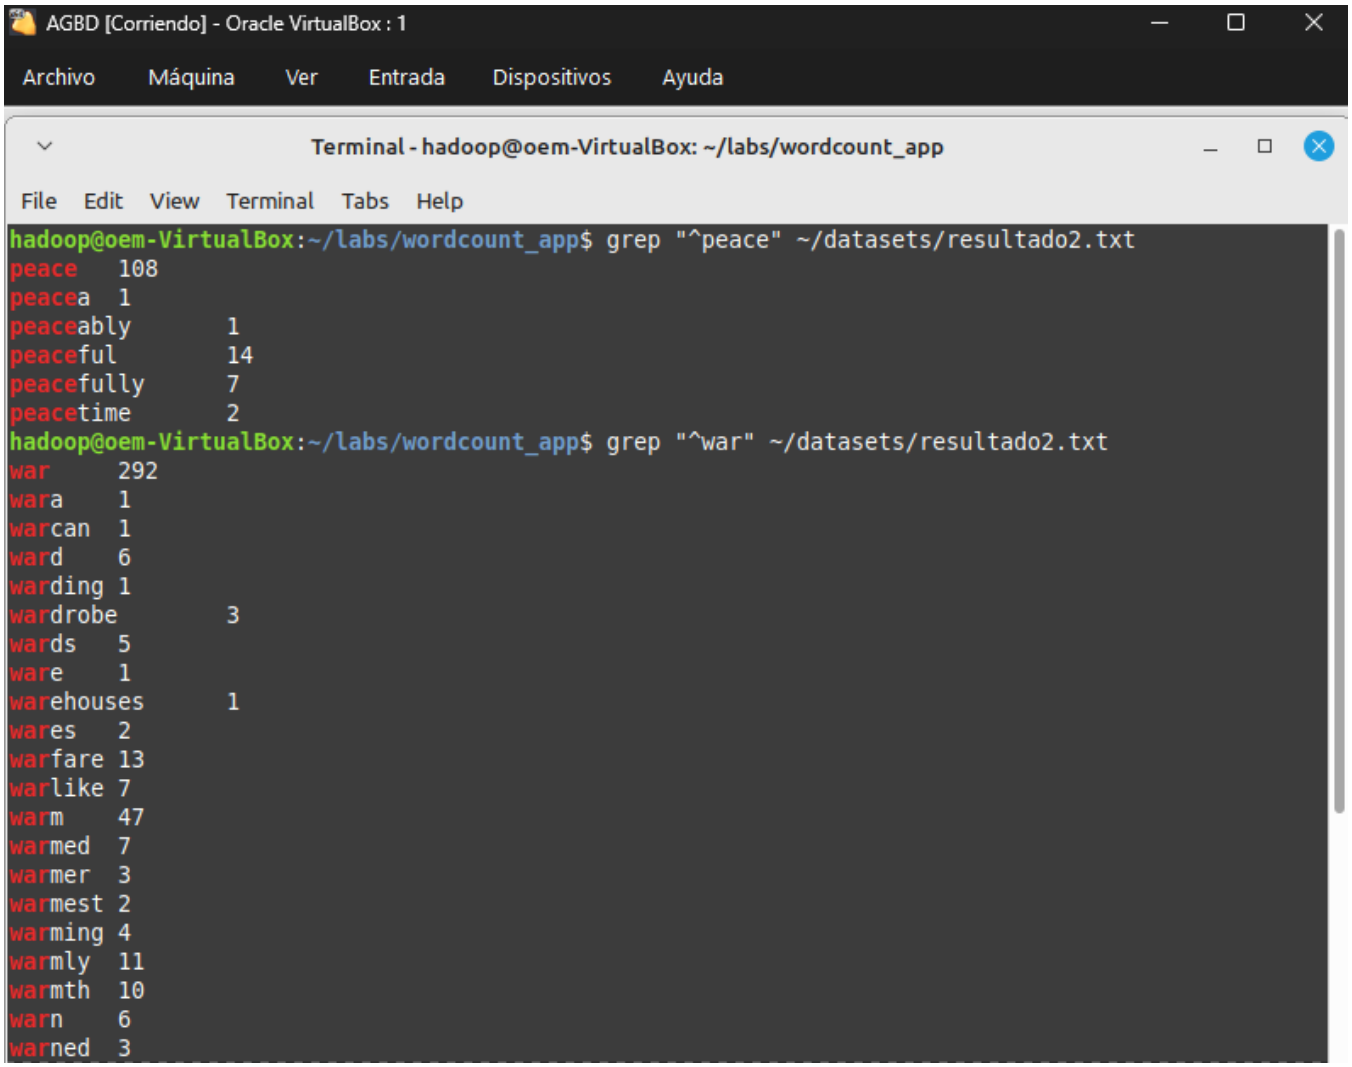
Captura 2 - Palabras únicas (wc -l) y Top 5

3. Cuantas veces aparece la palabra "peace"?

La palabra **"peace"** aparece **108** veces (vs 59 en la versión sin normalizar).

4. Cuantas veces aparece la palabra "war"?

La palabra **"war"** aparece **292** veces (vs 166 en la versión sin normalizar).

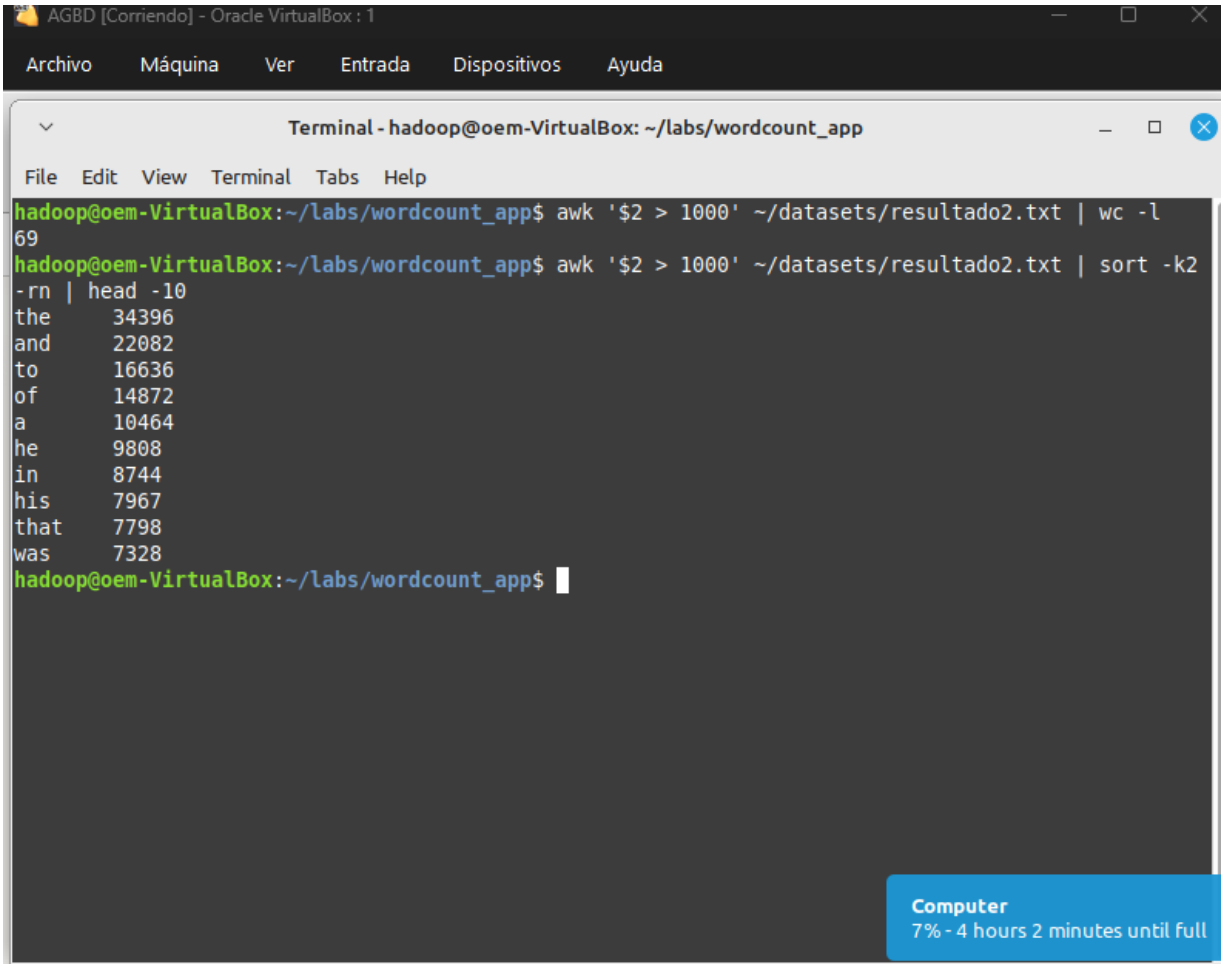


Captura 3 – Búsqueda de Peace y War en el texto normalizado

5. Cuantas palabras superan las 1,000 ocurrencias?

69 palabras tienen más de 1,000 ocurrencias.

#	Palabra	Ocurrencias
1	the	34,396
2	and	22,082
3	to	16,636
4	of	14,872
5	a	10,464
6	he	9,808
7	in	8,744
8	his	7,967
9	that	7,798
10	was	7,328

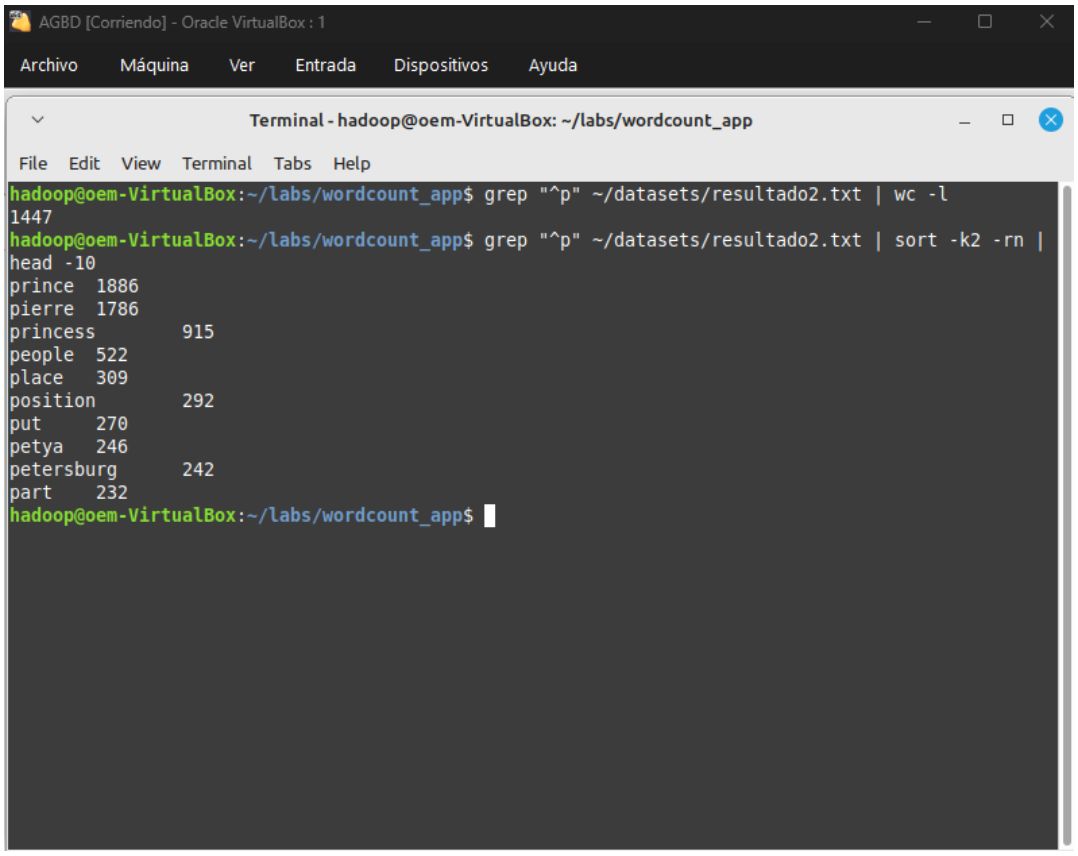


Captura 4 - Búsqueda de palabras con más de 1000 apariciones con el texto normalizado

6. Cuantas palabras inician con la letra "P" (Pulido)?

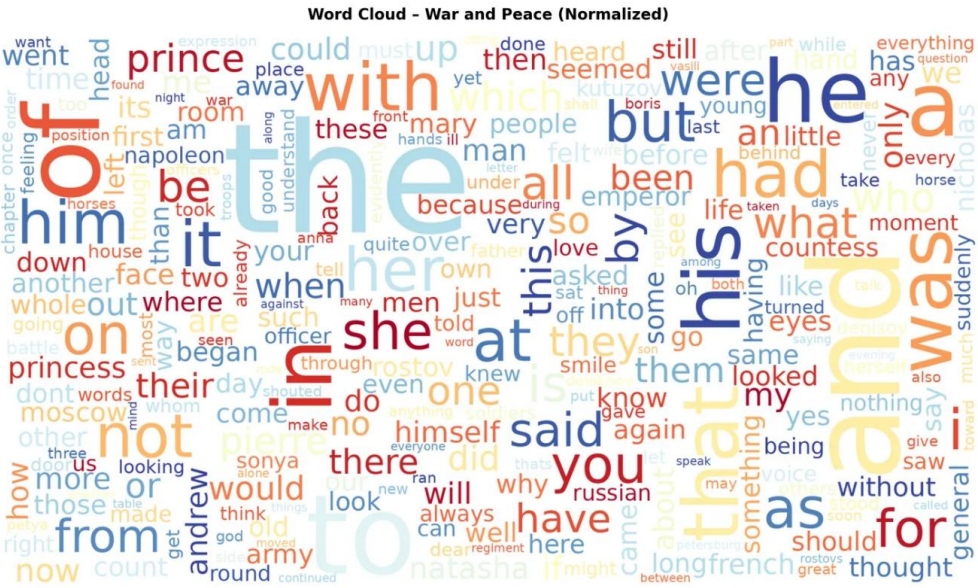
Las palabras que inician con la letra P son **1,447**.

Letra	Palabras unicas	Letra	Palabras unicas
A	1,277	N	399
B	1,090	O	483
C	1,755	**P**	**1,447**
D	1,323	Q	98
E	878	R	1,137
F	949	S	2,267
G	614	T	995
H	730	U	473
I	880	V	366
J	151	W	663
K	222	X	33
L	673	Y	89
M	985	Z	43



Captura 5 - Búsqueda de palabras que empiezan con "P" con el texto normalizado

Nube de Palabras



Captura 6 - Nube de palabras generada con Python wordcloud

Estadísticas Adicionales

Rango de ocurrencias	Numero de palabras
Exactamente 1	8,101
Entre 2 y 9	7,774
Entre 10 y 99	3,517
Entre 100 y 1,000	559
Mas de 1,000	69

Promedio de ocurrencias por palabra

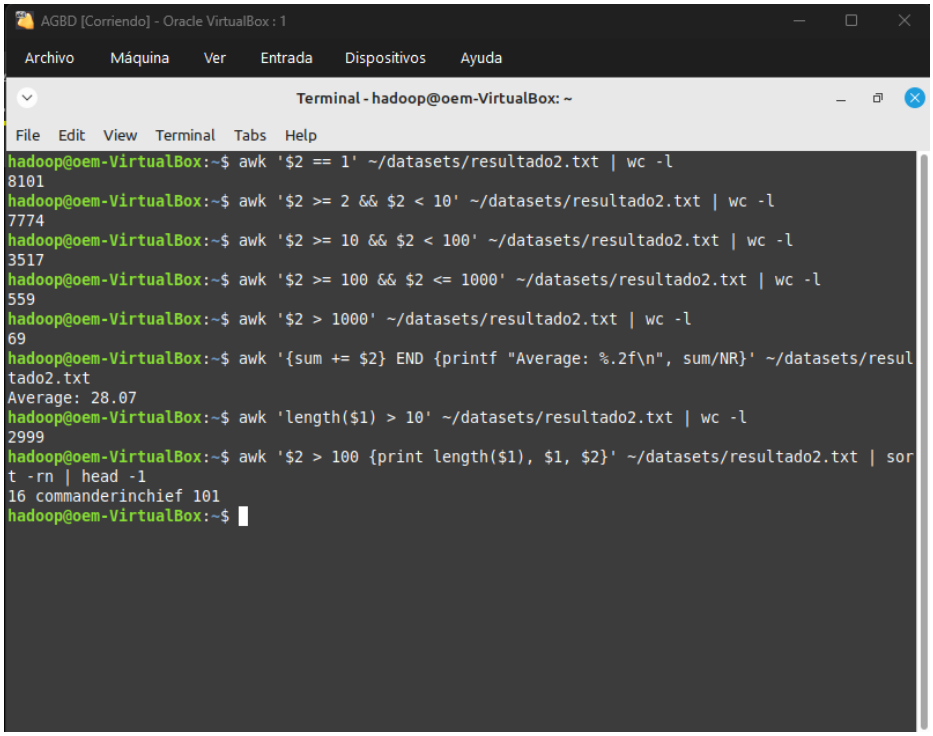
28.07

Palabras con mas de 10 caracteres

2,999

Palabra más larga con más de 100 ocurrencias

commanderinchief (101 ocurrencias)



Captura 7 - Estadísticas adicionales con comandos awk