Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Almacenamiento de Grandes Bases de Datos

Actividad: Importar Asegurados IMSS a HDFS y Hive

IMSS Asegurados (Primer Semestre del 2025) – Tabla Externa en Hive

Alumno:	Carlos Pulido Rosas
Fecha:	23 de Marzo de 2026
Entorno:	Linux Mint – Oracle VirtualBox – Hadoop 3.3.6 – YARN Single Node

1. Preparación y Limpieza del Dataset

Se descargó el archivo de asegurados mensuales del IMSS del portal de datos abiertos (datos.imss.gob.mx). Se realizó limpieza de datos con Python/pandas: eliminación de fila encabezado fantasma, renombrado de columnas sin nombre, eliminación de columnas vacóas, estandarización de la categoría “No Binario”, conversión del separador de miles (punto europeo) a valores enteros reales, y filtrado al primer semestre de 2025 (enero–junio). El dataset final contiene 498 registros y 9 columnas.

2. Carga del CSV a HDFS

Se creó el directorio en HDFS y se cargó el archivo CSV:

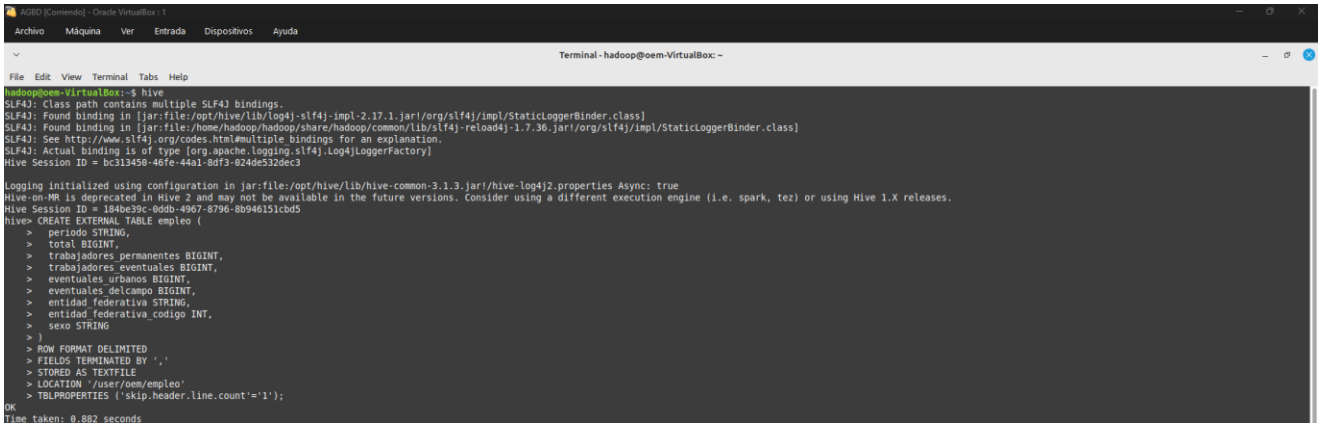
```
hdfs dfs -mkdir -p /user/oem/empleo
hdfs dfs -put /tmp/imss_asegurados_2025_s1.csv /user/oem/empleo/
hdfs dfs -ls /user/oem/empleo/
```

3. Creación de Tabla Externa en Hive

Se creó una tabla externa en Hive apuntando al directorio HDFS. Una tabla externa permite que los datos permanezcan en HDFS independientemente de Hive — si se elimina la tabla, los datos no se borran.

```
CREATE EXTERNAL TABLE empleo (
  periodo STRING,
  total BIGINT,
  trabajadores_permanentes BIGINT,
  trabajadores_eventuales BIGINT,
  eventuales_urbanos BIGINT,
  eventuales_delcampo BIGINT,
  entidad_federativa STRING,
  entidad_federativa_codigo INT,
  sexo STRING
)
```

```
ROW FORMAT DELIMITED FIELDS TERMINATED BY ’,’
STORED AS TEXTFILE
LOCATION ’/user/oem/empleo’
TBLPROPERTIES (’skip.header.line.count’=’1’);
```

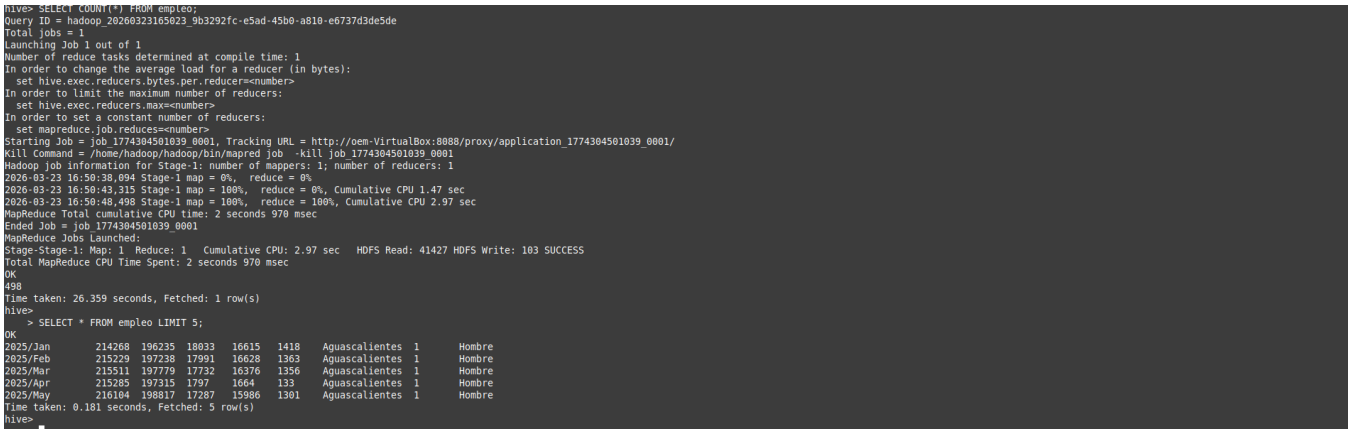


[Captura 1 – Creación exitosa de tabla externa empleo en Hive]

4. Consulta SQL en Hive

Se ejecutó un query en SQL para verificar la carga correcta de los datos y explorar el dataset:

```
-- Conteo total de registros
SELECT COUNT(*) FROM empleo;
```



*[Captura 2 – COUNT(*) = 498 y SELECT * LIMIT 5 con datos correctos]*