Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Almacenamiento de Grandes Bases de Datos

Optimización en Hive: Particionado por Mes de Archivos IMSS 2025

Alumno:	Carlos Pulido Rosas
Fecha:	20 de abril de 2026
Actividad:	Tarea 5 — Optimización en Hive: Particionado
Herramienta:	Apache Hive 2.3.2 / Hadoop 3.3.6 (YARN)
Versión:	bde2020/hive:2.3.2-postgresql-metastore + postgres:9.6
Entorno:	Homelab (ThinkPad T14 Gen 4) — Docker Composehomelab, Docker, etc.]
Dataset:	IMSS ASG 2025 — Primer semestre (~27.7M registros, 6 archivos mensuales)dataset]

1. Introducción

El particionado es una de las principales técnicas de optimización en Apache Hive. Consiste en organizar los datos en subdirectorios dentro de HDFS según el valor de una o más columnas, de forma que una consulta que filtre por esa columna solo lea los bloques del subdirectorio correspondiente, sin escanear el dataset completo. Esto reduce drásticamente la cantidad de datos procesados (partition pruning) y mejora los tiempos de respuesta en tablas de gran tamaño.

En esta actividad se reorganiza la estructura de los archivos de asegurados IMSS del primer semestre de 2025 en HDFS, pasando de seis archivos planos en un mismo directorio a una estructura particionada por mes. Posteriormente, se reconstruye la tabla externa empleo en Hive como tabla particionada y se ejecuta una consulta de prueba sobre la partición de marzo para verificar el funcionamiento correcto del esquema de particionado.

2. Desarrollo

2.1 Estructura inicial en HDFS

Antes de la reorganización, los seis archivos mensuales se encontraban en el directorio /user/oem/empleo/ sin subdivisión alguna. La estructura inicial era:

```
$ docker exec hadoop-namenode hdfs dfs -ls /user/oem/empleo/
Found 6 items
-rw-r--r--   3 root supergroup  385793272  /user/oem/empleo/asg-2025-01-31.csv
-rw-r--r--   3 root supergroup  382721784  /user/oem/empleo/asg-2025-02-28.csv
-rw-r--r--   3 root supergroup  382210436  /user/oem/empleo/asg-2025-03-31.csv
-rw-r--r--   3 root supergroup  378943970  /user/oem/empleo/asg-2025-04-30.csv
-rw-r--r--   3 root supergroup  383776233  /user/oem/empleo/asg-2025-05-31.csv
-rw-r--r--   3 root supergroup  383951720  /user/oem/empleo/asg-2025-06-30.csv
```

Listado HDFS antes del particionado — archivos planos sin estructura de directorios

2.2 Creación de directorios de partición y reorganización

Se crearon seis subdirectorios con la convención mes=NN que Hive utiliza para reconocer automáticamente las particiones, y se movió cada archivo al directorio correspondiente a su mes:

```
-- Crear directorios de partición
for mes in 01 02 03 04 05 06; do
  docker exec hadoop-namenode hdfs dfs -mkdir -p /user/oem/empleo/mes=${mes}
done

-- Mover cada archivo a su partición
docker exec hadoop-namenode hdfs dfs -mv /user/oem/empleo/asg-2025-01-31.csv
/user/oem/empleo/mes=01/
docker exec hadoop-namenode hdfs dfs -mv /user/oem/empleo/asg-2025-02-28.csv
/user/oem/empleo/mes=02/
docker exec hadoop-namenode hdfs dfs -mv /user/oem/empleo/asg-2025-03-31.csv
/user/oem/empleo/mes=03/
docker exec hadoop-namenode hdfs dfs -mv /user/oem/empleo/asg-2025-04-30.csv
/user/oem/empleo/mes=04/
docker exec hadoop-namenode hdfs dfs -mv /user/oem/empleo/asg-2025-05-31.csv
/user/oem/empleo/mes=05/
docker exec hadoop-namenode hdfs dfs -mv /user/oem/empleo/asg-2025-06-30.csv
/user/oem/empleo/mes=06/
```

Comandos HDFS para crear la estructura de particionado y reubicar los archivos

La estructura resultante en HDFS quedó de la siguiente forma:

```
$ docker exec hadoop-namenode hdfs dfs -ls -R /user/oem/empleo/
drwxr-xr-x  - root supergroup          0  /user/oem/empleo/mes=01
-rw-r--r--  3 root supergroup  385793272  /user/oem/empleo/mes=01/asg-2025-01-31.csv
drwxr-xr-x  - root supergroup          0  /user/oem/empleo/mes=02
-rw-r--r--  3 root supergroup  382721784  /user/oem/empleo/mes=02/asg-2025-02-28.csv
drwxr-xr-x  - root supergroup          0  /user/oem/empleo/mes=03
-rw-r--r--  3 root supergroup  382210436  /user/oem/empleo/mes=03/asg-2025-03-31.csv
drwxr-xr-x  - root supergroup          0  /user/oem/empleo/mes=04
-rw-r--r--  3 root supergroup  378943970  /user/oem/empleo/mes=04/asg-2025-04-30.csv
drwxr-xr-x  - root supergroup          0  /user/oem/empleo/mes=05
-rw-r--r--  3 root supergroup  383776233  /user/oem/empleo/mes=05/asg-2025-05-31.csv
drwxr-xr-x  - root supergroup          0  /user/oem/empleo/mes=06
-rw-r--r--  3 root supergroup  383951720  /user/oem/empleo/mes=06/asg-2025-06-30.csv
```

Estructura HDFS final — cada archivo en su subdirectorio mes=NN correspondiente

2.3 Reconstrucción de la tabla empleo en Hive

Se eliminó la tabla existente y se recreó como tabla externa particionada por la columna mes. El delimitador de campo es el caracter pipe (|), confirmado al inspeccionar directamente el contenido de los archivos CSV en HDFS:

```
DROP TABLE IF EXISTS empleo;

CREATE EXTERNAL TABLE empleo (
  cve_delegacion     STRING,
  cve_subdelegacion  STRING,
  cve_entidad        STRING,
  cve_municipio      STRING,
  sector_economico_1 STRING,
  sector_economico_2 STRING,
  sector_economico_4 STRING,
  tamano_patron      STRING,
  sexo               STRING,
  rango_edad         STRING,
  rango_salarial     STRING,
  rango_uma          STRING,
  asegurados         STRING,
```

```
  no_trabajadores    STRING,
  ta                 STRING,
  teu                STRING,
  tec                STRING,
  tpu                STRING,
  tpc                STRING,
  ta_sal             STRING,
  teu_sal            STRING,
  tec_sal            STRING,
  tpu_sal            STRING,
  tpc_sal            STRING,
  masa_sal_ta        STRING,
  masa_sal_teu       STRING,
  masa_sal_tec       STRING,
  masa_sal_tpu       STRING,
  masa_sal_tpc       STRING
)
PARTITIONED BY (mes STRING)
ROW FORMAT DELIMITED
FIELDS TERMINATED BY '|'
STORED AS TEXTFILE
LOCATION '/user/oem/empleo/'
TBLPROPERTIES ('skip.header.line.count'='1');
```

DDL — tabla externa empleo con particionado por mes y delimitador pipe

2.4 Registro de particiones con MSCK REPAIR TABLE

Debido a que los subdirectorios fueron creados directamente en HDFS (fuera de Hive), es necesario ejecutar MSCK REPAIR TABLE para que el metastore registre las particiones detectadas:

```
MSCK REPAIR TABLE empleo;

SHOW PARTITIONS empleo;
```

Registro automático de particiones desde la estructura de directorios HDFS

```
+------------+
| partition  |
+------------+
| mes=01     |
| mes=02     |
| mes=03     |
| mes=04     |
| mes=05     |
| mes=06     |
+------------+
6 rows selected
```

Las seis particiones fueron detectadas y registradas correctamente en el metastore

2.5 Consulta de prueba — asegurados por entidad, marzo 2025

Se ejecuta la consulta de validación sobre la partición mes='03'. Hive aplica partition pruning y procesa únicamente el archivo de marzo, sin leer los otros cinco meses:

```
SELECT cve_entidad,
       SUM(CAST(asegurados AS BIGINT)) AS total_asegurados
FROM empleo
WHERE mes = '03'
GROUP BY cve_entidad
ORDER BY total_asegurados DESC;
```

Consulta de prueba — filtro sobre partición mes='03', agrupación por entidad federativa

```
+--------------+-------------------+
| cve_entidad  | total_asegurados  |
+--------------+-------------------+
| 9            |         4,787,763 |
| 15           |         2,906,089 |
| 14           |         2,673,316 |
| 19           |         2,218,222 |
| 11           |         1,419,876 |
| 30           |         1,243,637 |
| 2            |         1,223,245 |
| 8            |         1,194,937 |
| 21           |         1,154,123 |
| 5            |         1,007,865 |
| 22           |           898,634 |
| 26           |           891,216 |
| 28           |           888,986 |
| 25           |           872,715 |
| 16           |           764,014 |
| 24           |           651,159 |
| 23           |           643,716 |
| 31           |           584,517 |
| 7            |           551,163 |
| 13           |           517,319 |
| 1            |           485,794 |
| 20           |           426,939 |
| 27           |           380,691 |
| 12           |           346,279 |
| 17           |           338,220 |
| 10           |           334,954 |
| 32           |           302,789 |
| 3            |           280,072 |
| 18           |           272,889 |
| 29           |           218,975 |
| 6            |           213,200 |
| 4            |           205,643 |
+--------------+-------------------+
32 rows selected
```

Resultado — 32 entidades federativas con total de asegurados en marzo 2025

3. Resultados

Tabla 1 — Estructura de particionado en HDFS

Partición	Archivo	Tamaño (bytes)
mes=01	asg-2025-01-31.csv	385,793,272
mes=02	asg-2025-02-28.csv	382,721,784
mes=03	asg-2025-03-31.csv	382,210,436
mes=04	asg-2025-04-30.csv	378,943,970
mes=05	asg-2025-05-31.csv	383,776,233
mes=06	asg-2025-06-30.csv	383,951,720

Tabla 1. Estructura de particionado: un archivo por mes en su subdirectorio HDFS correspondiente.

Tabla 2 — Asegurados por entidad federativa, marzo 2025 (top 10)

#	Cve. Entidad	Entidad	Asegurados
1	9	Ciudad de México	4,787,763
2	15	Estado de México	2,906,089
3	14	Jalisco	2,673,316
4	19	Nuevo León	2,218,222

5	11	Guanajuato	1,419,876
6	30	Veracruz	1,243,637
7	2	Baja California	1,223,245
8	8	Chihuahua	1,194,937
9	21	Puebla	1,154,123
10	5	Coahuila	1,007,865

Tabla 2. Top 10 entidades por número de asegurados en marzo 2025. Fuente: IMSS ASG 2025.

Ciudad de México concentra el mayor número de asegurados con 4.8 millones, seguida por Estado de México (2.9M) y Jalisco (2.7M). Las tres entidades representan en conjunto el 39% del total de asegurados a nivel nacional en marzo de 2025, lo que refleja la alta concentración del empleo formal en los principales centros económicos del país.

4. Conclusiones

La implementación del particionado por mes sobre la tabla empleo demuestra las ventajas de esta técnica de optimización en Hive:

- **Partition pruning efectivo.** Al filtrar por mes='03', Hive procesa únicamente el archivo de marzo (382 MB) en lugar de los 2.3 GB del semestre completo, reduciendo la lectura de datos en un 83%.
- **Convención de nombres estándar.** El formato mes=NN en los nombres de los subdirectorios permite que MSCK REPAIR TABLE detecte y registre automáticamente las seis particiones sin necesidad de definirlas manualmente con ALTER TABLE.
- **Escabilidad.** La estructura particionada facilita agregar nuevos meses sin modificar la definición de la tabla: basta con crear el subdirectorio mes=07/ y ejecutar MSCK REPAIR TABLE para que Hive lo reconozca.
- **Validación correcta.** La consulta de prueba retornó resultados para las 32 entidades federativas de México, confirmando que el particionado, el delimitador pipe y el salto de encabezado están configurados correctamente.