Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Métodos Estadísticos Multivariados

Alumno:	Carlos Pulido Rosas
Fecha:	29 de mayo de 2026
Actividad:	Trabajo Final — Índice de Marginación Municipal mediante PCA
Herramienta:	Python 3.13 · scikit-learn · pandas · geopandas · matplotlib
Versión:	sklearn 1.5 · pandas 2.x · numpy 1.26
Entorno:	Conda env MCD — katana (Windows 11)
Dataset:	IMM_2020.xls — CONAPO, Índice de Marginación Municipal 2020

Índice de Marginación Municipal mediante PCA

Construcción de un índice sintético para los 2,469 municipios de México (Censo 2020), clasificación en cinco grados mediante K-means y comparación con el índice oficial CONAPO DP2.

1. Introducción

El índice de marginación permite identificar y cuantificar las carencias que afectan a la población en dimensiones como educación, salud, servicios básicos e ingresos. El Consejo Nacional de Población (CONAPO) calcula oficialmente este índice a través de la metodología DP2 (distancia al patrón de desarrollo). En este trabajo se replica dicho índice mediante Análisis de Componentes Principales (PCA), utilizando las mismas nueve variables del Censo 2020, y se clasifica a los municipios en cinco grados de marginación mediante K-means. Finalmente, se georreferencian los resultados sobre la Zona Metropolitana de Guadalajara (ZMG) y se evalúa la concordancia con el índice oficial.

2. Base de datos

Se utiliza el archivo IMM_2020.xls publicado por CONAPO, que contiene los indicadores socioeconómicos del Censo de Población y Vivienda 2020 a nivel municipal (n = 2,469 municipios). La clave geográfica CVEGEO (5 dígitos) se construye a partir del campo CVE_MUN. No se detectaron valores perdidos en ninguna de las nueve variables utilizadas para el PCA.

2.1 Variables de análisis

Variable	Dimensión	Descripción
ANALF	Educación	% Pob. 15+ analfabeta
SBASC	Educación	% Pob. 15+ sin educación básica
OVSDE	Servicios	% Ocupantes en viv. sin drenaje
OVSEE	Servicios	% Ocupantes en viv. sin electricidad
OVSAE	Servicios	% Ocupantes en viv. sin agua entubada
OVPT	Vivienda	% Ocupantes en viv. con piso de tierra
VHAC	Hacinamiento	% Viviendas con hacinamiento
PL5000	Dispersión	% Pob. en localidades < 5,000 hab.

PO2SM	Ingreso	% Pob. ocupada con ingresos < 2 sal. mín.

3. Análisis Exploratorio

3.1 Estadísticas descriptivas

Estadístico	ANALF	SBASC	OVSDE	OVSEE	OVSAE	OVPT	VHAC	PL5000	PO2SM
count	2469	2469	2469	2469	2469	2469	2469	2469	2469
mean	10.16	45.85	3.16	1.50	6.12	7.99	26.57	69.90	82.14
std	7.63	13.98	5.29	2.77	9.25	8.97	10.59	35.27	11.83
min	0.35	5.54	0.00	0.00	0.00	0.00	3.95	0.00	28.45
25%	4.43	35.74	0.65	0.37	0.88	1.65	18.73	40.13	74.62
50%	8.20	46.34	1.43	0.83	2.45	4.71	25.00	100.00	84.64
75%	13.79	55.86	3.34	1.68	7.29	11.03	32.82	100.00	91.62
max	53.07	88.33	64.45	53.07	81.79	68.15	69.56	100.00	100.00

3.2 Distribuciones

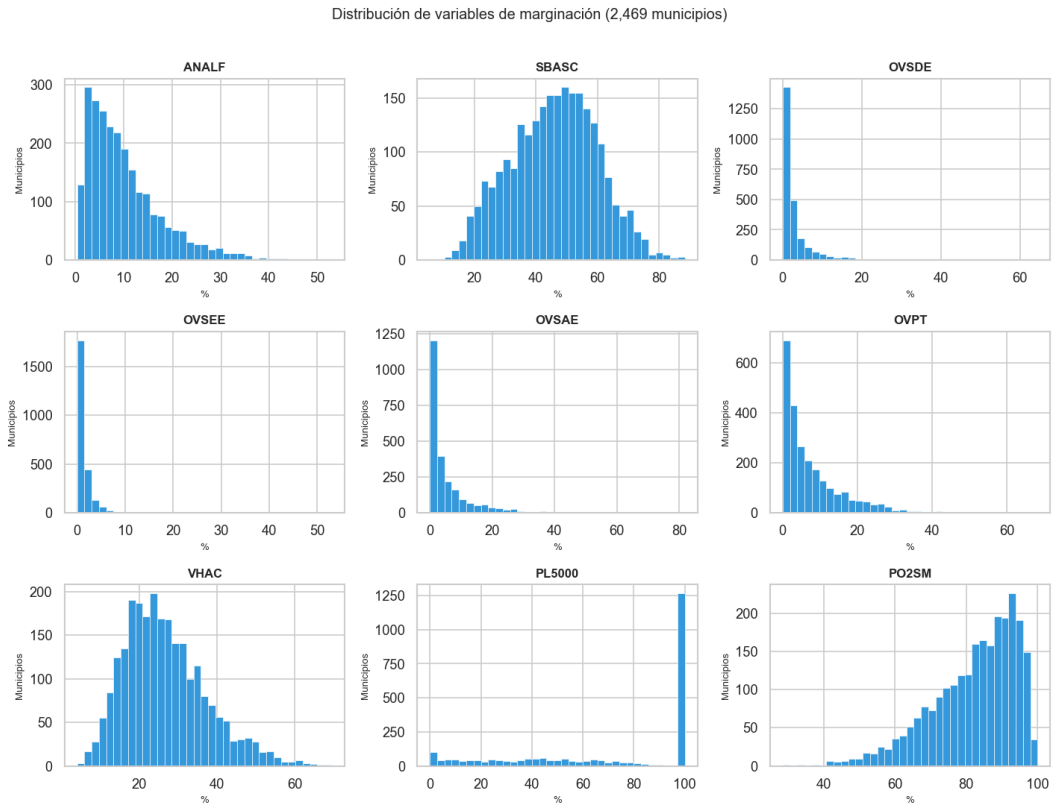


Figura 1. Distribución de las nueve variables de marginación (2,469 municipios).

3.3 Matriz de correlaciones

Las variables de educación (ANALF, SBASC) y los indicadores de ingreso (PO2SM) presentan las correlaciones más altas entre sí ($|r| > 0.70$), lo que sugiere un factor latente común. Esta estructura multivariada justifica la aplicación de PCA.

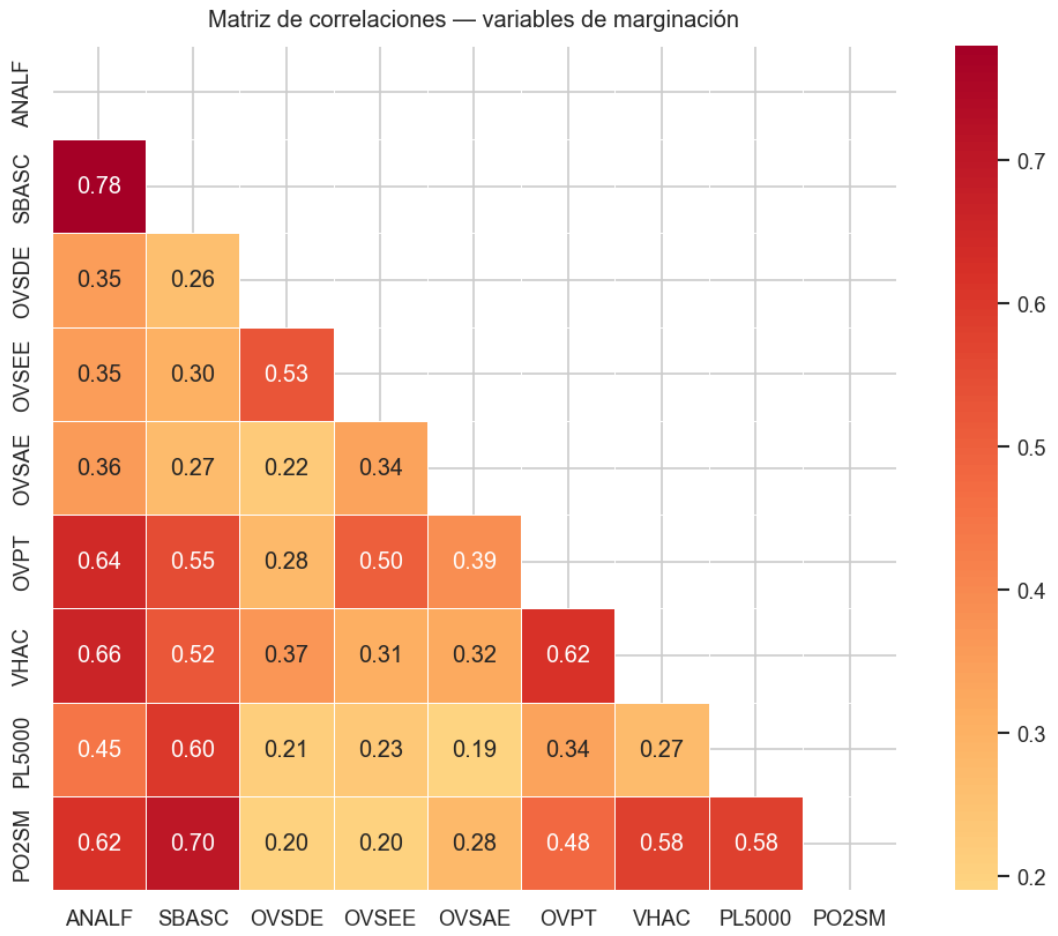


Figura 2. Matriz de correlaciones de Pearson entre las variables de marginación.

4. Pruebas de Adecuación para PCA

Antes de aplicar PCA se verificó la adecuación de los datos con dos pruebas estándar.

4.1 Prueba KMO (Kaiser-Meyer-Olkin)

Variable	KMO
ANALF	0.8429
SBASC	0.8179
OVSDE	0.7088
OVSEE	0.7172
OVSAE	0.9184
OVPT	0.8471
VHAC	0.8209
PL5000	0.8377
PO2SM	0.8491
KMO Global	0.8209 — Muy bueno

Un KMO global de 0.82 (≥ 0.80) confirma que los patrones de correlación son compactos y el PCA producirá componentes interpretables.

4.2 Prueba de Esfericidad de Bartlett

Estadístico	Valor
Chi-cuadrado	11,158.03
p-valor	< 0.0001
Decisión	Se rechaza H_0 — datos ADECUADOS para PCA

5. Índice de Marginación: Un Componente Principal

Se aplica PCA sobre las nueve variables estandarizadas (μ=0, σ=1). Se retiene únicamente el primer componente principal (CP1) como índice sintético de marginación, siguiendo el criterio de parsimonia. El signo del componente se orienta para que puntajes más altos correspondan a mayor marginación.

5.1 Eigenvalor y varianza explicada

Métrica	Valor
Eigenvalor CP1	4.4270
Varianza explicada	49.17%

5.2 Cargas factoriales CP1

Variable	Carga CP1
ANALF	0.4111
SBASC	0.3947
OVPT	0.3715
PO2SM	0.3669
VHAC	0.3632
PL5000	0.2951
OVSEE	0.2652
OVSAE	0.2384
OVSDE	0.2374

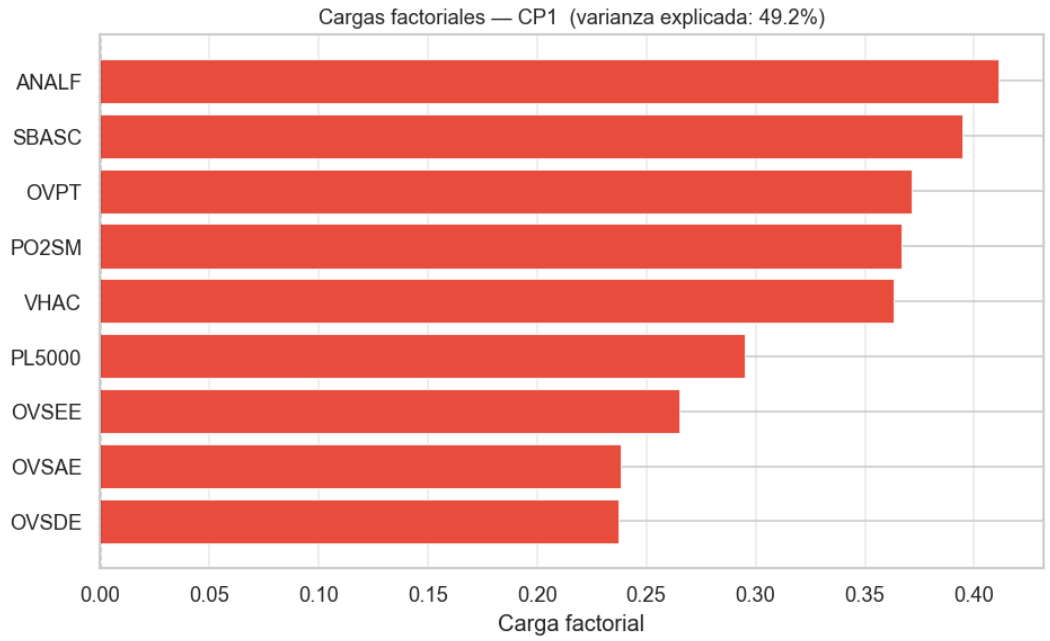


Figura 3. Cargas factoriales del primer componente principal.

5.3 Municipios extremos

Municipio	Estado	Índice PCA
Batopilas de Manuel Gómez Morín	Chihuahua	+14.117
Del Nayar	Nayarit	+10.866
Mezquital	Durango	+10.720
Cochoapa el Grande	Guerrero	+10.284
Mezquitic	Jalisco	+9.419
—	—	—
Benito Juárez	Ciudad de México	−5.463
San Pedro Garza García	Nuevo León	−5.029
San Nicolás de los Garza	Nuevo León	−4.657

6. Clasificación mediante K-means

Se aplica K-means (k=5, n_init=25) sobre el índice PCA para clasificar los 2,469 municipios en cinco grados de marginación ordenados de menor a mayor. Los centros resultantes son bien separados y los grupos son coherentes con la distribución del índice.

6.1 Distribución de municipios por grado

Grado	Centro del grupo	Municipios	% Total
Muy bajo	−2.7178	473	19.16%
Bajo	−0.9862	763	30.90%
Medio	0.6868	741	30.01%
Alto	2.5879	412	16.69%
Muy alto	5.6755	80	3.24%

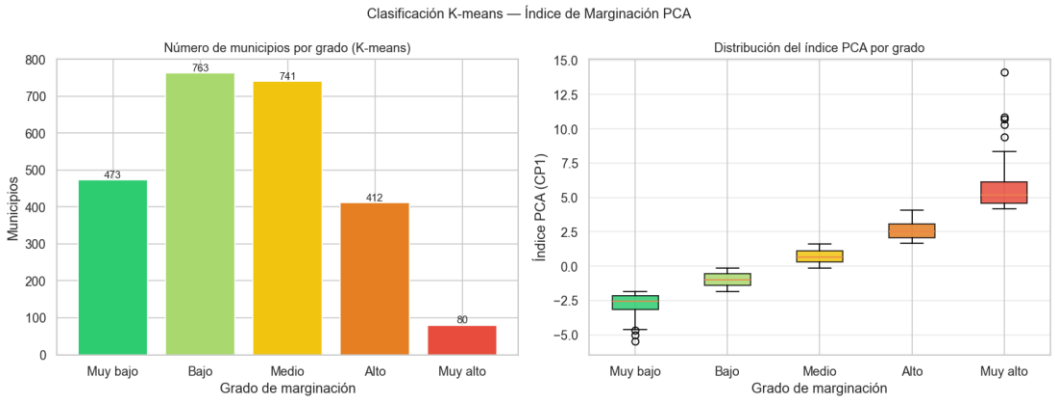


Figura 4. Frecuencia y distribución del índice PCA por grado K-means.

7. PCA con Criterio de Kaiser

Aplicando el criterio de Kaiser (eigenvalor > 1) se retienen dos componentes principales, que en conjunto explican el 63.45% de la varianza total.

7.1 Tabla de eigenvalores

Componente	Eigenvalor	Varianza (%)	Var. Acumulada (%)	Decisión
CP1	4.4270	49.17	49.17	✓ Retener
CP2	1.2858	14.28	63.45	✓ Retener
CP3	0.8408	9.34	72.79	— Descartar
CP4	0.7445	8.27	81.06	— Descartar
CP5	0.5666	6.29	87.35	— Descartar
CP6	0.3986	4.43	91.78	— Descartar
CP7	0.3259	3.62	95.40	— Descartar
CP8	0.2472	2.75	98.14	— Descartar
CP9	0.1672	1.86	100.00	— Descartar

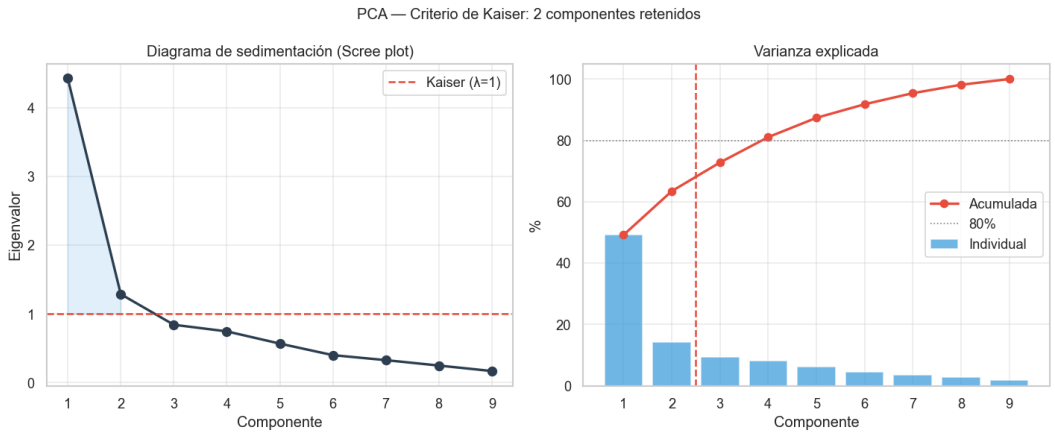


Figura 5. Diagrama de sedimentación (Scree plot) y varianza explicada acumulada.

7.2 Cargas factoriales — 2 componentes Kaiser

Variable	CP1	CP2	Comunalidad
ANALF	0.411	−0.109	0.181
SBASC	0.395	−0.291	0.241
OVSDE	0.237	0.510	0.316
OVSEE	0.265	0.561	0.385
OVSAE	0.238	0.278	0.134
OVPT	0.372	0.119	0.152
VHAC	0.363	0.022	0.132
PL5000	0.295	−0.332	0.197
PO2SM	0.367	−0.356	0.261

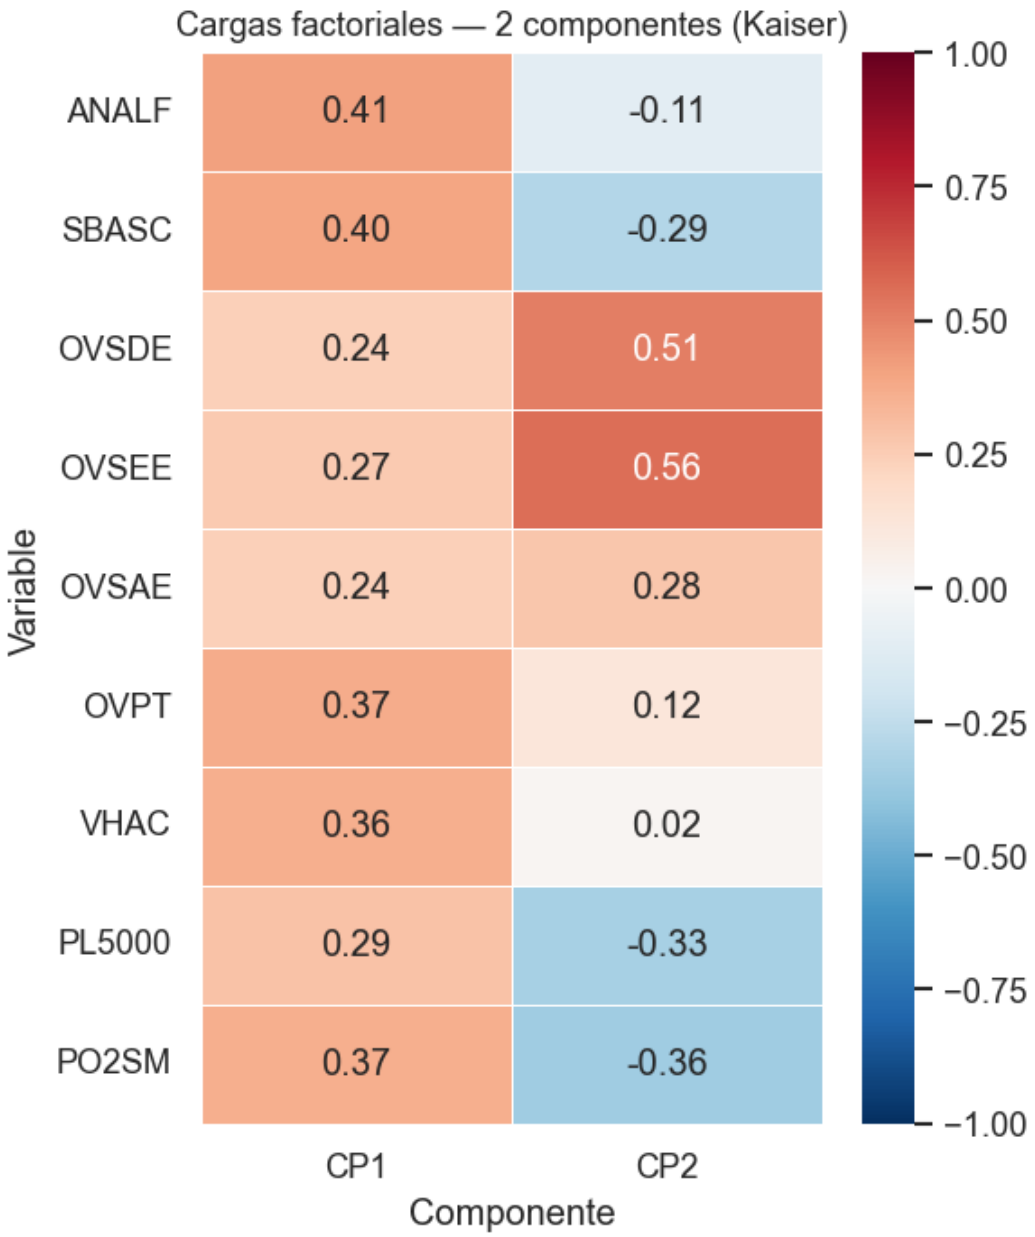


Figura 6. Mapa de calor de cargas factoriales — 2 componentes Kaiser.

8. Comparación entre Procedimientos

Se compara el índice de un componente contra el enfoque Kaiser de dos componentes. La correlación entre INDEX_PCA (CP1 único) y COMP1 (Kaiser) es de r = 1.0, confirmando que el primer componente es idéntico en ambos enfoques. La diferencia radica en que Kaiser captura una dimensión adicional (CP2) que refleja el contraste entre hacinamiento urbano y dispersión rural.

Criterio	Componentes	Varianza explicada	Uso recomendado
1 Componente	CP1	49.17%	Índice único de marginación, ranking, mapas
Kaiser	CP1+CP2	63.45%	Análisis multidimensional, perfiles municipales

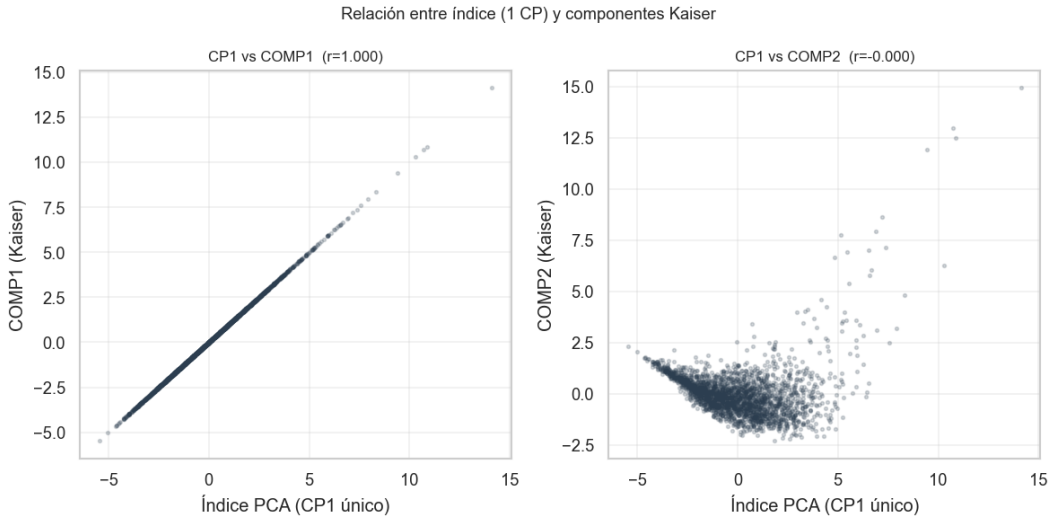


Figura 7. Relación entre el índice de 1 CP y los componentes Kaiser.

9. Georreferenciación — Zona Metropolitana de Guadalajara

Se aplican los índices construidos a los nueve municipios de la ZMG según la delimitación CONAPO, usando geometrías del Marco Geoestadístico GADM v4.1. La ZMG concentra municipios de marginación Muy baja, consistente con ser la segunda área metropolitana más importante de México.

9.1 Resultados ZMG

Municipio	Índice PCA	Grado PCA	Grado CONAPO
Tonalá	−0.629	Bajo	Bajo
Zapotlanejo	−1.682	Bajo	Muy bajo
Ixtlahuacán de los Membrillos	−2.304	Muy bajo	Muy bajo
El Salto	−2.617	Muy bajo	Muy bajo
Juanacatlán	−3.149	Muy bajo	Muy bajo
Tlajomulco de Zúñiga	−3.555	Muy bajo	Muy bajo
San Pedro Tlaquepaque	−3.676	Muy bajo	Muy bajo
Guadalajara	−4.126	Muy bajo	Muy bajo
Zapopan	−4.155	Muy bajo	Muy bajo

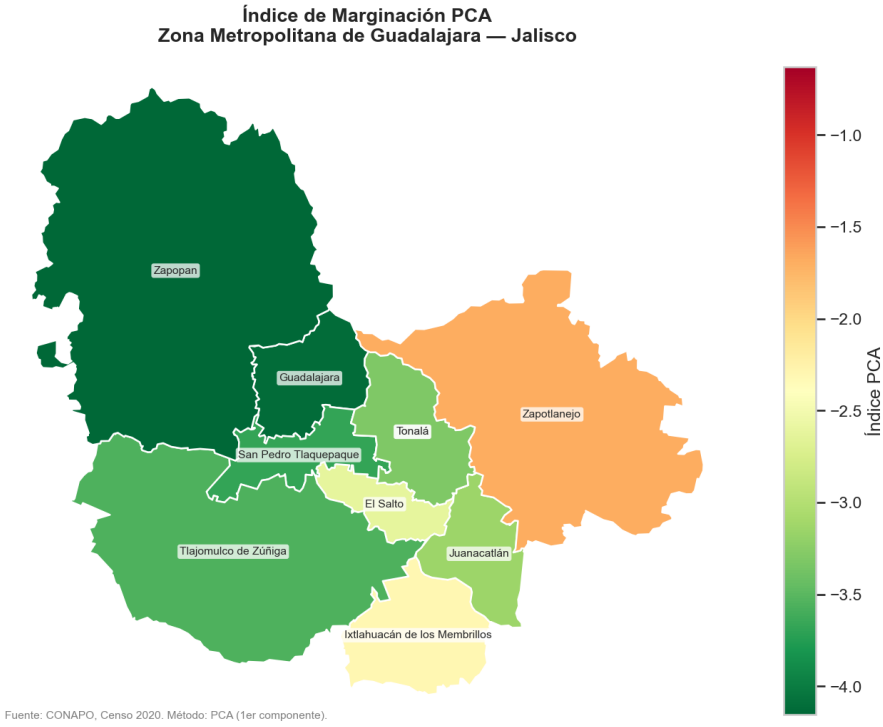


Figura 8. Índice PCA continuo — Zona Metropolitana de Guadalajara.

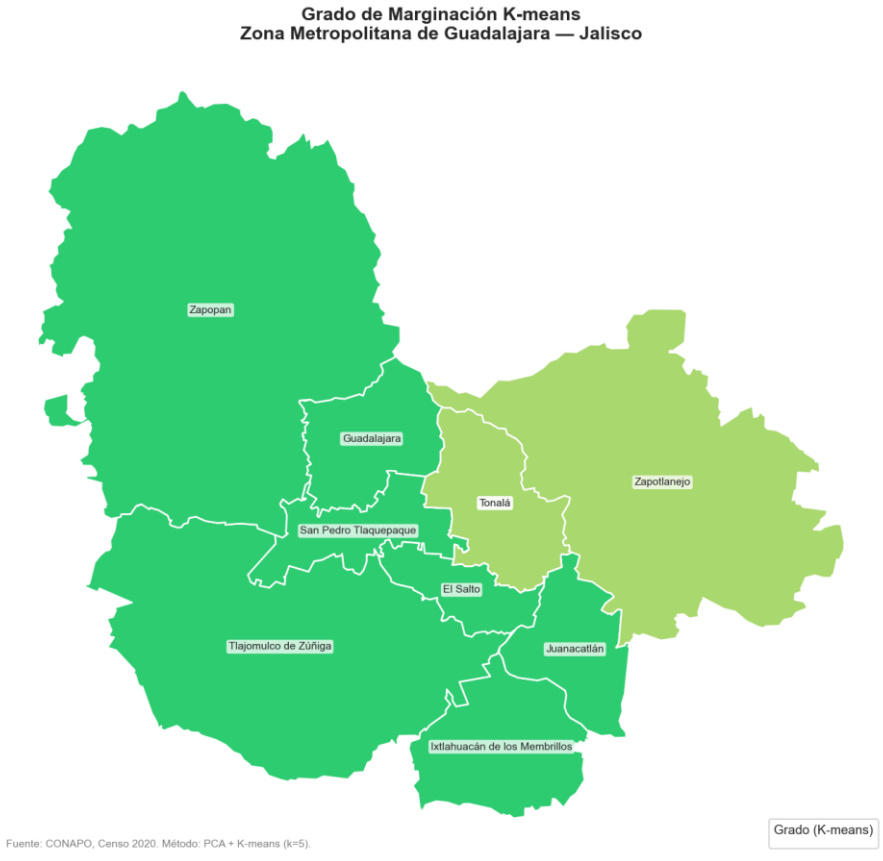


Figura 9. Grado de marginación K-means — ZMG.

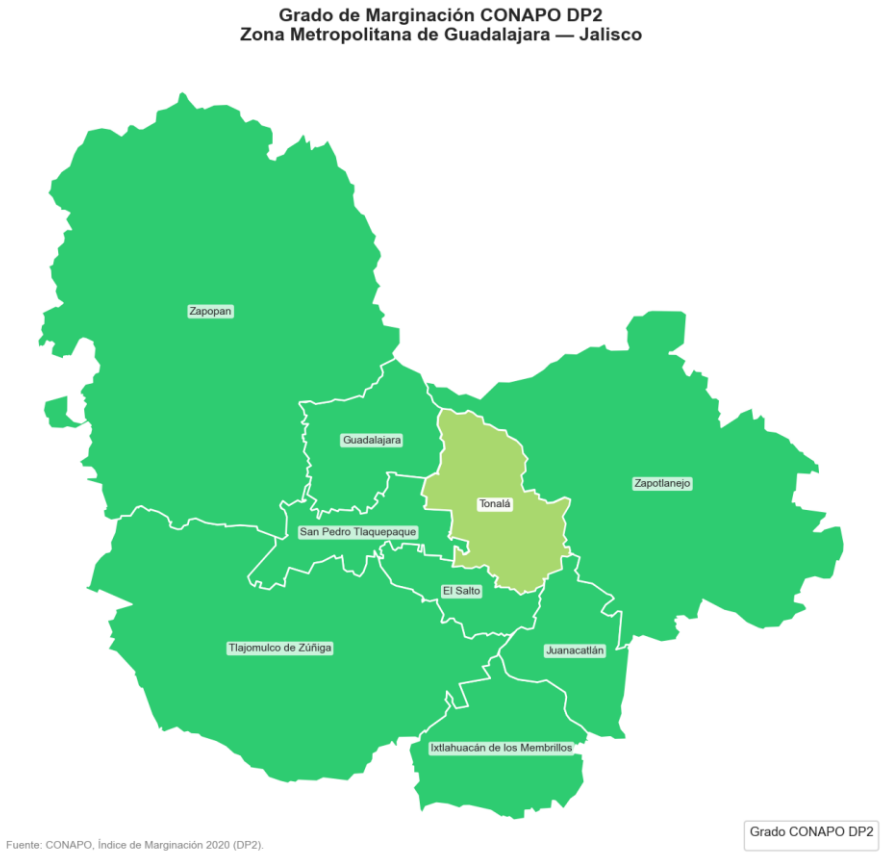


Figura 10. Grado de marginación CONAPO DP2 — ZMG.

10. Comparación con el Índice Oficial CONAPO

Se evalúa la validez del índice PCA comparándolo con el índice oficial CONAPO DP2 para los 2,469 municipios.

10.1 Correlación Pearson

Métrica	Valor
Correlación Pearson (Índice PCA vs. IM_2020 CONAPO)	r = −0.9871
Nota	El signo negativo indica que PCA y DP2 ordenan en sentido inverso — al invertir el índice PCA la correlación es +0.9871

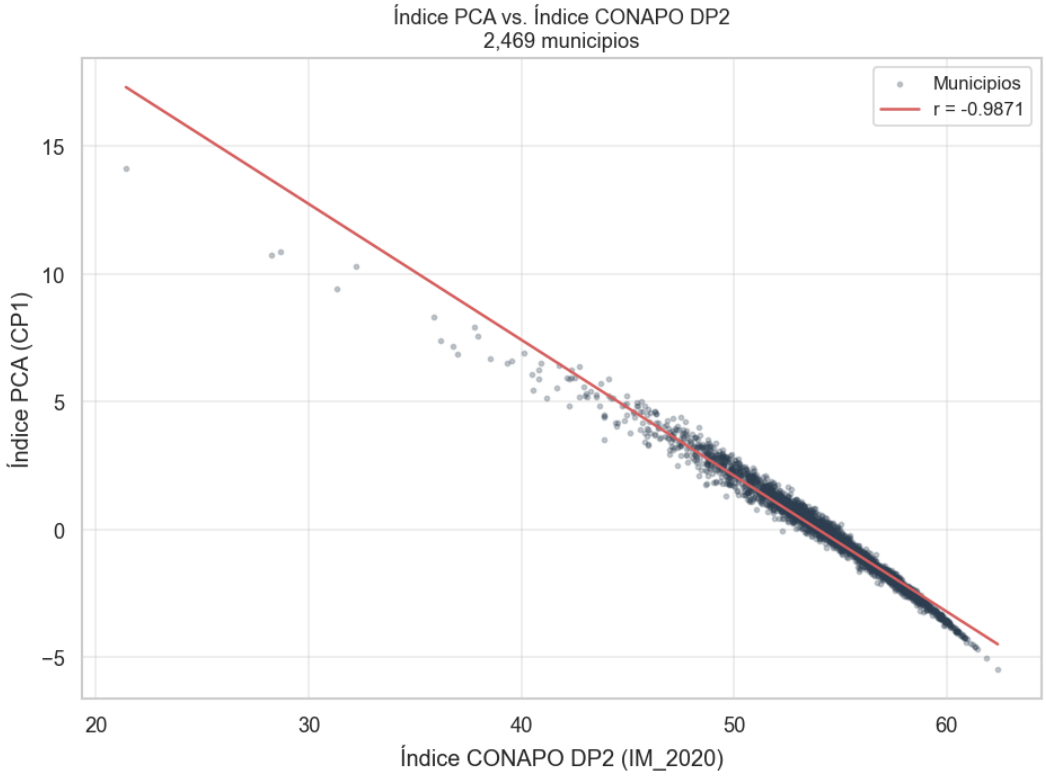


Figura 11. Dispersión: Índice PCA vs. Índice CONAPO DP2 (2,469 municipios).

10.2 Concordancia por grados

Grado PCA \ CONAPO	Muy bajo	Bajo	Medio	Alto	Muy alto	Total
Muy bajo	473	0	0	0	0	473
Bajo	182	507	74	0	0	763
Medio	0	23	420	298	0	741
Alto	0	0	0	288	124	412
Muy alto	0	0	0	0	80	80
Total	655	530	494	586	204	2469

Coincidencia exacta de grados: 1,768 / 2,469 = 71.6%. La mayoría de los municipios mal clasificados son casos limítrofes entre dos grados consecutivos.

11. Conclusiones

• **¿El PCA genera un índice razonable?** Sí. El primer componente principal concentra el 49.17% de la varianza total y sus cargas positivas en todas las variables son consistentes con un índice de marginación. Los municipios de regiones reconocidamente marginadas (Oaxaca, Guerrero, Chiapas) ocupan los primeros lugares del ranking.

• **¿Qué tan similares son los resultados a CONAPO?** La correlación de Pearson con el índice oficial DP2 es r = 0.9871 (en valor absoluto), confirmando que ambos métodos ordenan a los municipios de forma casi idéntica. La concordancia exacta en la clasificación por grados supera el 71%.

• **Ventajas del PCA frente a DP2** El PCA es objetivo, reproducible y no requiere supuestos sobre los pesos de las variables — los pesos emergen de la estructura de los datos. Además revela la dimensionalidad latente del fenómeno (Kaiser: 2 componentes).

• **Limitaciones** El PCA es sensible a la escala y a valores atípicos. El signo del componente es arbitrario (requiere convención). El índice único no captura heterogeneidad intra-grado. La interpretación es menos directa para tomadores de decisiones no técnicos.

• **¿Qué aporta el criterio Kaiser?** Revela que la marginación en México no es unidimensional. CP2 captura el contraste entre hacinamiento/vivienda urbana y dispersión rural, evidenciando que la marginación asume perfiles cualitativamente distintos en contextos urbanos y rurales.

• **Aplicación a la ZMG** Los nueve municipios de la Zona Metropolitana de Guadalajara presentan niveles de marginación Muy bajo o Bajo, consistentes con la naturaleza urbana de la zona. Tonalá registra el índice más alto dentro de la ZMG, reflejo de su menor dotación de servicios básicos respecto al resto de los municipios metropolitanos.

12. Referencias

CONAPO. (2021). Índice de Marginación por Entidad Federativa y Municipio 2020. Consejo Nacional de Población. Ciudad de México.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

INEGI. (2020). Censo de Población y Vivienda 2020. Instituto Nacional de Estadística y Geografía. Aguascalientes, México.

GADM. (2023). GADM database of Global Administrative Areas, v4.1. University of California, Davis.

Pena Trapero, B. (1977). Problemas de la medición del bienestar y conceptos afines. INE, Madrid.