UNIVERSIDAD DE GUADALAJARA
Centro Universitario de Ciencias Económico Administrativas

Maestría en Ciencias de Datos

PROYECTO FINAL

Programación II

Integración de SQL, Minería de Datos y Machine Learning aplicado a la Tesis

Ciclo Escolar: 2026-A
Entrega Final: 17 de Mayo de 2026
Modalidad: Individual

1. Presentación del Proyecto

El proyecto final de Programación II constituye la evidencia integradora de las competencias desarrolladas durante el semestre. A diferencia de ejercicios aislados, este proyecto exige que el estudiante demuestre su capacidad para construir una solución de datos completa y coherente, articulando tecnologías de bases de datos relacionales, herramientas de minería de datos y algoritmos de aprendizaje automático.

La particularidad de este proyecto radica en que los datos de trabajo provienen directamente de la investigación de tesis del propio estudiante. Esto garantiza que el aprendizaje técnico adquiera significado real y contribuya de forma directa al avance de su trabajo de grado.

El estudiante partirá de sus conjuntos de datos de tesis para diseñar un esquema relacional, poblarlo mediante SQL, explorar y transformar la información con herramientas de minería visual, y finalmente aplicar algoritmos supervisados y no supervisados de Machine Learning usando Python.

2. Objetivos

2.1 Objetivo General

Construir una solución integral de análisis de datos que integre diseño de bases de datos relacionales en SQL, exploración y minería de datos con Orange Data Mining, y procesamiento avanzado con algoritmos de Machine Learning en Python, aplicando todas las etapas sobre los datos reales de la tesis del estudiante.

2.2 Objetivos Específicos

- Diseñar e implementar un esquema relacional con un mínimo de dos tablas grandes debidamente relacionadas.
- Dominar operaciones SQL avanzadas: INSERT masivo, JOINs múltiples y creación de vistas (VIEWs).
- Construir un flujo de trabajo en Orange Data Mining para explorar y visualizar los datos respondiendo preguntas clave de la tesis.
- Implementar y evaluar al menos un algoritmo de aprendizaje supervisado y uno no supervisado usando Python y scikit-learn.
- Redactar un reporte técnico que documente cada etapa del pipeline, vincule resultados con las preguntas de investigación de la tesis y proponga interpretaciones.

3. Alcance y Contexto

Este proyecto abarca el pipeline completo de un proyecto de ciencia de datos, desde la persistencia de datos hasta la generación de conocimiento mediante algoritmos de ML. No se trata de ejercicios separados, sino de un flujo integrado donde cada etapa alimenta a la siguiente:

Pipeline del Proyecto Final
Etapa 1 → Modelado relacional y carga de datos en SQL
Etapa 2 → Consultas, JOINs y creación de VIEWs analíticas en SQL
Etapa 3 → Exploración visual y minería de datos con Orange Data Mining (3 flujos)
Etapa 4 → Machine Learning supervisado y no supervisado con Python (scikit-learn)
Etapa 5 → Reporte técnico y presentación de resultados vinculados a la tesis

4. Descripción Detallada de Entregables

Etapa 1 — Diseño e Inserción en SQL

1.1 Diseño del Esquema Relacional

El estudiante deberá diseñar un modelo entidad-relación que represente fielmente los datos de su tesis. El esquema debe incluir mínimo dos tablas principales con volumen significativo de registros (se recomienda un mínimo de 200 registros por tabla).

Cada tabla debe contar con:

- Clave primaria definida explícitamente (PRIMARY KEY).
- Al menos una clave foránea que establezca la relación entre tablas (FOREIGN KEY).
- Tipos de datos correctamente declarados (INT, VARCHAR, DATE, FLOAT, etc.).
- Restricciones de integridad según corresponda (NOT NULL, UNIQUE, CHECK).

1.2 Carga Masiva de Datos (INSERT)

Los datos de la tesis del estudiante deben ser insertados en las tablas mediante sentencias SQL. Se aceptan las siguientes estrategias:

- INSERT INTO ... VALUES (...) para lotes pequeños o demostrativos.
- LOAD DATA INFILE / COPY FROM (según el gestor) para cargas masivas desde CSV.
- Script Python con librería psycopg2, pymysql o sqlalchemy que automatice la carga desde el archivo de datos original.

El estudiante debe incluir en su entregable el script SQL o Python utilizado, completamente comentado.

Etapa 2 — Consultas SQL: JOINs y Vistas

2.1 Operaciones JOIN

Se requiere demostrar el dominio de las operaciones de unión entre tablas. El estudiante debe implementar y documentar un mínimo de tres consultas JOIN de distintos tipos:

- INNER JOIN: registros con coincidencia en ambas tablas.

- LEFT JOIN / RIGHT JOIN: inclusión de registros sin coincidencia.
- JOIN con condiciones adicionales (WHERE, GROUP BY, HAVING, ORDER BY).

Cada consulta debe ir acompañada de un comentario que explique qué pregunta de tesis responde y por qué se eligió ese tipo de JOIN.

2.2 Creación de Vista de Datos Minados (VIEW)

A partir de los JOINs anteriores, el estudiante creará una VIEW en SQL que consolide los datos transformados listos para el análisis. Esta vista servirá como fuente de datos para las etapas posteriores (Orange y Python).

La vista debe:

- Integrar columnas de al menos dos tablas.
- Incluir al menos un campo calculado o agregado (COUNT, AVG, SUM, CASE WHEN, etc.).
- Estar documentada con comentarios en el script SQL.

Etapa 3 — Orange Data Mining: 3 Flujos de Visualización

Orange Data Mining es una plataforma visual de código abierto para exploración, análisis y minería de datos. El estudiante construirá tres flujos de trabajo (workflows) independientes, cada uno orientado a responder una pregunta específica derivada de su tesis.

Los flujos deben estar exportados como archivos .ows y capturados en pantalla dentro del reporte.

Flujo 1 — Análisis Exploratorio y Distribuciones

Objetivo: Caracterizar estadísticamente los datos y detectar patrones iniciales.

Widgets sugeridos (el estudiante puede elegir los más pertinentes a su tesis):

- File / SQL Table: carga de datos.
- Data Table: inspección de registros.
- Feature Statistics: resumen estadístico.
- Distributions: histogramas por variable.
- Box Plot: comparación de distribuciones por categoría.
- Scatter Plot: exploración de relaciones bivariadas.

Flujo 2 — Correlaciones y Agrupaciones

Objetivo: Identificar relaciones entre variables y grupos naturales en los datos.

Widgets sugeridos:

- Correlations: mapa de calor de correlaciones.
- Heat Map: visualización matricial de valores.
- k-Means (exploratorio): segmentación visual preliminar.
- Mosaic Display: relaciones entre variables categóricas.

Flujo 3 — Modelo Predictivo Visual

Objetivo: Construir y evaluar un modelo de clasificación o regresión de forma visual, respondiendo directamente una pregunta predictiva de la tesis.

Widgets sugeridos:

- Select Rows / Preprocess: preparación de datos.
- Data Sampler: partición entrenamiento/prueba.
- Tree / Random Forest / Logistic Regression: entrenamiento.
- Test and Score: evaluación de métricas.
- Confusion Matrix: análisis de errores de clasificación.
- ROC Analysis: curva ROC si aplica.

Etapa 4 — Python: Algoritmo Supervisado y No Supervisado

Esta etapa se desarrolla en un Jupyter Notebook (.ipynb) correctamente documentado con celdas de markdown explicativas en cada sección. Los datos de entrada deben provenir idealmente de la VIEW creada en la Etapa 2 (conectando Python con la base de datos mediante sqlalchemy, psycopg2 o pymysql) o bien del archivo CSV exportado de dicha vista.

Las bibliotecas principales del curso para esta etapa son: NumPy, Pandas, Scikit-learn y Matplotlib. Opcionalmente se puede usar rpy2 para integrar funciones de R dentro del notebook Python.

4.1 Algoritmo Supervisado (elección del estudiante)

El estudiante seleccionará el algoritmo supervisado más adecuado para su problema de tesis entre los estudiados en la Unidad 3 del programa:

- Algoritmos predictivos (regresión): Regresión Lineal Múltiple, K Vecinos Más Cercanos (KNN Regressor).
- Algoritmos de clasificación: Clasificador Ingenuo de Bayes (Naive Bayes), Regresión Logística.

Requisitos mínimos de implementación:

- Justificación de la elección del algoritmo en relación con el problema de tesis (predictivo vs. clasificatorio).
- Preprocesamiento: manejo de valores nulos, codificación de categóricas, normalización/estandarización según el algoritmo (obligatoria para KNN y Regresión Logística).
- Aplicación de muestreo si existe desbalance de clases (Oversampling / Undersampling — Unidad 2.1.1).
- División de datos en conjuntos de entrenamiento, validación y prueba (Unidad 2.1.5). Mínimo 70/30 con random_state fijo.
- Entrenamiento, predicción y evaluación con métricas apropiadas (accuracy, F1, precision, recall, RMSE, R^2 según el tipo).
- Visualización con Matplotlib: matriz de confusión, curva de aprendizaje o gráfica de predicciones.
- Interpretación del rendimiento predictivo (Unidad 2.1.8) vinculada a las preguntas de la tesis.

4.2 Algoritmo No Supervisado (elección del estudiante)

El estudiante seleccionará el algoritmo no supervisado más pertinente para sus datos entre los estudiados en la Unidad 4 del programa:

- Análisis de cluster jerárquico (Aglomerativo): visualización mediante Dendrograma.
- Análisis de cluster no jerárquico — K-Means: determinación del K óptimo mediante Diagrama de Codo (Elbow Method).
- Reglas de asociación y filtros colaborativos: si los datos de tesis involucran transacciones o comportamientos.

Requisitos mínimos de implementación:

- Justificación de la elección en función de las características del conjunto de datos.
- Preprocesamiento específico: escala de variables (obligatoria para K-Means y jerárquico). Opcional: reducción de dimensiones con PCA previo al clustering (Unidad 2.1.7).
- Para K-Means: Diagrama de Codo para determinar el número óptimo de clusters.
- Para Jerárquico: construcción y visualización del Dendrograma con criterio de enlace justificado.
- Visualización de resultados con Matplotlib: gráfica de clusters coloreados, proyección 2D si aplica.
- Interpretación y hallazgos en el contexto de la tesis.

4.3 Extensión Opcional — Unidad 5 (si aplica al tema de tesis)

Para estudiantes cuya tesis involucre datos de texto o redes sociales, se puede incorporar como valor adicional:

- Minería de texto: preprocesamiento (tokenización, derivación, bolsa de palabras), matriz términos-documentos, TF-IDF, clasificación de documentos con LSI.
- Análisis de redes sociales: construcción de grafos con networkx, cálculo de métricas (grado, centralidad, clustering), visualización de grafos dirigidos/no dirigidos.

5. Entregables

La entrega será a través de la plataforma institucional y deberá incluir los siguientes archivos comprimidos en un único archivo .zip con la nomenclatura:

APELLIDO_NOMBRE_ProyectoFinal_ProgII.zip

Archivos Requeridos en la Entrega	
01_esquema.sql	Script SQL con CREATE TABLE, FOREIGN KEY y comentarios.
02_insercion.sql / .py	Script de carga masiva de datos con comentarios.
03_joins_views.sql	Consultas JOIN y sentencia CREATE VIEW documentadas.

04_orange_flujo1.ows	Flujo Orange: análisis exploratorio y distribuciones.
05_orange_flujo2.ows	Flujo Orange: correlaciones y agrupaciones.
06_orange_flujo3.ows	Flujo Orange: modelo predictivo visual.
07_ml_notebook.ipynb	Jupyter Notebook con algoritmo supervisado y no supervisado.
08_reporte_final.pdf	Reporte técnico completo (ver estructura en Sección 6).
data/	Carpeta con archivos de datos usados (.csv, .xlsx).

6. Estructura del Reporte Técnico

El reporte debe presentarse en formato PDF, con extensión mínima de 15 páginas, redacción propia y con el siguiente esquema de secciones:

1. Portada (título, nombre del estudiante, tema de tesis, fecha).
2. Resumen ejecutivo (máximo 1 página): qué problema de tesis se aborda, qué tecnologías se usaron y cuál es el hallazgo principal.
3. Descripción del conjunto de datos: origen, variables, contexto de la tesis, diagrama ER de las tablas.
4. Etapa SQL: diseño del esquema, captura de las tablas creadas, consultas JOIN con sus resultados, definición y consulta de la VIEW.
5. Etapa Orange: captura de los 3 flujos completos, descripción de cada widget utilizado, gráficas obtenidas e interpretación en el contexto de la tesis.
6. Etapa Python / Machine Learning: justificación de algoritmos, código documentado (fragmentos clave), métricas obtenidas, gráficas y análisis de resultados.
7. Discusión integrada: ¿cómo se articulan los resultados de las tres etapas? ¿Qué responde al planteamiento de la tesis?
8. Conclusiones y trabajo futuro.
9. Referencias (APA 7ª edición).

7. Criterios de Evaluación

La calificación del Proyecto Final forma parte de la evaluación global del curso. Dentro del proyecto, los componentes se ponderan de la siguiente manera:

Etapa / Componente	Peso	Criterio de Logro
Diseño e Inserción SQL	**20%**	Esquema relacional correcto, integridad referencial, carga exitosa de datos.

JOINs y VIEW	**20%**	Mínimo 3 JOINs funcionales y documentados. VIEW coherente con datos minados.
Orange Data Mining (3 flujos)	**25%**	Flujos completos y funcionales, widgets apropiados, gráficas interpretadas y vinculadas a la tesis.
Python ML (sup. + no sup.)	**25%**	Algoritmos del programa (U3 y U4), métricas reportadas, visualizaciones Matplotlib, interpretación fundamentada.
Reporte Técnico	**10%**	Redacción clara, estructura completa, integración coherente de las 4 etapas.
TOTAL PROYECTO	**100%**	*Calificación integral del Proyecto Final.*

Composición de la Calificación Final del Curso
Control de Lectura 25% de la calificación final.
Ejercicios de Interpretación 25% de la calificación final.
Proyecto Final 50% de la calificación final. ← Este proyecto.

Nota importante: El proyecto debe presentarse de forma individual. No se aceptan proyectos con los mismos datos o el mismo código entre compañeros. El uso de datos reales de tesis garantiza la unicidad del trabajo.

8. Consideraciones Técnicas

8.1 Gestor de Base de Datos

El estudiante puede utilizar cualquiera de los siguientes gestores de bases de datos relacionales:

- MySQL / MariaDB (recomendado para quienes ya tienen experiencia previa).
- PostgreSQL (recomendado para proyectos con mayor volumen o complejidad).
- SQLite (aceptable para proyectos con restricciones de instalación, pero con limitaciones en JOINs complejos).

8.2 Orange Data Mining

Se utilizará Orange Data Mining 3 (orange3.biolab.si), herramienta de código abierto con interfaz visual incluida en el programa oficial (Unidad 1.7 y Unidad 2.1.6.2). Para este proyecto se requieren los siguientes componentes:

- Orange3 (base): widgets de exploración, visualización y modelado.

- Orange3-Associate (recomendado): para análisis de reglas de asociación si el tema lo requiere.
- Orange3-Text (recomendado si la tesis usa datos textuales): compatible con Unidad 5 del programa.

8.3 Entorno Python

Se recomienda trabajar con Python 3.9 o superior bajo distribución Anaconda (incluida en el programa, Unidad 1.6). Las bibliotecas del curso son:

- numpy, pandas: manipulación y preprocesamiento de datos (Unidad 1.2, 1.3).
- scikit-learn: implementación de algoritmos supervisados y no supervisados (Unidad 1.5).
- matplotlib: visualización de resultados (Unidad 2.1.6.1).
- rpy2: integración de funciones R dentro de Python, útil para análisis estadístico avanzado (Unidad 1.4).
- sqlalchemy / psycopg2 / pymysql: conexión a base de datos SQL desde Python.
- jupyter: entorno de desarrollo del notebook.

Opcional: Power BI puede utilizarse como herramienta complementaria de visualización e inteligencia de negocios, sin sustituir los flujos de Orange ni las gráficas de Matplotlib. Es especialmente útil para construir dashboards interactivos a partir de los datos de tesis.

9. Fechas Importantes

Calendario del Proyecto Final	
Jueves 30 abril	Confirmación del tema de tesis y conjuntos de datos a utilizar.
Domingo 17 de mayo de 2026	Entrega final del proyecto completo (.zip en plataforma).
Por confirmar	Presentación oral / defensa del proyecto (si aplica).

Importante: El departamental del 13 de mayo es requisito indispensable para obtener calificación final. La no presentación del mismo impide integrar la evaluación del curso, independientemente de la calidad del proyecto.

10. Recomendaciones Finales del Profesor

Para maximizar las probabilidades de éxito en este proyecto, se sugiere seguir las siguientes recomendaciones:

- Empieza por los datos: define claramente tus tablas antes de escribir una sola línea de SQL. Un buen diagrama ER ahorra horas de corrección.

- Documenta mientras avanzas: un notebook o script sin comentarios no tiene valor académico. Escribe el por qué, no solo el qué.
- Conecta cada decisión técnica con tu tesis: cada JOIN, cada flujo de Orange y cada algoritmo debe responder a una pregunta real de investigación.
- Elige bien tu algoritmo supervisado: si tu variable objetivo es continua, usa Regresión Lineal Múltiple o KNN Regressor; si es categórica, usa Naive Bayes o Regresión Logística. No mezcles tipo de problema con tipo de algoritmo.
- Para el no supervisado: si no sabes cuántos clusters hay, empieza con el Diagrama de Codo para K-Means; si quieres explorar jerarquías naturales en tus datos, usa el Clustering Jerárquico con Dendrograma.
- Usa Orange antes que Python para exploración: Orange te ayudará a entender visualmente tus datos y a elegir el algoritmo correcto antes de escribir código, ahorrando tiempo.
- Valida tus resultados de ML con sentido crítico: una accuracy de 99% en datos pequeños o desbalanceados generalmente indica overfitting, no excelencia. Reporta también precision, recall y F1.
- Gestiona tu tiempo: el proyecto tiene cinco etapas. Dedicar los dos últimos días a todo es inviable. Se recomienda un mínimo de una etapa por semana.

Quedo atento a sus dudas, comentarios o solicitudes de asesoría. El proyecto es la oportunidad de integrar lo aprendido durante el semestre con el avance real de su investigación de tesis. ¡Mucho éxito a todos!