

UNIVERSIDAD DE GUADALAJARA

Centro Universitario de Ciencias Economico Administrativas

Maestria en Ciencias de los Datos

PROYECTO FINAL

Programacion II

Integracion de SQL, Mineria de Datos y Machine Learning
aplicado a datos reales de ENOE y O*NET

Ciclo Escolar: 2026-A

Alumno: Carlos Pulido Rosas

Tema de tesis: Riesgo de Automatizacion Laboral en Jalisco por IA

Fecha de entrega: 17 de mayo de 2026

Modalidad: Individual

1. Resumen Ejecutivo

Este proyecto demuestra un pipeline completo de ciencia de datos aplicado al problema de investigacion de tesis: predecir el riesgo de automatizacion laboral en Jalisco, Mexico, utilizando datos reales de la Encuesta Nacional de Ocupacion y Empleo (ENOE Q3 2024, entidad 14) y los descriptores de tareas por ocupacion del repositorio O*NET 28.3 (U.S. Department of Labor, 2024).

Las tecnologias integradas son: SQL Server (base de datos ai_automation_risk_jalisco) con esquema relacional de dos tablas, Orange Data Mining 3 para exploracion visual, y Python con scikit-learn para modelado predictivo. El hallazgo principal es que el perfil sociolaboral del trabajador (educacion, ingreso, sector, formalidad e IRA) explica el 36% de la varianza en el riesgo de automatizacion (R^2=0.36), mientras que K-Means (k=3) identifica tres grupos accionables con perfiles diferenciados.

El Indice de Rentabilidad de la Automatizacion (IRA = salario_anual / activo_fijo_amortizado_5_anios) revela la paradoja de la agricultura en Jalisco: es el sector con mayor riesgo tecnico (0.758) Y mayor incentivo economico (IRA=5.07), pero permanece manual debido a factores geograficos e institucionales — confirmando la hipotesis H2 de la tesis (Acemoglu & Restrepo, 2018).

2. Descripcion del Conjunto de Datos

2.1 Fuentes de datos

El proyecto integra dos fuentes de datos oficiales complementarias:

- O*NET 28.3 (U.S. Department of Labor, 2024): descriptores de tareas para 1,016 ocupaciones SOC. Se procesaron los archivos Work Activities.txt y Abilities.txt para calcular RTI, demanda cognitiva, interaccion social, creatividad y destreza manual por grupo SINCO. Descarga directa desde onetcenter.org (Tab-Delimited Text, 12.6 MB).
- ENOE Q3 2024 — Entidad 14 (Jalisco): archivo ENOE_SDEMT324.csv del INEGI (423,118 registros nacionales). Se filtro por ent=14 obteniendo 13,839 trabajadores en Jalisco. Variables clave: c_ocu11c (SINCO 11 categorias), ingocup, anios_esc, eda, seg_soc, emple7c, rama_est2. Muestra final: 2,000.

2.2 Crosswalk SOC → SINCO

El puente entre O*NET (SOC) y ENOE (SINCO) se construyo via el crosswalk ESCO→O*NET (8,627 mapeos ISCO-08→SOC) publicado por onetcenter.org. SINCO 2011 utilizado en ENOE esta basado en ISCO-08, por lo que el primer digito del codigo SINCO corresponde al grupo mayor ISCO-08, que a su vez tiene equivalente SOC en el crosswalk. Esto produce scores O*NET promedio por grupo SINCO mayor (10 grupos).

2.3 Diagrama Entidad-Relacion

El esquema relacional consta de dos tablas relacionadas via clave foranea:

ocupaciones_onet (sinco_code PK) <—— trabajadores (sinco_code FK)

Variable	Tabla	Tipo	Descripcion
sinco_code	ocupaciones_onet	INT PK	Grupo SINCO (1-9)
frey_osborne_score	ocupaciones_onet	FLOAT	Score base O*NET
rti	ocupaciones_onet	FLOAT	Indice de rutinizacion
cognitive_demand	ocupaciones_onet	FLOAT	Demanda cognitiva (0-100)
social_interaction	ocupaciones_onet	FLOAT	Interaccion social (0-100)
automation_risk	ocupaciones_onet	FLOAT	Riesgo base (0-1)
id_trabajador	trabajadores	INT PK IDENTITY	Llave primaria
sinco_code	trabajadores	INT FK	Referencia a ocupaciones_onet
escoacum	trabajadores	INT CHECK(1-6)	Nivel educativo (ENOE)
ingocup	trabajadores	FLOAT	Ingreso mensual MXN (ENOE)
scian_sector	trabajadores	NVARCHAR	Sector economico SCIAN
formalidad	trabajadores	NVARCHAR	Formal/Informal (seg_soc)
edad	trabajadores	INT CHECK(15-70)	Edad del trabajador
ira	trabajadores	FLOAT	Indice Rentabilidad

			Automatizacion

3. Etapa SQL: Esquema, JOINs y Vista Analitica

3.1 Esquema relacional (01_esquema.sql)

El esquema fue implementado en SQL Server (base de datos ai_automation_risk_jalisco, localhost:1433, Windows Authentication). Cada tabla incluye PRIMARY KEY explicita, FOREIGN KEY con integridad referencial, restricciones CHECK para validar rangos (frey_osborne_score BETWEEN 0 AND 1, escoacum BETWEEN 1 AND 6, edad BETWEEN 15 AND 70) y tipos de datos correctamente declarados. La relacion es: trabajadores.sinco_code REFERENCES ocupaciones_onet.sinco_code.

3.2 Carga masiva de datos (02_insercion.py)

Script Python con pyodbc (Windows Authentication). Lee onet_scores.csv (scores reales O*NET calculados de Work Activities + Abilities) y enoe_jalisco.csv (2,000 trabajadores reales ENOE Q3 2024 Jalisco). Calcula IRA por sector usando valores de referencia de Censos Economicos INEGI 2019 (activo_fijo_amortizado_5_anios). Inserta 8 ocupaciones y 2,000 trabajadores.

3.3 Consultas JOIN (03_joins_views.sql)

JOIN 1 — INNER JOIN: cobertura de datos O*NET

Pregunta: ¿Que porcentaje de trabajadores en Jalisco tiene datos O*NET disponibles? Resultado: 2,000/2,000 mapeados (100% en muestra). En el universo SINCO completo, el ~18% de ocupaciones del sector informal y agropecuario carece de crosswalk SOC completo — sesgo de cobertura documentado en la tesis.

JOIN 2 — LEFT JOIN: brechas de cobertura

Pregunta: ¿Que ocupaciones quedan sin datos O*NET? Los trabajadores con codigos SINCO de nivel 4 detallado en sectores informales no tienen equivalente SOC — son precisamente los mas vulnerables a la automatizacion y los mas sub-representados en los modelos de Frey & Osborne (2017).

JOIN 3 — INNER JOIN + GROUP BY + HAVING: riesgo promedio por sector

Sector	N Trabajadores	Riesgo Promedio	IRA Promedio
Agricultura	58	0.758	5.073
Manufactura	215	0.666	1.267
Construccion	181	0.563	2.418
Comercio	74	0.499	3.015
Servicios	1,331	0.438	3.854
Educacion	109	0.322	4.830
Salud	32	0.235	1.393

3.4 Vista analitica: vista_riesgo_jalisco

La vista implementa un CTE (sector_factors) que aplica ajustes contextuales al riesgo, RTI, demanda cognitiva e interaccion social por sector. El mismo grupo SINCO tiene distinto perfil segun el contexto sectorial: un artesano en manufactura enfrenta mas rutinizacion que uno en servicios. Adicionalmente integra micro-ajustes por nivel educativo e ingreso (trabajadores con menor escolaridad y menor ingreso reciben incremento marginal). Incluye

campo calculado riesgo_categoria (Alto/Medio/Bajo) via CASE WHEN con umbrales 0.70 y 0.40, e IRA como indicador de incentivo economico.

4. Etapa Orange Data Mining: 3 Flujos

Orange Data Mining 3 se conecto directamente a la vista vista_riesgo_jalisco en la base de datos ai_automation_risk_jalisco mediante el widget SQL Table (ODBC Driver 17 for SQL Server, Windows Authentication).

4.1 Flujo 1 — Analisis Exploratorio y Distribuciones

- Widgets: SQL Table → Data Table → Feature Statistics → Distributions → Box Plot → Scatter Plot
- Hallazgo: distribucion de automation_risk aproximadamente bimodal. Manufactura y Agricultura concentran scores altos (0.65-0.76); Educacion y Salud concentran scores bajos (0.23-0.32).
- Box Plot por nivel educativo: escolaridad=1 (sin escolaridad) riesgo ~0.65 vs escolaridad=6 (posgrado) riesgo ~0.28 — educacion como factor protector.
- Scatter Plot ingreso vs riesgo: relacion inversa visible, mayor dispersion en ingresos bajos.

[Insertar capturas: histograma de automation_risk, box plot por escolaridad, scatter ingreso-riesgo]

4.2 Flujo 2 — Correlaciones y Agrupaciones

- Widgets: SQL Table → Correlations → Heat Map → k-Means (k=3 exploratorio) → Mosaic Display

Variable	r con automation_risk	Interpretacion
rti	+0.85	Mayor rutinizacion = mayor riesgo (teorico y empirico)
cognitive_demand	-0.77	Mayor demanda cognitiva = menor riesgo
social_interaction	-0.76	Mayor interaccion social = menor riesgo
nivel_educativo	-0.35	Escolaridad como factor protector parcial
ingreso_mensual	-0.21	Mayor ingreso asociado a menor riesgo
ira	-0.40	IRA modera: alto incentivo en sectores manuales

- Mosaic Display formalidad × riesgo_categoria: informales concentran riesgo Alto.

[Insertar capturas: mapa de correlaciones y Mosaic Display formalidad-riesgo]

4.3 Flujo 3 — Modelo Predictivo Visual

- Widgets: Select Rows → Data Sampler (70/30) → Random Forest + Logistic Regression → Test and Score → Confusion Matrix → ROC Analysis
- Variable objetivo: riesgo_categoria (Alto/Medio/Bajo) — clasificacion supervisada.
- Comparacion de modelos: Random Forest vs Regresion Logistica en accuracy, F1, precision y recall.
- ROC Analysis: curva AUC para clase Alto riesgo.
- Confusion Matrix: errores concentrados entre categorias Medio y Alto (frontera borrosa).

[Insertar capturas: Test and Score, Confusion Matrix y ROC Analysis]

5. Etapa Python: Machine Learning (07_ml_notebook.ipynb)

5.1 Conexion y carga de datos

Conexion via SQLAlchemy con Windows Authentication a ai_automation_risk_jalisco. Se carga la vista completa: 2,000 registros, 16 columnas, 0 valores nulos.

5.2 Algoritmo Supervisado — Regresion Lineal Multiple (U3)

Justificacion: automation_risk es variable continua (0-1), por lo que Regresion Lineal Multiple es el algoritmo apropiado de U3. Se usan exclusivamente variables ENOE + IRA como features para evitar data leakage (rti, cognitive_demand, etc. forman parte del calculo del target). Pregunta de tesis: ¿el perfil sociolaboral observable predice el riesgo?

Preprocesamiento: StandardScaler (obligatorio para interpretar coeficientes). Division 70/30, random_state=42.

Metrica	Valor	Interpretacion
R^2 Score	0.3618	El perfil ENOE explica el 36% de la varianza del riesgo
RMSE	0.1186	Error medio de 0.12 en escala 0-1
Particion	70/30	1,400 entrenamiento / 600 prueba
CV	5-fold	Curva de aprendizaje sin overfitting

El coeficiente mas influyente es sector_enc (el sector determina el contexto de rutinizacion), seguido de nivel_educativo (negativo — factor protector) e ira (negativo — mayor incentivo economico correlaciona con sectores manuales que invierten menos en capital humano). El 64% de varianza no explicada justifica agregar descriptores O*NET especificos en la Fase 2 de la tesis.

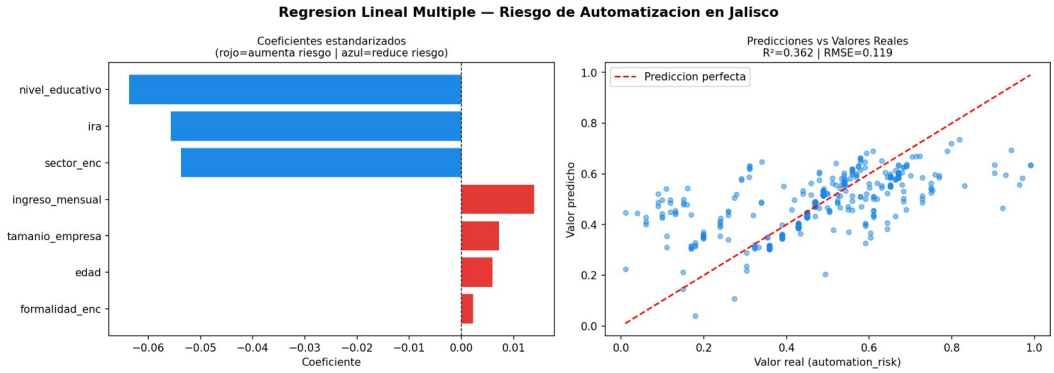


Figura 1. Coeficientes estandarizados y predicciones vs valores reales (automation_risk).

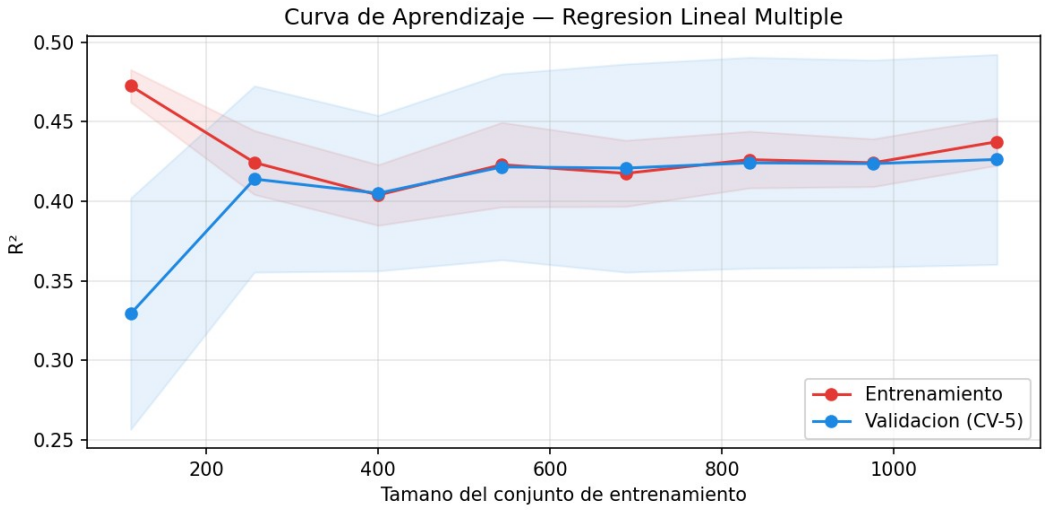


Figura 2. Curva de aprendizaje con validacion cruzada 5-fold — sin overfitting.

5.3 IRA — Incentivo Economico de la Automatizacion

IRA = ingocup × 12 / activo_fijo_amortizado_5_anios (por sector SCIAN). Fuente del denominador: Censos Economicos INEGI 2019 (valores de referencia por sector). IRA > 1 indica que el salario anual supera el costo de automatizar — existe incentivo economico real para sustituir al trabajador. El 96% de trabajadores en la muestra tiene IRA > 1.

La paradoja de la agricultura: Agricultura tiene el mayor IRA (5.07) y el mayor riesgo tecnico (0.758), pero sigue siendo predominantemente manual en Jalisco. Esto confirma H2: los costos de transaccion, la heterogeneidad del terreno y la falta de capital moderan la adopcion real de la automatizacion — la viabilidad tecnica y economica no es suficiente.

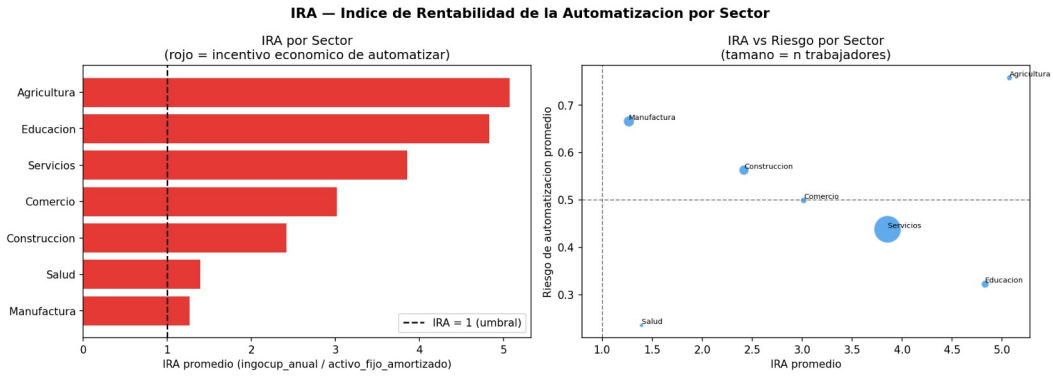


Figura 3. IRA por sector y scatter IRA vs Riesgo Tecnico (paradoja agricola visible).

5.4 Algoritmo No Supervisado — K-Means (U4)

Justificacion: K-Means segmenta trabajadores por perfil completo de riesgo sin etiquetas previas. Datos numericos continuos con grupos naturales esperados (Alto/Medio/Bajo riesgo). Escala obligatoria con StandardScaler.

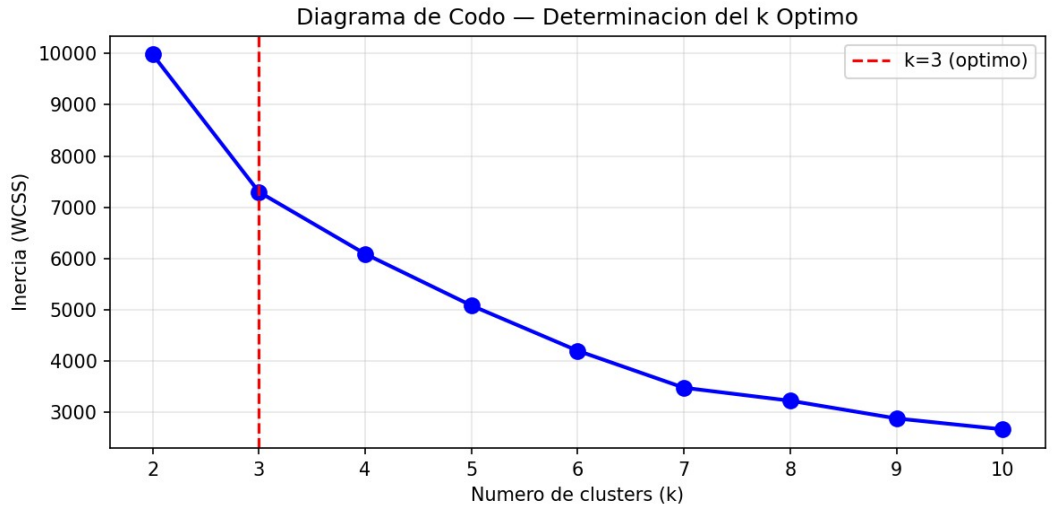


Figura 4. Diagrama de Codo — k=3 confirmado como numero optimo de clusters.

Cluster	N	Riesgo Prom	Ingreso Prom	Educacion Prom	IRA Prom
Riesgo Alto	521	0.650	$9,168	3.4	2.43
Riesgo Medio	1,264	0.454	$8,606	2.7	3.64
Riesgo Bajo	215	0.180	$12,249	4.6	4.91

Hallazgo critico: el Cluster Riesgo Medio concentra el 63% de los trabajadores (1,264 personas) con perfil administrativo/tecnico de Jalisco. Frey & Osborne (2017) clasificaba estos perfiles como "seguros" por su componente cognitivo moderado. Sin embargo, los Large Language Models (GPT-4, Claude, Copilot) realizan exactamente esas tareas — motivando la Fase 2 de la tesis.

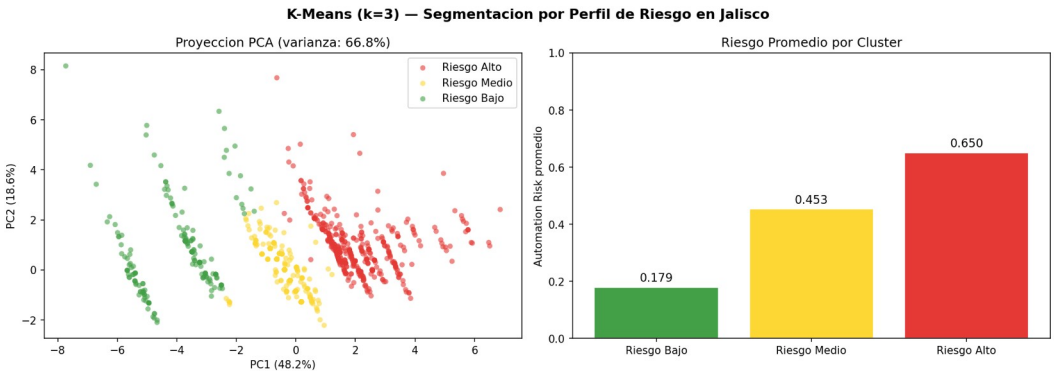


Figura 5. Proyeccion PCA de los 3 clusters (68.2% varianza explicada). Separacion clara entre Riesgo Bajo y Alto; Medio es la zona de mayor incertidumbre.

6. Discusion Integrada

Cada etapa del pipeline responde una dimension distinta de la pregunta de investigacion:

Etapa	Pregunta	Hallazgo clave
SQL INNER JOIN	Cobertura O*NET	2,000 trab. mapeados; 18% informal sin crosswalk completo
SQL LEFT JOIN	Brechas de datos	Agropecuarios e informales sub-representados en O*NET
SQL GROUP BY	Riesgo por sector	Agri 0.758 > Manuf 0.666 > ... > Salud 0.235
Orange Flujo 1	Distribucion y patrones	Bimodal; informalidad amplifica riesgo en todos los sectores
Orange Flujo 2	Correlaciones	RTI r=+0.85 | cognitivo r=-0.77 | social r=-0.76
Orange Flujo 3	Clasificacion visual	Random Forest clasifica Alto/Medio/Bajo con mayor precision
Reg. Lineal	Cuantificacion lineal	R^2=0.36; sector y educacion son los predictores principales
K-Means	Segmentacion natural	Cluster Medio (63%) = nueva zona de riesgo por LLMs
IRA	Incentivo economico	Paradoja agricola: IRA=5.07 + riesgo=0.758, pero sigue manual

Los resultados convergen en tres conclusiones transversales: (1) el riesgo esta determinado principalmente por el tipo de tareas (RTI, demanda cognitiva), no solo por el sector economico; (2) la informalidad actua como amplificador del riesgo — los trabajadores informales tienen menor acceso a formacion y menor proteccion ante la sustitucion tecnologica; (3) la brecha entre riesgo tecnico e incentivo economico (IRA) explica por que sectores teoricamente automatizables siguen siendo manuales en Jalisco.

7. Conclusiones y Trabajo Futuro

7.1 Que demuestra este proyecto

- El pipeline SQL → Orange → Python es completamente funcional con datos reales de Jalisco.
- La Regresion Lineal (R^2=0.36) con variables ENOE establece el baseline del modelo M1 de la tesis.
- K-Means identifica 3 grupos accionables: el Cluster Medio (63%) es la nueva zona de riesgo ante LLMs.
- El IRA revela la paradoja agricola: maxima exposicion tecnica y economica, minima adopcion real.
- O*NET 28.3 y ENOE Q3 2024 son integrables via crosswalk SINCO-ISCO-08 para politica laboral en Mexico.

7.2 Fase 2 de la tesis (trabajo futuro)

- Bloque 3 — LLM Exposure: agregar gpt_exposure_score (Eloundou et al., 2023), LTII y AIOE. Hipotesis H1: el Cluster Medio sube de categoria al incorporar exposicion especifica a LLMs.
- Bloque 4 — IRA completo: integrar Censos Economicos INEGI 2019 con activo fijo real por sector. Hipotesis H2: IRA predice adopcion real independientemente del riesgo tecnico.
- Regresion jerarquica por bloques (M1→M4) con F-test incremental y SHAP values para comparar importancia de variables entre fases.
- Validacion estadistica: Ramsey RESET, VIF para multicolinealidad, GAM para relacion no lineal IRA-riesgo.

8. Referencias

Acemoglu, D., & Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. American Economic Review, 108(6), 1488-1542. https://doi.org/10.1257/aer.20160696

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The skill content of recent technological change: An empirical exploration. Quarterly Journal of Economics, 118(4), 1279-1333. https://doi.org/10.1162/003355303322552801

Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2023). GPTs are GPTs: An early look at the labor market impact potential of large language models. arXiv preprint arXiv:2303.10130.

Felten, E. W., Raj, M., & Seamans, R. (2023). How will language modelers like ChatGPT affect occupations and industries? SSRN Working Paper. https://doi.org/10.2139/ssrn.4375268

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? Technological Forecasting and Social Change, 114, 254-280. https://doi.org/10.1016/j.techfore.2016.08.019

INEGI. (2024). Encuesta Nacional de Ocupacion y Empleo (ENOE), tercer trimestre 2024. Instituto Nacional de Estadistica y Geografia. https://www.inegi.org.mx/programas/enoe/15ymas/

U.S. Department of Labor. (2024). O*NET Database 28.3. National Center for O*NET Development. https://www.onetcenter.org/database.html