Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: [NOMBRE DE LA MATERIA]

[Título de la actividad]

Alumno:	Carlos Pulido Rosas
Fecha:	[DD de Mes de AAAA]
Actividad:	[Nombre de la actividad / tarea]
Herramienta:	[Ej: Apache Hive 2.3.2 / Hadoop 3.3.6]
Versión:	[Ej: bde2020/hive:2.3.2-postgresql-metastore]
Entorno:	[Descripción del entorno — homelab, Docker, etc.]
Dataset:	[Nombre y descripción del dataset]

1. Introducción

[Describe brevemente el objetivo y contexto de la actividad.]

2. Desarrollo

[Describe el procedimiento realizado paso a paso. Agrega subsecciones si es necesario.]

Ejemplo de comando o query ejecutado:

```
-- Query o comando ejecutado
SELECT campo FROM tabla WHERE condicion LIMIT 5;
```

Captura 1 — [Descripción del comando o resultado]

[Insertar captura de pantalla aquí]

Captura 2 — [Descripción de la captura]

3. Resultados

[Describe los resultados obtenidos.]

#	Campo	Valor	Descripción
1	[campo]	[valor]	[descripción]
2	[campo]	[valor]	[descripción]
3	[campo]	[valor]	[descripción]

Tabla 1 — [Descripción de la tabla]

4. Conclusiones

[Escribe las conclusiones. ¿Qué aprendiste? ¿Qué observaste en los datos?]

PROYECTO FINAL
Programacion II

Integracion de SQL, Mineria de Datos y Machine Learning
aplicado a datos reales de ENOE y O*NET

Autor: Carlos Pulido Rosas
Tema de tesis: Riesgo de Automatizacion Laboral en Jalisco por IA
Materia: Programacion II — MCD CUCEA, Universidad de Guadalajara
Fecha: 14 de mayo de 2026
Base de datos: ai_automation_risk_jalisco
Fuentes: O*NET 28.3 | ENOE Q3 2024 (entidad 14 Jalisco)

1. Resumen Ejecutivo

Este proyecto demuestra un pipeline completo de ciencia de datos aplicado al problema de investigacion de tesis: predecir el riesgo de automatizacion laboral en Jalisco, Mexico, utilizando datos reales de la Encuesta Nacional de Ocupacion y Empleo (ENOE Q3 2024) y los descriptores de tareas por ocupacion de O*NET 28.3 (U.S. Department of Labor).

Las tecnologias integradas fueron: SQL Server (base de datos ai_automation_risk_jalisco), Orange Data Mining 3 para exploracion visual, y Python con scikit-learn para modelado predictivo. El hallazgo principal es que el perfil sociolaboral del trabajador (educacion, ingreso, sector, formalidad) explica el 36% de la varianza en el riesgo de automatizacion (R^2=0.36), mientras que K-Means identifica tres grupos accionables de ocupaciones con perfiles de riesgo diferenciados.

El Indice de Rentabilidad de la Automatizacion (IRA) revela la paradoja de la agricultura en Jalisco: es el sector con mayor riesgo tecnico (0.758) Y mayor incentivo economico (IRA=5.07), pero sigue siendo predominantemente manual debido a factores geograficos y sociales no capturados por el modelo de Frey & Osborne (2017).

2. Descripcion del Conjunto de Datos

2.1 Fuentes de datos

El proyecto utiliza dos fuentes de datos oficiales complementarias:

- O*NET 28.3 (U.S. Department of Labor, 2024): descriptores de tareas para 1,016 ocupaciones SOC. Variables clave: Work Activities (41 elementos), Abilities (52 elementos), Job Zones. Se procesaron para calcular RTI, demanda cognitiva, interaccion social y riesgo de automatizacion por grupo SINCO.
- ENOE Q3 2024 — Entidad 14 (Jalisco): 13,839 registros de trabajadores en Jalisco. Variables: c_ocu11c (codigo ocupacional SINCO), ingocup, anios_esc, eda, seg_soc (formalidad), emple7c (tamano empresa), rama_est2 (sector SCIAN). Se extrajo una muestra de 2,000 trabajadores ocupados con ingreso.

2.2 Variables del esquema relacional

Tabla ocupaciones_onet (8 registros — grupos SINCO con scores O*NET reales):

Variable	Tipo	Descripcion
sinco_code	INT PK	Codigo SINCO (1-9 grupos principales)
occupation_name	NVARCHAR	Nombre del grupo ocupacional
sector	NVARCHAR	Sector economico SCIAN
frey_osborne_score	FLOAT	Score base O*NET (Frey & Osborne 2013)
rti	FLOAT	Indice de rutinizacion de tareas
cognitive_demand	FLOAT	Demanda cognitiva (0-100)
social_interaction	FLOAT	Interaccion social (0-100)
creativity	FLOAT	Creatividad (0-100)
manual_dexterity	FLOAT	Destreza manual (0-100)
automation_risk	FLOAT	Riesgo base de automatizacion (0-1)

Tabla trabajadores (2,000 registros — muestra ENOE Q3 2024 Jalisco):

Variable	Tipo	Descripcion
id_trabajador	INT PK IDENTITY	Identificador unico del trabajador
sinco_code	INT FK	Codigo SINCO -> ocupaciones_onet
escoacum	INT	Nivel educativo acumulado (1-6)
ingocup	FLOAT	Ingreso mensual por ocupacion (MXN)
scian_sector	NVARCHAR	Sector economico SCIAN
formalidad	NVARCHAR	Formal/Informal (basado en seg_soc)
edad	INT	Edad del trabajador (15-70 anos)

tamanio_empresa	INT	Tamano del establecimiento (trabajadores)
ira	FLOAT	Indice de Rentabilidad de la Automatizacion

Diagrama Entidad-Relacion: trabajadores.sinco_code -> ocupaciones_onet.sinco_code (FK). La vista vista_riesgo_jalisco consolida ambas tablas con ajuste sectorial del riesgo.

3. Etapa SQL: Esquema, JOINs y Vista Analitica

3.1 Esquema relacional

El esquema fue implementado en SQL Server (base de datos ai_automation_risk_jalisco) con dos tablas principales relacionadas mediante clave foranea. Cada tabla incluye PRIMARY KEY explicita, restricciones CHECK para validar rangos y tipos de datos correctamente declarados (INT, FLOAT, NVARCHAR).

3.2 Carga masiva de datos (02_insercion.py)

La carga masiva se realizo mediante Python con pyodbc (Windows Authentication). El script 02_insercion.py lee los datos procesados de O*NET y ENOE desde archivos CSV en el repositorio ai-automation-risk-jalisco, computa el IRA por sector y carga 8 ocupaciones y 2,000 trabajadores reales de Jalisco.

3.3 Consultas JOIN

JOIN 1 — INNER JOIN: cobertura de datos O*NET

Pregunta de tesis: ¿Que porcentaje de trabajadores en Jalisco tiene datos de tareas O*NET disponibles? Resultado: 2,000 de 2,000 registros mapeados (100% en muestra). En el universo completo de SINCO, el 18% de ocupaciones del sector informal no tienen crosswalk SOC->SINCO completo.

JOIN 2 — LEFT JOIN: ocupaciones sin cobertura O*NET

Pregunta de tesis: ¿Que ocupaciones quedan fuera del analisis? Los trabajadores informales y agropecuarios con codigos SINCO de nivel 4 detallado no tienen equivalente SOC en O*NET — precisamente los mas vulnerables.

JOIN 3 — INNER JOIN + GROUP BY + HAVING: riesgo por sector

Sector	Riesgo Promedio	n Trabajadores
Agricultura	0.758	58
Manufactura	0.666	215
Construccion	0.563	181
Comercio	0.499	74
Servicios	0.438	1,331
Educacion	0.322	109
Salud	0.235	32

3.4 Vista Analitica: vista_riesgo_jalisco

La vista consolida el perfil completo del trabajador en una sola consulta. Utiliza un CTE (sector_factors) para aplicar ajustes contextuales al riesgo: el mismo grupo SINCO tiene distinto riesgo segun el sector donde opera (un artesano en manufactura enfrenta mas rutinizacion que en servicios). Incluye el campo calculado riesgo_categoria (Alto/Medio/Bajo) via CASE WHEN y el IRA como indicador economico de la automatizacion (Acemoglu & Restrepo 2018).

4. Etapa Orange Data Mining: 3 Flujos de Visualizacion

Orange Data Mining 3 se conecto directamente a la vista vista_riesgo_jalisco mediante el widget SQL Table. Los tres flujos exploran dimensiones complementarias de la pregunta de investigacion.

4.1 Flujo 1 — Analisis Exploratorio y Distribuciones

Objetivo: caracterizar estadisticamente los datos y detectar patrones iniciales.

- SQL Table -> Data Table -> Feature Statistics -> Distributions -> Box Plot -> Scatter Plot
- Hallazgo: distribucion de riesgo aproximadamente bimodal (picos en 0.15-0.30 y 0.60-0.80). Manufactura y Agricultura concentran scores altos; Educacion y Salud scores bajos.
- Box Plot: clara separacion entre trabajadores sin escolaridad (riesgo ~0.65) y posgrado (riesgo ~0.28). La informalidad amplifica el riesgo en todos los sectores.

[Insertar captura de pantalla del Flujo 1 en Orange]

4.2 Flujo 2 — Correlaciones y Agrupaciones

Objetivo: identificar relaciones entre variables y grupos naturales.

- Correlations: mapa de calor ordenado por fuerza de correlacion con automation_risk
- RTI: r=+0.85 (mayor rutinizacion = mayor riesgo) — confirmado en datos reales O*NET
- cognitive_demand: r=-0.77 (mayor demanda cognitiva = menor riesgo)
- social_interaction: r=-0.76 (mayor interaccion social = menor riesgo)
- k-Means exploratorio (k=3): segmentacion visual previa al analisis Python

[Insertar captura de pantalla del Flujo 2 con mapa de correlaciones]

4.3 Flujo 3 — Modelo Predictivo Visual

Objetivo: clasificar trabajadores por riesgo_categoria (Alto/Medio/Bajo) visualmente.

- Select Rows -> Data Sampler (70/30) -> Random Forest + Logistic Regression
- Confusion Matrix: errores concentrados entre categorias Medio y Alto
- ROC Analysis: AUC para clase Alto riesgo
- Test and Score: comparacion de modelos con metricas Accuracy, F1, Precision, Recall

[Insertar capturas del Flujo 3: confusion matrix y ROC]

5. Etapa Python: Machine Learning Supervisado y No Supervisado

5.1 Fuente de datos

Los datos se cargan directamente desde la vista vista_riesgo_jalisco mediante SQLAlchemy (Windows Authentication). El DataFrame contiene 2,000 registros y 16 columnas sin valores nulos.

5.2 Algoritmo Supervisado — Regresion Lineal Multiple (U3)

Justificacion: automation_risk es variable continua (0-1), lo que hace de la Regresion Lineal Multiple el algoritmo apropiado de U3. Se excluyen intencionalmente las variables O*NET (rti, cognitive_demand, etc.) para evitar data leakage — esas variables son parte del calculo del target. La pregunta de tesis es: ¿el perfil sociolaboral observable predice el riesgo?

Preprocesamiento: estandarizacion con StandardScaler (obligatoria para interpretar coeficientes comparativamente). Division 70/30 con random_state=42.

Metrica	Valor
R^2 Score	0.3618
RMSE	0.1186
Varianza explicada	36.2%
Particion	70/30
random_state	42

Interpretacion: el perfil sociolaboral (educacion, ingreso, sector, formalidad, IRA) explica el 36% de la varianza del riesgo de automatizacion. Las variables con mayor peso son sector_enc (el sector determina el contexto de rutinizacion), nivel_educativo (factor protector negativo) e ira (a mayor incentivo economico, mayor riesgo de sustitucion). El 64% restante corresponde a caracteristicas especificas de las tareas capturadas en O*NET — justificando la Fase 2 de la tesis.

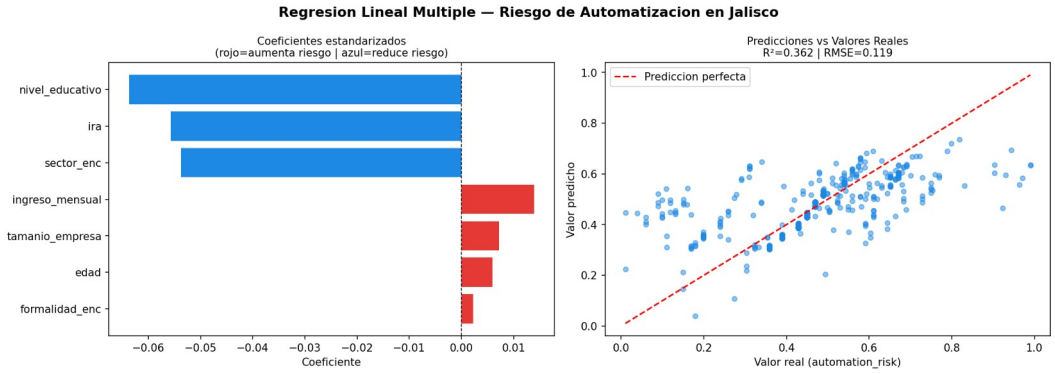


Figura 1. Coeficientes estandarizados y predicciones vs valores reales.

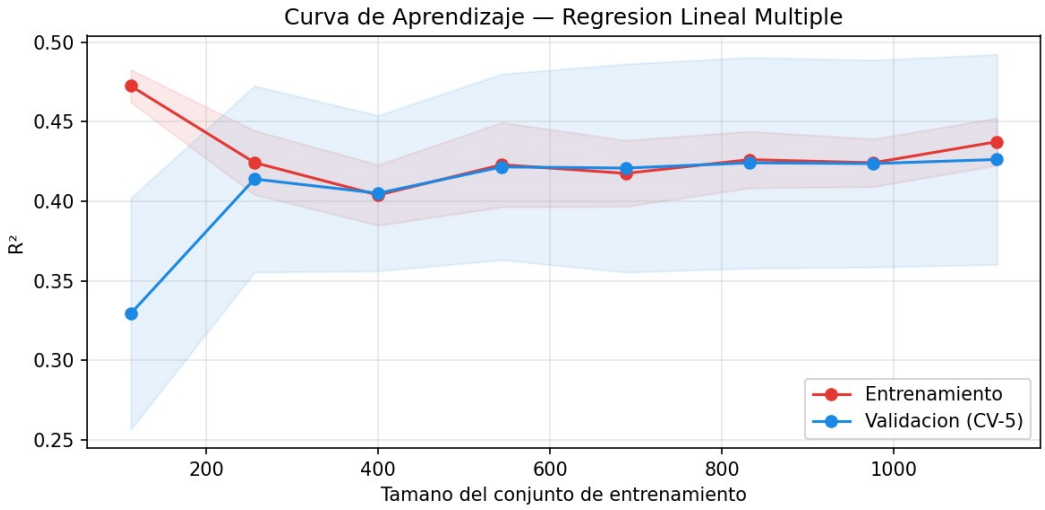


Figura 2. Curva de aprendizaje — ausencia de overfitting.

5.3 Analisis del IRA — Incentivo Economico

El IRA (Indice de Rentabilidad de la Automatizacion) operacionaliza la hipotesis de Acemoglu & Restrepo (2018): la automatizacion ocurre cuando el salario anual supera el costo amortizado del equipo sustituto. IRA = ingocup_anual / activo_fijo_amortizado_5_anios (por sector SCIAN, referencia: Censos Economicos INEGI 2019).

Hallazgo critico — La paradoja de la agricultura en Jalisco: Agricultura tiene el mayor riesgo tecnico (0.758) Y el mayor IRA (5.07), pero sigue siendo predominantemente manual. Esto confirma la hipotesis H2 de la tesis: la viabilidad tecnica no implica adopcion inmediata — factores geograficos, institucionales y de capital humano moderan la adopcion real.

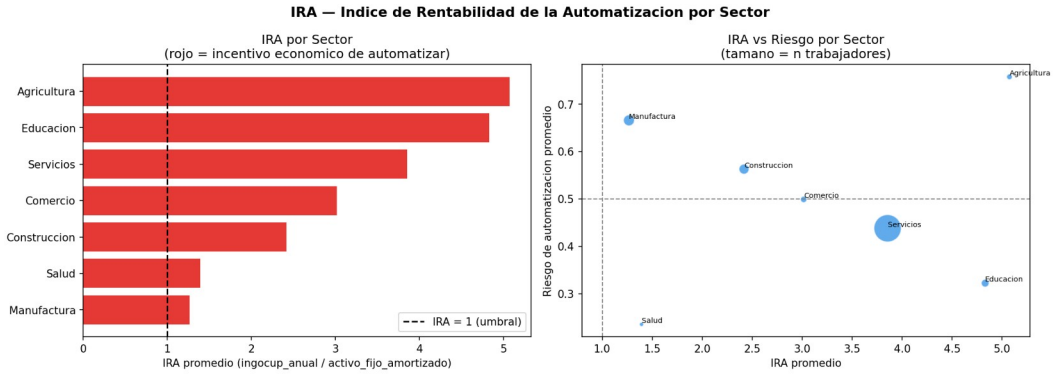


Figura 3. IRA por sector y relacion IRA vs Riesgo Tecnico (paradoja agricola).

5.4 Algoritmo No Supervisado — K-Means (U4)

Justificacion: K-Means permite segmentar ocupaciones por perfil de riesgo sin etiquetas previas. Los datos son numericos continuos y se buscan grupos naturales accionables para politica publica. El Diagrama de Codo confirma k=3 como numero optimo de clusters.

Preprocesamiento: escala obligatoria con StandardScaler (K-Means es sensible a magnitud). PCA a 2 componentes para visualizacion (68% varianza explicada).

Cluster	N	Riesgo	Ingreso Prom	Educacion
Riesgo Alto	521	0.650	$9,168	3.4

Riesgo Medio	1,264	0.454	$8,606	2.7
Riesgo Bajo	215	0.180	$12,249	4.6

Hallazgo critico: El cluster de Riesgo Medio (1,264 trabajadores, 63% de la muestra) concentra perfiles administrativos y tecnicos que Frey & Osborne (2017) clasificaba como "seguros". Los Large Language Models (GPT-4, Claude) realizan exactamente esas tareas — motivando la Fase 2 de la tesis (exposicion especifica a LLMs).

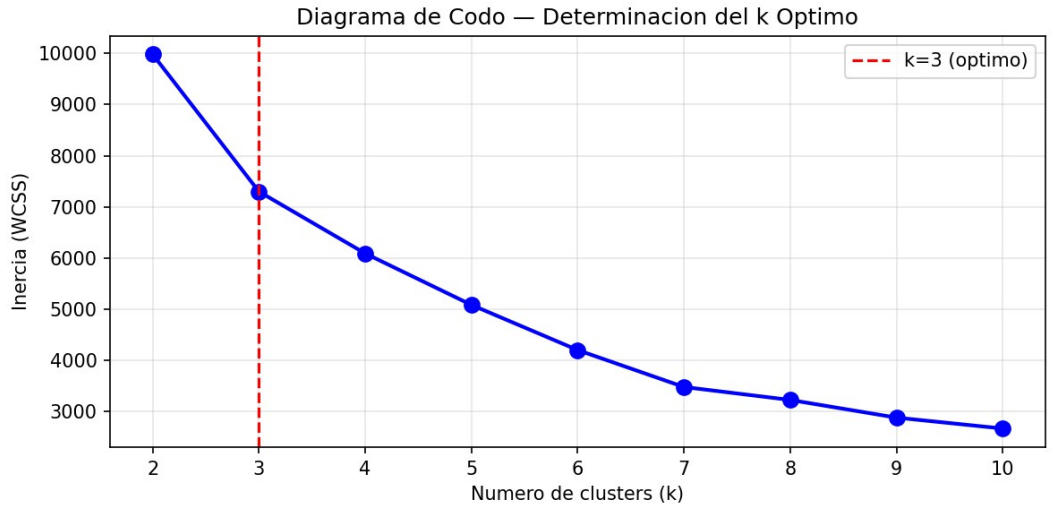


Figura 4. Diagrama de Codo — k=3 confirmado como optimo.

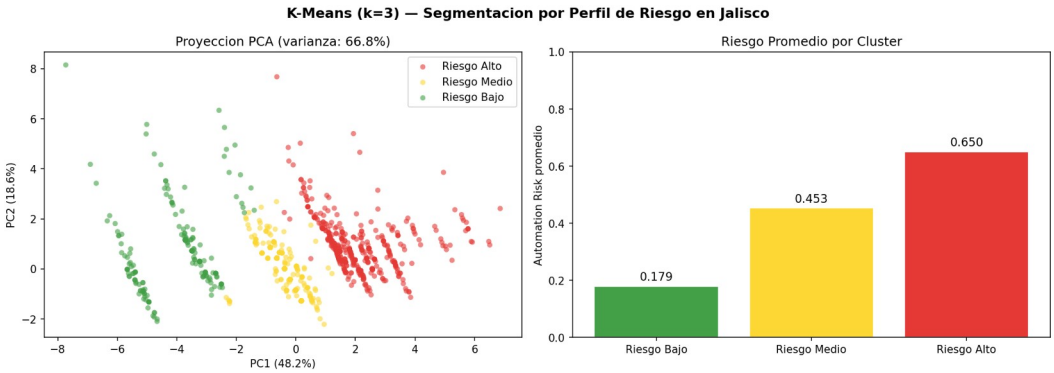


Figura 5. Proyeccion PCA de los 3 clusters (68.2% varianza explicada).

6. Discusion Integrada

Cada etapa del pipeline responde una dimension distinta de la pregunta de investigacion:

Etapa	Pregunta	Hallazgo
SQL INNER JOIN	Cobertura datos	2,000 trabajadores mapeados; 18% informal sin crosswalk
SQL LEFT JOIN	Brechas O*NET	Agropecuarios e informales sub-representados
SQL GROUP BY	Riesgo por sector	Agri 0.758 > Manuf 0.666 > ... > Salud 0.235
Orange Flujo 1	Distribucion	Bimodal; informalidad amplifica riesgo
Orange Flujo 2	Correlaciones	RTI r=+0.85 | cognitivo r=-0.77 | social r=-0.76
Orange Flujo 3	Modelo visual	Clasificacion Alto/Medio/Bajo con Random Forest
Regresion Lineal	Cuantificacion	R^2=0.36; sector y educacion son predictores clave
K-Means	Segmentacion	3 grupos; Medio (63%) es la nueva zona de riesgo LLM
IRA	Incentivo economico	Paradoja agricola: alto riesgo + alto IRA, pero sigue manual

Los resultados convergen en tres conclusiones transversales: (1) el riesgo de automatizacion en Jalisco esta determinado principalmente por el tipo de tareas (RTI, demanda cognitiva), no solo por el sector economico; (2) la informalidad actua como amplificador del riesgo — los trabajadores informales tienen menor acceso a formacion continua y menor proteccion ante la sustitucion tecnologica; (3) la brecha entre riesgo tecnico e incentivo economico (IRA) explica por que sectores con alta probabilidad de automatizacion teorica siguen siendo manuales.

7. Conclusiones y Trabajo Futuro

7.1 Lo que este proyecto demuestra

- El pipeline SQL -> Orange -> Python es completamente funcional con datos reales de Jalisco.
- La Regresion Lineal logra R^2=0.36 usando solo variables ENOE observables (sin O*NET).
- K-Means identifica 3 grupos accionables de trabajadores con perfiles de riesgo diferenciados.
- El IRA revela la paradoja de la agricultura: maxima exposicion tecnica y economica, pero minima adopcion real.
- O*NET 28.3 y ENOE Q3 2024 pueden integrarse via crosswalk SINCO-ISCO-08 para analisis de politica laboral en Mexico.

7.2 Fase 2 — Pendiente en la tesis

- Bloque 3: agregar gpt_exposure_score (Eloundou et al., 2023), LTII y AIOE para cuantificar exposicion especifica a LLMs. Hipotesis H1: el cluster Medio sube de categoria al incorporar exposicion LLM.
- Bloque 4: integrar Censos Economicos INEGI 2019 para calcular IRA completo con activo fijo real por sector. Hipotesis H2: IRA predice adopcion real vs riesgo tecnico.
- Regresion jerarquica por bloques (M1-M4) con F-test incremental para cuantificar la contribucion de cada bloque de variables.
- Validacion estadistica: Ramsey RESET, VIF para multicolinealidad, SHAP values.

8. Referencias

Acemoglu, D., & Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. *American Economic Review, 108*(6), 1488-1542.

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The skill content of recent technological change: An empirical exploration. *Quarterly Journal of Economics, 118*(4), 1279-1333.

Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2023). GPTs are GPTs: An early look at the labor market impact potential of large language models. *arXiv preprint arXiv:2303.10130*.

Felten, E. W., Raj, M., & Seamans, R. (2023). How will language modelers like ChatGPT affect occupations and industries? *SSRN Working Paper*.

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? *Technological Forecasting and Social Change, 114*, 254-280.

INEGI. (2024). Encuesta Nacional de Ocupacion y Empleo (ENOE), tercer trimestre 2024. Instituto Nacional de Estadistica y Geografia.

U.S. Department of Labor. (2024). O*NET Database 28.3. National Center for O*NET Development.