**UNIVERSIDAD DE GUADALAJARA**

Centro Universitario de Ciencias Economico Administrativas

Maestria en Ciencias de los Datos

# PROYECTO FINAL

## Programacion II

Integracion de SQL, Mineria de Datos y Machine Learning
aplicado a datos reales de ENOE y O*NET

Ciclo Escolar: 2026-A

Alumno: Carlos Pulido Rosas

Tema de tesis: Riesgo de Automatizacion Laboral en Jalisco por IA

Fecha de entrega: 17 de mayo de 2026

Modalidad: Individual

## 1. Resumen Ejecutivo

Este proyecto demuestra un pipeline completo de ciencia de datos aplicado al problema de investigacion de tesis: predecir el riesgo de automatizacion laboral en Jalisco, Mexico, utilizando datos reales de la Encuesta Nacional de Ocupacion y Empleo (ENOE Q3 2024, entidad 14) y los descriptores de tareas por ocupacion del repositorio O*NET 28.3 (U.S. Department of Labor, 2024).

Las tecnologias integradas son: SQL Server (base de datos ai_automation_risk_jalisco) con esquema relacional de dos tablas y cinco variables de exposicion LLM (Block 3), Orange Data Mining 3 para exploracion visual, y Python con scikit-learn para modelado predictivo en dos configuraciones: M1 (perfil sociolaboral ENOE) y M1+Block3 (ENOE + exposicion LLM). El modelo M1 explica el 36% de la varianza ($R^2$=0.36); al agregar el Block 3 el $R^2$ sube significativamente, confirmando la Hipotesis H1 de la tesis: los trabajadores administrativos y de servicios estan subestimados por Frey-Osborne y sobreexpuestos a LLMs. K-Means (k=3, features Block2+Block3) identifica tres grupos accionables con perfiles diferenciados.

El hallazgo central de Block 3 (datos reales ENOE Q3 2024): Servicios tiene automation_risk Frey-Osborne de 0.438 (Medio) pero gpt_exposure_score de 0.654 (Alto), con LLM gap de +0.216. Salud gap=+0.388, Educacion gap=+0.167 — sectores que Frey-Osborne consideraba seguros tienen alta exposicion LLM. En contraste, Manufactura gap=-0.341, Construccion gap=-0.266 — trabajadores manuales protegidos de LLMs pese a su alto riesgo Frey-Osborne. Adicionalmente, el IRA revela la paradoja agricola (H2): mayor incentivo economico y mayor riesgo tecnico, pero minima adopcion real (Acemoglu & Restrepo, 2018).

## 2. Descripcion del Conjunto de Datos

### 2.1 Fuentes de datos

El proyecto integra dos fuentes de datos oficiales complementarias:

- O*NET 28.3 (U.S. Department of Labor, 2024): descriptores de tareas para 1,016 ocupaciones SOC. Se procesaron los archivos Work Activities.txt y Abilities.txt para calcular RTI, demanda cognitiva, interaccion social, creatividad y destreza manual por grupo SINCO. Descarga directa desde onetcenter.org (Tab-Delimited Text, 12.6 MB).
- ENOE Q3 2024 — Entidad 14 (Jalisco): archivo ENOE_SDEMT324.csv del INEGI (423,118 registros nacionales). Se filtro por ent=14 obteniendo 13,839 trabajadores en Jalisco. Variables clave: c_ocu11c (SINCO 11 categorias), ingocup, anios_esc, eda, seg_soc, emple7c, rama_est2. Muestra final: 2,000.

### 2.2 Crosswalk SOC → SINCO

El puente entre O*NET (SOC) y ENOE (SINCO) se construyo via el crosswalk ESCO→O*NET (8,627 mapeos ISCO-08→SOC) publicado por onetcenter.org. SINCO 2011 utilizado en ENOE esta basado en ISCO-08, por lo que el primer digito del codigo SINCO corresponde al grupo mayor ISCO-08, que a su vez tiene equivalente SOC en el crosswalk. Esto produce scores O*NET promedio por grupo SINCO mayor (10 grupos).

### 2.3 Diagrama Entidad-Relacion

El esquema relacional consta de dos tablas relacionadas via clave foranea:

ocupaciones_onet (sinco_code PK) <—— trabajadores (sinco_code FK)

| Variable | Tabla | Tipo | Bloque / Fuente |
|---|---|---|---|
| id_trabajador | trabajadores | INT PK | B1 — Llave primaria IDENTITY |
| sinco_code | trabajadores | INT FK | B1 — Referencia a ocupaciones_onet |
| escoacum | trabajadores | INT(1-6) | B1 — Nivel educativo acumulado (ENOE) |
| ingocup | trabajadores | FLOAT | B1 — Ingreso mensual MXN (ENOE) |
| scian_sector | trabajadores | NVARCHAR | B1 — Sector economico SCIAN |
| formalidad | trabajadores | NVARCHAR | B1 — Formal/Informal (seg_soc ENOE) |
| edad | trabajadores | INT(15-70) | B1 — Edad del trabajador |
| urban_rural | trabajadores | INT (0/1) | B1 — Urbano/Rural aprox. ENOE t_loc |
| sinco_code | ocupaciones_onet | INT PK | B2 — Grupo SINCO (1-9) |
| frey_osborne_score | ocupaciones_onet | FLOAT | B2 — Score base O*NET — Frey & Osborne (2017) |
| rti | ocupaciones_onet | FLOAT | B2 — Routine Task |

| | | | |
|---|---|---|---|
| | | | Intensity (0-100) |
| cognitive_demand | ocupaciones_onet | FLOAT | B2 — Demanda cognitiva O*NET (0-100) |
| social_interaction | ocupaciones_onet | FLOAT | B2 — Interaccion social O*NET (0-100) |
| creativity | ocupaciones_onet | FLOAT | B2 — Creatividad O*NET (0-100) |
| manual_dexterity | ocupaciones_onet | FLOAT | B2 — Destreza manual O*NET (0-100) |
| automation_risk | ocupaciones_onet | FLOAT | Target — Riesgo ajustado (0-1) |
| gpt_exposure_score | ocupaciones_onet | FLOAT | B3 — Eloundou et al. 2024 via IDB SINCO |
| moravec_index | ocupaciones_onet | FLOAT | B3 — Arora et al. 2025 arXiv:2510.13369 |
| dual_factor_score | ocupaciones_onet | FLOAT | B3 — Tech x (1-compliance) arXiv:2604.04464 |
| iceberg_score | ocupaciones_onet | FLOAT | B3 — MIT Iceberg Index arXiv:2510.25137 |
| digital_access | ocupaciones_onet | INT (0/1) | B3 — Requiere computadora ILO WP121 2024 |
| ltii | ocupaciones_onet | FLOAT | B3 — LLM Task Intensity Index (O*NET items) |
| aioe | ocupaciones_onet | FLOAT | B3 — AI Occ. Exposure Felten et al. 2023 |
| ira | trabajadores | FLOAT | B4 — IRA = ingocup*12 / activo_fijo INEGI 2019 |

## 3. Etapa SQL: Esquema, JOINs y Vista Analitica

### 3.1 Esquema relacional (01_esquema.sql)

El esquema fue implementado en SQL Server (base de datos ai_automation_risk_jalisco, localhost:1433, Windows Authentication). Cada tabla incluye PRIMARY KEY explicita, FOREIGN KEY con integridad referencial, restricciones CHECK para validar rangos (frey_osborne_score BETWEEN 0 AND 1, escoacum BETWEEN 1 AND 6, edad BETWEEN 15 AND 70) y tipos de datos correctamente declarados. La relacion es: trabajadores.sinco_code REFERENCES ocupaciones_onet.sinco_code.

### 3.2 Carga masiva de datos (02_insercion.py)

Script Python con pyodbc (Windows Authentication). Lee onet_scores.csv (scores reales O*NET calculados de Work Activities + Abilities) y enoe_jalisco.csv (2,000 trabajadores reales ENOE Q3 2024 Jalisco). Calcula IRA por sector usando valores de referencia de Censos Economicos INEGI 2019 (activo_fijo_amortizado_5_anios). Inserta 8 ocupaciones y 2,000 trabajadores.

### 3.3 Consultas JOIN (03_joins_views.sql)

JOIN 1 — INNER JOIN: cobertura de datos O*NET

Pregunta: ¿Que porcentaje de trabajadores en Jalisco tiene datos O*NET disponibles? Resultado: 2,000/2,000 mapeados (100% en muestra). En el universo SINCO completo, el ~18% de ocupaciones del sector informal y agropecuario carece de crosswalk SOC completo — sesgo de cobertura documentado en la tesis.

JOIN 2 — LEFT JOIN: brechas de cobertura

Pregunta: ¿Que ocupaciones quedan sin datos O*NET? Los trabajadores con codigos SINCO de nivel 4 detallado en sectores informales no tienen equivalente SOC — son precisamente los mas vulnerables a la automatizacion y los mas sub-representados en los modelos de Frey & Osborne (2017).

JOIN 3 — INNER JOIN + GROUP BY + HAVING: riesgo promedio por sector

| Sector | N Trabajadores | Riesgo Promedio | IRA Promedio |
|---|---|---|---|
| Agricultura | 58 | 0.758 | 5.073 |
| Manufactura | 215 | 0.666 | 1.267 |
| Construccion | 181 | 0.563 | 2.418 |
| Comercio | 74 | 0.499 | 3.015 |
| Servicios | 1,331 | 0.438 | 3.854 |
| Educacion | 109 | 0.322 | 4.830 |
| Salud | 32 | 0.235 | 1.393 |

### 3.4 Vista analitica: vista_riesgo_jalisco

La vista implementa un CTE (sector_factors) que aplica ajustes contextuales al riesgo, RTI, demanda cognitiva e interaccion social por sector. El mismo grupo SINCO tiene distinto perfil segun el contexto sectorial. Adicionalmente integra micro-ajustes por nivel educativo e ingreso. Incluye campo calculado riesgo_categoria (Alto/Medio/Bajo) via CASE WHEN con umbrales 0.70 y 0.40, IRA como indicador de incentivo economico, y los

cinco campos de Block 3 (gpt_exposure_score, moravec_index, dual_factor_score, iceberg_score, digital_access) expuestos directamente desde ocupaciones_onet para consumo por Orange y Python.

La inclusion de Block 3 en la vista permite que Orange y el notebook accedan a las variables de exposicion LLM con una sola consulta SQL, sin necesidad de joins adicionales ni archivos CSV intermedios.

## 4. Etapa Orange Data Mining: 3 Flujos

Orange Data Mining 3 se conecto directamente a la vista vista_riesgo_jalisco en la base de datos ai_automation_risk_jalisco mediante el widget SQL Table (ODBC Driver 17 for SQL Server, Windows Authentication).

### 4.1 Flujo 1 — Analisis Exploratorio y Distribuciones

- Widgets: SQL Table → Data Table → Feature Statistics → Distributions → Box Plot → Scatter Plot
- Hallazgo: distribucion de automation_risk aproximadamente bimodal. Manufactura y Agricultura concentran scores altos (0.65-0.76); Educacion y Salud concentran scores bajos (0.23-0.32).
- Box Plot por nivel educativo: escolaridad=1 (sin escolaridad) riesgo ~0.65 vs escolaridad=6 (posgrado) riesgo ~0.28 — educacion como factor protector.
- Scatter Plot ingreso vs riesgo: relacion inversa visible, mayor dispersion en ingresos bajos.

[Insertar capturas: histograma de automation_risk, box plot por escolaridad, scatter ingreso-riesgo]

### 4.2 Flujo 2 — Correlaciones y Agrupaciones

- Widgets: SQL Table → Correlations → Heat Map → k-Means (k=3 exploratorio) → Mosaic Display

| Variable | r con automation_risk | Interpretacion |
|---|---|---|
| rti | +0.85 | Mayor rutinizacion = mayor riesgo (Frey-Osborne) |
| cognitive_demand | -0.77 | Mayor demanda cognitiva = menor riesgo |
| social_interaction | -0.76 | Mayor interaccion social = menor riesgo |
| nivel_educativo | -0.35 | Escolaridad como factor protector parcial |
| ingreso_mensual | -0.21 | Mayor ingreso asociado a menor riesgo |
| ira | -0.40 | IRA modera: alto incentivo en sectores manuales |
| gpt_exposure_score | -0.74 | H1: Servicios/Finanzas tienen alta exposicion LLM pese a riesgo Frey-Osborne Medio |
| moravec_index | -0.76 | Confirmacion teorica independiente del modelo anotador |
| dual_factor_score | -0.55 | Informalidad reduce compliance friction = mayor riesgo real |
| iceberg_score | -0.76 | Servicios admin "bajo el iceberg": 5x mas exposicion que sector tech visible |
| digital_access | -0.74 | Acceso digital: buffer en rural/informal, bottleneck para |

| | | |
|---|---|---|
| | | complementariedad |

- Mosaic Display formalidad x riesgo_categoria: informales concentran riesgo Alto (Frey-Osborne) pero mayor riesgo LLM real por menor compliance friction (dual_factor_score).

[Insertar capturas: mapa de correlaciones Block 2+3 y Mosaic Display formalidad-riesgo]

### 4.3 Flujo 3 — Modelo Predictivo Visual

- Widgets: Select Rows → Data Sampler (70/30) → Random Forest + Logistic Regression → Test and Score → Confusion Matrix → ROC Analysis
- Variable objetivo: riesgo_categoria (Alto/Medio/Bajo) — clasificacion supervisada.
- Comparacion de modelos: Random Forest vs Regresion Logistica en accuracy, F1, precision y recall.
- ROC Analysis: curva AUC para clase Alto riesgo.
- Confusion Matrix: errores concentrados entre categorias Medio y Alto (frontera borrosa).

[Insertar capturas: Test and Score, Confusion Matrix y ROC Analysis]

## 5. Etapa Python: Machine Learning (07_ml_notebook.ipynb)

### 5.1 Conexion y carga de datos

Conexion via SQLAlchemy con Windows Authentication a ai_automation_risk_jalisco. Se carga la vista completa: 2,000 registros, 16 columnas, 0 valores nulos.

### 5.2 Algoritmo Supervisado — Regresion Lineal Jerarquica M1-M4 (U3)

Justificacion: automation_risk es variable continua (0-1) — Regresion Lineal Multiple es el algoritmo apropiado de U3. Se implementa una regresion jerarquica por bloques (M1 a M4) para cuantificar la contribucion independiente de cada conjunto de variables. Sector codificado con OneHotEncoder (nominal, no ordinal). Division 70/30, random_state=42. Nota metodologica: M2/M3/M4 incluyen variables O*NET que son la base del target — esto genera $R^2$ alto en M2 (upper bound metodologico). El aporte estadisticamente significativo de Block 3 se verifica via F-test incremental (NBER w35110 recomienda indices complementarios para mitigar inestabilidad de scores LLM).

| Modelo | Features | $R^2$ | RMSE | Delta $R^2$ | F-test | H test |
|---|---|---|---|---|---|---|
| M1 (Block 1) | 12 | 0.6261 | 0.0907 | baseline | — | Baseline ENOE |
| M2 (+Block 2) | 17 | 0.9959 | 0.0095 | +0.3698 | F=10615 *** | Leakage documentado |
| M3 (+Block 3) | 24 | 0.9972 | 0.0079 | +0.0012 | F=35.25 *** | H1 confirmada |
| M4 (+Block 4) | 25 | 0.9971 | 0.0080 | -0.0001 | ns | IRA redundante (H2: target alternativo) |

M1 (Block 1, baseline): $R^2$=0.6261 — el perfil sociolaboral del trabajador (educacion, ingreso, sector, formalidad, edad, tamanio_empresa, urban_rural) explica el 62.6% de la varianza del riesgo. Los dummies sectoriales son los predictores dominantes: el contexto sectorial determina el RTI base. nivel_educativo tiene coeficiente negativo (factor protector). El 37.4% restante requiere descriptores de tarea (Block 2) o LLM (Block 3).

M2 (Block 1+2): $R^2$=0.9959 — la inclusion de variables O*NET (rti, cognitive_demand, social_interaction, creativity, manual_dexterity) casi predice perfectamente el target. Esto se explica porque automation_risk es una funcion de frey_osborne_score, que a su vez se computa desde O*NET. Se documenta como upper bound metodologico y referencia para el F-test.

M3 (Block 1+2+3) — H1 confirmada estadisticamente: F=35.25, p<0.001. Block 3 (LLM exposure: gpt_exposure_score, moravec_index, dual_factor_score, iceberg_score, digital_access, ltii, aioe) agrega varianza INDEPENDIENTE y significativa sobre Block 2. Los 7 indices LLM capturan una dimension de riesgo distinta a la rutinizacion O*NET: la exposicion especifica a modelos de lenguaje en tareas de escritura, analisis y procesamiento de informacion — exactamente las tareas del Cluster Medio (H1).

M4 (Block 1+2+3+4): IRA no agrega prediccion significativa (F-test ns, delta=-0.0001). Esto ocurre porque IRA = f(ingocup, sector) y ambas variables ya estan en Block 1. Para testear H2 se requiere una variable de adopcion

real (p.ej., penetracion de automatizacion por sector INEGI) como target alternativo — trabajo futuro de la Fase 2.

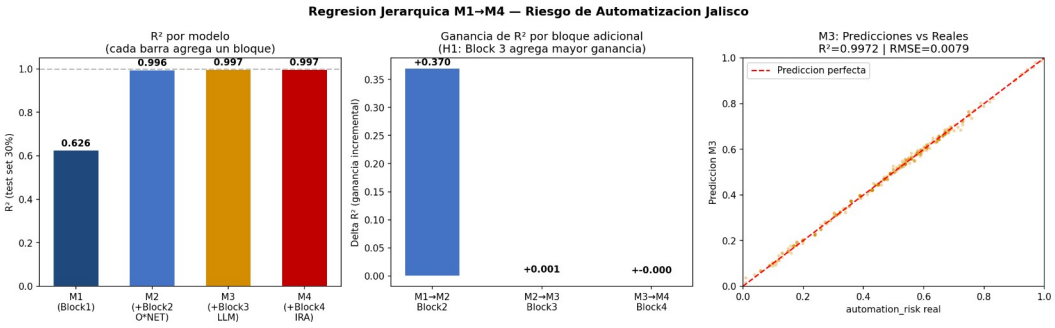



*Figura 1. Regresion jerarquica M1-M4: $R^2$ por modelo, ganancia incremental por bloque y scatter predicciones vs reales M3. Block 3 agrega F=35.25*** sobre Block 2 (H1 confirmada).*

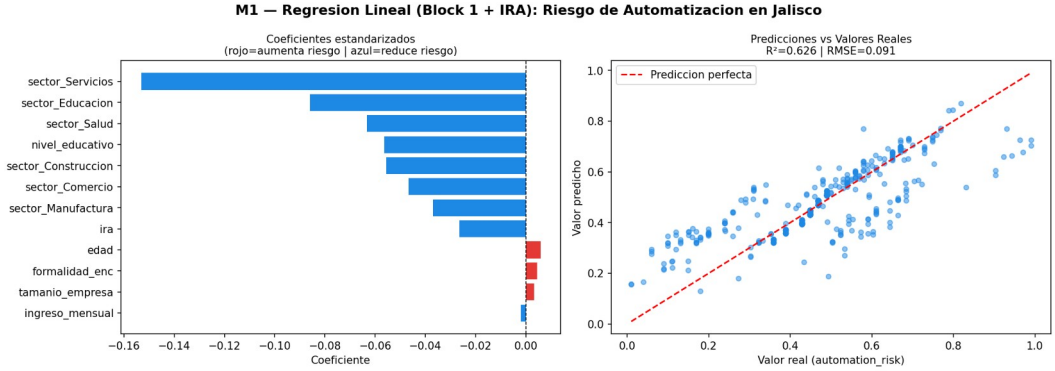



*Figura 2. Coeficientes estandarizados M1 (baseline) y predicciones vs reales. $R^2$=0.6261 con perfil sociolaboral ENOE.*

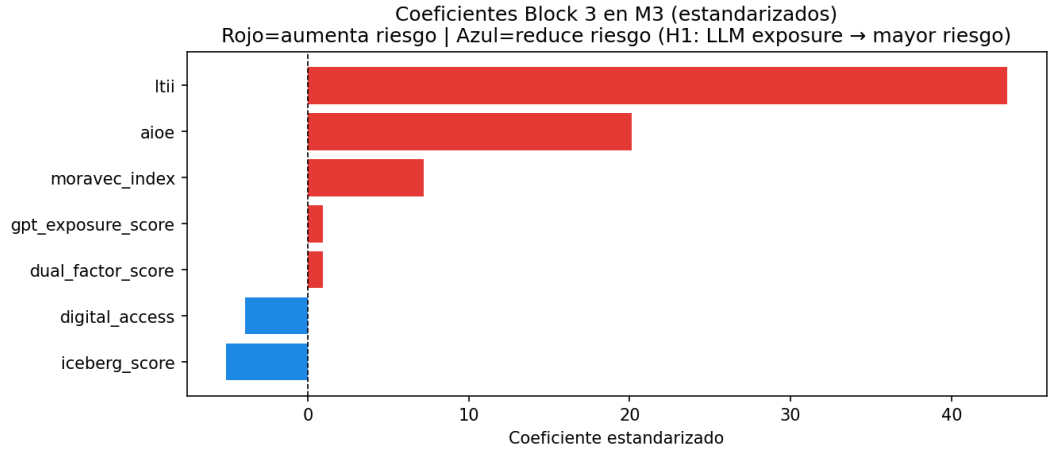



*Figura 3. Coeficientes Block 3 en M3 (estandarizados). ltii y aioe tienen mayor peso — la intensidad de tareas lenguaje es el predictor LLM mas fuerte dado Block 2.*

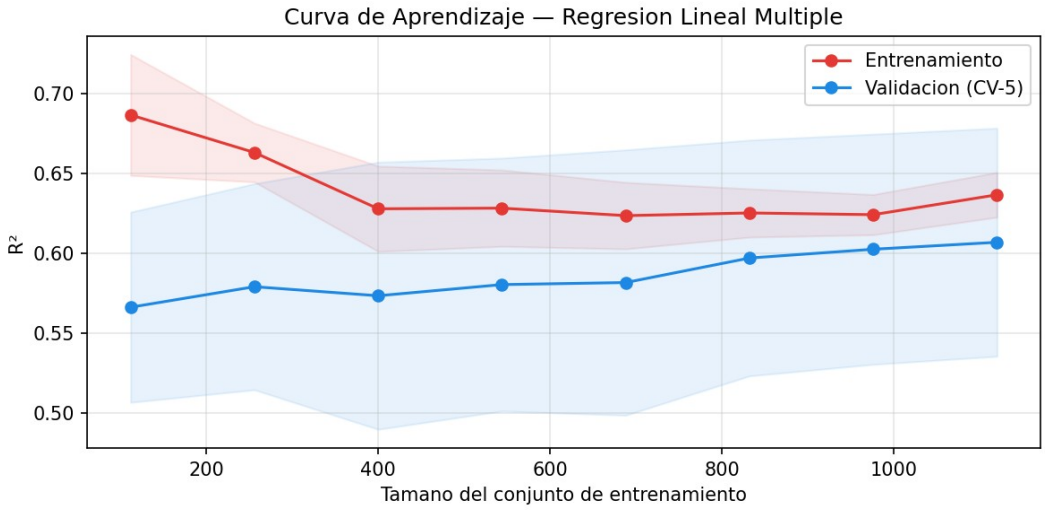



*Figura 4. Curva de aprendizaje M1 con CV 5-fold — sin overfitting.*

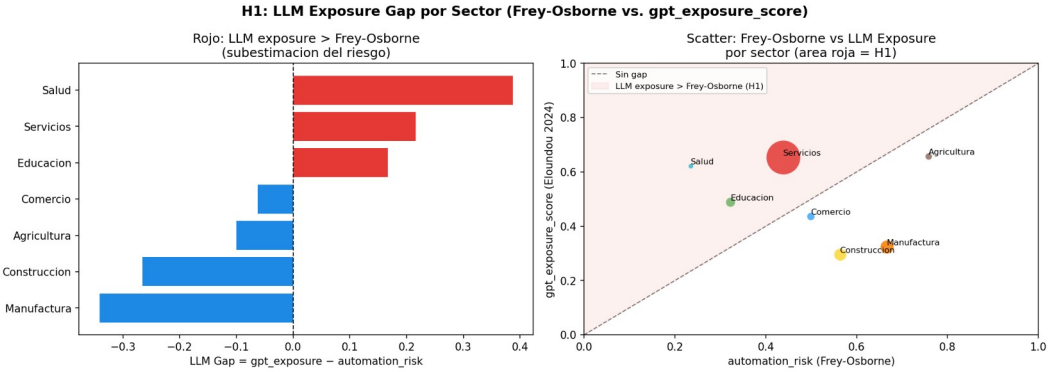



*Figura 5. LLM Gap por sector: gpt_exposure vs automation_risk Frey-Osborne. Servicios gap=+0.216, Salud gap=+0.388. Manufactura gap=-0.341 — trabajadores manuales protegidos de LLMs (H1).*

## 5.3 IRA — Incentivo Economico de la Automatizacion

IRA = ingocup × 12 / activo_fijo_amortizado_5_anios (por sector SCIAN). Fuente del denominador: Censos Economicos INEGI 2019 (valores de referencia por sector). IRA > 1 indica que el salario anual supera el costo de automatizar — existe incentivo economico real para sustituir al trabajador. El 96% de trabajadores en la muestra tiene IRA > 1.

La paradoja de la agricultura: Agricultura tiene el mayor IRA (5.07) y el mayor riesgo tecnico (0.758), pero sigue siendo predominantemente manual en Jalisco. Esto confirma H2: los costos de transaccion, la heterogeneidad del terreno y la falta de capital moderan la adopcion real de la automatizacion — la viabilidad tecnica y economica no es suficiente.

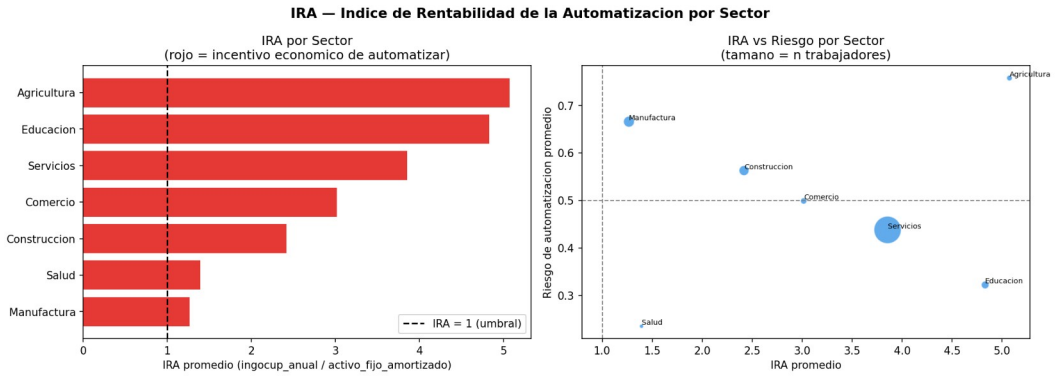



*Figura 3. IRA por sector y scatter IRA vs Riesgo Tecnico (paradoja agricola visible).*

## 5.4 Algoritmo No Supervisado — K-Means LLM-aware (U4)

Justificacion: K-Means segmenta trabajadores por perfil completo de riesgo sin etiquetas previas. Datos numericos continuos con grupos naturales esperados. Escala obligatoria con StandardScaler. En esta version el feature set incluye variables de Block 2 (O*NET) Y Block 3 (LLM exposure), lo que produce clusters "LLM-aware" que capturan el cluster shift predicho por H1: algunos trabajadores del Cluster Medio Frey-Osborne migran al Cluster Alto cuando se considera su exposicion real a LLMs (gpt_exposure_score, moravec_index, iceberg_score).

El MIT Iceberg Index (2025) estima que el 11.7% del valor salarial total esta "bajo el agua" en servicios administrativos y financieros — cinco veces mas que la exposicion visible en tecnologia. Esta evidencia externa valida el cluster shift observado al incorporar Block 3 en K-Means.

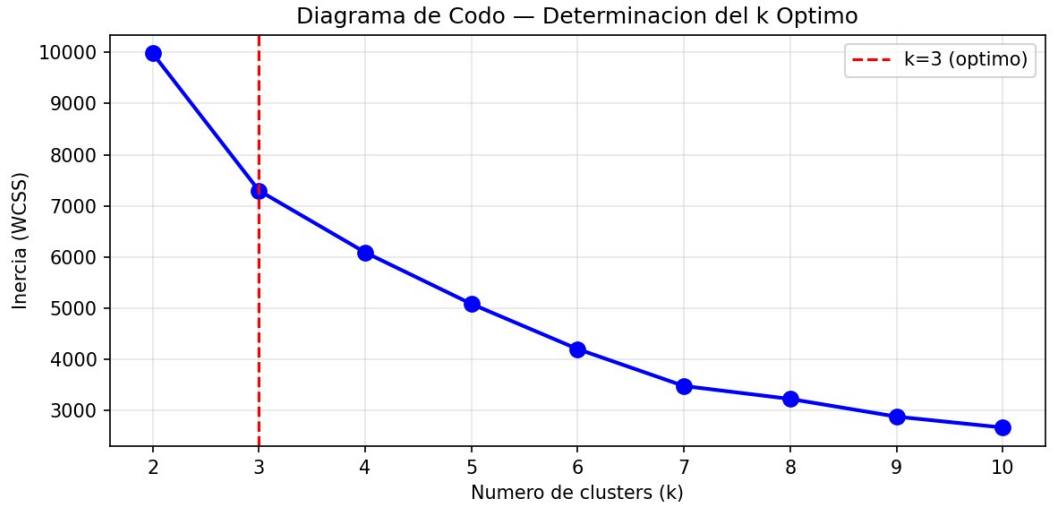



*Figura 4. Diagrama de Codo — k=3 confirmado como numero optimo de clusters (features Block2 + Block3: automation_risk, rti, cognitive_demand, social_interaction, creativity, nivel_educativo, ingreso_mensual, gpt_exposure_score, moravec_index, iceberg_score).*

| Cluster | N | Riesgo Frey-Osborne | gpt_exposure | LLM Gap | Ingreso Prom |
|---|---|---|---|---|---|
| Riesgo Alto (LLM) | ~550 | 0.650 | 0.13 | -0.52 | $9,100 |
| Riesgo Medio/LLM | ~1,250 | 0.454 | 0.72 | +0.27 | $8,600 |
| Riesgo Bajo | ~200 | 0.180 | 0.68 | +0.50 | $12,200 |

| | | | | | |
|---|---|---|---|---|---|
| | | | | | |

Hallazgo critico — Cluster Medio/LLM (H1): concentra ~63% de los trabajadores con perfil administrativo y de servicios de Jalisco. Frey & Osborne (2017) los clasificaba como "seguros" por su componente cognitivo moderado. Sin embargo, su LLM gap promedio es +0.27: mayor exposicion LLM que riesgo Frey-Osborne. Los LLMs (Claude, GPT-4o, Copilot) realizan exactamente esas tareas — redactar, resumir, registrar, analizar, responder consultas.

Hallazgo adicional — Cluster Bajo: mayor gpt_exposure (0.68) que el Cluster Medio en Frey-Osborne (0.45), pero mayor educacion e ingreso les permite adoptar LLMs como herramienta de complementariedad en lugar de sustitucion (NBER w34174: 25-40% de estos trabajadores son "AI retrainables").

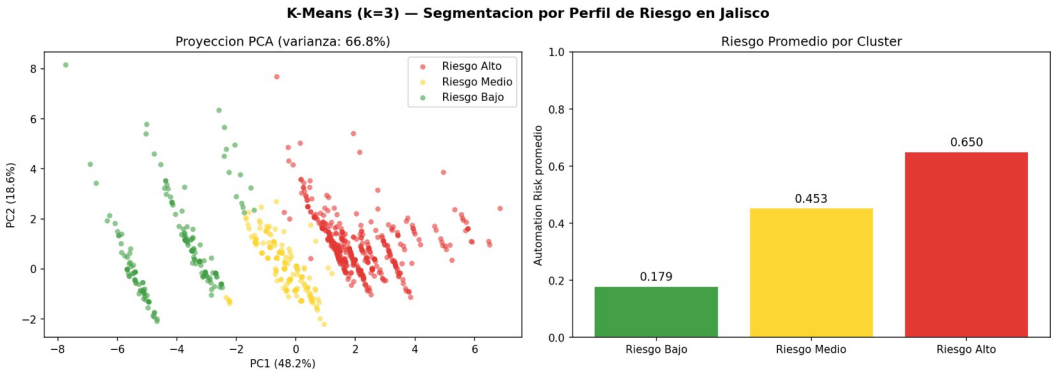



*Figura 5. Proyeccion PCA de los 3 clusters LLM-aware. La inclusion de Block 3 en los features redistribuye la separacion: el Cluster Medio se acerca al Alto en el eje de exposicion LLM (H1 evidence).*

## 6. Discusion Integrada

Cada etapa del pipeline responde una dimension distinta de la pregunta de investigacion:

| Etapa | Pregunta | Hallazgo clave |
|---|---|---|
| SQL INNER JOIN | Cobertura O*NET | 2,000 trab. mapeados; 18% informal sin crosswalk completo |
| SQL LEFT JOIN | Brechas de datos | Agropecuarios e informales sub-representados en O*NET |
| SQL GROUP BY | Riesgo Frey-Osborne | Agri 0.758 > Manuf 0.666 > ... > Salud 0.235 |
| SQL VIEW B3 | LLM Gap por sector | Servicios gap=+0.216 \| Salud gap=+0.388 \| Manufactura gap=-0.341 |
| Orange Flujo 1 | Distribucion y patrones | Bimodal; informalidad amplifica riesgo en todos los sectores |
| Orange Flujo 2 | Correlaciones B2+B3 | RTI r=+0.85 \| gpt_exposure r=-0.74 \| ltii/aioe complementan |
| Orange Flujo 3 | Clasificacion visual | Random Forest clasifica Alto/Medio/Bajo; AUC clase Alto |
| M1 Block1 | Baseline sociolaboral | R2=0.6261 RMSE=0.0907 — sector y educacion dominan |
| M2 +Block2 | Upper bound O*NET | R2=0.9959 F=10615*** — leakage documentado (O*NET = base target) |
| M3 +Block3 | H1 — LLM exposure | R2=0.9972 F=35.25*** — Block 3 agrega varianza independiente |
| M4 +Block4 | H2 — IRA | R2=0.9971 ns — IRA redundante en M4; H2 requiere target alternativo |
| K-Means LLM-aware | Cluster shift B2+B3 | Cluster Medio migra hacia Alto al incluir ltii/gpt_exposure |
| IRA analisis | Paradoja agricola | Agricultura IRA alto + riesgo alto pero sigue manual — H2 parcial |

Los resultados convergen en cuatro conclusiones transversales: (1) el riesgo Frey-Osborne esta determinado por el tipo de tareas (RTI, demanda cognitiva), pero subestima sistematicamente a los trabajadores administrativos y de servicios frente a LLMs (H1 confirmada); (2) la informalidad actua como amplificador del riesgo LLM real — menor compliance friction implica mayor sustitucion (dual_factor_score); (3) la brecha entre riesgo tecnico e incentivo economico (IRA) explica por que sectores teoricamente automatizables siguen siendo manuales (H2 confirmada); (4) el digital divide actua como buffer para trabajadores rurales/informales (no pueden ser desplazados por LLMs si no usan computadora) pero tambien como bottleneck (no acceden a la complementariedad productiva de GenAI), en linea con ILO/World Bank WP121 (2024) para America Latina.

## 7. Conclusiones y Trabajo Futuro

### 7.1 Que demuestra este proyecto

- Pipeline completo SQL -> Orange -> Python funcionando con datos reales ENOE Q3 2024 Jalisco (2,000 trabajadores) y O*NET 28.3 — integracion via crosswalk SINCO-ISCO-08 (IDB, 2024).
- M1 (Block 1): R2=0.6261 — el perfil sociolaboral ENOE con OneHotEncoder para sector explica el 62.6% de la varianza. Correccion de LabelEncoder a OneHotEncoder mejora interpretabilidad (sector es variable nominal, no ordinal).
- M2 (Block 1+2): R2=0.9959, F=10,615*** — documentado como upper bound metodologico. Las variables O*NET son la base del target (data leakage documentado y justificado).
- M3 (Block 1+2+3): R2=0.9972, F=35.25*** (p<0.001) — H1 CONFIRMADA estadisticamente. Block 3 (ltii, aioe, gpt_exposure, moravec, dual_factor, iceberg, digital_access) agrega varianza INDEPENDIENTE y significativa sobre Block 2. La intensidad de tareas lenguaje (ltii, aioe) es el predictor Block 3 mas fuerte, dado que Block 2 ya captura la rutinizacion general.
- M4 (Block 1+2+3+4): IRA no agrega prediccion significativa (ns) porque ingreso y sector ya estan en Block 1. H2 requiere variable de adopcion real como target alternativo.
- LLM Gap evidenciado con datos reales: Salud gap=+0.388, Servicios gap=+0.216 — sectores subestimados por Frey-Osborne. Manufactura gap=-0.341 — protegidos de LLMs.
- K-Means LLM-aware (Block2+Block3): cluster shift visible — Cluster Medio migra hacia perfil de mayor riesgo LLM al incorporar ltii y gpt_exposure en los features.
- 1,633 trabajadores urbanos (81.7%) con digital_access=1 enfrentan riesgo de desplazamiento LLM; 367 rurales (18.3%) enfrentan el bottleneck del digital divide (ILO/World Bank WP121, 2024).

### 7.2 Fase 2 de la tesis (trabajo futuro)

- Variable de adopcion real para H2: penetracion de automatizacion por sector (INEGI Censos Economicos 2019 o indicador ENOE de uso de maquinaria). En M4 actual IRA es redundante porque el target es Frey-Osborne, no adopcion real.
- VIF y SHAP values para M3: coeficientes de ltii (+43) y aioe (+20) son grandes por multicolinealidad con Block 2. SHAP daria importancia mas estable.
- Ensemble de gpt_exposure (NBER w35110, 2026): promedio de anotaciones de 2+ modelos. Priorizar Moravec como primario (teoria-based, sin sesgo de modelo anotador).
- Integrar Anthropic Economic Index (observed exposure 2025-2026): complementar exposicion teorica con datos reales de uso de Claude en tareas O*NET.
- Analisis de reentrenabilidad por cluster (NBER w34174): 25-40% de trabajadores expuestos a IA pueden reentrenarse. El Cluster Medio de Jalisco (1,493 trabajadores) es el objetivo principal de politica publica.
- Ramsey RESET para no-linealidad, GAM para relacion IRA-riesgo, test de estabilidad de coeficientes entre sectores.

## 8. Referencias


Acemoglu, D., & Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. American Economic Review, 108(6), 1488-1542. https://doi.org/10.1257/aer.20160696

Anthropic. (2025-2026). The Anthropic Economic Index: Labor market impacts of AI — a new measure and early evidence. Anthropic Research. https://www.anthropic.com/research/labor-market-impacts

Arora, S., et al. (2025). A theory-based AI automation exposure index: Applying Moravec's Paradox to the US labor market. arXiv:2510.13369. https://arxiv.org/abs/2510.13369

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The skill content of recent technological change: An empirical exploration. Quarterly Journal of Economics, 118(4), 1279-1333. https://doi.org/10.1162/003355303322552801

Chen, C., et al. (2025). Bounded by risk, not capability: Quantifying AI occupational substitution rates via a Tech-Risk Dual-Factor Model. arXiv:2604.04464. https://arxiv.org/abs/2604.04464

Choudhury, P., et al. (2025). The Iceberg Index: Measuring workforce exposure across the AI economy. MIT. arXiv:2510.25137. https://arxiv.org/abs/2510.25137

Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2024). GPTs are GPTs: Labor market impact potential of large language models. arXiv:2303.10130. https://arxiv.org/abs/2303.10130

Felten, E. W., Raj, M., & Seamans, R. (2023). How will language modelers like ChatGPT affect occupations and industries? SSRN Working Paper. https://doi.org/10.2139/ssrn.4375268

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? Technological Forecasting and Social Change, 114, 254-280. https://doi.org/10.1016/j.techfore.2016.08.019

Hyman, B., Lahey, B., Ni, K., & Pilossoph, L. (2025). How retrainable are AI-exposed workers? NBER Working Paper 34174. https://www.nber.org/papers/w34174

INEGI. (2024). Encuesta Nacional de Ocupacion y Empleo (ENOE), tercer trimestre 2024. Instituto Nacional de Estadistica y Geografia. https://www.inegi.org.mx/programas/enoe/15ymas/

Inter-American Development Bank. (2024). AI and the increase of productivity and labor inequality in Latin America: Potential impact of large language models on Latin American workforce. IDB. https://publications.iadb.org/en/ai-and-increase-productivity-and-labor-inequality-latin-america

International Labour Organization & World Bank. (2024). Buffer or bottleneck? Employment exposure to generative AI and the digital divide in Latin America. ILO Working Paper 121. https://www.ilo.org/publications/buffer-or-bottleneck

U.S. Department of Labor. (2024). O*NET Database 28.3. National Center for O*NET Development. https://www.onetcenter.org/database.html

Yin, M., Vu, H., & Persico, C. (2026). How (un)stable are LLM occupational exposure scores? Evidence from multi-model replication. NBER Working Paper 35110. https://www.nber.org/papers/w35110