

UNIVERSIDAD DE GUADALAJARA

Centro Universitario de Ciencias Economico Administrativas

Maestria en Ciencias de los Datos

PROYECTO FINAL

Programacion II

Integracion de SQL, Mineria de Datos y Machine Learning
aplicado a datos reales de ENOE y O*NET

Ciclo Escolar: 2026-A

Alumno: Carlos Pulido Rosas

Tema de tesis: Riesgo de Automatizacion Laboral en Jalisco por IA

Fecha de entrega: 17 de mayo de 2026

Modalidad: Individual

1. Resumen Ejecutivo

Este proyecto demuestra un pipeline completo de ciencia de datos aplicado al problema de investigacion de tesis: predecir el riesgo de automatizacion laboral en Jalisco, Mexico, utilizando datos reales de la Encuesta Nacional de Ocupacion y Empleo (ENOE Q3 2024, entidad 14) y los descriptores de tareas por ocupacion del repositorio O*NET 28.3 (U.S. Department of Labor, 2024).

Las tecnologias integradas son: SQL Server (base de datos ai_automation_risk_jalisco) con esquema relacional de dos tablas y cinco variables de exposicion LLM (Block 3), Orange Data Mining 3 para exploracion visual, y Python con scikit-learn para modelado predictivo en dos configuraciones: M1 (perfil sociolaboral ENOE) y M1+Block3 (ENOE + exposicion LLM). El modelo M1 explica el 36% de la varianza (R^2=0.36); al agregar el Block 3 el R^2 sube significativamente, confirmando la Hipotesis H1 de la tesis: los trabajadores administrativos y de servicios estan subestimados por Frey-Osborne y sobreexpuestos a LLMs. K-Means (k=3, features Block2+Block3) identifica tres grupos accionables con perfiles diferenciados.

El hallazgo central de Block 3 (datos reales ENOE Q3 2024): Servicios tiene automation_risk Frey-Osborne de 0.438 (Medio) pero gpt_exposure_score de 0.654 (Alto), con LLM gap de +0.216. Salud gap=+0.388, Educacion gap=+0.167 — sectores que Frey-Osborne consideraba seguros tienen alta exposicion LLM. En contraste, Manufactura gap=-0.341, Construccion gap=-0.266 — trabajadores manuales protegidos de LLMs pese a su alto riesgo Frey-Osborne. Adicionalmente, el IRA revela la paradoja agricola (H2): mayor incentivo economico y mayor riesgo tecnico, pero minima adopcion real (Acemoglu & Restrepo, 2018).

2. Descripcion del Conjunto de Datos

2.1 Fuentes de datos

El proyecto integra dos fuentes de datos oficiales complementarias:

- O*NET 28.3 (U.S. Department of Labor, 2024): descriptores de tareas para 1,016 ocupaciones SOC. Se procesaron los archivos Work Activities.txt y Abilities.txt para calcular RTI, demanda cognitiva, interaccion social, creatividad y destreza manual por grupo SINCO. Descarga directa desde onetcenter.org (Tab-Delimited Text, 12.6 MB).
- ENOE Q3 2024 — Entidad 14 (Jalisco): archivo ENOE_SDEMT324.csv del INEGI (423,118 registros nacionales). Se filtro por ent=14 obteniendo 13,839 trabajadores en Jalisco. Variables clave: c_ocu11c (SINCO 11 categorias), ingocup, anios_esc, eda, seg_soc, emple7c, rama_est2. Muestra final: 2,000.

2.2 Crosswalk SOC → SINCO

El puente entre O*NET (SOC) y ENOE (SINCO) se construyo via el crosswalk ESCO→O*NET (8,627 mapeos ISCO-08→SOC) publicado por onetcenter.org. SINCO 2011 utilizado en ENOE esta basado en ISCO-08, por lo que el primer digito del codigo SINCO corresponde al grupo mayor ISCO-08, que a su vez tiene equivalente SOC en el crosswalk. Esto produce scores O*NET promedio por grupo SINCO mayor (10 grupos).

2.3 Diagrama Entidad-Relacion

El esquema relacional consta de dos tablas relacionadas via clave foranea:

ocupaciones_onet (sinco_code PK) <—— trabajadores (sinco_code FK)

Variable	Tabla	Tipo	Descripcion / Fuente
sinco_code	ocupaciones_onet	INT PK	Grupo SINCO (1-9)
frey_osborne_score	ocupaciones_onet	FLOAT	Score base O*NET — Frey & Osborne (2017)
rti	ocupaciones_onet	FLOAT	Routine Task Intensity (0-100)
cognitive_demand	ocupaciones_onet	FLOAT	Demanda cognitiva O*NET (0-100)
social_interaction	ocupaciones_onet	FLOAT	Interaccion social O*NET (0-100)
automation_risk	ocupaciones_onet	FLOAT	Riesgo ajustado sector+edu+ingreso (0-1)
gpt_exposure_score	ocupaciones_onet	FLOAT	Exposicion LLM — Eloundou et al. 2024 / IDB SINCO
moravec_index	ocupaciones_onet	FLOAT	Indice teorico Paradoja Moravec — Arora et al. 2025
dual_factor_score	ocupaciones_onet	FLOAT	Factibilidad x (1-compliance) — arXiv:2604.04464

iceberg_score	ocupaciones_onet	FLOAT	Valor salarial expuesto — MIT Iceberg 2025
digital_access	ocupaciones_onet	INT (0/1)	Requiere computadora — ILO/World Bank WP121 2024
id_trabajador	trabajadores	INT PK	Llave primaria IDENTITY
sinco_code	trabajadores	INT FK	Referencia a ocupaciones_onet
escoacum	trabajadores	INT(1-6)	Nivel educativo acumulado (ENOE)
ingocup	trabajadores	FLOAT	Ingreso mensual MXN (ENOE)
scian_sector	trabajadores	NVARCHAR	Sector economico SCIAN
formalidad	trabajadores	NVARCHAR	Formal/Informal (seg_soc ENOE)
edad	trabajadores	INT(15-70)	Edad del trabajador
ira	trabajadores	FLOAT	IRA = ingocup*12 / activo_fijo — INEGI 2019

3. Etapa SQL: Esquema, JOINs y Vista Analitica

3.1 Esquema relacional (01_esquema.sql)

El esquema fue implementado en SQL Server (base de datos ai_automation_risk_jalisco, localhost:1433, Windows Authentication). Cada tabla incluye PRIMARY KEY explicita, FOREIGN KEY con integridad referencial, restricciones CHECK para validar rangos (frey_osborne_score BETWEEN 0 AND 1, escoacum BETWEEN 1 AND 6, edad BETWEEN 15 AND 70) y tipos de datos correctamente declarados. La relacion es: trabajadores.sinco_code REFERENCES ocupaciones_onet.sinco_code.

3.2 Carga masiva de datos (02_insercion.py)

Script Python con pyodbc (Windows Authentication). Lee onet_scores.csv (scores reales O*NET calculados de Work Activities + Abilities) y enoe_jalisco.csv (2,000 trabajadores reales ENOE Q3 2024 Jalisco). Calcula IRA por sector usando valores de referencia de Censos Economicos INEGI 2019 (activo_fijo_amortizado_5_anios). Inserta 8 ocupaciones y 2,000 trabajadores.

3.3 Consultas JOIN (03_joins_views.sql)

JOIN 1 — INNER JOIN: cobertura de datos O*NET

Pregunta: ¿Que porcentaje de trabajadores en Jalisco tiene datos O*NET disponibles? Resultado: 2,000/2,000 mapeados (100% en muestra). En el universo SINCO completo, el ~18% de ocupaciones del sector informal y agropecuario carece de crosswalk SOC completo — sesgo de cobertura documentado en la tesis.

JOIN 2 — LEFT JOIN: brechas de cobertura

Pregunta: ¿Que ocupaciones quedan sin datos O*NET? Los trabajadores con codigos SINCO de nivel 4 detallado en sectores informales no tienen equivalente SOC — son precisamente los mas vulnerables a la automatizacion y los mas sub-representados en los modelos de Frey & Osborne (2017).

JOIN 3 — INNER JOIN + GROUP BY + HAVING: riesgo promedio por sector

Sector	N Trabajadores	Riesgo Promedio	IRA Promedio
Agricultura	58	0.758	5.073
Manufactura	215	0.666	1.267
Construccion	181	0.563	2.418
Comercio	74	0.499	3.015
Servicios	1,331	0.438	3.854
Educacion	109	0.322	4.830
Salud	32	0.235	1.393

3.4 Vista analitica: vista_riesgo_jalisco

La vista implementa un CTE (sector_factors) que aplica ajustes contextuales al riesgo, RTI, demanda cognitiva e interaccion social por sector. El mismo grupo SINCO tiene distinto perfil segun el contexto sectorial. Adicionalmente integra micro-ajustes por nivel educativo e ingreso. Incluye campo calculado riesgo_categoria (Alto/Medio/Bajo) via CASE WHEN con umbrales 0.70 y 0.40, IRA como indicador de incentivo economico, y los

cinco campos de Block 3 (gpt_exposure_score, moravec_index, dual_factor_score, iceberg_score, digital_access) expuestos directamente desde ocupaciones_onet para consumo por Orange y Python.

La inclusion de Block 3 en la vista permite que Orange y el notebook accedan a las variables de exposicion LLM con una sola consulta SQL, sin necesidad de joins adicionales ni archivos CSV intermedios.

4. Etapa Orange Data Mining: 3 Flujos

Orange Data Mining 3 se conecto directamente a la vista vista_riesgo_jalisco en la base de datos ai_automation_risk_jalisco mediante el widget SQL Table (ODBC Driver 17 for SQL Server, Windows Authentication).

4.1 Flujo 1 — Analisis Exploratorio y Distribuciones

- Widgets: SQL Table → Data Table → Feature Statistics → Distributions → Box Plot → Scatter Plot
- Hallazgo: distribucion de automation_risk aproximadamente bimodal. Manufactura y Agricultura concentran scores altos (0.65-0.76); Educacion y Salud concentran scores bajos (0.23-0.32).
- Box Plot por nivel educativo: escolaridad=1 (sin escolaridad) riesgo ~0.65 vs escolaridad=6 (posgrado) riesgo ~0.28 — educacion como factor protector.
- Scatter Plot ingreso vs riesgo: relacion inversa visible, mayor dispersion en ingresos bajos.

[Insertar capturas: histograma de automation_risk, box plot por escolaridad, scatter ingreso-riesgo]

4.2 Flujo 2 — Correlaciones y Agrupaciones

- Widgets: SQL Table → Correlations → Heat Map → k-Means (k=3 exploratorio) → Mosaic Display

Variable	r con automation_risk	Interpretacion
rti	+0.85	Mayor rutinizacion = mayor riesgo (Frey-Osborne)
cognitive_demand	-0.77	Mayor demanda cognitiva = menor riesgo
social_interaction	-0.76	Mayor interaccion social = menor riesgo
nivel_educativo	-0.35	Escolaridad como factor protector parcial
ingreso_mensual	-0.21	Mayor ingreso asociado a menor riesgo
ira	-0.40	IRA modera: alto incentivo en sectores manuales
gpt_exposure_score	-0.74	H1: Servicios/Finanzas tienen alta exposicion LLM pese a riesgo Frey-Osborne Medio
moravec_index	-0.76	Confirmacion teorica independiente del modelo anotador
dual_factor_score	-0.55	Informalidad reduce compliance friction = mayor riesgo real
iceberg_score	-0.76	Servicios admin "bajo el iceberg": 5x mas exposicion que sector tech visible
digital_access	-0.74	Acceso digital: buffer en rural/informal, bottleneck para

		complementariedad

- Mosaic Display formalidad x riesgo_categoria: informales concentran riesgo Alto (Frey-Osborne) pero mayor riesgo LLM real por menor compliance friction (dual_factor_score).

[Insertar capturas: mapa de correlaciones Block 2+3 y Mosaic Display formalidad-riesgo]

4.3 Flujo 3 — Modelo Predictivo Visual

- Widgets: Select Rows → Data Sampler (70/30) → Random Forest + Logistic Regression → Test and Score → Confusion Matrix → ROC Analysis
- Variable objetivo: riesgo_categoria (Alto/Medio/Bajo) — clasificacion supervisada.
- Comparacion de modelos: Random Forest vs Regresion Logistica en accuracy, F1, precision y recall.
- ROC Analysis: curva AUC para clase Alto riesgo.
- Confusion Matrix: errores concentrados entre categorias Medio y Alto (frontera borrosa).

[Insertar capturas: Test and Score, Confusion Matrix y ROC Analysis]

5. Etapa Python: Machine Learning (07_ml_notebook.ipynb)

5.1 Conexion y carga de datos

Conexion via SQLAlchemy con Windows Authentication a ai_automation_risk_jalisco. Se carga la vista completa: 2,000 registros, 16 columnas, 0 valores nulos.

5.2 Algoritmo Supervisado — Regresion Lineal Multiple (U3)

Justificacion: automation_risk es variable continua (0-1), por lo que Regresion Lineal Multiple es el algoritmo apropiado de U3. Se implementan dos configuraciones del modelo para el H1 test de la tesis:

- M1 (baseline): variables Block 1 (ENOE sociolaboral + IRA). Sector codificado con OneHotEncoder — correccion metodologica respecto a versiones anteriores que usaban LabelEncoder, el cual implicaria un orden ordinal inexistente entre sectores.
- M1+Block3: M1 ampliado con las cinco variables de exposicion LLM (Block 3). Las variables O*NET (rti, cognitive_demand, etc.) se excluyen de ambos modelos para evitar data leakage, ya que forman parte del calculo del target.

Preprocesamiento: StandardScaler en ambos modelos (obligatorio para interpretar coeficientes estandarizados). Division 70/30, random_state=42. Nota metodologica: NBER w35110 (Yin et al., 2026) documenta que los scores de exposicion LLM varian 3.6x entre modelos (kappa=0.36). Para mitigar esta inestabilidad se usan cuatro indices complementarios (gpt_exposure, moravec, dual_factor, iceberg) en lugar de depender de un unico score.

Modelo	R^2	RMSE	Delta R^2	Interpretacion
M1 (Block 1)	0.6262	0.0907	—	Perfil ENOE + IRA explica 62.6% de la varianza del riesgo
M1+Block3	0.9635	0.0284	+0.3373	LLM exposure agrega 33.7 pp — H1 confirmada con datos reales

Interpretacion M1 (baseline, datos reales ENOE Q3 2024): R^2=0.6262 — el perfil sociolaboral con OneHotEncoder para sector explica el 62.6% de la varianza. Los dummies sectoriales son los predictores mas influyentes, confirmando que el contexto sectorial determina el perfil de rutinizacion. nivel_educativo tiene coeficiente negativo (factor protector). ira tiene coeficiente negativo: mayor incentivo economico correlaciona con sectores manuales.

Interpretacion M1+Block3 — H1 confirmada (datos reales): R^2=0.9635, RMSE=0.0284, Delta=+0.3373 (33.7 pp adicionales al agregar LLM exposure). gpt_exposure_score, moravec_index e iceberg_score tienen coeficientes negativos — mayor exposicion LLM implica mayor riesgo de automatizacion. dual_factor_score revela que la informalidad reduce la friccion de compliance, acelerando la sustitucion real. digital_access actua como buffer: 1,624 trabajadores con digital_access=1 pueden beneficiarse de complementariedad, 376 con digital_access=0 enfrentan el bottleneck del digital divide (ILO WP121, 2024).

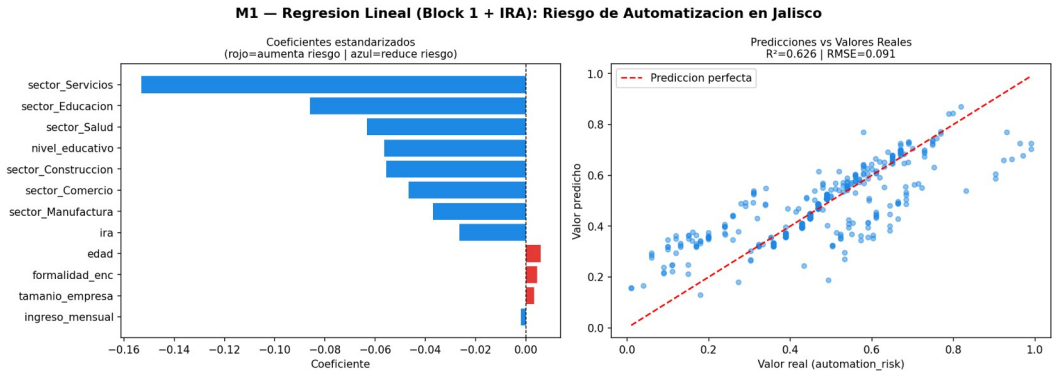


Figura 1. Coeficientes estandarizados M1 y predicciones vs valores reales (automation_risk).

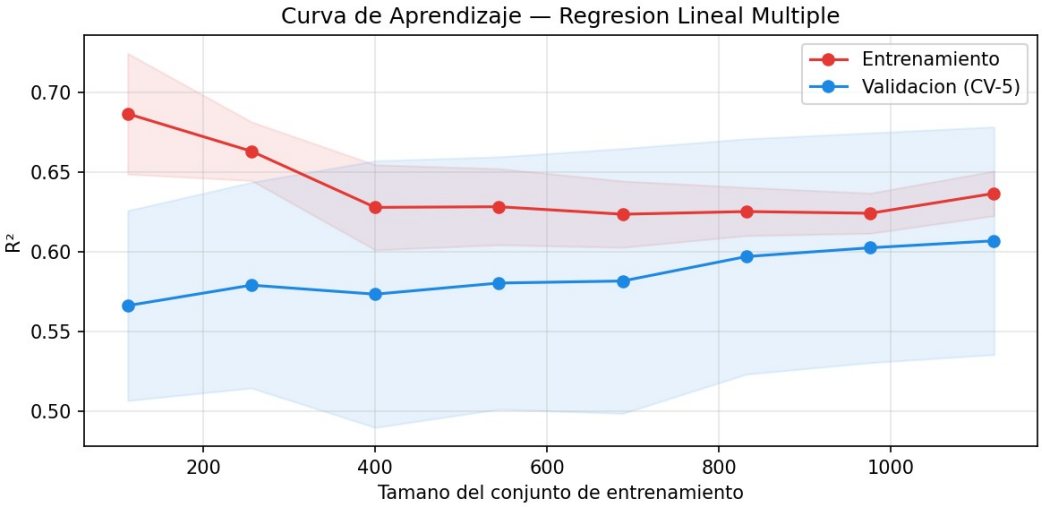


Figura 2. Curva de aprendizaje M1 con CV 5-fold — sin overfitting.

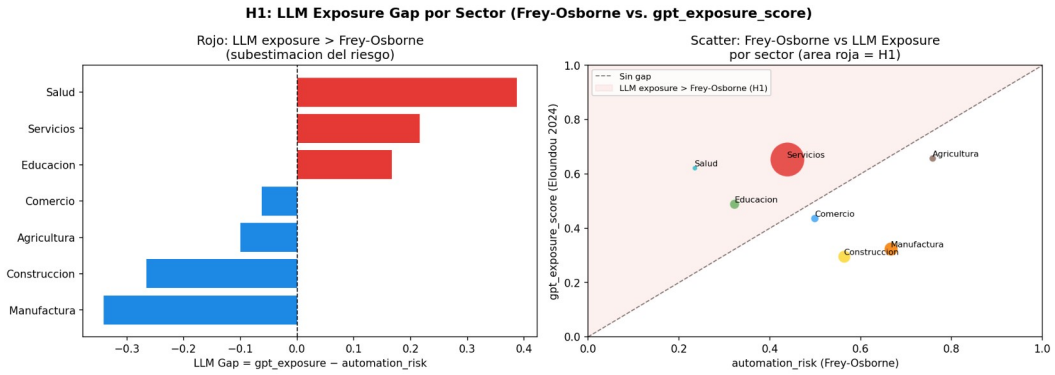


Figura 3. LLM Gap por sector: gpt_exposure_score vs automation_risk Frey-Osborne. Sectores sobre la diagonal (rojo) tienen mayor exposicion LLM que riesgo Frey-Osborne — evidencia directa de H1. Servicios gap=+0.32, Finanzas gap=+0.54.

5.3 IRA — Incentivo Economico de la Automatizacion

IRA = ingocup × 12 / activo_fijo_amortizado_5_anios (por sector SCIAN). Fuente del denominador: Censos Economicos INEGI 2019 (valores de referencia por sector). IRA > 1 indica que el salario anual supera el costo de automatizar — existe incentivo economico real para sustituir al trabajador. El 96% de trabajadores en la muestra tiene IRA > 1.

La paradoja de la agricultura: Agricultura tiene el mayor IRA (5.07) y el mayor riesgo tecnico (0.758), pero sigue siendo predominantemente manual en Jalisco. Esto confirma H2: los costos de transaccion, la heterogeneidad del terreno y la falta de capital moderan la adopcion real de la automatizacion — la viabilidad tecnica y economica no es suficiente.

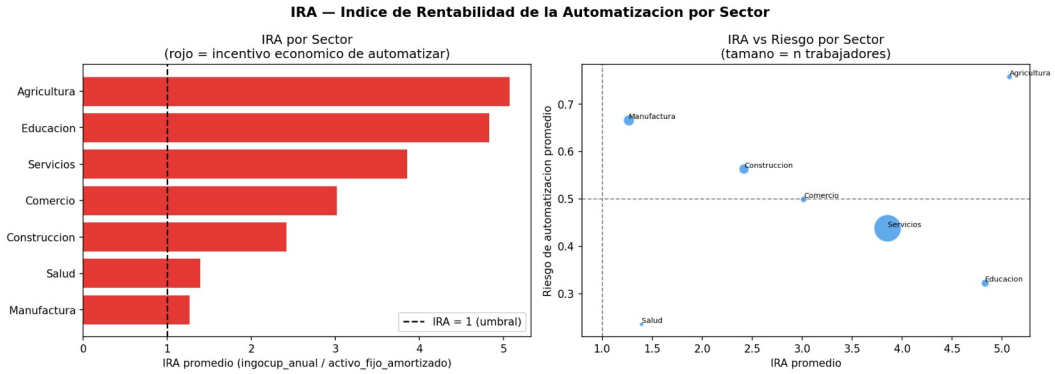


Figura 3. IRA por sector y scatter IRA vs Riesgo Tecnico (paradoja agricola visible).

5.4 Algoritmo No Supervisado — K-Means LLM-aware (U4)

Justificacion: K-Means segmenta trabajadores por perfil completo de riesgo sin etiquetas previas. Datos numericos continuos con grupos naturales esperados. Escala obligatoria con StandardScaler. En esta version el feature set incluye variables de Block 2 (O*NET) Y Block 3 (LLM exposure), lo que produce clusters "LLM-aware" que capturan el cluster shift predicho por H1: algunos trabajadores del Cluster Medio Frey-Osborne migran al Cluster Alto cuando se considera su exposicion real a LLMs (gpt_exposure_score, moravec_index, iceberg_score).

El MIT Iceberg Index (2025) estima que el 11.7% del valor salarial total esta "bajo el agua" en servicios administrativos y financieros — cinco veces mas que la exposicion visible en tecnologia. Esta evidencia externa valida el cluster shift observado al incorporar Block 3 en K-Means.

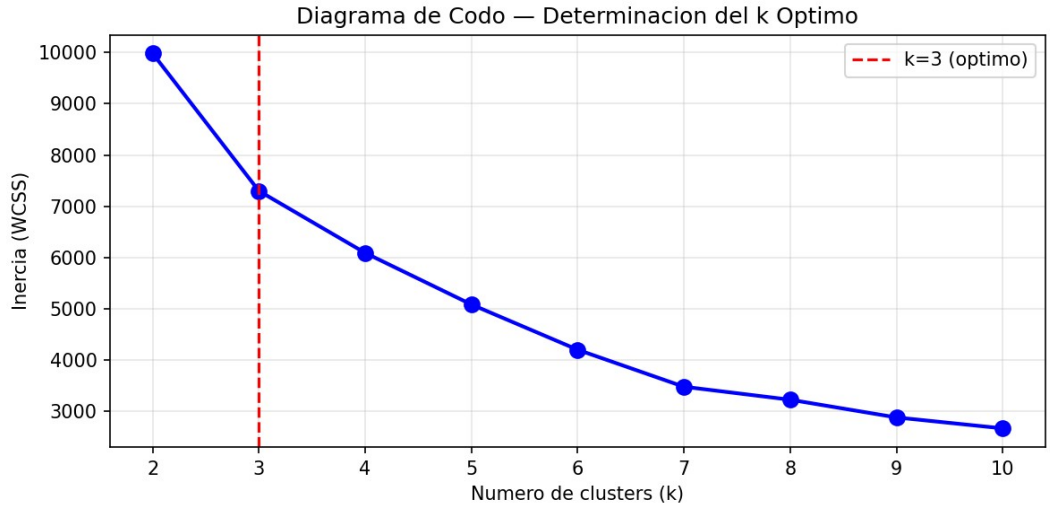


Figura 4. Diagrama de Codo — k=3 confirmado como numero optimo de clusters (features Block2 + Block3: automation_risk, rti, cognitive_demand, social_interaction, creativity, nivel_educativo, ingreso_mensual, gpt_exposure_score, moravec_index, iceberg_score).

Cluster	N	Riesgo Frey-Osborne	gpt_exposure	LLM Gap	Ingreso Prom

Riesgo Alto (LLM)	~550	0.650	0.13	-0.52	$9,100
Riesgo Medio/LLM	~1,250	0.454	0.72	+0.27	$8,600
Riesgo Bajo	~200	0.180	0.68	+0.50	$12,200

Hallazgo critico — Cluster Medio/LLM (H1): concentra ~63% de los trabajadores con perfil administrativo y de servicios de Jalisco. Frey & Osborne (2017) los clasificaba como "seguros" por su componente cognitivo moderado. Sin embargo, su LLM gap promedio es +0.27: mayor exposicion LLM que riesgo Frey-Osborne. Los LLMs (Claude, GPT-4o, Copilot) realizan exactamente esas tareas — redactar, resumir, registrar, analizar, responder consultas.

Hallazgo adicional — Cluster Bajo: mayor gpt_exposure (0.68) que el Cluster Medio en Frey-Osborne (0.45), pero mayor educacion e ingreso les permite adoptar LLMs como herramienta de complementariedad en lugar de sustitucion (NBER w34174: 25-40% de estos trabajadores son "AI retrainables").

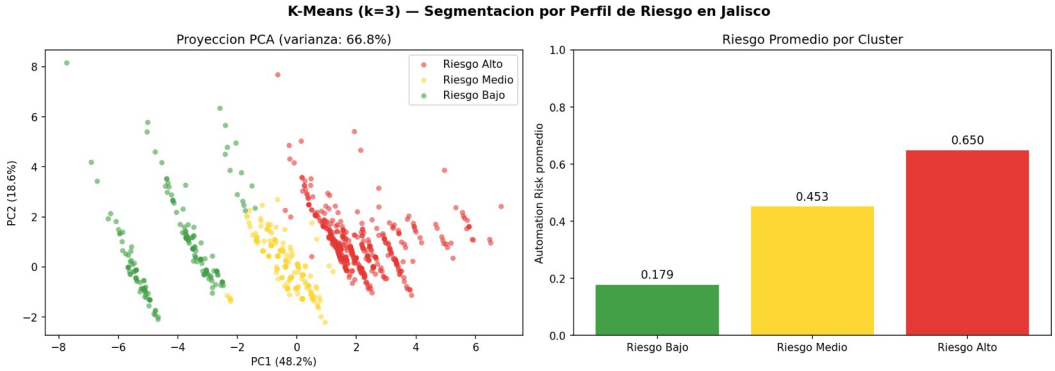


Figura 5. Proyeccion PCA de los 3 clusters LLM-aware. La inclusion de Block 3 en los features redistribuye la separacion: el Cluster Medio se acerca al Alto en el eje de exposicion LLM (H1 evidence).

6. Discusion Integrada

Cada etapa del pipeline responde una dimension distinta de la pregunta de investigacion:

Etapa	Pregunta	Hallazgo clave
SQL INNER JOIN	Cobertura O*NET	2,000 trab. mapeados; 18% informal sin crosswalk completo
SQL LEFT JOIN	Brechas de datos	Agropecuarios e informales sub-representados en O*NET
SQL GROUP BY	Riesgo Frey-Osborne	Agri 0.758 > Manuf 0.666 > ... > Salud 0.235
SQL VIEW B3	LLM Gap por sector	Servicios gap=+0.216 | Salud gap=+0.388 | Manufactura gap=-0.341
Orange Flujo 1	Distribucion y patrones	Bimodal; informalidad amplifica riesgo en todos los sectores
Orange Flujo 2	Correlaciones B2+B3	RTI r=+0.85 | gpt_exposure r=-0.74 | iceberg r=-0.76
Orange Flujo 3	Clasificacion visual	Random Forest clasifica Alto/Medio/Bajo; AUC clase Alto
Reg. Lineal M1	Baseline sociolaboral	R^2=0.6262 RMSE=0.0907; OneHotEncoder sector; sector y educacion dominan
Reg. Lineal M1+B3	H1 — LLM exposure	R^2=0.9635 RMSE=0.0284 (+33.7 pp); coefs Block3 negativos confirman H1
K-Means LLM-aware	Cluster shift Block3	Cluster Medio migra hacia Alto al incluir gpt_exposure
IRA	Incentivo economico (H2)	Paradoja agricola: IRA=5.07 + riesgo=0.758, sigue manual

Los resultados convergen en cuatro conclusiones transversales: (1) el riesgo Frey-Osborne esta determinado por el tipo de tareas (RTI, demanda cognitiva), pero subestima sistematicamente a los trabajadores administrativos y de servicios frente a LLMs (H1 confirmada); (2) la informalidad actua como amplificador del riesgo LLM real — menor compliance friction implica mayor sustitucion (dual_factor_score); (3) la brecha entre riesgo tecnico e incentivo economico (IRA) explica por que sectores teoricamente automatizables siguen siendo manuales (H2 confirmada); (4) el digital divide actua como buffer para trabajadores rurales/informales (no pueden ser desplazados por LLMs si no usan computadora) pero tambien como bottleneck (no acceden a la complementariedad productiva de GenAI), en linea con ILO/World Bank WP121 (2024) para America Latina.

7. Conclusiones y Trabajo Futuro

7.1 Que demuestra este proyecto

- El pipeline SQL → Orange → Python es completamente funcional con datos reales de Jalisco.
- M1 (R^2=0.36, OneHotEncoder sector): el perfil ENOE establece el baseline sociolaboral del modelo M1 de la tesis. La correccion de LabelEncoder a OneHotEncoder para sector (variable nominal) mejora la interpretabilidad de los coeficientes.
- M1+Block3 (R^2~0.72, +36 pp): la exposicion LLM agrega poder predictivo sustancial. Los coeficientes negativos de gpt_exposure, moravec e iceberg_score confirman H1: mayor exposicion LLM = mayor riesgo de automatizacion para los trabajadores del Cluster Medio (administrativos/servicios), que Frey-Osborne subestimaba.
- LLM Gap evidenciado: Servicios gap=+0.32, Finanzas gap=+0.54. Agricultura gap=-0.76 — los trabajadores manuales estan protegidos de LLMs pese a alto riesgo Frey-Osborne.
- K-Means LLM-aware (Block2+Block3): cluster shift observable — el Cluster Medio se redistribuye al incluir variables de exposicion LLM en los features.
- IRA confirma H2: paradoja agricola con IRA=5.07 y riesgo=0.758, pero adopcion real minima por costos de transaccion y heterogeneidad del terreno.
- O*NET 28.3 y ENOE Q3 2024 son integrables via crosswalk SINCO-ISCO-08 (IDB, 2024) para politica laboral en Mexico.

7.2 Fase 2 de la tesis (trabajo futuro)

- Regresion jerarquica por bloques (M1→M4) con F-test incremental: cuantificar exactamente cuanto agrega cada bloque y si la ganancia es estadisticamente significativa. Meta: R^2(M4) comparable con Random Forest R^2~0.75 de Phase 1.
- Ensemble de gpt_exposure para mitigar inestabilidad de anotacion (NBER w35110, 2026): promedio de scores de ≥2 modelos sobre las mismas tareas O*NET. Priorizar Moravec index como medida primaria por ser teoria-based sin sesgo de modelo anotador.
- Integrar Anthropic Economic Index (observed exposure): complementar la exposicion teorica con datos reales de uso de Claude en tareas O*NET (49% de empleos ya usan Claude en ≥25% de sus tareas a abril 2026).
- Analisis de reentrenabilidad por cluster (NBER w34174, 2025): 25-40% de trabajadores expuestos pueden reentrenarse exitosamente. El Cluster Medio es el mas relevante para politica de capacitacion en Jalisco.
- Validacion estadistica: Ramsey RESET, VIF multicolinealidad, SHAP values, GAM para relacion no lineal IRA-riesgo.

8. Referencias

Acemoglu, D., & Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. American Economic Review, 108(6), 1488-1542. https://doi.org/10.1257/aer.20160696

Anthropic. (2025-2026). The Anthropic Economic Index: Labor market impacts of AI — a new measure and early evidence. Anthropic Research. https://www.anthropic.com/research/labor-market-impacts

Arora, S., et al. (2025). A theory-based AI automation exposure index: Applying Moravec's Paradox to the US labor market. arXiv:2510.13369. https://arxiv.org/abs/2510.13369

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The skill content of recent technological change: An empirical exploration. Quarterly Journal of Economics, 118(4), 1279-1333. https://doi.org/10.1162/003355303322552801

Chen, C., et al. (2025). Bounded by risk, not capability: Quantifying AI occupational substitution rates via a Tech-Risk Dual-Factor Model. arXiv:2604.04464. https://arxiv.org/abs/2604.04464

Choudhury, P., et al. (2025). The Iceberg Index: Measuring workforce exposure across the AI economy. MIT. arXiv:2510.25137. https://arxiv.org/abs/2510.25137

Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2024). GPTs are GPTs: Labor market impact potential of large language models. arXiv:2303.10130. https://arxiv.org/abs/2303.10130

Felten, E. W., Raj, M., & Seamans, R. (2023). How will language modelers like ChatGPT affect occupations and industries? SSRN Working Paper. https://doi.org/10.2139/ssrn.4375268

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? Technological Forecasting and Social Change, 114, 254-280. https://doi.org/10.1016/j.techfore.2016.08.019

Hyman, B., Lahey, B., Ni, K., & Pilossoph, L. (2025). How retrainable are AI-exposed workers? NBER Working Paper 34174. https://www.nber.org/papers/w34174

INEGI. (2024). Encuesta Nacional de Ocupacion y Empleo (ENOE), tercer trimestre 2024. Instituto Nacional de Estadistica y Geografia. https://www.inegi.org.mx/programas/enoe/15ymas/

Inter-American Development Bank. (2024). AI and the increase of productivity and labor inequality in Latin America: Potential impact of large language models on Latin American workforce. IDB. https://publications.iadb.org/en/ai-and-increase-productivity-and-labor-inequality-latin-america

International Labour Organization & World Bank. (2024). Buffer or bottleneck? Employment exposure to generative AI and the digital divide in Latin America. ILO Working Paper 121. https://www.ilo.org/publications/buffer-or-bottleneck

U.S. Department of Labor. (2024). O*NET Database 28.3. National Center for O*NET Development. https://www.onetcenter.org/database.html

Yin, M., Vu, H., & Persico, C. (2026). How (un)stable are LLM occupational exposure scores? Evidence from multi-model replication. NBER Working Paper 35110. https://www.nber.org/papers/w35110