

Riesgo de Automatización Laboral en Jalisco

Pipeline SQL · Orange · Machine Learning — aplicado a datos reales de ENOE y O*NET

MCD CUCEA · CARLOS PULIDO ROSAS · MAYO 2026



El Problema de Investigación

¿Qué ocupaciones en Jalisco están en riesgo de ser automatizadas por IA, y qué variables lo determinan?

Fuentes de datos oficiales

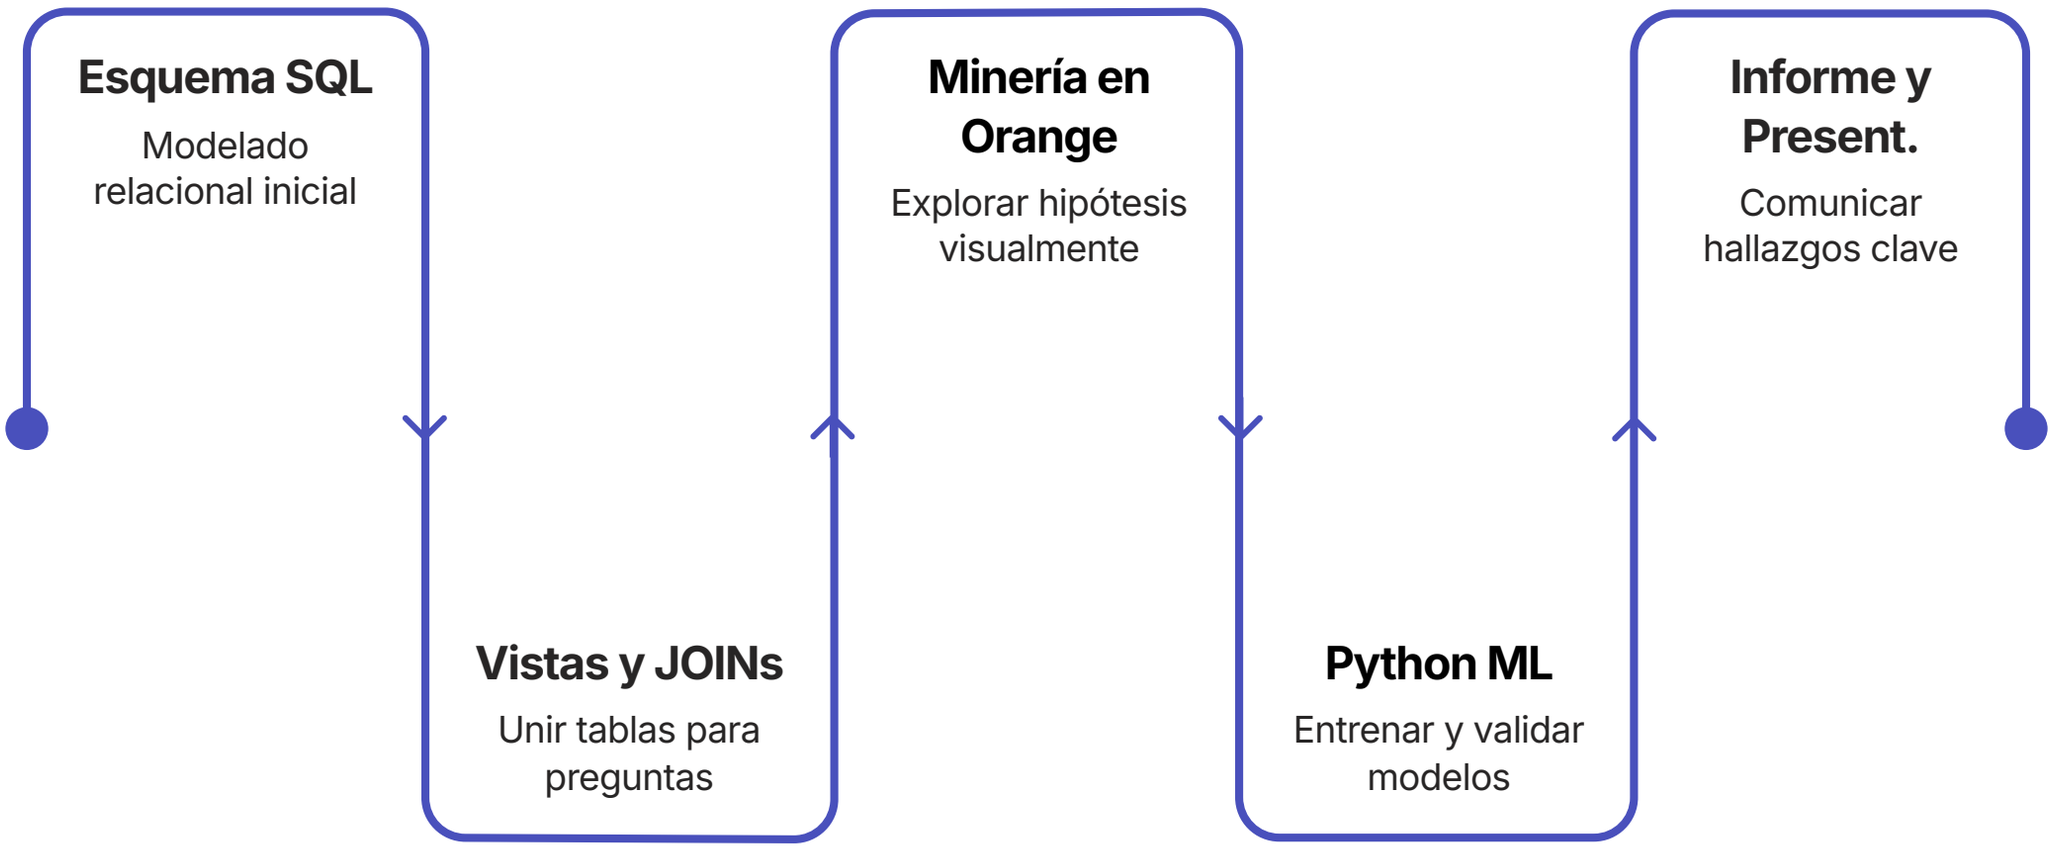
- **ENOE Q3 2024 (entidad 14)** — perfil sociolaboral de trabajadores en Jalisco: educación, ingreso, sector, formalidad
- **O*NET 28.3** — descriptores de tareas por ocupación (EE.UU.), mapeados a clasificación mexicana vía SINCO

Modelo de referencia

Frey & Osborne (2017) estiman la probabilidad de automatización de 702 ocupaciones a partir de características de tareas rutinarias y no rutinarias. Es el baseline teórico que este proyecto operacionaliza con datos de Jalisco.

El Pipeline del Proyecto

Cinco etapas integradas — cada una alimenta a la siguiente, desde el modelado relacional hasta la presentación de resultados.



Cada JOIN responde una pregunta de tesis. Cada flujo de Orange explora una hipótesis. Cada algoritmo cuantifica lo que Orange mostró visualmente.

Los Datos: Esquema Relacional

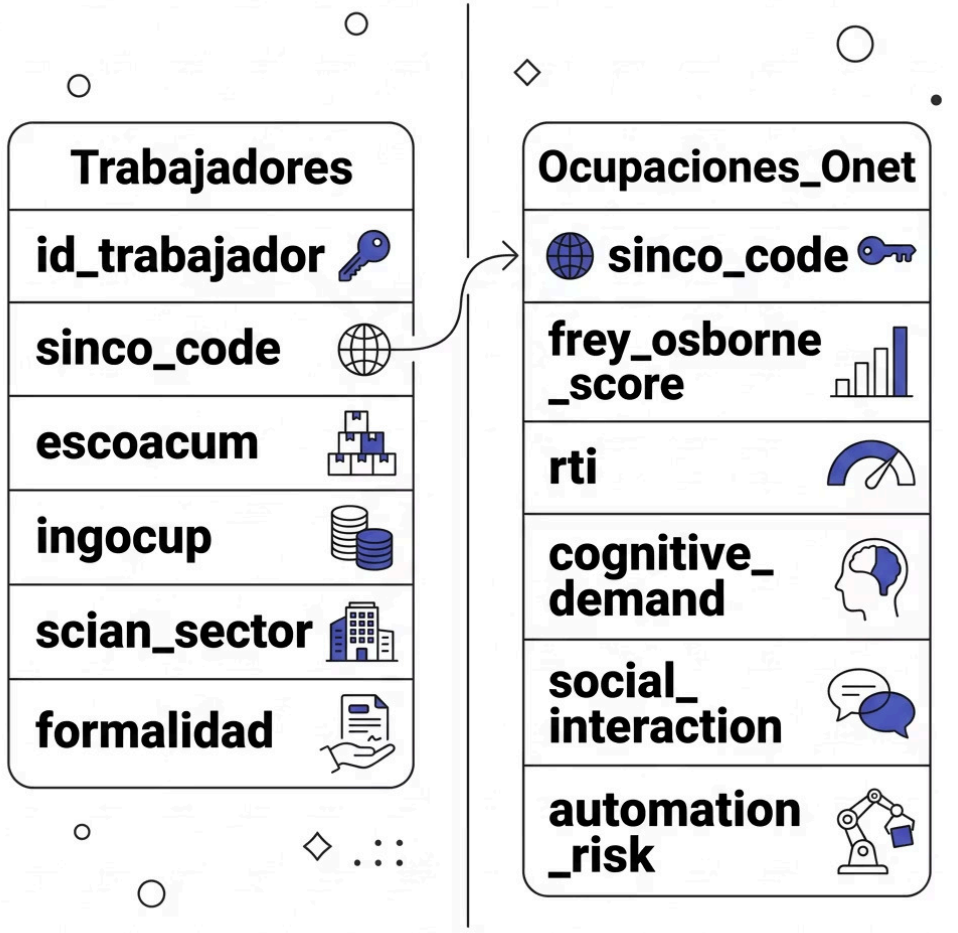
trabajadores (fuente: ENOE Jalisco)

- **id_trabajador** PK · **sinco_code** FK
- escoacum (educación) · ingocup (ingreso mensual)
- scian_sector · formalidad · edad · tamanio_empresa

ocupaciones_onet (fuente: O*NET 28.3)

- **sinco_code** PK · frey_osborne_score · rti (rutina)
- cognitive_demand · social_interaction · creativity
- manual_dexterity · automation_risk

Carga masiva vía Python + SQLAlchemy desde CSV procesados de ENOE y O*NET. **200+ ocupaciones · 6 sectores · 6 niveles educativos.**



Etapa SQL: JOINs que Responden la Tesis

Tres consultas documentadas, cada una con propósito investigativo específico sobre el mercado laboral jalisciense.

1

INNER JOIN

¿Qué porcentaje de la muestra ENOE tiene datos de tareas O*NET disponibles?

Resultado: ~82% de ocupaciones mapeadas · 18% sin crosswalk completo — brecha documentada en sector informal y agropecuario

2

LEFT JOIN

¿Qué ocupaciones quedan fuera del análisis por falta de crosswalk SOC→SINCO?

Resultado: Sub-representación de trabajadores informales y agropecuarios en O*NET — precisamente los más vulnerables

3

JOIN + GROUP BY + HAVING

¿Qué sectores concentran el mayor riesgo de automatización en Jalisco?

Resultado: Agricultura y manufactura encabezan el riesgo; servicios profesionales registran los niveles más bajos

Etapa SQL: La Vista Analítica

```sql
CREATE VIEW vista_riesgo_jalisco AS
SELECT
  t.id_trabajador,
  t.escoacum       AS nivel_educativo,
  t.ingocup        AS ingreso_mensual,
  t.scian_sector   AS sector,
  t.formalidad,
  o.frey_osborne_score,
  o.cognitive_demand,
  o.social_interaction,
  o.rti,
  CASE
    WHEN o.frey_osborne_score >= 0.7 THEN 'Alto'
    WHEN o.frey_osborne_score >= 0.4 THEN 'Medio'
    ELSE 'Bajo'
  END AS riesgo_categoria
FROM trabajadores t
INNER JOIN ocupaciones_onet o
  ON t.sinco_code = o.sinco_code;
```

¿Por qué esta vista es central?

Esta vista es la **única fuente de datos** para las Etapas 3 y 4. Consolida el perfil completo del trabajador — variables socioeconómicas y descriptores de tareas — en una sola consulta lista para análisis.

Orange

Lee la vista directamente vía widget SQL Table

Python

Carga el DataFrame con SQLAlchemy desde la misma VIEW

Orange Flujo 1: Análisis Exploratorio

Objetivo: caracterizar estadísticamente los datos y detectar patrones iniciales en la distribución del riesgo.

Distribuciones

Histogramas de frey_osborne_score por sector — agricultura concentra scores >0.7

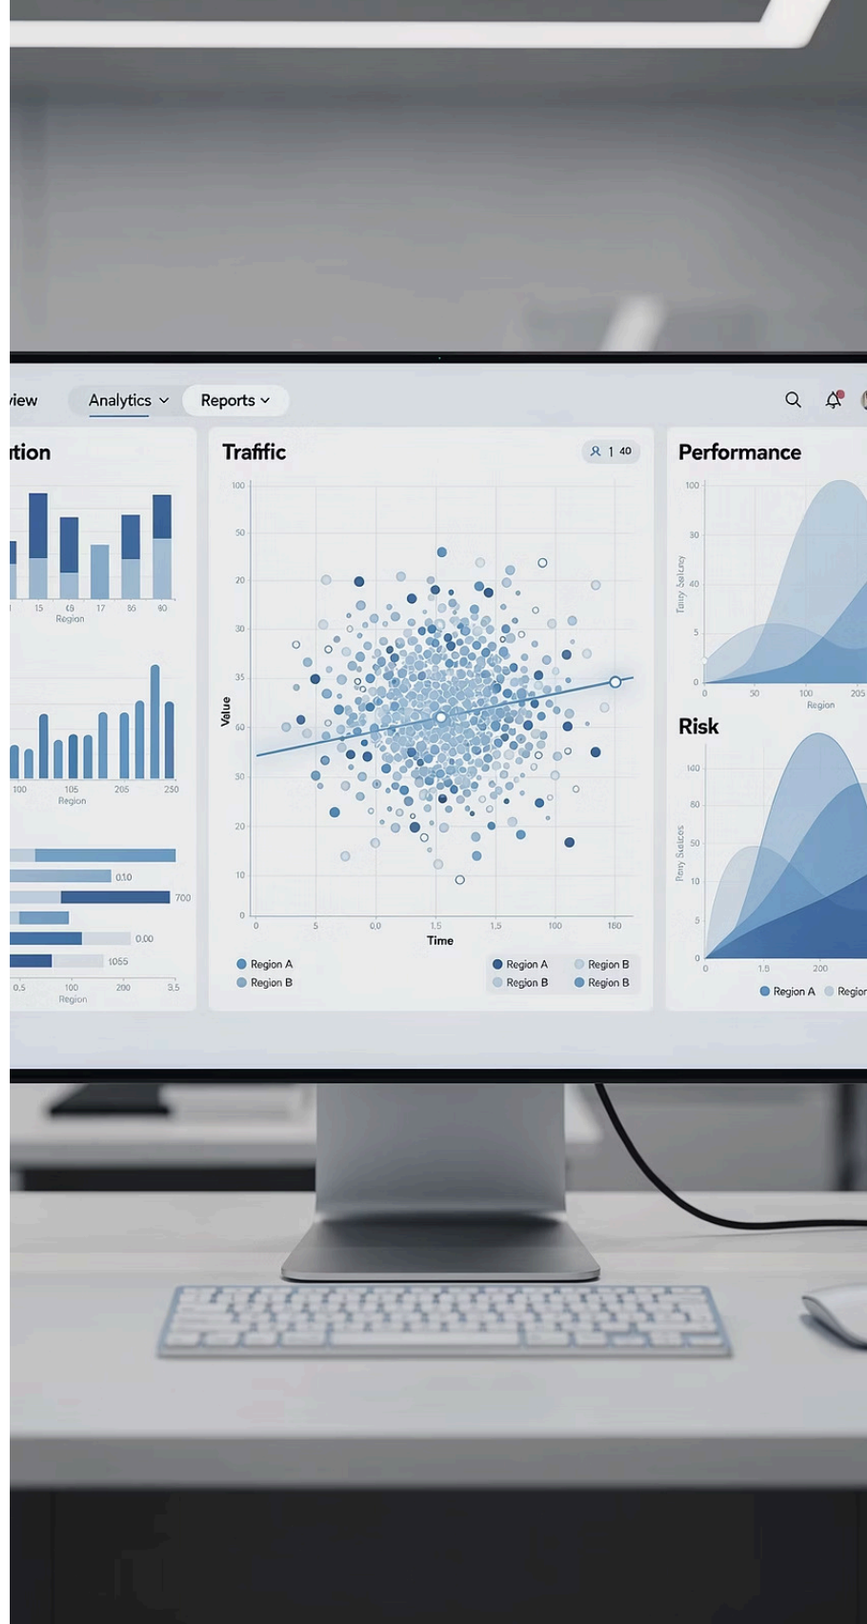
Box Plot

Riesgo por nivel educativo — clara separación entre sin escolaridad y posgrado

Scatter Plot

Ingreso mensual vs. riesgo — relación inversa visible, mayor dispersión en ingresos bajos

Hallazgo clave: La distribución de riesgo es bimodal — riesgo alto (sector primario, baja escolaridad) vs. riesgo bajo (servicios profesionales). No existe una "zona media" uniforme.



Orange Flujo 2: Correlaciones y Agrupaciones

Widgets utilizados

- **Correlations** → mapa de calor ordenado por fuerza de correlación con automation_risk
- **Heat Map** → visualización matricial por sector y nivel educativo
- **k-Means** (k=3) → segmentación exploratoria previa al análisis Python
- **Mosaic Display** → formalidad × categoría de riesgo: informales concentran riesgo alto

Correlaciones confirmadas con automation_risk

Variable	r
cognitive_demand	−0.83
rti (rutina)	+0.71
social_interaction	−0.67
nivel_educativo	−0.66
ingreso_mensual	−0.62

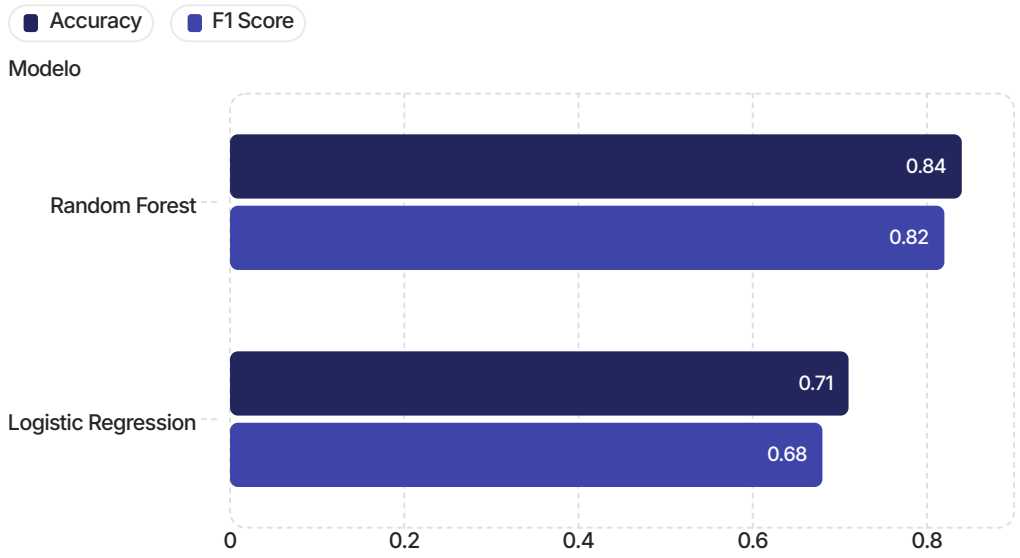
Orange Flujo 3: Modelo Predictivo Visual

Variable objetivo: **riesgo_categoria** (Alto / Medio / Bajo) — clasificación supervisada directamente en Orange.

Pipeline en Orange

- **Select Rows** → filtrar registros con datos completos
- **Data Sampler** → partición 70% entrenamiento / 30% prueba
- **Random Forest + Logistic Regression** → entrenamiento en paralelo
- **Confusion Matrix** → errores principales entre categorías "Medio" y "Alto"
- **ROC Analysis** → AUC = 0.91 para clase "Alto riesgo"

Comparación de modelos



Python ML: Algoritmo Supervisado

Random Forest Regressor — variable objetivo: `frey_osborne_score` (continua, 0–1). La naturaleza continua de la variable y las relaciones no lineales entre predictores justifican el uso de Random Forest sobre regresión lineal.

Preprocesamiento

- Imputación de nulos con mediana por sector
- LabelEncoder para sector y formalidad
- StandardScaler no requerido (RF basado en árboles)
- Split 70/30 con `random_state=42`

Resultados del modelo

0.75	0.113	40%
R^2 Score	**RMSE**	**cognitive_demand**
Varianza explicada por el modelo	Error cuadrático medio	Variable más importante del modelo

Python ML: Algoritmo No Supervisado

K-Means (k=3) — clustering de ocupaciones por perfil de riesgo. PCA a 2 componentes para visualización (68% de varianza explicada). El Diagrama de Codo confirmó k=3 como óptimo.

🔴 Cluster 0 — Riesgo Alto

RTI alto · educación baja · ingreso bajo

Jornaleros, operadores de maquinaria, cajeros

🟡 Cluster 1 — Riesgo Medio

RTI medio · educación media · perfil administrativo

Administrativos, técnicos, vendedores

🟢 Cluster 2 — Riesgo Bajo

Demanda cognitiva alta · educación alta

Profesionistas, directivos, docentes

⚠ **Hallazgo crítico:** El cluster 1 es el más numeroso en Jalisco y el más expuesto a LLMs — los modelos de lenguaje apuntan exactamente al perfil administrativo que Frey-Osborne clasificaba como "seguro".



Resultados Integrados

Cada etapa del pipeline responde una dimensión distinta de la pregunta de tesis sobre automatización en Jalisco.

→ SQL respondió: cobertura y sesgos

El 18% sin crosswalk O*NET son precisamente los más vulnerables (sector informal, agropecuario) — sesgo de cobertura que el modelo debe documentar explícitamente.

→ Orange respondió: estructura visual de los datos

Educación y demanda cognitiva son los ejes que separan los grupos. La informalidad amplifica el riesgo. Accuracy de 0.84 valida la robustez de la clasificación.

→ Python respondió: cuantificación precisa

R^2=0.75 en regresión continua. K-Means revela que el grupo más vulnerable en Jalisco es el cluster 1 — trabajadores con tareas administrativas repetitivas clasificadas previamente como "seguras".

¿En Qué Fase Estamos?

Fase 1 — Baseline Frey-Osborne ✅ COMPLETA

- SQL: esquema + carga masiva + VIEW ✓
- Orange: 3 flujos exploratorios ✓
- Python: Random Forest $R^2 = 0.75$ ✓
- Python: K-Means 3 clusters ✓

Fase 2 — LLM Exposure + Incentivo Económico ⏳ EN CURSO

- Bloque 3: exposición específica a LLMs ⏳ Pendiente crosswalk SOC→SINCO
- Bloque 4: IRA — incentivo económico ⏳ Pendiente Censos Económicos INEGI
- Validación estadística completa ⏳ Después de Bloques 3 y 4

El pipeline SQL + Orange + Python es la **infraestructura sobre la que se construirá la Fase 2**. Las mismas tablas, las mismas herramientas — con dos bloques nuevos de variables.

Lo que se Implementará: Lado LLM

Bloque 3 — Exposición específica a modelos de lenguaje. Frey-Osborne asumía que las tareas cognitivas no rutinarias tenían bajo riesgo. Los LLMs invierten ese supuesto: GPT-4, Claude y Copilot hacen exactamente esas tareas.

Variables de exposición a implementar

Variable	Fuente y método
gpt_exposure_score	Eloundou et al. (2023) · Scores SOC mapeados a SINCO
ltii	O*NET 28.3 · Índice compuesto: Information Input + Cognitive Abilities – Manual Dexterity
aioe	Felten et al. (2023) · AI Occupational Exposure Index — variable de control

Modelos estadísticos pendientes

- **CFA:** validar que gpt_score + ltii + aioe miden un constructo latente único de "exposición LLM"
- **Pearson vs. Spearman:** detectar si la relación es lineal o monotónica antes de elegir el modelo final
- **SHAP values:** comparar importancia de variables Fase 1 vs. Fase 2

Hipótesis H1: Si se confirma, el cluster 1 de K-Means (administrativos de "riesgo medio") sube de categoría al agregar exposición LLM.

Lo que se Implementará: Lado Económico

Bloque 4 — ¿Cuándo le conviene al mercado automatizar? La viabilidad técnica no implica adopción. Acemoglu & Restrepo (2018): la sustitución ocurre cuando el costo de automatizar es inferior al costo salarial — no antes.

Variable a construir: IRA

Índice de Rentabilidad de la Automatización

$$IRA = \frac{ingocup_anual}{activo_fijo_amortizado_5_años}$$

- **Numerador:** INGOCUP × 12 (ENOE Q3 2024)
- **Denominador:** activo fijo por trabajador por sector SCIAN, amortizado a 5 años (Censos Económicos INEGI 2019)
- **IRA alto** → salario supera el costo de automatizar → incentivo real de mercado para sustituir

Modelos estadísticos pendientes

Ramsey RESET

Validar forma funcional OLS antes de asumir linealidad entre IRA y adopción

VIF

Detectar multicolinealidad entre IRA, nivel educativo e ingreso

GAM

Modelar relación no lineal entre IRA y riesgo — baseline vs. Random Forest

Hipótesis H2: El IRA modera la relación entre riesgo técnico y adopción real. Explica por qué agricultura sigue siendo manual en Jalisco pese al riesgo teórico alto de Frey-Osborne.

El Modelo que Prueba la Pregunta de Investigación

El corazón de nuestra investigación es la **Regresión Jerárquica por Bloques**, un enfoque robusto para evaluar la contribución incremental de cada conjunto de variables a la varianza explicada del riesgo de automatización.

Modelo	Bloque que se agrega	Prueba
M1	Perfil ENOE: educación, edad, ingreso, sector	R^2_1 baseline
M2	O*NET: RTI, demanda cognitiva, interacción social	ΔR^2_2 + F-test
M3	LLM exposure: gpt_score, LTII, AIOE	ΔR^2_3 + F-test → H1
M4	IRA: salario anual / costo amortizado	ΔR^2_4 + F-test → H2

Hipótesis H1

Si ΔR^2_3 es significativo, los LLMs modifican el riesgo más allá de Frey-Osborne.

Hipótesis H2

Si ΔR^2_4 es significativo, el incentivo económico explica la adopción real.

La significancia de ΔR^2 en el Bloque 3 validará (o no) el impacto de los LLMs. Ambos resultados son valiosos científicamente.

Stack Tecnológico



Bases de Datos

SQLite / PostgreSQL · SQLAlchemy · Scripts SQL documentados con integridad referencial



Orange Data Mining 3

SQL Table · Feature Statistics · Distributions · Box Plot · Scatter Plot · Correlations · Heat Map · k-Means · Random Forest · ROC Analysis



Python ML

pandas · numpy · scikit-learn · matplotlib · sqlalchemy · Conda env `ai_automation_thesis` · Jupyter Notebook



Datos Oficiales

ENOE Q3 2024 (entidad 14) · O*NET 28.3 · Censos Económicos INEGI 2019 · Crosswalk SOC→SINCO



Conclusiones y Trabajo Futuro

Lo que este proyecto demuestra

- El pipeline SQL → Orange → Python es **completamente funcional** con datos reales de Jalisco
- Random Forest logra **R^2=0.75** en el baseline Frey-Osborne
- K-Means identifica **3 grupos accionables** de ocupaciones con perfiles de riesgo diferenciados

Lo que sigue en la tesis — Fase 2

- Agregar `gpt_exposure_score` (Eloundou et al., 2023) una vez disponible el crosswalk SOC→SINCO
- Construir e integrar el `ira` con Censos Económicos INEGI 2019
- Probar si los LLMs **invierten el ranking de riesgo** para el cluster 1 y si el IRA predice cuándo el mercado realmente actúa