Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Tópicos Selectos de Grandes Bases de Datos

Tarea 7

Paradigmas supervisados y no supervisados en Machine Learning

Alumno:	Carlos Pulido Rosas
Fecha:	24 de Marzo de 2026

Parte 1 - Cita textual

"In supervised learning, the goal is to learn a mapping from inputs x to outputs y, given a labeled training set of input-output pairs."
Kevin P. Murphy, Probabilistic Machine Learning: An Introduction, página 1.

Parte 2 - Explicación conceptual

El aprendizaje supervisado es el paradigma donde el modelo aprende a partir de ejemplos etiquetados: se le proporcionan pares de entrada y salida, y su objetivo es encontrar la función que mejor mapea una cosa con la otra. El "supervisor" es precisamente esa etiqueta que le dice al modelo si acertó o no. Un ejemplo clásico es predecir el precio de una casa a partir de sus características: sabemos el precio real de muchas casas anteriores, y con eso entrenamos el modelo.

El aprendizaje no supervisado funciona distinto porque no hay etiquetas. El modelo recibe solo datos de entrada y tiene que encontrar estructura por sí mismo, sin que nadie le diga qué es correcto. El objetivo puede ser agrupar observaciones similares, detectar patrones, o reducir la dimensionalidad de los datos. Un ejemplo es agrupar clientes según su comportamiento de compra sin saber de antemano cuántos grupos existen ni cuáles son.

La diferencia fundamental está en la presencia o ausencia de una señal de supervisión. En el paradigma supervisado, el error se puede medir directamente comparando la predicción con la etiqueta real. En el no supervisado no hay esa referencia externa, por lo que los criterios de evaluación son distintos y más difíciles de definir. Esto hace que el aprendizaje no supervisado sea conceptualmente más abierto, pero también más difícil de validar.

Parte 3 - Ejemplo matemático: K-means en el plano (no supervisado)

Datos de entrada

Punto	x_1	x_2
A	1	1
B	1.5	2
C	2	1.5
D	7	8
E	8	8
F	7.5	7

Formulación matemática

K-means busca particionar n puntos en k clusters minimizando la suma de distancias cuadráticas de cada punto a su centroide:

$$\min \Sigma_k \Sigma (x_i \in C_i) \|x_i - \mu_k\|^2$$

donde μ_k es el centroide del clúster k.

Resolución paso a paso (k = 2)

Iteración 1 - Inicialización: Se eligen centroides iniciales μ_1 = A = (1, 1) y μ_2 = D = (7, 8).
Asignación de puntos al centroide más cercano (distancia euclidiana):

Punto	$d(\mu_1)$	$d(\mu_2)$	Cluster asignado
A (1, 1)	0.00	9.22	C_1
B (1.5, 2)	1.12	8.14	C_1
C (2, 1.5)	1.12	8.28	C_1
D (7, 8)	9.22	0.00	C_2
E (8, 8)	9.90	1.00	C_2
F (7.5, 7)	9.01	1.12	C_2

Actualización de centroides:

$$\mu_1 = [(1+1.5+2)/3, (1+2+1.5)/3] = (1.5, 1.5)$$
$$\mu_2 = [(7+8+7.5)/3, (8+8+7)/3] = (7.5, 7.67)$$

Iteración 2 - Convergencia: Con los nuevos centroides, cada punto mantiene su asignación anterior. No hay cambios en los clusters, por lo que el algoritmo converge.

Resultado final

- Cluster 1: {A, B, C} - puntos próximos al origen. Centroide final: (1.5, 1.5)
- Cluster 2: {D, E, F} - puntos en zona superior derecha. Centroide final: (7.5, 7.67)

El modelo identificó dos grupos naturales sin ninguna etiqueta previa, únicamente a partir de la proximidad geométrica entre puntos. Eso ilustra la esencia del aprendizaje no supervisado: encontrar estructura implícita en los datos.

