Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Tópicos Selectos de Grandes Bases de Datos

Tarea 8

Machine Learning como problema de inferencia

Alumno:	Carlos Pulido Rosas
Fecha:	24 de Marzo de 2026

Parte 1 - Cita textual

"In the supervised learning problem... we have an outcome measurement Y, usually quantitative or categorical, that we wish to predict based on a set of features X."

Trevor Hastie, Robert Tibshirani, Jerome Friedman, The Elements of Statistical Learning, página 9.

Parte 2 - Explicación conceptual

El aprendizaje supervisado es el paradigma donde el modelo aprende a partir de ejemplos etiquetados: se tienen pares de entrada X y salida Y conocida, y el objetivo es encontrar la función que mejor mapea uno con el otro. El modelo recibe una señal de supervisión porque sabe cuándo se equivoca — puede comparar su predicción con el valor real. Un ejemplo clásico es predecir el precio de una casa a partir de su tamaño: hay un precio real con el que comparar.

El aprendizaje no supervisado funciona diferente porque solo existen datos de entrada X, sin ninguna etiqueta Y. El modelo tiene que encontrar estructura por sí mismo, sin referencia externa de qué es correcto. El objetivo puede ser agrupar observaciones similares, detectar patrones ocultos o reducir dimensiones. Un ejemplo es segmentar clientes según su comportamiento de compra sin saber de antemano cuántos grupos existen.

La diferencia fundamental está en la presencia o ausencia de una variable de salida conocida. En el paradigma supervisado el error es medible directamente comparando $\hat{Y}$ contra Y. En el no supervisado no hay esa referencia, lo que hace la evaluación más difícil. Hastie señala que esta distinción define arquitecturas, algoritmos y criterios de evaluación completamente distintos.

Parte 3 - Ejemplo matemático: Regresión lineal simple (supervisado)

Datos de entrada

Predecir el precio de una casa (Y, en miles de pesos) a partir de su tamaño (X, en m²):

Obs.	X (m²)	Y (precio)
1	50	100
2	70	150
3	80	160
4	100	200
5	120	230

Formulación matemática

El modelo de regresión lineal simple es:

$$\hat{Y} = \beta_0 + \beta_1 X$$

Los coeficientes minimizan la suma de errores cuadráticos (mínimos cuadrados):

$$\min \Sigma (Y_i - \beta_0 - \beta_1 X_i)^2$$

Con fórmulas cerradas:

$$\beta_1 = \Sigma(X_i - \bar{X})(Y_i - \hat{Y}) / \Sigma(X_i - \bar{X})^2 \qquad \beta_0 = \hat{Y} - \beta_1 \bar{X}$$

Resolución paso a paso

Paso 1 - Medias:

$\bar{X}$ = (50+70+80+100+120) / 5 = 84 $\qquad$ $\hat{Y}$ = (100+150+160+200+230) / 5 = 168

Paso 2 - Cálculo de β_1:

i	$X_i - \bar{X}$	$Y_i - \hat{Y}$	$(X_i-\bar{X})(Y_i-\hat{Y})$	$(X_i-\bar{X})^2$
1	−34	−68	2312	1156
2	−14	−18	252	196
3	−4	−8	32	16
4	16	32	512	256
5	36	62	2232	1296
Σ			5340	2920

$$\beta_1 = 5340 / 2920 = 1.829$$

Paso 3 — Cálculo de β_0:

$$\beta_0 = 168 - 1.829 \times 84 = 168 - 153.6 = 14.4$$

Modelo final:

$$\hat{Y} = 14.4 + 1.829 \cdot X$$

Paso 4 — Predicción (X = 90 m²):

$$\hat{Y} = 14.4 + 1.829 \times 90 = 14.4 + 164.6 = 179 \text{ mil pesos}$$

Este es aprendizaje supervisado porque el modelo aprendía la relación X→Y a partir de pares etiquetados reales, y su error se puede medir directamente comparando $\hat{Y}$ contra Y. La gráfica de la regresión muestra cómo la línea ajustada minimiza las distancias verticales a cada punto observado.

