Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Tópicos Selectos de Grandes Bases de Datos

Tarea 9

Flujo general de modelado y evaluación en Machine Learning

Alumno:	Carlos Pulido Rosas
Fecha:	24 de Marzo de 2026

Parte 1 - Cita textual

"The typical supervised learning pipeline involves: collecting a dataset of (input, output) pairs, choosing a model family, fitting the model to the training data, and then evaluating it on held-out test data to estimate its generalization performance."

Kevin P. Murphy, Probabilistic Machine Learning: An Introduction, página 1.

Parte 2 - Explicación conceptual

El flujo general de un proyecto de Machine Learning sigue una secuencia lógica que empieza mucho antes de que exista cualquier modelo. Todo comienza con la obtención de datos: se recopilan observaciones del fenómeno que se quiere modelar, se limpian, se transforman y se dividen en al menos dos conjuntos: entrenamiento y prueba. Esta división es crítica porque garantiza que el modelo sea evaluado con datos que nunca vio durante su construcción.

El entrenamiento consiste en ajustar los parámetros del modelo para que sus predicciones se acerquen lo más posible a las salidas reales del conjunto de entrenamiento. El modelo aprende la relación entre las variables de entrada y la variable objetivo minimizando una función de pérdida. En este punto el modelo existe, pero no sabemos si sirve.

La validación ocurre durante el desarrollo: se usa un conjunto separado del de entrenamiento para comparar distintas versiones del modelo, ajustar hiperparámetros y evitar el sobreajuste. Una técnica común es la validación cruzada (k-fold), que divide los datos en k bloques y rota cuál sirve como conjunto de validación.

Finalmente, la evaluación mide el desempeño real del modelo sobre el conjunto de prueba, datos que no participaron en ningún paso previo. Esta etapa es irreemplazable porque un modelo puede funcionar perfectamente en entrenamiento y fallar en datos nuevos (sobreajuste). Murphy lo resume con precisión: lo que importa es la capacidad de generalización, no el rendimiento en los datos conocidos.

Parte 3 - Ejemplo práctico: predicción del precio de una casa

1. Datos necesarios

Se necesitaría una base de datos histórica de casas vendidas con al menos tres variables de entrada: tamaño de la casa (m²), número de habitaciones (entero) y ubicación (variable categórica: colonia o zona). La variable de salida sería el precio de venta (en pesos o miles de pesos). Idealmente se tendrían cientos o miles de registros para que el modelo pueda capturar patrones confiables. Los datos se dividirían 80% entrenamiento y 20% prueba.

Variable	Tipo	Ejemplo
Tamaño (m²)	Numérica continua	85 m²
Núm. habitaciones	Numérica discreta	3
Ubicación	Categórica	Zapopan Centro
Precio (Y)	Numérica — salida	1,850,000 pesos

2. Entrenamiento del modelo

Se usaría un modelo de regresión lineal múltiple como punto de partida. La ubicación se codificaría mediante variables dummy (one-hot encoding). El modelo ajustaría los coeficientes β1, β2, β3 para cada variable minimizando el error cuadrático medio sobre el conjunto de entrenamiento. Si la relación no fuera lineal, se podría probar un modelo más flexible como un árbol de decisión o un Random Forest.

$$\hat{Y} = \beta 0 + \beta 1(\text{tamaño}) + \beta 2(\text{habitaciones}) + \beta 3(\text{ubicación})$$

3. Validación del modelo

Durante el desarrollo se aplicaría validación cruzada de 5 pliegues (5-fold cross-validation) sobre el conjunto de entrenamiento. Esto permite comparar distintas versiones del modelo (por ejemplo, con o sin regularización, o con distintos hiperparámetros) sin tocar el conjunto de prueba. Se seleccionaría la configuración con menor error promedio de validación.

4. Evaluación y métrica de desempeño

Una vez elegido el modelo final, se evalúa sobre el 20% de datos de prueba que nunca se usaron. La métrica principal sería el Error Cuadrático Medio (RMSE, Root Mean Squared Error), porque penaliza errores grandes y se expresa en las mismas unidades que el precio:

$$\text{RMSE} = \sqrt{\left[\ (1/n) \times \Sigma\ (Y_i - \hat{Y}_i)^2\ \right]}$$

Complementariamente se usaría el coeficiente R^2 para medir qué proporción de la variabilidad del precio explica el modelo. Un R^2 cercano a 1 indica buen ajuste; uno cercano a 0 indica que el modelo no captura la estructura de los datos. Si el RMSE fuera demasiado alto o el R^2 demasiado bajo, se regresaría a la etapa de features o se probaría un modelo más complejo.

