Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Tópicos Selectos de Grandes Bases de Datos

Tarea 11

Esperanza, varianza y covarianza en Machine Learning

Alumno:	Carlos Pulido Rosas
Fecha:	24 de Marzo de 2026

Parte 1 - Cita textual

"The variance of a random variable X is the expected squared deviation from the mean: Var(X) = E[(X − μ)²], where μ = E[X]. The covariance between two random variables X and Y measures how they vary together: Cov(X, Y) = E[(X − μx)(Y − μy)]."

Kevin P. Murphy, Probabilistic Machine Learning: An Introduction, página 31.

Parte 2 - Explicación conceptual

La esperanza matemática E[X] es el valor promedio que se espera obtener de una variable aleatoria a largo plazo. No es necesariamente un valor que la variable pueda tomar; es el centro de gravedad de su distribución. Para datos observados se calcula como la media aritmética. En Machine Learning aparece en todas partes: en la función de pérdida, en el gradiente esperado, en la definición del sesgo de un estimador.

La varianza Var(X) mide cuánto se dispersan los valores de X alrededor de su media. Una varianza alta indica que los datos están muy esparcidos; una varianza baja indica que están concentrados cerca del promedio. Su raíz cuadrada es la desviación estándar, que se expresa en las mismas unidades que los datos. En ML, la varianza de un modelo mide su sensibilidad al ruido en los datos de entrenamiento — modelos con alta varianza tienden al sobreajuste.

La covarianza Cov(X, Y) mide la relación lineal entre dos variables. Si es positiva, cuando X sube Y también tiende a subir; si es negativa, van en direcciones opuestas; si es cero, no hay relación lineal. En ML la covarianza es clave para el análisis de componentes principales (PCA), donde se busca reducir la dimensionalidad eliminando redundancias entre variables correlacionadas. La matriz de covarianza resume las relaciones entre todas las variables del dataset y es el punto de partida de muchos algoritmos de reducción de dimensionalidad y modelos generativos.

Parte 3 - Ejemplo matemático

Datos: X = [2, 4, 6, 8] Y = [1, 3, 5, 7] n = 4

1. Esperanza matemática de X

$$E[X] = (1/n) \times \Sigma x_i = (2 + 4 + 6 + 8) / 4 = 20 / 4$$

$$E[X] = 5$$

2. Varianza de X

$$Var(X) = (1/n) \times \Sigma (x_i - E[X])^2$$

x_i	$x_i - E[X]$	$(x_i - E[X])^2$
2	$2 - 5 = -3$	$(-3)^2 = 9$
4	$4 - 5 = -1$	$(-1)^2 = 1$
6	$6 - 5 = +1$	$(+1)^2 = 1$
8	$8 - 5 = +3$	$(+3)^2 = 9$
Σ		20

$$Var(X) = 20 / 4 = 5$$

Interpretación: los valores de X se desvían en promedio 5 unidades cuadradas respecto a la media. La desviación estándar es $\sqrt{5} \approx 2.24$, lo que significa que los valores típicamente se alejan 2.24 unidades de la media (5). Dado que los datos van de 2 a 8, una desviación de 2.24 refleja una dispersión moderada y uniforme.

3. Covarianza entre X y Y

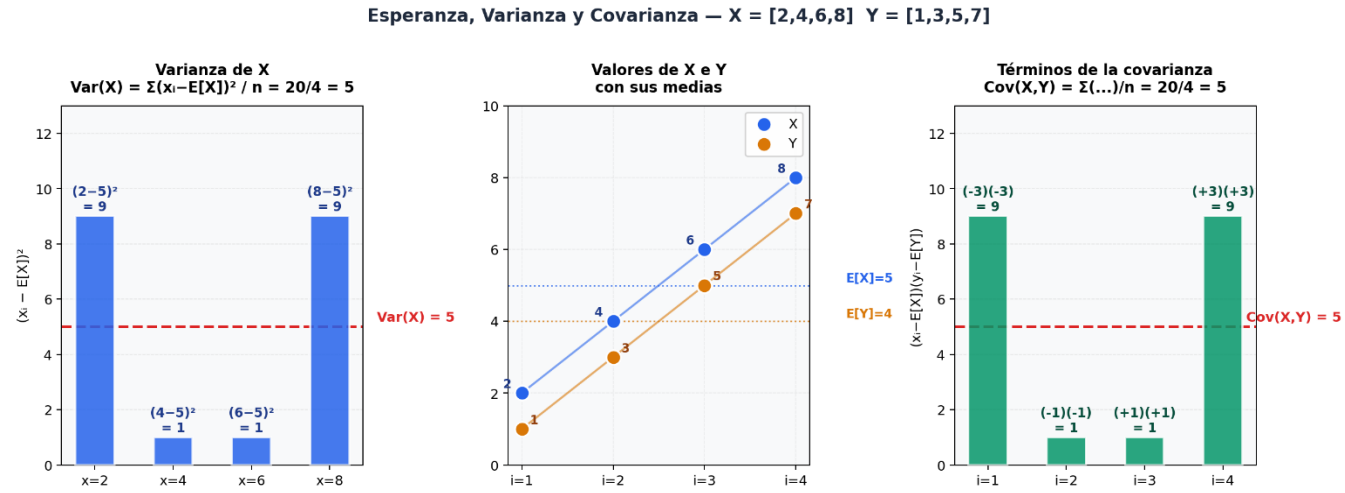
Primero calculamos $E[Y] = (1 + 3 + 5 + 7) / 4 = 16 / 4 = 4$

$$Cov(X, Y) = (1/n) \times \Sigma (x_i - E[X])(y_i - E[Y])$$

x_i	y_i	$x_i - E[X]$	$y_i - E[Y]$	$(x_i - E[X])(y_i - E[Y])$
2	1	−3	−3	$(-3)(-3) = 9$
4	3	−1	−1	$(-1)(-1) = 1$
6	5	+1	+1	$(+1)(+1) = 1$
8	7	+3	+3	$(+3)(+3) = 9$
Σ				20

$$Cov(X, Y) = 20 / 4 = 5$$

Interpretación: la covarianza positiva de 5 indica que X y Y se mueven en la misma dirección — cuando X aumenta, Y también aumenta. Esto tiene sentido porque $Y = X - 1$, es decir, existe una relación lineal perfecta entre ambas variables. En un contexto real de ML, una covarianza tan alta entre dos variables de entrada sería una señal de multicolinealidad: ambas aportan prácticamente la misma información, por lo que considerar las dos en el modelo sería redundante. PCA aprovecharía precisamente esta estructura para reducir las dos variables a una sola componente principal.


Esperanza, Varianza y Covarianza — X = [2,4,6,8] Y = [1,3,5,7]
Varianza de X
Var(X) = Σ(xᵢ−E[X])² / n = 20/4 = 5
(xᵢ − E[X])²
(2−5)²
= 9
(4−5)²
= 1
(6−5)²
= 1
(8−5)²
= 9
Var(X) = 5
x=2
x=4
x=6
x=8
Valores de X e Y
con sus medias
X
Y
E[X]=5
E[Y]=4
i=1
i=2
i=3
i=4
Términos de la covarianza
Cov(X,Y) = Σ(...)/n = 20/4 = 5
(xᵢ−E[X])(yᵢ−E[Y])
(-3)(-3)
= 9
(-1)(-1)
= 1
(+1)(+1)
= 1
(+3)(+3)
= 9
Cov(X,Y) = 5