Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 2° Semestre
Materia: Tópicos Selectos de Grandes Bases de Datos

Tarea 12

Máxima verosimilitud e inferencia estadística en Machine Learning

Alumno:	Carlos Pulido Rosas
Fecha:	24 de Marzo de 2026

Parte 1 - Cita textual

"The most common approach to parameter estimation is the method of maximum likelihood estimation (MLE), which picks the parameters that maximize the likelihood of the observed data under the model."
Kevin P. Murphy, Probabilistic Machine Learning: An Introduction, página 78.

Parte 2 - Explicación conceptual

Estimar parámetros mediante máxima verosimilitud significa encontrar los valores de los parámetros de un modelo que hacen más probable haber observado los datos que realmente se tienen. En lugar de preguntar "¿cuál es la probabilidad de estos datos dado el modelo?", MLE responde: "¿qué parámetros hacen que estos datos sean lo más probable posible?". Es una inversión del razonamiento clásico.

La relación entre los datos observados y el modelo probabilístico es central en este método. Se asume que los datos provienen de una distribución con parámetros desconocidos — por ejemplo, una normal con media μ desconocida. La función de verosimilitud L(μ) evalúa qué tan compatible es cada valor posible de μ con los datos observados. Maximizarla equivale a encontrar el parámetro bajo el cual los datos observados son el resultado más esperado.

En Machine Learning este método es fundamental porque el entrenamiento de la mayoría de los modelos es equivalente a resolver un problema de MLE. Minimizar el error cuadrático medio en regresión lineal es exactamente MLE bajo el supuesto de errores normales. Minimizar la entropía cruzada en clasificación es MLE bajo distribución Bernoulli o Categórica. En ambos casos, el optimizador ajusta los parámetros del modelo para que las predicciones sean lo más consistentes posible con los datos de entrenamiento, que es exactamente la lógica de la máxima verosimilitud.

Parte 3 - Ejemplo matemático

Datos: $x = [4, 6, 5, 7, 8]$ $n = 5$ $\sigma^2 = 1$ (conocida)

1. Función de verosimilitud

Bajo el supuesto de que cada observación x_i proviene de una distribución normal $N(\mu, \sigma^2 = 1)$, la función de densidad para cada dato es:

$$f(x_i \mid \mu) = (1 / \sqrt{(2\pi)}) \times \exp\left[-(x_i - \mu)^2 / 2 \right]$$

Como las observaciones son independientes, la verosimilitud conjunta es el producto de las densidades individuales:

$$L(\mu) = \prod_{i=1}^{n} f(x_i \mid \mu) = (1 / \sqrt{(2\pi)})^n \times \exp\left[-\Sigma (x_i - \mu)^2 / 2 \right]$$

2. Log-verosimilitud y maximización

Para simplificar el cálculo se trabaja con el logaritmo de la verosimilitud (log-likelihood), que tiene el mismo máximo porque el logaritmo es una función monótona creciente:

$$\ell(\mu) = \log L(\mu) = -(n/2) \log(2\pi) - (1/2) \Sigma (x_i - \mu)^2$$

Para maximizar, se deriva respecto a μ e iguala a cero:

$$d\ell/d\mu = \Sigma (x_i - \mu) = 0$$

Despejando μ:

$$\Sigma x_i - n\mu = 0 \quad \Longrightarrow \quad \hat{\mu} = (1/n) \Sigma x_i$$

Sustituyendo los datos:

x_i	4	6	5	7	8	Σ
Valor	4	6	5	7	8	30

$$\hat{\mu} = 30 / 5 = 6$$

3. Interpretación del resultado

El estimador de máxima verosimilitud para la media de una distribución normal es simplemente la media muestral. En este caso, $\hat{\mu} = 6$ es el valor que hace más probable haber observado los datos [4, 6, 5, 7, 8].

Esto tiene una interpretación intuitiva clara: si los datos se generan alrededor de una media verdadera con ruido gaussiano simétrico, el punto que minimiza las distancias cuadráticas a todos los datos — y por tanto maximiza la verosimilitud — es su promedio. Un valor de μ mayor o menor que 6 haría que algunos datos fueran menos probables bajo el modelo, reduciendo la verosimilitud total.

En términos de Machine Learning, este resultado confirma que minimizar el error cuadrático medio (MSE) sobre los datos de entrenamiento es exactamente equivalente a aplicar MLE bajo el supuesto de ruido gaussiano. El parámetro $\hat{\mu} = 6$ es la predicción óptima del modelo para este conjunto de datos.

