UNIVERSIDAD DE GUADALAJARA

CENTRO UNIVERSITARIO DE CIENCIAS ECONÓMICO ADMINISTRATIVAS

COORDINACIÓN DE POSGRADO

MAESTRÍA EN CIENCIA DE LOS DATOS

Modelo de ciencia de datos para evaluar el riesgo de movilidad laboral por modelos de inteligencia artificial: carreras de informática y ciencia de datos

P R E S E N T A

Carlos Pulido Rosas

21 de octubre de 2026

Datos de Localización
carlos.pulido.rosas@gmail.com
Teléfono

CUCEA
El mejor lugar para el talento

MCD MAESTRÍA EN CIENCIA DE LOS DATOS

I. PLANTEAMIENTO DEL PROBLEMA

1.1. Contexto

Los modelos de lenguaje de gran escala son sistemas de inteligencia artificial capaces de comprender y generar texto y código, y se definen formalmente en el marco teórico. Su difusión a partir de 2022 reabrió la pregunta de qué ocurre con el empleo cuando una tecnología puede realizar tareas cognitivas que antes solo hacían las personas. Eloundou et al. (2023) estimaron que alrededor del 80 % de los trabajadores de Estados Unidos podría ver afectado al menos el 10 % de sus tareas por estos modelos, y que cerca del 19 % podría ver afectada al menos la mitad. En otras palabras, la exposición alcanza a casi todas las ocupaciones, pero solo en una de cada cinco toca la mayor parte del trabajo.

Las ocupaciones relacionadas con la informática y el análisis de datos están entre las más involucradas. En el análisis de millones de conversaciones con el asistente Claude, las ocupaciones de computación y matemáticas concentraron el 37.2 % de todas las consultas, la proporción más alta de cualquier grupo ocupacional, y el 57 % de los usos mostró un patrón de aumento de las capacidades humanas más que de automatización (Handa et al., 2025). Es decir, más de un tercio del uso observado de esta herramienta proviene de tareas de informática y matemáticas, y en la mayoría de los casos el modelo trabaja junto con la persona en lugar de reemplazarla. Gao y Huang (2026), por su parte, calcularon un índice relativo de automatización ocupacional para Estados Unidos y encontraron que los puestos cognitivos no rutinarios que dependen de la manipulación de símbolos son los más vulnerables; los científicos de datos encabezan ese índice, con un valor cercano a 0.70.

Sin embargo, una exposición alta no se ha traducido en pérdidas generales de empleo. Acemoglu et al. (2022) encontraron, con las vacantes publicadas en línea en Estados Unidos

desde 2010, que los establecimientos que adoptan inteligencia artificial reducen sus contrataciones en puestos no relacionados con ella y cambian los requisitos de habilidades de las vacantes que mantienen, aunque el efecto todavía es demasiado pequeño para observarse en el empleo agregado. Broady et al. (2026) mostraron que, entre 2019 y 2024, las ocupaciones con mayor aplicabilidad de la inteligencia artificial aumentaron su empleo y sus salarios, por lo que proponen leer la exposición como un indicador de reestructuración de las ocupaciones y no como un pronóstico de pérdida de empleo.

Donde sí aparece un cambio es en la entrada al mercado de trabajo. Con registros de nómina de millones de trabajadores de Estados Unidos, Brynjolfsson et al. (2026) encontraron que el empleo de los jóvenes de 22 a 25 años en ocupaciones expuestas a la inteligencia artificial se encuentra 19 % por debajo de donde estaría si hubiera crecido al mismo ritmo que el de sus pares en ocupaciones menos expuestas, sin una brecha comparable entre los trabajadores con más experiencia. Los autores precisan que la diferencia se explica sobre todo por menos contrataciones de jóvenes y no por más despidos, y analizan el desarrollo de software como uno de sus casos de estudio. Este resultado sugiere que el efecto de la tecnología se manifiesta en quién entra, quién sale y hacia dónde se mueven los trabajadores, más que en la desaparición de las ocupaciones.

1.2. Definición del problema

La mayoría de los estudios sobre inteligencia artificial y empleo miden la exposición de cada ocupación en un momento dado, pero no siguen a los trabajadores. Frank et al. (2025) mostraron, con datos mensuales de desempleo por ocupación de cada estado de Estados Unidos entre 2010 y 2020, que ningún índice de exposición por sí solo predice bien el riesgo de desempleo; solo al combinarlos se explica un 18 % adicional de la variación del riesgo de

desempleo entre ocupaciones, estados y periodos, respecto a un modelo que ya considera la escolaridad, las habilidades, la estacionalidad y la región. Dicho de otro modo, saber que una ocupación está expuesta no basta para saber qué les pasará a quienes trabajan en ella.

Del Rio-Chanona et al. (2021) plantean el problema desde otro ángulo: cuando la automatización afecta a una ocupación, el resultado para sus trabajadores depende de cuántas ocupaciones cercanas existen hacia donde puedan moverse. Con un modelo de red de movilidad ocupacional, encontraron que las ocupaciones ubicadas en zonas de la red con pocas opciones de transición tienen más riesgo de desempleo de largo plazo. Por su parte, Georgieff y Hyee (2022) encontraron, para 23 países de la OCDE, que en las ocupaciones con uso intensivo de computadora una mayor exposición a la inteligencia artificial se asocia con un mayor crecimiento del empleo, y Chen et al. (2022) mostraron, con 701 ocupaciones de Estados Unidos, que las habilidades digitales moderan el efecto negativo del riesgo de desplazamiento sobre los salarios y el empleo.

Estos trabajos coinciden en que el riesgo relevante no es solo el de perder el empleo, sino el de verse obligado a cambiar de ocupación, de empleador o de condición laboral, y en que ese riesgo depende de las habilidades del trabajador y de las rutas de transición disponibles. Además, como muestran Khan y Varshney (2026), estimar ese riesgo implica medir también su incertidumbre, porque en sus resultados el error de predicción es mayor justamente en las ocupaciones de riesgo alto. Sin embargo, estos estudios se basan en datos de Estados Unidos o de países de la OCDE. En México no se ha medido cómo se mueven las personas que estudiaron una carrera de informática o de ciencia de datos, o que trabajan en esas ocupaciones, desde la llegada de los modelos de lenguaje, ni si esa movilidad es distinta para quienes empiezan su carrera profesional.

En consecuencia, el problema de investigación es la falta de un modelo que permita

evaluar, con datos de México, el riesgo de movilidad laboral que enfrentan las personas formadas o empleadas en informática y ciencia de datos ante los modelos de inteligencia artificial, es decir, con qué probabilidad cambian de ocupación, quedan desocupadas o salen del mercado de trabajo, hacia qué ocupaciones se mueven, qué características aumentan o reducen ese riesgo y cómo difiere entre carreras.

1.3. Preguntas de investigación

Pregunta general: ¿cómo se relaciona la exposición a los modelos de inteligencia artificial con la movilidad laboral de las personas formadas o empleadas en informática y ciencia de datos en México?

1. ¿Qué tareas de las ocupaciones de informática y ciencia de datos están más expuestas a los modelos de inteligencia artificial?
2. ¿Con qué frecuencia estas personas cambian de ocupación, quedan desocupadas o salen del mercado de trabajo, hacia qué ocupaciones se mueven y cómo cambió esa movilidad después de 2022?
3. ¿Cómo difiere el riesgo de movilidad entre carreras y qué características de la persona, como la edad, la experiencia y la escolaridad, se asocian con un riesgo mayor?

II. JUSTIFICACIÓN

Relevancia social. Si el efecto de la inteligencia artificial se concentra en la entrada al mercado de trabajo, como sugieren Brynjolfsson et al. (2026), quienes más lo resentirían serían los egresados recientes de carreras de informática y ciencia de datos, que buscan su primer empleo en las ocupaciones más expuestas. Un modelo que compare el riesgo de movilidad entre carreras serviría a los estudiantes que eligen una carrera universitaria y a las instituciones que

diseñan sus planes de estudio.

Relevancia práctica. Los resultados permitirán identificar qué ocupaciones reciben a las personas que salen de la informática y la ciencia de datos, y qué habilidades facilitan esas transiciones. Paolillo et al. (2022) mostraron que es posible identificar, para cada ocupación, alternativas que reducen el riesgo de automatización con un esfuerzo de reentrenamiento moderado; un análisis similar con datos mexicanos serviría a universidades, empleadores y trabajadores para orientar la capacitación.

Aportación a la ciencia. El proyecto propone medir la movilidad laboral asociada a la inteligencia artificial siguiendo a las mismas personas en el tiempo, en lugar de comparar fotografías de la exposición en distintos años. Frank et al. (2025) muestran que la exposición por sí sola es un mal predictor de lo que ocurre con el empleo, por lo que observar las transiciones reales aporta una medida más directa del riesgo. Además, incorporar la incertidumbre de la estimación, como proponen Khan y Varshney (2026), permitiría distinguir los casos en los que el modelo es confiable de aquellos en los que no lo es.

Viabilidad. Las fuentes de información son públicas y gratuitas. La Encuesta Nacional de Ocupación y Empleo (ENOE) del INEGI tiene un diseño de panel rotatorio: la muestra se divide en cinco paneles y cada vivienda permanece en la encuesta durante cinco trimestres, de modo que en cada trimestre se mantiene el 80 % de la muestra (INEGI, 2025). Esto significa que una misma persona se entrevista hasta cinco veces seguidas, lo que permite observar si cambió de ocupación o de condición laboral entre un trimestre y otro. La encuesta registra además la carrera que estudió cada persona mediante un código de carrera (INEGI, 2025), y la ocupación con el Sistema Nacional de Clasificación de Ocupaciones (INEGI, 2019). Las tareas de cada ocupación pueden obtenerse de la base O*NET (National Center for O*NET Development, 2024).

III. OBJETIVOS

3.1. Objetivo general

Evaluar el riesgo de movilidad laboral de las personas formadas o empleadas en informática y ciencia de datos en México frente a los modelos de inteligencia artificial, mediante un modelo de ciencia de datos que relacione la exposición de las tareas con las transiciones laborales observadas y permita comparar ese riesgo entre carreras.

3.2. Objetivos específicos

1. Delimitar las carreras de informática y ciencia de datos en la Clasificación Mexicana de Planes de Estudio y las ocupaciones correspondientes en el Sistema Nacional de Clasificación de Ocupaciones, y caracterizar a estas personas con la ENOE.
2. Medir la exposición de las tareas de esas ocupaciones a los modelos de inteligencia artificial a partir de O*NET y de índices de exposición publicados.
3. Construir las trayectorias trimestrales con el panel de la ENOE y estimar matrices de transición entre ocupaciones y condiciones laborales, antes y después de 2022.
4. Estimar modelos que expliquen el riesgo de movilidad en función de la exposición, la carrera y las características de la persona, cuantificar la incertidumbre de sus estimaciones y evaluar su desempeño.
5. Identificar las ocupaciones de destino y presentar el riesgo de movilidad por carrera en un tablero de visualización.

IV. HIPÓTESIS

H1. Después de la difusión de los modelos de lenguaje en 2022, las personas jóvenes formadas o empleadas en informática y ciencia de datos presentan un riesgo de movilidad mayor

que las que tienen más experiencia. La hipótesis se sustenta en la caída relativa del empleo de los jóvenes en ocupaciones expuestas, explicada por menos contrataciones (Brynjolfsson et al., 2026), y en la reducción de contrataciones en puestos no relacionados con la inteligencia artificial dentro de los establecimientos que la adoptan (Acemoglu et al., 2022).

H2. Quienes salen de las ocupaciones de informática y ciencia de datos se mueven principalmente hacia ocupaciones cercanas en habilidades, y no hacia la desocupación, porque sus habilidades digitales son transferibles. La hipótesis se basa en el papel de la red de movilidad ocupacional en las opciones de transición (del Rio-Chanona et al., 2021) y en la protección que las habilidades digitales ofrecen frente al riesgo de desplazamiento (Chen et al., 2022; Georgieff y Hyee, 2022).

V. ANTECEDENTES

Los antecedentes se presentan en orden cronológico. Autor et al. (2003) establecieron el enfoque de tareas, según el cual la tecnología sustituye tareas y no ocupaciones completas. Kambourov y Manovskii (2008) documentaron el aumento de la movilidad ocupacional en Estados Unidos entre 1968 y 1997 y destacaron su importancia porque buena parte del capital humano de los trabajadores es específico de su ocupación, de modo que cambiar de ocupación implica perder parte de ese capital. Frey y Osborne (2017) estimaron la probabilidad de automatización de 702 ocupaciones, y Acemoglu y Restrepo (2019) formalizaron la idea de que la automatización desplaza trabajo de unas tareas mientras la creación de tareas nuevas lo reinstala en otras.

Sobre la movilidad, Meng et al. (2019) propusieron una red neuronal jerárquica con mecanismos de atención que aprende de las trayectorias laborales para predecir el siguiente empleador de una persona y cuánto tiempo permanecerá en el nuevo puesto. Del Rio-Chanona

et al. (2021) construyeron una red empírica de movilidad ocupacional y simularon cómo se mueven los trabajadores ante distintos escenarios de automatización. Paolillo et al. (2022) calcularon el riesgo de automatización de casi 1,000 ocupaciones y propusieron un método para encontrar, para cada una, alternativas que reduzcan ese riesgo con el menor esfuerzo de reentrenamiento.

Con la llegada de los modelos de lenguaje, Eloundou et al. (2023) midieron la exposición de las tareas a estos modelos, y Acemoglu et al. (2022) documentaron cambios en las contrataciones y en los requisitos de las vacantes de los establecimientos que adoptan inteligencia artificial. Georgieff y Hyee (2022) y Chen et al. (2022) mostraron que el uso de computadora y las habilidades digitales cambian el signo o moderan el efecto de la exposición. Dahlin (2024) encontró, con una encuesta en Estados Unidos, que los trabajadores de cuello blanco y con experiencia técnica son quienes más reportan haber sido desplazados por la inteligencia artificial. Frank et al. (2025) relacionaron la exposición con el riesgo de desempleo, y Handa et al. (2025) midieron el uso real de un modelo de lenguaje por tarea.

En 2026, Broady et al. compararon la exposición con la evolución del empleo entre 2019 y 2024; Gao y Huang separaron la factibilidad técnica del riesgo comercial de automatizar cada actividad; y Brynjolfsson et al. documentaron la caída relativa del empleo de los trabajadores jóvenes en ocupaciones expuestas. En el mismo año, Khan y Varshney propusieron un modelo probabilístico de aprendizaje profundo para predecir el riesgo de desplazamiento por tarea: combina redes neuronales bayesianas, redes profundas deterministas y la técnica de Monte Carlo Dropout, y lo probaron con 18,796 registros de tareas. Su modelo explica una parte pequeña de la variación del riesgo (un coeficiente de determinación de 0.067), pero muestra que la incertidumbre estimada crece junto con el error real, lo que permite saber cuándo confiar en una predicción, y que el error es menor en las ocupaciones de riesgo medio y mayor en las de riesgo

alto.

VI. MARCO TEÓRICO

6.1. Conceptos y definiciones

Movilidad laboral. Se refiere a los cambios en la situación laboral de una persona entre dos momentos. En este protocolo incluye tres tipos de transición: el cambio de ocupación, que Kambourov y Manovskii (2008) miden como el paso de un trabajador de una ocupación a otra entre dos periodos; el paso del empleo a la desocupación; y la salida de la fuerza de trabajo. El riesgo de movilidad laboral es la probabilidad de que ocurra alguna de esas transiciones en un periodo determinado.

Desplazamiento y reinstalación. La automatización permite que el capital realice tareas que antes hacían las personas, lo que produce un efecto de desplazamiento del trabajo; la creación de tareas nuevas genera, en sentido contrario, un efecto de reinstalación (Acemoglu y Restrepo, 2019). La movilidad laboral es la forma en que estos dos efectos se observan en las personas: unas dejan las tareas que se automatizan y otras se mueven hacia las tareas nuevas.

Modelos de lenguaje de gran escala. Se trata de modelos de lenguaje basados en la arquitectura Transformer que contienen cientos de miles de millones de parámetros o más, se entrenan con grandes volúmenes de texto y muestran una fuerte capacidad para comprender el lenguaje natural y resolver tareas complejas mediante la generación de texto; ejemplos de ellos son GPT-3, PaLM y LLaMA (Zhao et al., 2023). La arquitectura Transformer es una red neuronal que se apoya únicamente en mecanismos de atención (Vaswani et al., 2017).

Exposición a la inteligencia artificial. Es el grado en que las tareas de una ocupación pueden ser realizadas o asistidas por un sistema de inteligencia artificial. Eloundou et al. (2023) consideran que una tarea está expuesta cuando usar un modelo de lenguaje puede reducir al

menos a la mitad el tiempo necesario para completarla con la misma calidad. La exposición no implica sustitución: puede traducirse en automatización o en aumento de las capacidades del trabajador (Handa et al., 2025).

Carreras de informática y ciencia de datos. Se delimitarán con la Clasificación Mexicana de Planes de Estudio por Campos de Formación Académica 2016 (INEGI, 2016). En ella, el campo amplio 06, Tecnologías de la información y la comunicación, comprende la innovación en tecnologías de la información (061: ciencias computacionales, desarrollo de hardware y desarrollo de software) y su implementación (062: telecomunicaciones, informática, y soporte y servicios de mantenimiento). La ciencia de datos aparece explícitamente dentro del campo 0613, Desarrollo de software, y las carreras de estadística y actuaría forman el campo 0532 (INEGI, 2016).

Ocupaciones de informática y ciencia de datos. En el Sistema Nacional de Clasificación de Ocupaciones 2019 corresponden principalmente a los desarrolladores y analistas de software y multimedia (2271), los administradores de bases de datos y redes de computadora (2272) y los investigadores y profesionistas en matemáticas, estadística y actuaría (2212). Como ocupaciones cercanas se considerarán los técnicos en la instalación y reparación de redes, equipos y sistemas computacionales (2651) y los directores y coordinadores de informática (1321 y 1621) (INEGI, 2019).

6.2. Teoría de tareas y movilidad

El fundamento teórico es el enfoque de tareas (Autor et al., 2003), según el cual la tecnología no sustituye ocupaciones completas, sino tareas específicas, y la teoría del desplazamiento y la reinstalación de Acemoglu y Restrepo (2019). Si la inteligencia artificial absorbe algunas tareas de una ocupación, la demanda de trabajo se reorganiza: las personas

cuyas tareas se automatizan pueden cambiar de funciones dentro de la ocupación, moverse a otra ocupación o quedar sin empleo. Qué tan costoso es ese ajuste depende de cuánto capital humano específico se pierde al cambiar de ocupación (Kambourov y Manovskii, 2008) y de cuántas ocupaciones cercanas existen para recibir a la persona (del Rio-Chanona et al., 2021).

6.3. Elección del método

El enfoque es cuantitativo porque el riesgo se expresa como una probabilidad comparable entre carreras, grupos de personas y periodos. El panel rotatorio de la ENOE permite construir trayectorias individuales de hasta cinco trimestres, lo que hace posible estimar matrices de transición, en las que cada celda indica la proporción de personas que pasa de una situación laboral a otra entre dos trimestres. Para explicar esas transiciones se usarán modelos estadísticos con inferencia formal y modelos de aprendizaje automático, en línea con los trabajos que modelan la movilidad con redes ocupacionales (del Rio-Chanona et al., 2021) y con redes neuronales (Meng et al., 2019), y con los que miden la incertidumbre de la predicción del riesgo (Khan y Varshney, 2026).

VII. METODOLOGÍA

Tipo de estudio. Investigación cuantitativa, no experimental y longitudinal, basada en el seguimiento de personas en el panel de la ENOE.

Población y unidades de análisis. Personas de 15 años o más que estudiaron una carrera de los campos 06 o 0532 de la Clasificación Mexicana de Planes de Estudio, o que trabajan en las ocupaciones de informática y ciencia de datos señaladas en el marco teórico, en México. Jalisco se analizará como caso estatal en la medida en que el tamaño de la muestra lo permita. Las unidades de análisis son la persona, observada trimestre a trimestre, la ocupación y la

carrera.

Fuentes de datos. La ENOE (INEGI, 2025) para las trayectorias laborales, la carrera y las características de las personas; la Clasificación Mexicana de Planes de Estudio (INEGI, 2016) y el Sistema Nacional de Clasificación de Ocupaciones (INEGI, 2019) para delimitar carreras y ocupaciones; la base O*NET (National Center for O*NET Development, 2024) para las tareas de cada ocupación; e índices publicados de exposición a la inteligencia artificial (Eloundou et al., 2023; Felten et al., 2023) y de uso observado (Handa et al., 2025).

Procedimiento. El trabajo se organiza en cinco pasos alineados con los objetivos específicos:

1. Delimitación de las carreras y ocupaciones de informática y ciencia de datos, y depuración de los trimestres de la ENOE disponibles antes y después de 2022.
2. Asignación de las tareas de O*NET a las ocupaciones mexicanas mediante tablas de correspondencia y cálculo de su exposición a los modelos de inteligencia artificial.
3. Enlace de los registros de cada persona entre trimestres y construcción de matrices de transición entre ocupaciones, desocupación e inactividad, comparando el periodo anterior y el posterior a 2022.
4. Estimación de modelos de la probabilidad de transición, como regresiones logísticas multinomiales y modelos de diferencias en diferencias que comparen a jóvenes y a personas con experiencia antes y después de 2022, complementados con modelos de aprendizaje automático con validación cruzada y con modelos que estimen la incertidumbre de la predicción, para contrastar H1 y comparar el riesgo entre carreras.
5. Construcción de una red de movilidad con las ocupaciones de destino observadas, para contrastar H2, y elaboración del tablero de visualización del riesgo por carrera.

Herramientas de análisis. Python (pandas, NumPy, statsmodels, scikit-learn y

Matplotlib), SQL Server para la integración de datos y GitHub para el control de versiones y la reproducibilidad del análisis.

VIII. RECURSOS

Recursos humanos. El tesista, responsable del desarrollo del proyecto; el director de tesis, por designar; y la profesora de la unidad de aprendizaje Desarrollo de Proyecto I, que da seguimiento al protocolo.

Recursos materiales. Equipo de cómputo personal, un servidor local con SQL Server para la base de datos del proyecto, software libre para el análisis (Python y sus bibliotecas) y un repositorio en GitHub. Las fuentes de información son públicas y gratuitas.

Recursos económicos. El proyecto no requiere la compra de datos ni de licencias de software. Los costos se limitan al uso del equipo propio y a la conexión a internet, cubiertos por el tesista.

IX. CRONOGRAMA

El cronograma parte del plan registrado en el avance de protocolo de la tesis e incorpora el reenfoque hacia la movilidad laboral en informática y ciencia de datos, con el estado de cada etapa a octubre de 2026.

Tabla 1

Cronograma de actividades del proyecto de tesis

Etapa / actividad	2025B	2026A	2026B	2027A	Estado
Revisión de literatura y antecedentes	Ago-Sep		Oct		En curso
Reenfoque a movilidad laboral en informática y ciencia de datos			Oct-Nov		En curso
Obtención y depuración del panel de la ENOE			Nov-Dic		Pendiente

Etapa / actividad	2025B	2026A	2026B	2027A	Estado
Mapeo de carreras, ocupaciones y tareas (CMPE, SINCO, O*NET)			Nov-Dic		Pendiente
Cálculo de la exposición de las tareas			Dic	Ene	Pendiente
Construcción de trayectorias y matrices de transición				Ene-Feb	Pendiente
Estimación y validación de modelos				Feb-Abr	Pendiente
Red de movilidad y tablero por carrera				Abr-May	Pendiente
Escritura y revisión del documento final				May-Jun	Pendiente
Presentación y defensa del trabajo de tesis				Jul 2027	Pendiente

Nota. Elaboración propia con base en el plan del avance de protocolo de la tesis.

X. REFERENCIAS BIBLIOGRÁFICAS

Acemoglu, D., Autor, D., Hazell, J., & Restrepo, P. (2022). Artificial intelligence and jobs: Evidence from online vacancies. Journal of Labor Economics, 40(S1), S293-S340. https://doi.org/10.1086/718327

Acemoglu, D., & Restrepo, P. (2019). Automation and new tasks: How technology displaces and reinstates labor. Journal of Economic Perspectives, 33(2), 3-30. https://doi.org/10.1257/jep.33.2.3

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The skill content of recent technological change: An empirical exploration. The Quarterly Journal of Economics, 118(4), 1279-1333. https://doi.org/10.1162/003355303322552801

Broady, K. E., Dunson, C., & Barr, A. (2026). Rethinking automation risk: AI applicability and occupational outcomes, 2019-24 (Working Paper 2026-12). Federal Reserve Bank of Chicago. https://doi.org/10.21033/wp-2026-12

Brynjolfsson, E., Chandar, B., & Chen, R. (2026). Canaries in the coal mine? Six facts about the recent employment effects of artificial intelligence [Documento de trabajo, versión de agosto de 2026]. Stanford Digital Economy Lab. https://digitaleconomy.stanford.edu/publications/canaries-in-the-coal-mine/

Chen, N., Li, Z., & Tang, B. (2022). Can digital skill protect against job displacement risk caused by artificial intelligence? Empirical evidence from 701 detailed occupations. PLOS ONE, 17(11), e0277280. https://doi.org/10.1371/journal.pone.0277280

Dahlin, E. (2024). Who says artificial intelligence is stealing our jobs? Socius, 10. https://doi.org/10.1177/23780231241259672

del Rio-Chanona, R. M., Mealy, P., Beguerisse-Díaz, M., Lafond, F., & Farmer, J. D. (2021). Occupational mobility and automation: A data-driven network model. Journal of the Royal Society Interface, 18(174), 20200898. https://doi.org/10.1098/rsif.2020.0898

Eloundou, T., Manning, S., Mishkin, P., & Rock, D. (2023). GPTs are GPTs: An early look at the labor market impact potential of large language models. arXiv. https://arxiv.org/abs/2303.10130

Felten, E., Raj, M., & Seamans, R. (2023). How will language modelers like ChatGPT affect occupations and industries? arXiv. https://arxiv.org/abs/2303.01157

Frank, M. R., Ahn, Y.-Y., & Moro, E. (2025). AI exposure predicts unemployment risk: A new approach to technology-driven job loss. PNAS Nexus, 4(4), pgaf107. https://doi.org/10.1093/pnasnexus/pgaf107

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? Technological Forecasting and Social Change, 114, 254-280. https://doi.org/10.1016/j.techfore.2016.08.019

Gao, S., & Huang, M. (2026). Bounded by risk, not capability: Quantifying AI occupational substitution rates via a tech-risk dual-factor model. arXiv. https://doi.org/10.48550/arXiv.2604.04464

Georgieff, A., & Hyee, R. (2022). Artificial intelligence and employment: New cross-country evidence. Frontiers in Artificial Intelligence, 5, 832736. https://doi.org/10.3389/frai.2022.832736

Handa, K., Tamkin, A., McCain, M., Huang, S., Durmus, E., Heck, S., Mueller, J., Hong, J., Ritchie, S., Belonax, T., Troy, K. K., Amodei, D., Kaplan, J., Clark, J., & Ganguli, D. (2025). Which economic tasks are performed with AI? Evidence from millions of Claude conversations. arXiv. https://arxiv.org/abs/2503.04761

Instituto Nacional de Estadística y Geografía. (2016). Clasificación mexicana de planes de estudio por campos de formación académica 2016: Educación superior y media superior. INEGI.

Instituto Nacional de Estadística y Geografía. (2019). Sistema Nacional de Clasificación de Ocupaciones (SINCO) 2019. INEGI.

Instituto Nacional de Estadística y Geografía. (2025). Encuesta Nacional de Ocupación y Empleo 2025, cuestionario ampliado, primer trimestre [Metadatos y bases de datos].

Red Nacional de Metadatos. https://www.inegi.org.mx/rnm/index.php/catalog/1104

Kambourov, G., & Manovskii, I. (2008). Rising occupational and industry mobility in the United States: 1968-97. International Economic Review, 49(1), 41-79. https://doi.org/10.1111/j.1468-2354.2008.00473.x

Khan, I. R., & Varshney, M. (2026). Dynamic uncertainty-aware Bayesian neural model for real-time workforce displacement risk under AI automation. International Journal of Computer Information Systems and Industrial Management Applications. https://doi.org/10.70917/ijcisim-2026-4563

Meng, Q., Zhu, H., Xiao, K., Zhang, L., & Xiong, H. (2019). A hierarchical career-path-aware neural network for job mobility prediction. En Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (pp. 14-24). ACM. https://doi.org/10.1145/3292500.3330969

National Center for O*NET Development. (2024). O*NET 28.3 Database [Base de datos]. U.S. Department of Labor. https://www.onetcenter.org/database.html

Paolillo, A., Colella, F., Nosengo, N., Schiano, F., Stewart, W., Zambrano, D., Chappuis, I., Lalive, R., & Floreano, D. (2022). How to compete with robots by assessing job automation risks and resilient alternatives. Science Robotics, 7(65), eabg5561. https://doi.org/10.1126/scirobotics.abg5561

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30. https://arxiv.org/abs/1706.03762

Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., . . . Wen, J.-R. (2023). A survey of large language models. arXiv. https://arxiv.org/abs/2303.18223