Reducción dimensional y cuantización

Problemas con Big Data

Un gran conjunto de datos **no implica una mayor dispersión (varianza) de las variables que lo componen**. De hecho, es común que se presenten las siguientes situaciones:

- Redundancia (duplicidad de valores)
- Ruido (ligeras variaciones de valores centrales)
- Irrelevancia (variables no aportan información)

Caso de estudio: Google Trends

El número de búsquedas diarias que se realiza a nivel mundial en el buscador de Internet Google es enorme: aproximadamente ~ 1G. ¿ Cómo se visualiza un gran volumen de información como este ?

https://trends.google.com/trends/

K-Medias

Algoritmo de clasificación no supervisada que permite agrupar un conjunto de datos en k grupos

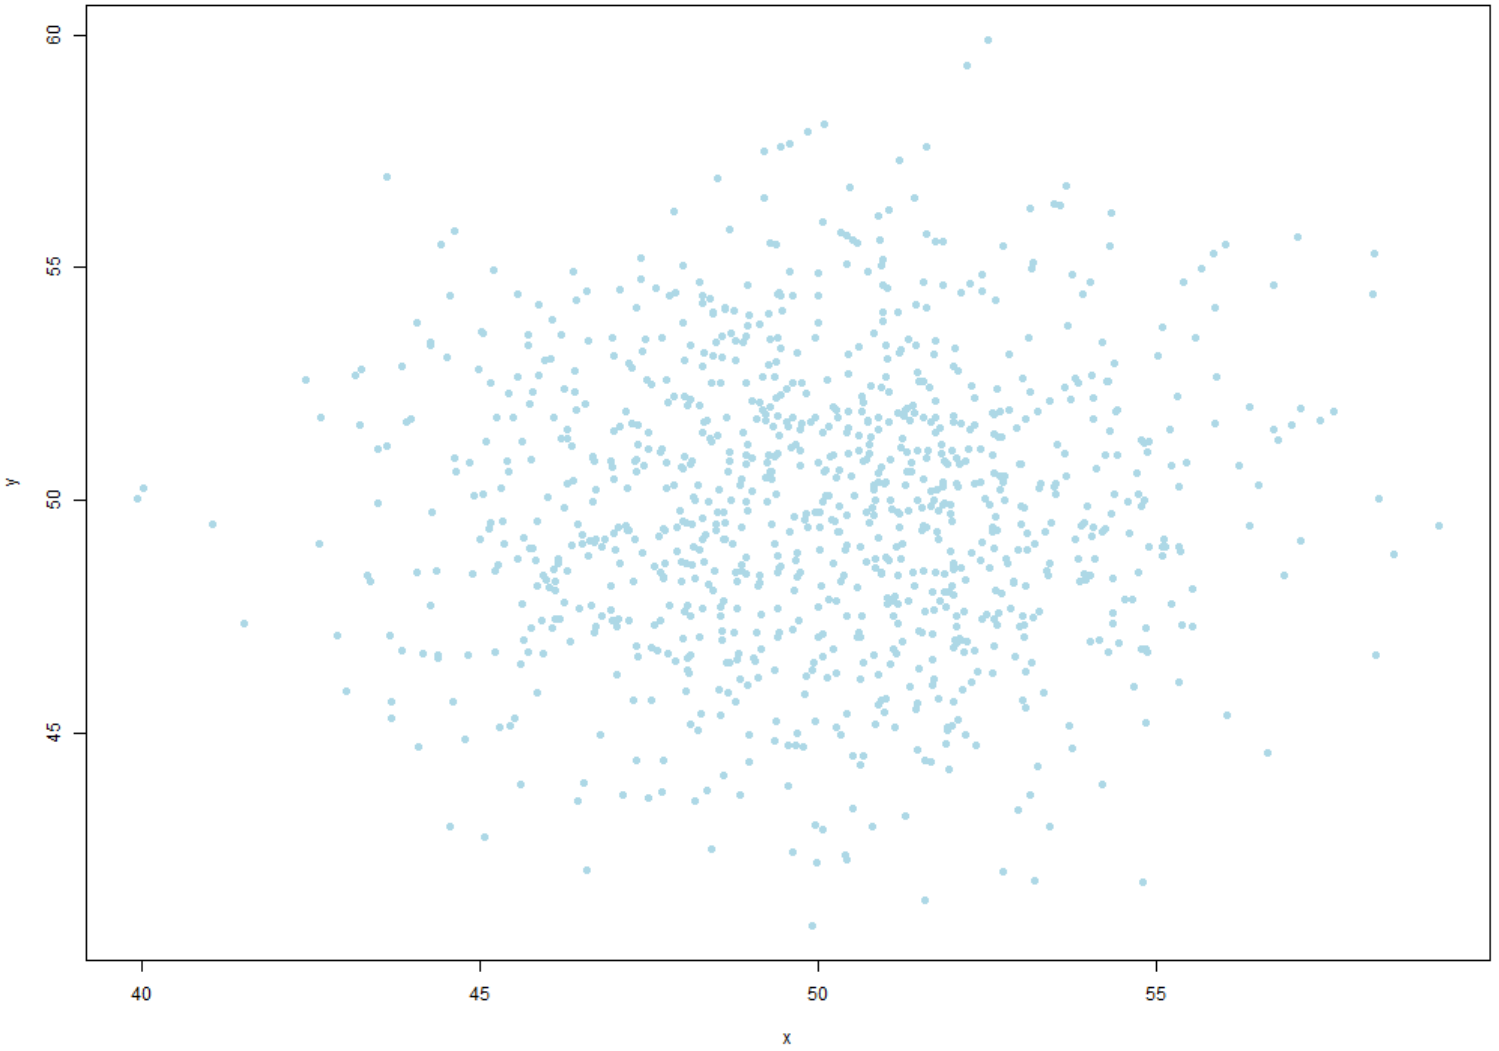
$$\forall\, c \in C, J = \sum_{j=1}^{k} \sum_{i^j=1}^{n^j} \| x_i^j - c_j \|^2$$

Métrica de distancia: Euclidiana

La métrica utilizada por K-Medias **para medir las distancia que existe entre un vector x^j y un centro^j es la distancia Euclidiana**

$$d\left(x^j, c^j\right) = \sqrt{\sum \left(x_i^j - c_i^j\right)^2}$$

Ejemplo: agrupar X → N(50, 3) en k agrupaciones



Ejemplo: agrupar X → N(50, 3) en k agrupaciones

