Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 3er Semestre
Materia: Visualización de Grandes Bases de Datos

Tarea 1.4. Correlación lineal entre el NO_2 y otros contaminantes
Estación de monitoreo Centro, Zona Metropolitana de Guadalajara, 2024

Alumno:	Carlos Pulido Rosas
Fecha:	24 de septiembre de 2026
Actividad:	Tarea 1.4. Correlación con NO_2
Herramienta:	Python 3.13 (pandas, NumPy, Matplotlib, statsmodels)
Versión:	SIMAJ, base de calidad del aire 2024 (BD_2024)
Entorno:	Equipo personal, entorno conda MCD
Dataset:	Calidad del aire ZMG 2024, estación Centro (CEN)

1. Introducción

El dióxido de nitrógeno (NO_2) es uno de los contaminantes criterio que se asocian con mayor claridad a las emisiones del tránsito vehicular. En esta actividad se busca identificar cuál de los contaminantes registrados por la red de monitoreo guarda la relación lineal más fuerte con el NO_2, a partir del coeficiente de correlación de Pearson, y sustentar el resultado mediante gráficas de dispersión y rectas de regresión. Siguiendo los temas de la sesión 6, el análisis se complementa con una revisión de la linealidad de las relaciones y con un modelo para una variable de respuesta discreta. Los datos provienen de la base horaria de calidad del aire de 2024 del Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ).

1.1 Estación de monitoreo

En las tareas 1.0 a 1.2 se trabajó con la estación Country, por ser la más próxima a mi domicilio. Al revisar la base, sin embargo, se comprobó que esta estación no reporta mediciones de NO_2 durante 2024, lo que impide realizar el análisis solicitado. Por ese motivo se utilizó la estación Centro, ya empleada en la Tarea 1.3, que cuenta con 2,706 registros horarios de NO_2 y mide además O_3, NO, NOx, CO, PM10 y PM2.5. El SO_2 no se registra en esta estación, por lo que quedó fuera del análisis.

2. Metodología

2.1 Covarianza y coeficiente de correlación

La covarianza mide el grado en que dos variables varían de manera conjunta respecto a sus medias. Su signo indica el sentido de la relación, pero su magnitud depende de las unidades de medición, por lo que no permite comparar pares de variables expresadas en escalas distintas. El coeficiente de correlación de Pearson resuelve esta limitación al estandarizar la covarianza por la dispersión de ambas variables. Su valor se ubica entre −1 y 1: los extremos corresponden a una relación lineal perfecta, negativa o positiva, y los valores cercanos a cero indican ausencia de relación lineal. Ambos estadísticos se calcularon con las expresiones vistas en clase (Figura 1), considerando para cada par únicamente las horas en que las dos variables tienen lectura válida.

$$cov(X, Y) = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{n}$$

$$r_{X,Y} = \frac{\sum x_i y_i - \frac{\sum x_i \sum y_i}{n}}{\sqrt{\sum x_i^2 - \frac{(\sum x_i)^2}{n}} \sqrt{\sum y_i^2 - \frac{(\sum y_i)^2}{n}}}$$

Figura 1. Expresiones de la covarianza y del coeficiente de correlación lineal de Pearson.

2.2 Recta de regresión y coeficiente de determinación

Para cada contaminante X se ajustó por mínimos cuadrados ordinarios la recta $NO_2 = b_0 + b_1X$. El coeficiente de determinación (R^2) indica la proporción de la variabilidad del NO_2 que reproduce el modelo; en la regresión lineal simple coincide con el cuadrado de r.

2.3 Linealidad de la relación

Un coeficiente de correlación moderado no implica necesariamente que la asociación sea débil, ya que la relación puede existir sin seguir una línea recta. Para valorar este aspecto, en el NOx, el CO y el O_3 se compararon tres especificaciones con base en su R^2: lineal ($\hat{y} = b_0 + b_1x$), logarítmica ($\hat{y} = b_0 + b_1 \cdot \log x$) y cuadrática ($\hat{y} = b_0 + b_1x + b_2x^2$).

2.4 Variable continua y variable discreta

Por último, el NO_2 se transformó en una variable binaria que distingue las horas de concentración alta, definidas como aquellas que superan el percentil 90 (0.042 ppm), del resto de las observaciones. La relación entre esta variable y el CO se modeló mediante una regresión logística, P(Y = 1 | x) = 1 / (1 + e^−($b_0 + b_1x$)), que estima la probabilidad de una hora con NO_2 alto en función de la concentración de CO.

3. Resultados

3.1 Correlación lineal con el NO_2

La Tabla 1 resume los estadísticos de cada par, ordenados por el valor absoluto de r. Las covarianzas confirman el sentido de cada relación, pero sus magnitudes no son comparables entre sí. La del PM10 (0.3337) es varios cientos de veces mayor que la del NOx (0.000542) únicamente porque las partículas se expresan en µg/m³ y presentan mayor variabilidad absoluta. Por esa razón, la comparación entre contaminantes se basa en el coeficiente de correlación.

Contaminante	r de Pearson	Covarianza	R^2	Pares (n)
NOx (óxidos de nitrógeno)	**+0.814**	**0.000542**	**0.662**	**2,700**
CO (monóxido de carbono)	+0.806	0.010437	0.649	2,706
PM10 (partículas < 10 µm)	+0.696	0.333678	0.484	2,651
NO (monóxido de nitrógeno)	+0.650	0.000331	0.422	2,694
O_3 (ozono)	-0.591	-0.000171	0.349	2,412
PM2.5 (partículas < 2.5 µm)	+0.572	0.129150	0.327	2,666

Tabla 1. Covarianza, correlación lineal y R^2 de cada contaminante con el NO_2, estación Centro, 2024.

La Figura 2 presenta las gráficas de dispersión con su recta de regresión y el valor de r en el encabezado de cada panel.

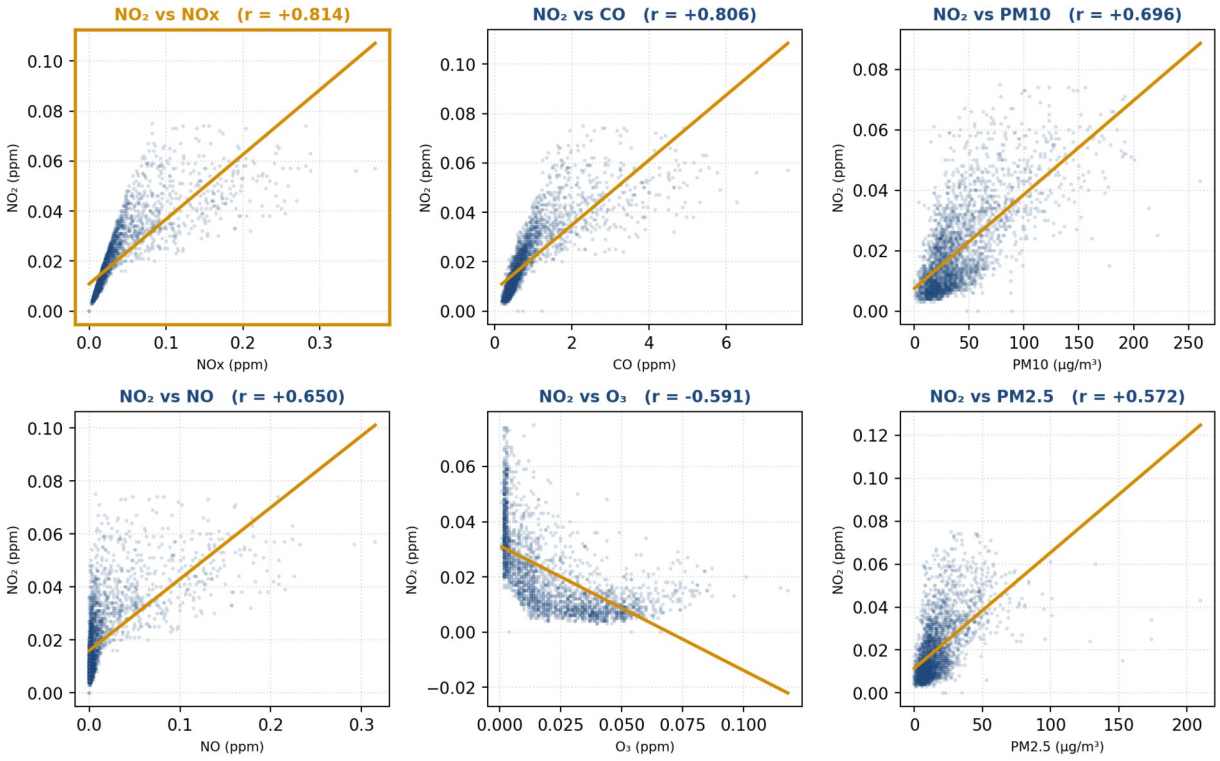


Figura 2. Gráficas de dispersión y rectas de regresión del NO_2 frente a cada contaminante, estación Centro, 2024. El panel con borde ámbar corresponde a la correlación más alta.

Con excepción del O_3, todos los contaminantes presentan correlación positiva: la nube de puntos asciende hacia la derecha y la pendiente de la recta es positiva. El O_3 muestra el patrón inverso. Los coeficientes más altos corresponden al NOx (r =

0.814) y al CO (r = 0.806), cuyas nubes son también las más compactas alrededor de la recta. En el PM10, el NO y el PM2.5 la dispersión es mayor, lo que concuerda con correlaciones de intensidad moderada.

3.2 ¿Relación lineal o no lineal?

En los paneles del NOx y del CO, la recta se ajusta bien en las concentraciones bajas, pero sobrestima el NO_2 en los valores altos, donde los puntos quedan sistemáticamente por debajo de ella. Este patrón sugiere una relación cóncava, por lo que se compararon las tres especificaciones descritas en la metodología (Tabla 2 y Figura 3).

Contaminante	R^2 lineal	R^2 logarítmico	R^2 cuadrático
NOx (óxidos de nitrógeno)	0.662	0.841	0.801
CO (monóxido de carbono)	0.649	0.811	0.788
O_3 (ozono)	0.349	0.522	0.502

Tabla 2. Comparación del ajuste de los modelos lineal, logarítmico y cuadrático para el NO_2.

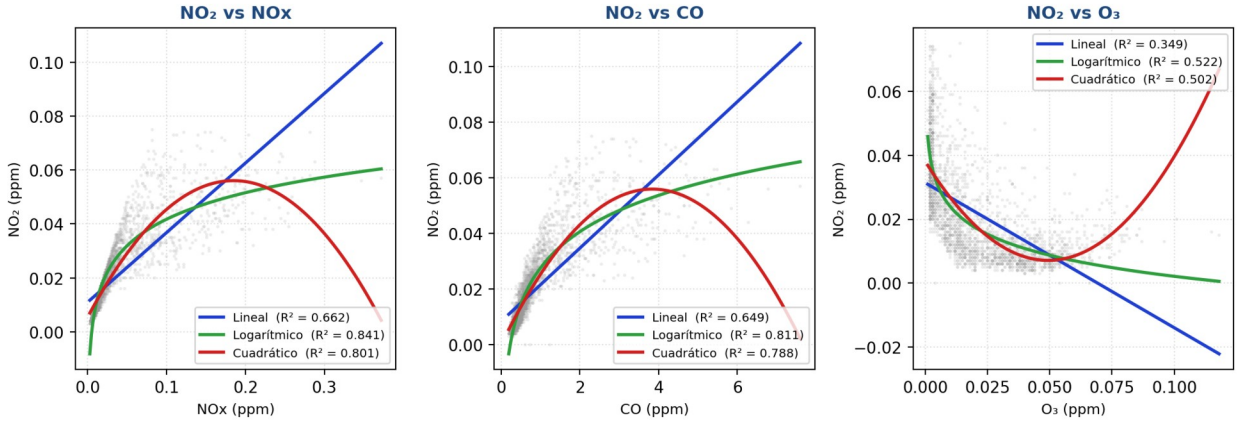


Figura 3. Ajustes lineal, logarítmico y cuadrático del NO_2 frente al NOx, el CO y el O_3, estación Centro, 2024.

En los tres casos el modelo logarítmico obtiene el mayor R^2. Para el NOx, la proporción de variabilidad explicada pasa de 0.662 con la recta a 0.841, y para el CO, de 0.649 a 0.811. La curva logarítmica sigue la forma de la nube con mucha mayor fidelidad que la recta, lo que indica que el coeficiente de Pearson, al medir solo la componente lineal, subestima la intensidad de la asociación. El NO_2 crece con rapidez cuando el NOx o el CO aumentan desde niveles bajos y lo hace de forma más gradual en concentraciones altas. Este comportamiento es compatible con la química de la atmósfera urbana: las emisiones vehiculares recientes están compuestas sobre todo por NO, cuya oxidación a NO_2 depende de la disponibilidad de ozono y otros oxidantes, de manera que en los episodios de mayor emisión la proporción de NO_2 dentro del NOx disminuye. El modelo cuadrático también mejora el ajuste, aunque en menor medida, y su forma de parábola hace que la curva descienda dentro del propio rango observado, algo que carece de interpretación física para estos contaminantes.

3.3 Probabilidad de horas con NO_2 alto

De las 2,706 horas con lectura de ambos contaminantes, 263 superan el percentil 90 del NO_2. La Figura 4 muestra la regresión logística ajustada entre esta variable binaria y el CO.

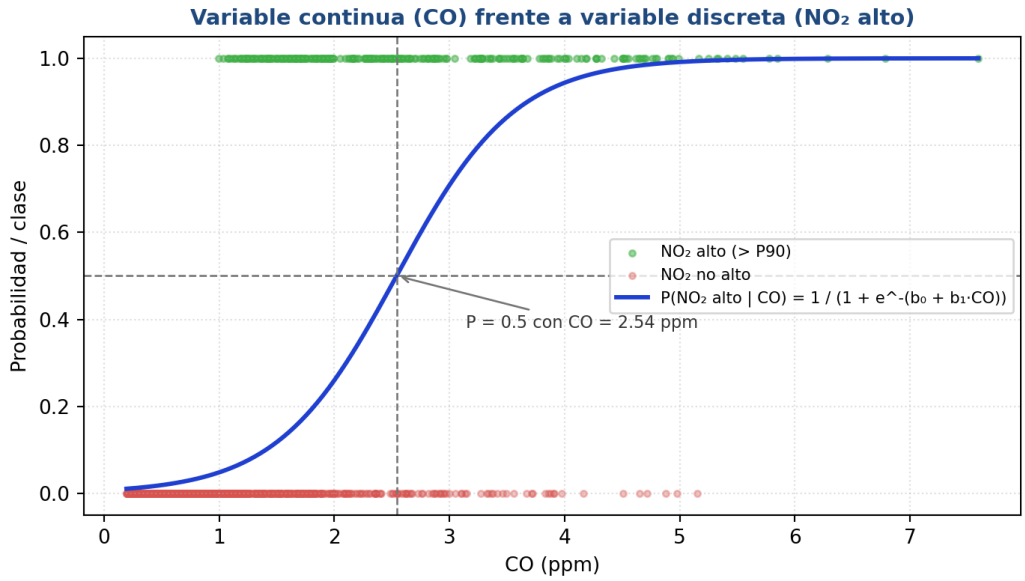


Figura 4. Regresión logística de la probabilidad de una hora con NO_2 alto en función de la concentración de CO, estación Centro, 2024.

La probabilidad estimada es inferior a 5 % cuando el CO no rebasa 1 ppm, crece con rapidez a partir de ese nivel y alcanza 50 % cuando el CO llega a 2.54 ppm. El modelo obtiene un pseudo R^2 de McFadden de 0.459, valor que indica un buen ajuste para este tipo de regresión. El resultado complementa el análisis de correlación: además de variar en la misma dirección, las concentraciones altas de CO permiten anticipar con buena probabilidad las horas de mayor concentración de NO_2.

4. Conclusiones

El contaminante con el mayor coeficiente de correlación lineal con el NO_2 en la estación Centro es el NOx (r = 0.814). Este resultado debe interpretarse con reserva, ya que el NOx se calcula como la suma de NO y NO_2 y, por lo tanto, contiene a la variable con la que se compara. Una parte de la correlación obedece, entonces, a la forma en que está definido el indicador.

Entre los contaminantes que no incluyen al NO_2 en su cálculo, el CO presenta la correlación más alta (r = 0.806), prácticamente igual a la del NOx. La afinidad entre ambos se explica porque comparten su principal fuente, la combustión en vehículos automotores, y responden de la misma forma a las condiciones de dispersión de la atmósfera. El O_3, en cambio, se relaciona de manera inversa con el NO_2 (r = -0.591), debido a que su formación fotoquímica ocurre en las horas de mayor radiación solar, cuando el NO_2 desciende.

El análisis de linealidad matiza estos resultados. Las relaciones del NO_2 con el NOx y con el CO son cóncavas, y un modelo logarítmico explica cerca de 84 % y 81 % de la variabilidad del NO_2, frente a 66 % y 65 % de la recta. El coeficiente de Pearson resulta adecuado para jerarquizar a los contaminantes, pero subestima la fuerza de la asociación. La regresión logística, por su parte, confirma que el CO es un buen indicador de las horas con NO_2 alto. En todos los casos se trata de asociaciones estadísticas, que por sí mismas no establecen relaciones de causalidad.

Referencias

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). Applied logistic regression (3.ª ed.). Wiley.

Ruiz Chávez, C. F. (2026). Visualización de grandes bases de datos: Sesión 6 [Diapositivas de clase]. Maestría en Ciencia de los Datos, Centro Universitario de Ciencias Económico Administrativas, Universidad de Guadalajara.

Secretaría de Medio Ambiente y Desarrollo Territorial. (2024). Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ): base de datos de calidad del aire 2024. Gobierno del Estado de Jalisco. https://siga.jalisco.gob.mx/aire/

Seinfeld, J. H., & Pandis, S. N. (2016). Atmospheric chemistry and physics: From air pollution to climate change (3.ª ed.). Wiley.