Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 3er Semestre
Materia: Visualización de Grandes Bases de Datos

Tarea 1.5. Ajustes a la correlación lineal con el NO_2
Estación de monitoreo Centro, Zona Metropolitana de Guadalajara, 2024

Alumno:	Carlos Pulido Rosas
Fecha:	8 de octubre de 2026
Actividad:	Tarea 1.5. Ajustes a la correlación con NO_2
Herramienta:	Python 3.13 (pandas, NumPy, Matplotlib, statsmodels)
Versión:	SIMAJ, base de calidad del aire 2024 (BD_2024)
Entorno:	Equipo personal, entorno conda MCD
Dataset:	Calidad del aire ZMG 2024, estación Centro (CEN)

1. Introducción

En la Tarea 1.4 se identificó el contaminante con mayor correlación lineal con el dióxido de nitrógeno (NO_2) en la estación Centro del Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ). Con base en lo revisado en la sesión 7, en esta actividad se corrigen tres aspectos de aquel análisis: (a) se trabaja con un corpus homogéneo, es decir, con el mismo conjunto de horas para todos los contaminantes; (b) se excluyen los valores atípicos antes de ajustar las regresiones, y (c) las rectas de regresión se fuerzan a pasar por el origen (0, 0). Con los datos ajustados se vuelve a determinar qué contaminante tiene el mayor coeficiente de correlación lineal con el NO_2 y se apoya la respuesta con mapas de calor, gráficas de dispersión, diagramas de caja y rectas de regresión.

2. Metodología

2.1 Corpus homogéneo

En la Tarea 1.4 cada coeficiente se calculó con las horas en que el NO_2 y el contaminante comparado tenían lectura válida, de modo que cada par se basaba en un número distinto de observaciones (entre 2,412 y 2,706) y no necesariamente en las mismas horas. Así, las diferencias entre coeficientes podían deberse en parte a que se comparaban periodos distintos. Además, la estación solo registra NO_2 de septiembre a diciembre de 2024, mientras que el O_3, el CO y las partículas tienen cobertura anual. Para que la comparación sea justa, se conservaron únicamente las horas con lectura válida de las siete variables al mismo tiempo (Tabla 1).

Etapa	Horas	% del total
Registros horarios de la estación Centro, 2024	8,784	100.0 %
Con lectura de NO_2 (septiembre a diciembre)	2,706	30.8 %
Corpus homogéneo (lectura de las siete variables)	2,312	26.3 %
Corpus homogéneo sin valores atípicos	**1,882**	**21.4 %**

Tabla 1. Construcción del corpus de análisis, estación Centro, 2024.

2.2 Exclusión de valores atípicos

Para identificar los valores atípicos se aplicó el criterio de Tukey visto en las tareas 1.0 y 1.1: una lectura es atípica cuando queda fuera del intervalo [Q1 − 1.5·RIC, Q3 + 1.5·RIC], donde RIC = Q3 − Q1. Las cercas se calcularon por variable sobre el corpus homogéneo. Para no perder la homogeneidad, se excluyó toda hora que fuera atípica en al menos una de las siete variables, de forma que todas las regresiones siguen usando exactamente las mismas horas. Como las distribuciones son asimétricas a la derecha, la cerca inferior es negativa en todos los casos y solo se excluyen concentraciones altas (Tabla 2 y Figura 1).

Variable	Q1	Q3	Cerca superior	Horas atípicas
NO_2 (dióxido de nitrógeno)	0.009	0.031	0.0640	28
O_3 (ozono)	0.004	0.035	0.0815	12
NO (monóxido de nitrógeno)	0.001	0.014	0.0335	380
NOx (óxidos de nitrógeno)	0.012	0.047	0.0995	235
CO (monóxido de carbono)	0.433	1.111	2.1280	239
PM10 (partículas < 10 µm)	21.0	56.0	108.5	138
PM2.5 (partículas < 2.5 µm)	8.0	23.0	45.5	138

Tabla 2. Cercas de Tukey y horas atípicas por variable, corpus homogéneo (n = 2,312).

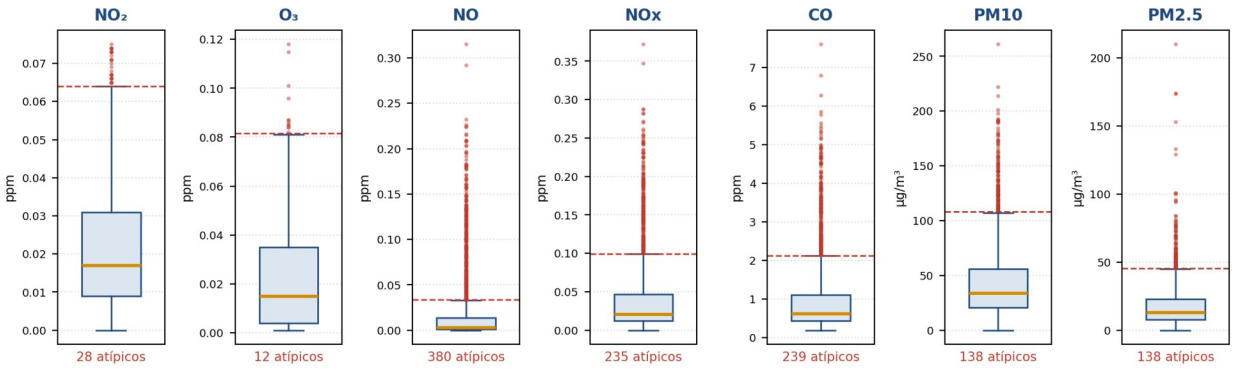


Figura 1. Diagramas de caja de cada variable en el corpus homogéneo. La línea punteada roja marca la cerca superior de Tukey; los puntos rojos son los valores atípicos.

En total se excluyeron 430 horas (18.6 % del corpus homogéneo). El NO concentra la mayor cantidad de atípicos (380), lo que es esperable porque se emite directamente en el escape de los vehículos y presenta picos muy marcados en las horas de

mayor tránsito. Las mismas horas suelen ser atípicas en varias variables a la vez, por eso el número de horas excluidas es menor que la suma de la última columna de la Tabla 2.

2.3 Recta de regresión que cruza por el origen

En lugar de la recta $NO_2 = b_0 + b_1X$ de la Tarea 1.4, se ajustó por mínimos cuadrados el modelo sin intercepto $NO_2 = b \cdot X$, cuya recta pasa por el punto (0, 0). La restricción tiene sentido físico: cuando no hay emisiones de combustión, la concentración esperada de NO_2 debe ser cercana a cero. La pendiente y el coeficiente de determinación se obtienen con las expresiones de la Figura 2. El R^2_0 de un modelo sin intercepto se calcula respecto a cero y no respecto a la media, por lo que su valor no es comparable con el R^2 de una recta con intercepto ni con el cuadrado de r. Por esa razón, la jerarquía de contaminantes se establece con el coeficiente de correlación de Pearson, y la recta por el origen se usa para describir la proporción entre el NO_2 y cada contaminante.

$$\hat{y} = b\,x, \qquad b = \frac{\sum x_i\,y_i}{\sum x_i^2}$$

$$R_0^2 = 1 - \frac{\sum (y_i - b\,x_i)^2}{\sum y_i^2}$$

Figura 2. Pendiente y coeficiente de determinación de la recta de regresión que cruza por el origen.

3. Resultados

3.1 Efecto de los ajustes sobre el coeficiente de correlación

La Tabla 3 muestra cómo cambia el coeficiente de correlación de cada contaminante con el NO_2 en cada etapa del ajuste, y la Figura 3 compara las matrices de correlación de la Tarea 1.4 y de esta tarea mediante mapas de calor.

Contaminante	r Tarea 1.4	r corpus homogéneo	r sin atípicos	Cambio
NOx (óxidos de nitrógeno)	**+0.814**	**+0.809**	**+0.942**	**+0.128**
CO (monóxido de carbono)	+0.806	+0.800	+0.909	+0.103
NO (monóxido de nitrógeno)	+0.650	+0.646	+0.578	-0.072
O_3 (ozono)	-0.591	-0.595	-0.523	+0.068
PM10 (partículas < 10 µm)	+0.696	+0.688	+0.500	-0.196
PM2.5 (partículas < 2.5 µm)	+0.572	+0.560	+0.438	-0.134

Tabla 3. Coeficiente de correlación de Pearson con el NO_2 en cada etapa del ajuste, ordenado por el valor absoluto de r sin atípicos.

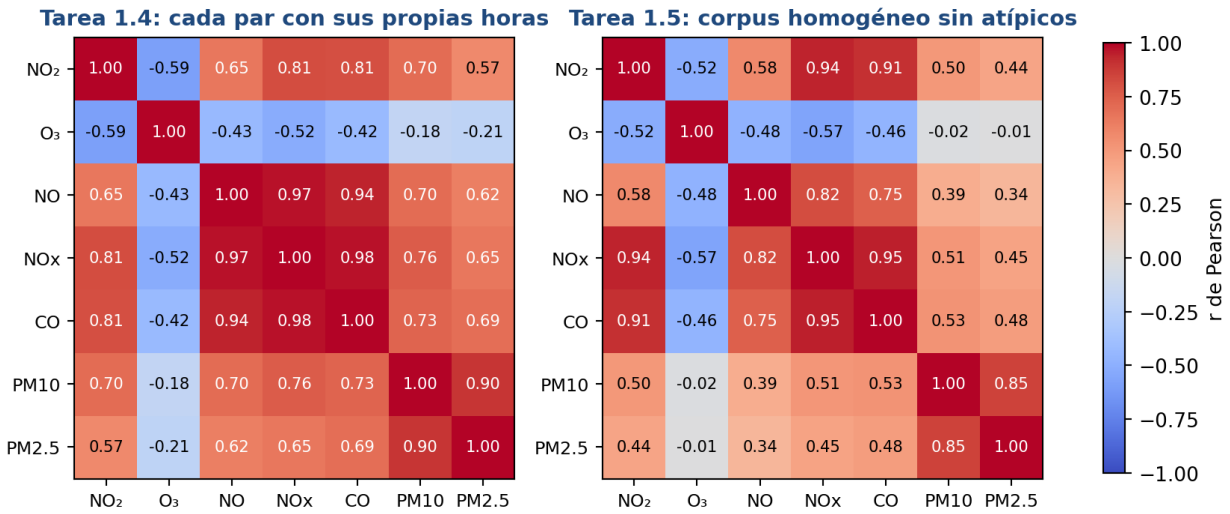


Figura 3. Mapas de calor de la matriz de correlación de Pearson antes (Tarea 1.4) y después de los ajustes (Tarea 1.5).

El paso al corpus homogéneo apenas modifica los coeficientes (cambios menores a 0.02), lo que indica que la diferencia en el número de horas de la Tarea 1.4 no alteraba los resultados de manera importante. La exclusión de atípicos, en cambio, tiene un efecto claro y en dos sentidos opuestos. La correlación del NO_2 con el NOx sube de 0.814 a 0.942 y la del CO de 0.806 a 0.909. En la Tarea 1.4 se observó que estas relaciones son cóncavas: en las concentraciones altas el NO_2 crece más despacio que el NOx y el CO, y los puntos quedan por debajo de la recta. Esos episodios son precisamente los que el criterio de Tukey identifica como atípicos, y al retirarlos la relación que queda es mucho más cercana a una recta. En el NO, el PM10 y el PM2.5 ocurre lo contrario: su correlación disminuye, porque una parte de ella se debía a unas cuantas horas con valores extremos simultáneos en ambas variables, que actuaban como puntos de alta palanca.

3.2 Gráficas de dispersión y rectas por el origen

La Figura 4 presenta las gráficas de dispersión del corpus depurado con la recta que cruza por el origen (ámbar) y, como referencia, la recta con intercepto (gris punteada). La Tabla 4 reúne los estadísticos de ambos modelos.

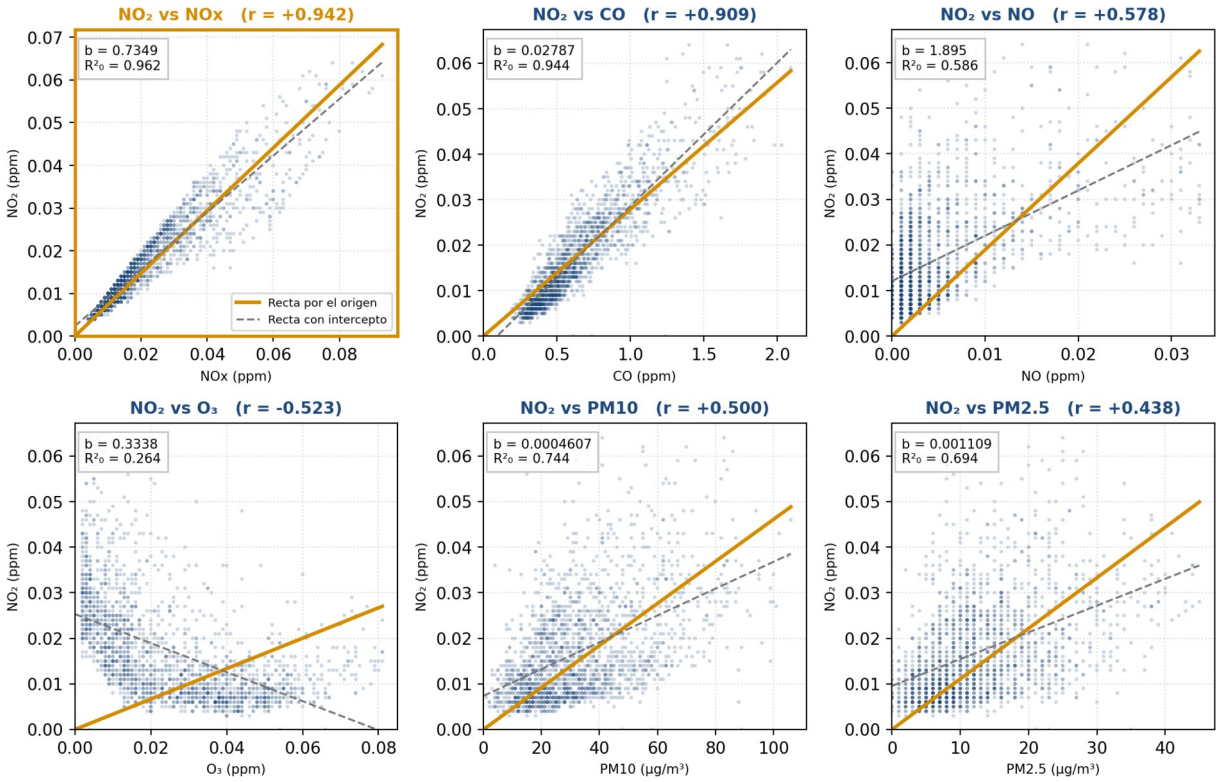


Figura 4. Dispersión del NO_2 frente a cada contaminante con rectas de regresión que cruzan por el origen, corpus homogéneo sin atípicos (n = 1,882). El panel con borde ámbar corresponde a la correlación más alta.

Contaminante	r	b (origen)	R^2_0	b_0 (intercepto)	b_1	R^2
NOx (óxidos de nitrógeno)	**+0.942**	**0.7349**	**0.962**	**+0.0023**	**0.6649**	**0.888**
CO (monóxido de carbono)	+0.909	0.02787	0.944	-0.0029	0.0315	0.826
NO (monóxido de nitrógeno)	+0.578	1.895	0.586	+0.0121	0.9939	0.334
O_3 (ozono)	-0.523	0.3338	0.264	+0.0253	-0.3185	0.273
PM10 (partículas < 10 µm)	+0.500	0.0004607	0.744	+0.0074	0.0002942	0.250
PM2.5 (partículas < 2.5 µm)	+0.438	0.001109	0.694	+0.0096	0.0005874	0.192

Tabla 4. Regresión por el origen y regresión con intercepto del NO_2 sobre cada contaminante, corpus homogéneo sin atípicos.

En el NOx y el CO las dos rectas casi se superponen y el intercepto estimado es muy cercano a cero (+0.0023 y -0.0029 ppm), de modo que la restricción de pasar por el origen es coherente con los datos y casi no cuesta ajuste. La pendiente del NOx (b = 0.735) indica que, en el corpus depurado, el NO_2 representa alrededor de 73.5 % del NOx medido, y la del CO (b = 0.0279) que por cada ppm de CO se observan, en promedio, 27.9 ppb de NO_2.

En el resto de los contaminantes la recta por el origen se separa claramente de la recta con intercepto. El caso más ilustrativo es el O_3: su correlación con el NO_2 es negativa (r = -0.523), pero la recta forzada al origen tiene pendiente positiva (b = 0.334), porque la única forma de acercarse a la nube partiendo de (0, 0) es subir hacia ella. En este caso la restricción contradice la relación observada, lo que confirma que el O_3 no responde a la misma fuente que el NO_2 sino a su consumo fotoquímico. Los

R^2_0 de estas variables son engañosamente altos: calculado respecto a la media, el ajuste de la recta por el origen resulta peor que una línea horizontal en el NO, el O_3 y el PM2.5, ejemplo de por qué el R^2_0 no sirve para comparar contaminantes.

3.3 Dispersión y distribución del NOx y el CO

La Figura 5 combina la gráfica de dispersión con los diagramas de caja de cada eje, como se vio en la sesión 7, para los dos contaminantes con mayor correlación. Las horas excluidas por atípicas aparecen en rojo.

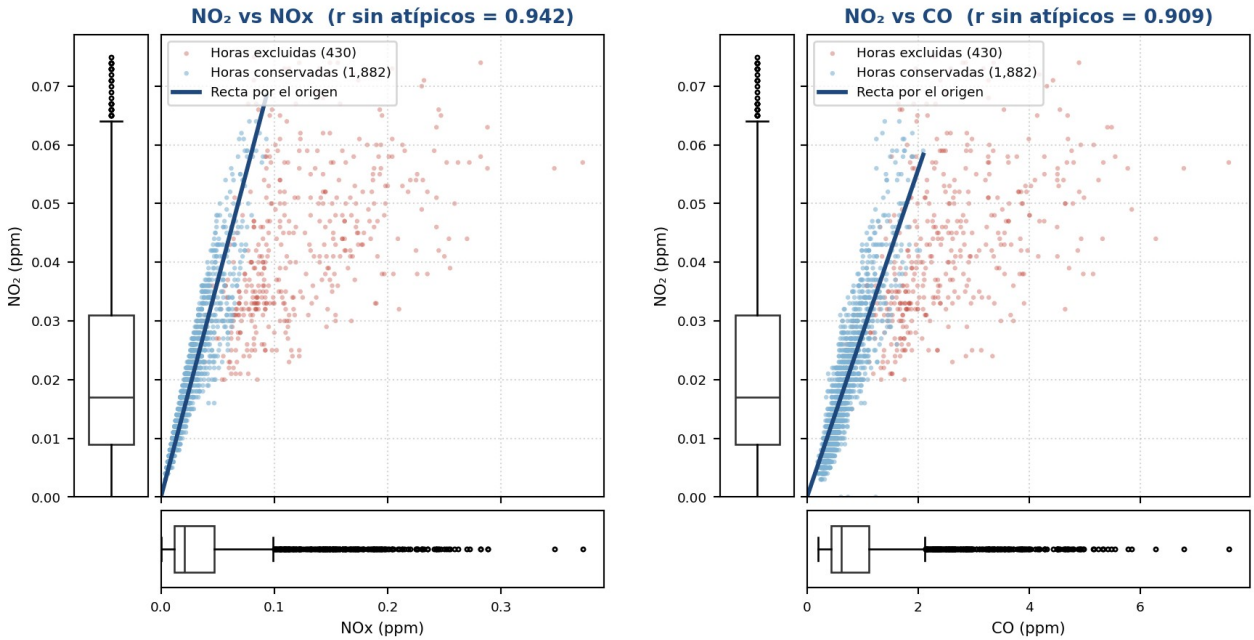


Figura 5. Dispersión del NO_2 frente al NOx y al CO con diagramas de caja marginales, corpus homogéneo. En rojo, las horas excluidas por atípicas; la recta se ajustó solo con las horas conservadas.

Los diagramas de caja muestran que las tres variables tienen una cola larga hacia los valores altos. Las horas excluidas se ubican en esa cola y forman la zona donde la nube se abre y se curva; las horas conservadas siguen una banda estrecha y casi recta que nace en el origen, sobre todo en el caso del NOx. Esta forma explica el aumento de r tras la depuración y confirma visualmente que la recta por el origen es una buena descripción de la relación en el rango habitual de concentraciones.

4. Conclusiones

Después de homogeneizar el corpus, excluir los valores atípicos y ajustar rectas que cruzan por el origen, el contaminante con el mayor coeficiente de correlación lineal con el NO_2 sigue siendo el NOx (r = 0.942, frente a 0.814 en la Tarea 1.4). Como se señaló en la tarea anterior, este resultado debe leerse con cautela, porque el NOx se obtiene como la suma de NO y NO_2 y, por lo tanto, contiene a la variable con la que se compara.

Entre los contaminantes que no incluyen al NO_2 en su cálculo, el de mayor correlación es el CO (r = 0.909), cuya relación con el NO_2 también se fortalece con los ajustes y queda bien descrita por una recta que cruza por el origen (b = 0.0279, intercepto libre de -0.0029 ppm). Ambos contaminantes provienen sobre todo de la combustión vehicular, lo que explica que crezcan de manera proporcional. El O_3 conserva una relación inversa (r = -0.523) y, junto con el NO y las partículas, queda muy por debajo de los dos anteriores.

Los ajustes también muestran que los resultados de la Tarea 1.4 estaban influidos por los valores extremos: en el NOx y el CO ocultaban parte de la relación lineal, mientras que en el NO y las partículas la inflaban. Por último, la recta por el origen solo es adecuada cuando el intercepto libre es cercano a cero, como ocurre con el NOx y el CO; para el O_3 la restricción produce una pendiente con el signo equivocado. En todos los casos se trata de asociaciones estadísticas, que por sí mismas no establecen relaciones de causalidad.

Referencias

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to linear regression analysis (6.ª ed.). Wiley.

Ruiz Chávez, C. F. (2026). Visualización de grandes bases de datos: Sesión 7 [Diapositivas de clase]. Maestría en Ciencia de los Datos, Centro Universitario de Ciencias Económico Administrativas, Universidad de Guadalajara.

Secretaría de Medio Ambiente y Desarrollo Territorial. (2024). Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ): base de datos de calidad del aire 2024. Gobierno del Estado de Jalisco. https://siga.jalisco.gob.mx/aire/

Seinfeld, J. H., & Pandis, S. N. (2016). Atmospheric chemistry and physics: From air pollution to climate change (3.ª ed.). Wiley.

Tukey, J. W. (1977). Exploratory data analysis. Addison-Wesley.