Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 3er Semestre
Materia: Visualización de Grandes Bases de Datos

Tarea 1.6. Imputación del NO_2 y exploración de su relación con el PM10 y el PM2.5
Estación de monitoreo Centro, Zona Metropolitana de Guadalajara, 2024

Alumno:	Carlos Pulido Rosas
Fecha:	13 de octubre de 2026
Actividad:	Tarea 1.6. Exploración entre NO_2 y PM2.5/PM10
Herramienta:	Python 3.13 (pandas, NumPy, Matplotlib, statsmodels)
Versión:	SIMAJ, base de calidad del aire 2024 (BD_2024)
Entorno:	Equipo personal, entorno conda MCD
Dataset:	Calidad del aire ZMG 2024, estación Centro (CEN)

1. Introducción

La estación Centro del Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ) solo registra dióxido de nitrógeno (NO_2) de septiembre a diciembre de 2024: de las 8,784 horas del año, 6,078 (69.2 %) carecen de lectura. Esta tarea tiene dos partes. Primero, se completan los valores faltantes del NO_2 con los modelos de regresión lineal simple construidos en las tareas 1.4 y 1.5. Después, con la serie completada, se explora la relación del NO_2 con las partículas PM10 y PM2.5 mediante gráficas de dispersión entre la variable dependiente y cada variable independiente, gráficas entre las propias variables independientes para detectar colinealidad y modelos de regresión lineal múltiple representados como planos y superficies, siguiendo lo visto en la sesión 8.

2. Imputación de los valores faltantes de NO_2

2.1 Elección de la variable explicativa

En las tareas anteriores el NOx tuvo la correlación más alta con el NO_2, pero no puede usarse para imputar por dos razones: contiene al NO_2 en su cálculo y le faltan exactamente las mismas horas, porque ambos se miden con el mismo analizador. El CO es el contaminante independiente con mayor correlación ($r = 0.909$ en la Tarea 1.5) y además tiene cobertura casi anual. Con él se pueden imputar 5,711 de las 6,078 horas faltantes; las 367 restantes tampoco tienen lectura de CO y se dejaron sin imputar, para no encadenar una estimación sobre otra.

El vacío no es exclusivo de esta estación. De las 13 estaciones de la red SIMAJ en la base de 2024, 12 registran NO_2 y ninguna lo hace antes de agosto, de modo que el hueco de enero a julio afecta a toda la red. Esto justifica estimar los valores faltantes a partir de otro contaminante, pero también impide validar la imputación contra una estación vecina.

2.2 Comparación de los modelos de las tareas 1.4 y 1.5

Se evaluaron los dos modelos simples del NO_2 en función del CO: el de la Tarea 1.4, con intercepto y ajustado con todas las horas (NO_2 = 0.0084 + 0.0132·CO), y el de la Tarea 1.5, que cruza por el origen y se ajustó sin valores atípicos (NO_2 = 0.0279·CO). La Tabla 1 compara sus errores sobre las horas en que el NO_2 sí se observó, separando las horas con CO dentro y fuera de la cerca superior de Tukey (2.128 ppm), que es el límite del rango con el que se estimó el modelo 1.5.

Modelo	RMSE total	RMSE CO ≤ 2.13	RMSE CO > 2.13	Sesgo CO > 2.13	RMSE nov-dic*
Modelo 1.4 (con intercepto)	0.0086	0.0076	0.0157	-0.0040	0.0191
Modelo 1.5 (por el origen)	0.0164	0.0060	0.0517	-0.0440	0.0204
Regla combinada (1.5 y 1.4)	0.0074	0.0060	0.0157	-0.0040	0.0191
Modelo 1.5 acotado	**0.0075**	**0.0060**	**0.0163**	**-0.0116**	**0.0088**

*Tabla 1. Error de imputación (ppm) sobre las 2,706 horas con NO_2 y CO observados; 241 de ellas tienen CO por encima de la cerca. *Validación fuera de muestra: modelos reestimados con septiembre y octubre y evaluados en noviembre y diciembre. Sesgo = observado − estimado.*

Ninguno de los dos modelos es mejor en todo el rango. Dentro de la cerca, el modelo 1.5 tiene menos error que el 1.4 (RMSE de 0.0060 frente a 0.0076 ppm). Fuera de ella, sin embargo, extrapola una recta que nunca vio esas concentraciones y sobrestima el NO_2 en 0.044 ppm en promedio, porque la relación real es cóncava y se aplana en los valores altos, como se observó en la Tarea 1.4. El modelo 1.4, al estimarse con todas las horas, tiene una pendiente menor y se equivoca mucho menos en ese tramo. A partir de esto se probaron dos reglas. La primera combina ambos modelos: el 1.5 cuando el CO no rebasa la cerca y el 1.4 cuando la rebasa. La segunda usa solo el modelo 1.5 dentro del rango en el que fue estimado: cuando el CO supera la cerca, el NO_2 estimado se mantiene en el valor que el modelo da en la cerca (0.0593 ppm), en lugar de prolongar la recta.

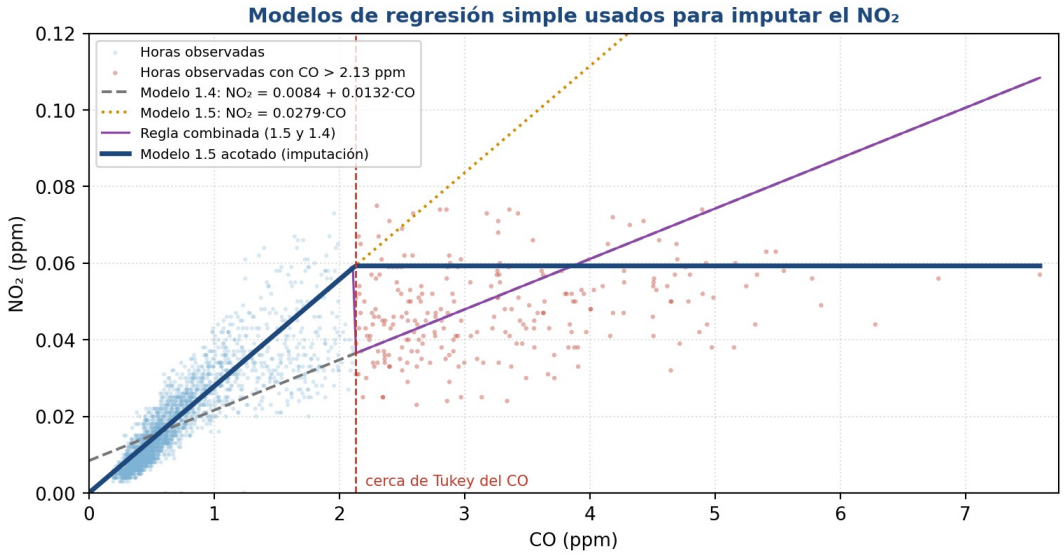


Figura 1. Modelos de regresión simple del NO_2 en función del CO y reglas de imputación evaluadas. La línea azul gruesa es la regla adoptada.

Con los mismos datos con los que se estimaron, la regla combinada obtiene el menor error (RMSE de 0.0074 ppm, frente a 0.0075 del modelo acotado), pero tiene un salto en la cerca: al pasar de un modelo a otro, el NO_2 estimado cae de 0.059 a 0.036 ppm, algo que no tiene sentido físico. La validación fuera de muestra, en la que los modelos se reestiman con septiembre y octubre y se aplican a noviembre y diciembre, resuelve la elección. Los tres esquemas que prolongan una recta

tienen errores parecidos y altos (RMSE cercano a 0.019 ppm), mientras que el modelo 1.5 acotado reduce el error a 0.0088 ppm, menos de la mitad. Cuando el CO alcanza valores que el modelo no conoce, es más seguro no extrapolar. Por eso se adoptó el modelo 1.5 acotado para la imputación. Aun así, la relación entre el NO_2 y el CO cambia de un mes a otro, por lo que los valores imputados deben tomarse como una aproximación y no como mediciones.

2.3 Serie completada

Se imputaron 5,711 horas; en 446 de ellas el CO superaba la cerca y el NO_2 se fijó en el valor del límite. La Figura 2 muestra la serie diaria resultante y la Tabla 2 los promedios mensuales.



Figura 2. Promedio diario de NO_2 observado (septiembre a diciembre) e imputado a partir del CO, estación Centro, 2024.

Mes	Horas observadas	Horas imputadas	NO_2 observado	NO_2 completado
Enero	0	711		0.0409
Febrero	0	692		0.0348
Marzo	0	741		0.0302
Abril	0	706		0.0269
Mayo	0	742		0.0263
Junio	0	720		0.0244
Julio	0	688		0.0264
Agosto	0	653		0.0156
Septiembre	535	32	0.0123	0.0122
Octubre	720	13	0.0185	0.0183
Noviembre	717	3	0.0227	0.0226
Diciembre	734	10	0.0261	0.0263

Tabla 2. Horas observadas e imputadas y promedio mensual de NO_2 (ppm).

En septiembre a diciembre los promedios casi no cambian, porque solo se completaron 222 horas sueltas. De enero a agosto toda la información proviene del CO. El patrón que resulta es razonable: el promedio más alto se da en enero (0.0409 ppm) y desciende hacia el verano, lo que coincide con la temporada seca e invernal, en la que las inversiones térmicas dificultan la dispersión de los contaminantes en Guadalajara, y con la temporada de lluvias, que la favorece. Aun así, ese comportamiento es heredado del CO y no puede verificarse, porque no existen mediciones de NO_2 en esos meses.

3. Relación del NO_2 con el PM10 y el PM2.5

3.1 Las partículas PM10 y PM2.5

Las partículas suspendidas, o material particulado (PM, por sus siglas en inglés), son una mezcla de partículas sólidas y gotas líquidas que permanecen en el aire. Se clasifican por su diámetro aerodinámico: el PM10 agrupa a las partículas de 10 µm o menos y el PM2.5 a las de 2.5 µm o menos, unas treinta veces más delgadas que un cabello humano. Por definición, el PM2.5 es una fracción del PM10; la diferencia entre ambos corresponde a la llamada fracción gruesa, de entre 2.5 y 10 µm. A diferencia del NO_2 o del CO, que son gases, ambas se miden en masa por volumen de aire (µg/m³) (Seinfeld y Pandis, 2016).

Sus fuentes son distintas. La fracción gruesa proviene sobre todo de procesos mecánicos: polvo resuspendido por el viento y el tránsito en calles sin pavimentar, construcción, erosión del suelo y desgaste de llantas y frenos. El PM2.5, en cambio, se origina principalmente en la combustión (motores, en particular los de diésel, quemas agrícolas e industria) y en la formación secundaria, es decir, en partículas que se forman en la atmósfera a partir de gases precursores. Entre esos precursores están los óxidos de nitrógeno: el NO_2 se oxida a ácido nítrico, que al reaccionar con el amoniaco forma nitrato de amonio, una sal que pasa a formar parte del PM2.5 (Seinfeld y Pandis, 2016). Por eso se espera que el NO_2 se relacione con las partículas finas a través de dos vías: la fuente vehicular que comparten y la química atmosférica.

Su efecto en la salud depende del tamaño. El PM10 llega a las vías respiratorias superiores y a los bronquios, mientras que el PM2.5 alcanza los alvéolos pulmonares y puede pasar al torrente sanguíneo, por lo que se asocia con enfermedades respiratorias, cardiovasculares y con mortalidad prematura. La Organización Mundial de la Salud (OMS, 2021) recomienda que el promedio de 24 horas no rebase 45 µg/m³ de PM10 ni 15 µg/m³ de PM2.5. En la estación Centro, durante 2024, el PM10 promedió 40.1 µg/m³ y el PM2.5 17.1 µg/m³; el promedio diario superó la recomendación de la OMS en 123 de 350 días para el PM10 y en 155 de 336 días para el PM2.5. La mediana del cociente PM2.5/PM10 es de 0.41, lo que indica que algo menos de la mitad de la masa de partículas en esta estación corresponde a la fracción fina.

3.2 Corpus de análisis

Para el análisis se tomaron las horas con NO_2 (observado o imputado), PM10 y PM2.5 al mismo tiempo (6,752) y, como en la Tarea 1.5, se excluyeron las horas atípicas en cualquiera de las tres variables según el criterio de Tukey, con lo que quedaron 6,260 horas, 3,878 de ellas con NO_2 imputado. Como control, todos los modelos se estimaron también con las horas de NO_2 observado únicamente (2,395 horas tras la misma depuración).

3.3 Dispersión entre las variables y colinealidad

La Figura 3 sigue la técnica de la sesión 8: se grafica la variable dependiente contra cada variable independiente y, además, las variables independientes entre sí. La Tabla 3 reúne los coeficientes de correlación.

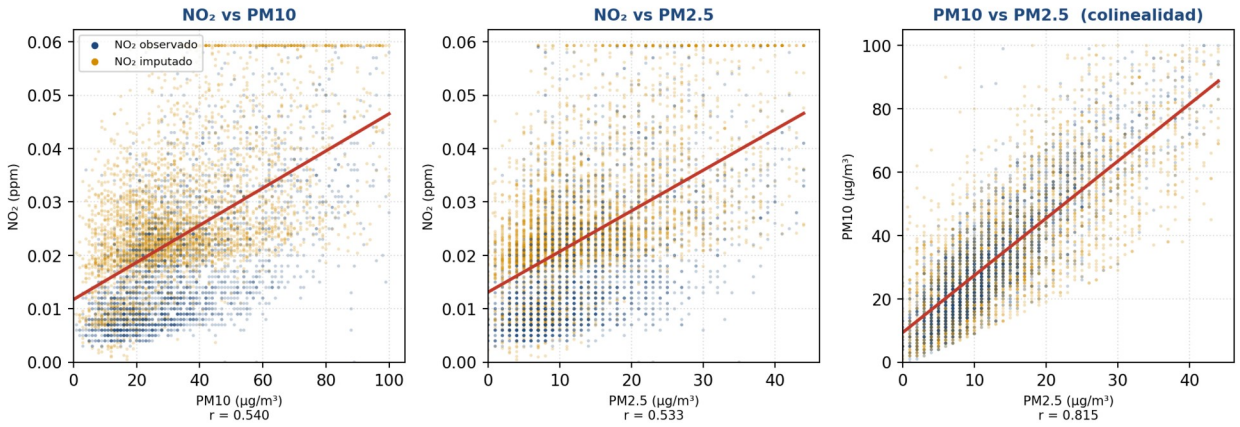


Figura 3. Dispersión del NO_2 frente al PM10 y al PM2.5, y del PM10 frente al PM2.5, serie completada sin atípicos. Los puntos ámbar son horas con NO_2 imputado.

Par de variables	r serie completada	r solo observadas
NO_2 – PM10	0.540	0.604
NO_2 – PM2.5	0.533	0.541
PM10 – PM2.5	**0.815**	**0.876**
VIF de PM10 y PM2.5	2.97	4.31

Tabla 3. Correlación de Pearson entre el NO_2 y las partículas, y entre las partículas, corpus sin atípicos.

El NO_2 se relaciona de forma positiva y moderada con ambas partículas, un poco más con el PM10. La relación más fuerte de la tabla, sin embargo, no es la del NO_2 sino la de las partículas entre sí (r = 0.815 en la serie completada y 0.876 con datos observados). No es casual: el PM10 incluye a todas las partículas menores de 10 µm y, por lo tanto, al PM2.5. Las dos variables independientes aportan en buena medida la misma información, que es justamente la colinealidad que la sesión 8 recomienda revisar antes de ajustar un modelo múltiple. El factor de inflación de la varianza (VIF = 1 / (1 − R^2_j)) es de 2.97 y 4.31: no llega al umbral de 5 o 10 que suele considerarse grave, pero indica que la varianza de cada coeficiente se multiplica por tres o cuatro por compartir información con la otra partícula.

3.4 Modelos de regresión lineal múltiple

Se ajustaron cuatro modelos por mínimos cuadrados: los dos simples, el lineal múltiple $NO_2 = b_0 + b_1 \cdot PM10 + b_2 \cdot PM2.5$ y un modelo cuadrático en el PM10, $NO_2 = b_0 + b_1 \cdot PM10 + b_2 \cdot PM10^2 + b_3 \cdot PM2.5$, como el de la sesión 8. Los resultados se presentan en la Tabla 4 y los planos de regresión en la Figura 4.

Serie y modelo	b PM10	b $PM10^2$	b PM2.5	R^2	R^2 ajustado
Completada: simple PM10	0.348	–	–	0.291	0.291
Completada: simple PM2.5	–	–	0.761	0.284	0.284
Completada: múltiple lineal	**0.202**	**–**	**0.396**	**0.317**	**0.317**
Completada: múltiple cuadrático	0.193	0.00011 (p = 0.70)	0.397	0.317	0.317
Observada: simple PM10	0.349	–	–	0.365	0.364
Observada: simple PM2.5	–	–	0.721	0.293	0.293
Observada: múltiple lineal	0.323	–	0.069 (p = 0.12)	0.365	0.365
Observada: múltiple cuadrático	0.321	0.00002 (p = 0.95)	0.069 (p = 0.13)	0.365	0.365

Tabla 4. Coeficientes (ppb de NO_2 por µg/m³; por (µg/m³)² en el término cuadrático) y ajuste de los modelos. Salvo donde se indica el valor p, los coeficientes son significativos al 5 %.

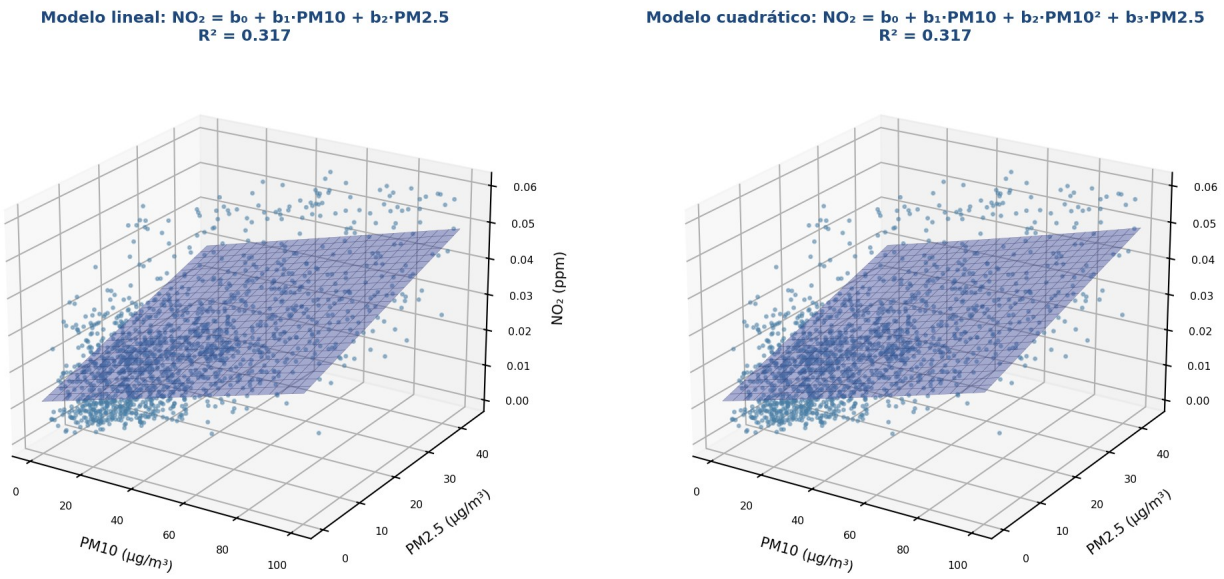


Figura 4. Plano de regresión lineal múltiple y superficie del modelo cuadrático del NO_2 en función del PM10 y el PM2.5, serie completada (muestra de 1,500 horas).

Los coeficientes se leen como el cambio esperado en el NO_2 por cada µg/m³ adicional de partículas. Con los datos observados, un aumento de 10 µg/m³ de PM10 se asocia con 3.5 ppb más de NO_2, y uno de 10 µg/m³ de PM2.5 con 7.2 ppb, frente a un promedio de 18.3 ppb de NO_2 en esas horas. El coeficiente del PM2.5 es mayor porque sus concentraciones son más bajas, de modo que 10 µg/m³ representan un cambio relativo más grande. Estas cifras no significan que las partículas produzcan NO_2: ambas variables aumentan juntas porque comparten fuentes de combustión y porque se acumulan bajo las mismas condiciones meteorológicas, como las inversiones térmicas y la falta de viento.

Con los datos observados, agregar el PM2.5 a un modelo que ya contiene al PM10 no mejora el ajuste (R^2 de 0.365 en ambos casos) y el coeficiente del PM2.5 se vuelve no significativo ($p = 0.12$), aunque en el modelo simple sí lo era. Es el síntoma típico de la colinealidad: una vez que el PM10 está en el modelo, el PM2.5 ya no aporta información propia sobre el NO_2. La Figura 5 lo muestra con claridad: el coeficiente del PM2.5 pasa de 0.721 a 0.069 ppb por µg/m³ y su intervalo de confianza incluye el cero.

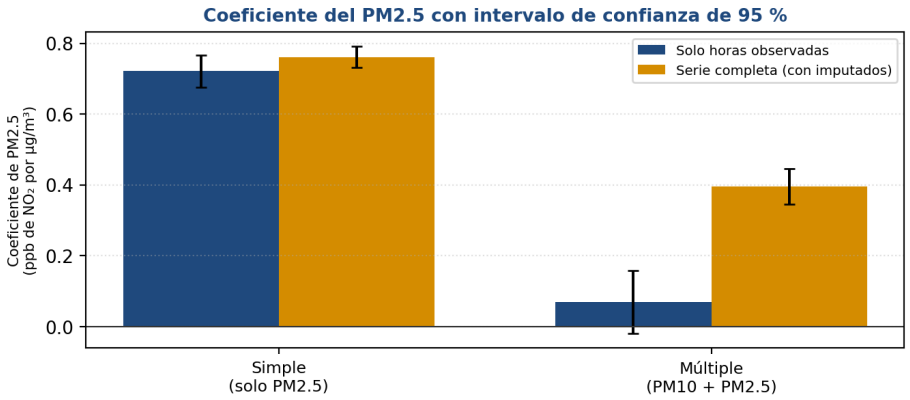


Figura 5. Coeficiente del PM2.5 en el modelo simple y en el múltiple, con su intervalo de confianza de 95 %, para la serie observada y la completada.

En la serie completada ambos coeficientes son significativos y el R^2 sube de 0.291 a 0.317. Esta diferencia debe interpretarse con cuidado. Las horas imputadas no contienen mediciones de NO_2, sino una función lineal del CO, de modo que en esos meses el modelo mide en realidad la relación entre el CO y las partículas, que es más pareja entre el PM10 y el PM2.5 porque

ambos comparten la combustión como fuente. Parte de la información que el PM2.5 parece aportar proviene, entonces, de la imputación y no de los datos observados.

Por último, el término cuadrático no mejora el ajuste en ninguna de las dos series (p = 0.70 y 0.95), y la superficie de la Figura 4 es prácticamente un plano. A diferencia de lo que ocurría con el NOx y el CO, la relación del NO_2 con las partículas no muestra una curvatura relevante una vez excluidos los atípicos. Lo que limita el ajuste es la dispersión de los puntos: las dos partículas juntas explican apenas 31.7 % de la variabilidad del NO_2 en la serie completada.

3.5 Fracción fina y fracción gruesa

La colinealidad entre el PM10 y el PM2.5 tiene una causa conocida: el PM10 contiene al PM2.5. Por eso puede eliminarse sin quitar información, separando el PM10 en sus dos componentes, la fracción fina (PM2.5) y la fracción gruesa (PM10 − PM2.5), y ajustando $NO_2 = b_0 + b_1 \cdot PM2.5 + b_2 \cdot (PM10 - PM2.5)$. Este modelo tiene exactamente el mismo ajuste que el lineal múltiple de la Tabla 4, porque usa la misma información, pero sus dos variables ya no comparten partículas. La correlación entre ellas baja a 0.677 con datos observados y el VIF a 1.84 (Tabla 5).

Serie	b fracción fina (IC 95 %)	b fracción gruesa (IC 95 %)	R^2	VIF
Observada	**0.392 (0.334 a 0.450)**	**0.323 (0.284 a 0.361)**	**0.365**	**1.84**
Completada	0.599 (0.564 a 0.633)	0.202 (0.179 a 0.225)	0.317	1.39

Tabla 5. Modelo del NO_2 con la fracción fina y la fracción gruesa de las partículas (ppb de NO_2 por µg/m³). Todos los coeficientes son significativos al 1 %.

Con la colinealidad resuelta, los dos coeficientes son significativos y sus intervalos de confianza son estrechos. En los datos observados, cada µg/m³ de partículas finas se asocia con 0.392 ppb de NO_2 y cada µg/m³ de partículas gruesas con 0.323 ppb. Ambas fracciones se relacionan con el NO_2 en magnitud parecida, con una ventaja moderada de la fina, coherente con su origen en la combustión. Este resultado precisa la lectura de la sección anterior: que el PM2.5 dejara de ser significativo junto al PM10 no significa que las partículas finas no se relacionen con el NO_2, sino que no lo hacen mucho más que las gruesas. El coeficiente del PM2.5 en el modelo con PM10 mide justamente esa diferencia entre ambas fracciones. En la serie completada la ventaja de la fracción fina es mayor, lo que de nuevo refleja la imputación con CO, un gas de combustión.

En 11 horas observadas y 44 de la serie completada el PM2.5 medido es ligeramente mayor que el PM10, lo que es físicamente imposible y se debe a la incertidumbre de los equipos de medición. Son pocas horas y se conservaron en el análisis.

3.6 Ciclo diario

La Figura 6 compara el perfil horario promedio de cada contaminante, dividido entre su propio promedio para poder verlos en la misma escala. Solo se usaron horas con NO_2 observado, para que el perfil no dependa de la imputación.

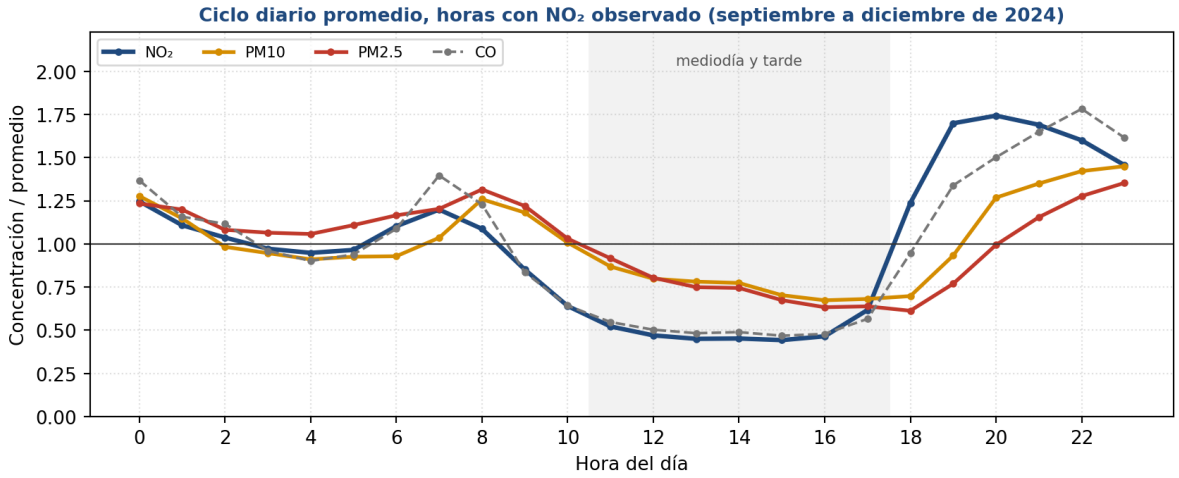


Figura 6. Ciclo diario promedio del NO_2, el PM10, el PM2.5 y el CO, expresado como proporción del promedio de cada variable, estación Centro, septiembre a diciembre de 2024.

Los cuatro contaminantes siguen el mismo patrón general: suben en la mañana, alrededor de las 7 y 8 horas, caen durante el mediodía y la tarde, y vuelven a subir a partir de las 18 o 19 horas hasta la noche. El NO_2 alcanza su mínimo a las 15 horas y su máximo a las 20 horas, con una concentración 3.9 veces mayor. Los picos coinciden con las horas de mayor tránsito, y el descenso del mediodía con el crecimiento de la capa de mezcla de la atmósfera, que diluye los contaminantes cuando el sol calienta el suelo. En el NO_2 la caída es más pronunciada que en las partículas porque, además, en esas horas se consume en las reacciones fotoquímicas que forman ozono. Este ciclo compartido es la explicación más directa de la correlación entre el NO_2 y las partículas: ambos responden a la misma actividad vehicular y a las mismas condiciones de dispersión, sin que uno cause al otro.

4. Conclusiones

La imputación permitió completar 94.0 % de las horas sin NO_2 a partir del CO. Ninguno de los modelos de las tareas anteriores funcionó bien en todo el rango: la recta por el origen de la Tarea 1.5 es la más precisa en las concentraciones habituales, pero sobrestima el NO_2 cuando el CO es alto, porque prolonga una recta fuera del rango con el que fue estimada. Limitarla a ese rango fue la opción que mejor resistió la validación fuera de muestra, con menos de la mitad del error de las alternativas. Aun así, la relación entre ambos contaminantes cambia de un mes a otro, por lo que los ocho meses imputados son una aproximación que no puede contrastarse con mediciones.

El NO_2 mantiene una relación positiva y moderada con las partículas, algo mayor con el PM10. La relación más fuerte entre las variables analizadas es la del PM10 con el PM2.5, y esa colinealidad condiciona el modelo múltiple: con los datos observados, el PM2.5 deja de ser significativo cuando se incluye el PM10 y no mejora el ajuste. Separar el PM10 en fracción fina y fracción gruesa resuelve el problema: con dos variables que ya no se traslapan, ambas resultan significativas y se relacionan con el NO_2 en magnitud parecida, con una ventaja moderada de la fracción fina. El ciclo diario muestra por qué: el NO_2 y las partículas suben con el tránsito de la mañana y la noche y bajan juntos al mediodía, cuando la atmósfera dispersa mejor los contaminantes.

En términos generales, las partículas explican una fracción mucho menor del NO_2 que el CO o el NOx, lo que concuerda con que tienen fuentes más diversas (polvo, construcción, combustión, formación secundaria), mientras que el NO_2 depende sobre todo del tránsito vehicular. Como en las tareas anteriores, se trata de asociaciones estadísticas que no establecen relaciones de causalidad.

Referencias

Little, R. J. A., & Rubin, D. B. (2019). Statistical analysis with missing data (3.ª ed.). Wiley.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to linear regression analysis (6.ª ed.). Wiley.

Organización Mundial de la Salud. (2021). WHO global air quality guidelines: Particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. World Health Organization. https://iris.who.int/handle/10665/345329

Ruiz Chávez, C. F. (2026). Visualización de grandes bases de datos: Sesión 8 [Diapositivas de clase]. Maestría en Ciencia de los Datos, Centro Universitario de Ciencias Económico Administrativas, Universidad de Guadalajara.

Secretaría de Medio Ambiente y Desarrollo Territorial. (2024). Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ): base de datos de calidad del aire 2024. Gobierno del Estado de Jalisco. https://siga.jalisco.gob.mx/aire/

Seinfeld, J. H., & Pandis, S. N. (2016). Atmospheric chemistry and physics: From air pollution to climate change (3.ª ed.). Wiley.