Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 3er Semestre
Materia: Visualización de Grandes Bases de Datos

Tarea 1.6. Imputación del NO_2 y exploración de su relación con el PM10 y el PM2.5
Estación de monitoreo Centro, Zona Metropolitana de Guadalajara, 2024

Alumno:	Carlos Pulido Rosas
Fecha:	13 de octubre de 2026
Actividad:	Tarea 1.6. Exploración entre NO_2 y PM2.5/PM10
Herramienta:	Python 3.13 (pandas, NumPy, Matplotlib, statsmodels)
Versión:	SIMAJ, base de calidad del aire 2024 (BD_2024)
Entorno:	Equipo personal, entorno conda MCD
Dataset:	Calidad del aire ZMG 2024, estación Centro (CEN)

1. Introducción

La estación Centro del Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ) solo registra dióxido de nitrógeno (NO_2) de septiembre a diciembre de 2024: de las 8,784 horas del año, 6,078 (69.2 %) carecen de lectura. Esta tarea tiene dos partes. Primero, se completan los valores faltantes del NO_2 con los modelos de regresión lineal simple construidos en las tareas 1.4 y 1.5. Después, con la serie completada, se explora la relación del NO_2 con las partículas PM10 y PM2.5 mediante gráficas de dispersión entre la variable dependiente y cada variable independiente, gráficas entre las propias variables independientes para detectar colinealidad y modelos de regresión lineal múltiple representados como planos y superficies, siguiendo lo visto en la sesión 8.

2. Imputación de los valores faltantes de NO_2

2.1 Elección de la variable explicativa

En las tareas anteriores el NOx tuvo la correlación más alta con el NO_2, pero no puede usarse para imputar por dos razones: contiene al NO_2 en su cálculo y le faltan exactamente las mismas horas, porque ambos se miden con el mismo analizador. El CO es el contaminante independiente con mayor correlación ($r = 0.909$ en la Tarea 1.5) y además tiene cobertura casi anual. Con él se pueden imputar 5,711 de las 6,078 horas faltantes; las 367 restantes tampoco tienen lectura de CO y se dejaron sin imputar, para no encadenar una estimación sobre otra.

2.2 Comparación de los modelos de las tareas 1.4 y 1.5

Se evaluaron los dos modelos simples del NO_2 en función del CO: el de la Tarea 1.4, con intercepto y ajustado con todas las horas (NO_2 = 0.0084 + 0.0132·CO), y el de la Tarea 1.5, que cruza por el origen y se ajustó sin valores atípicos (NO_2 = 0.0279·CO). La Tabla 1 compara sus errores sobre las horas en que el NO_2 sí se observó, separando las horas con CO dentro y fuera de la cerca superior de Tukey (2.128 ppm), que es el límite del rango con el que se estimó el modelo 1.5.

Modelo	RMSE total	RMSE CO ≤ 2.13	RMSE CO > 2.13	Sesgo CO > 2.13	RMSE nov-dic*
Modelo 1.4 (con intercepto)	0.0086	0.0076	0.0157	-0.0040	0.0191
Modelo 1.5 (por el origen)	0.0164	0.0060	0.0517	-0.0440	0.0204
Regla combinada (1.5 y 1.4)	0.0074	0.0060	0.0157	-0.0040	0.0191
Modelo 1.5 acotado	**0.0075**	**0.0060**	**0.0163**	**-0.0116**	**0.0088**

*Tabla 1. Error de imputación (ppm) sobre las 2,706 horas con NO_2 y CO observados; 241 de ellas tienen CO por encima de la cerca. *Validación fuera de muestra: modelos reestimados con septiembre y octubre y evaluados en noviembre y diciembre. Sesgo = observado − estimado.*

Ninguno de los dos modelos es mejor en todo el rango. Dentro de la cerca, el modelo 1.5 tiene menos error que el 1.4 (RMSE de 0.0060 frente a 0.0076 ppm). Fuera de ella, sin embargo, extrapola una recta que nunca vio esas concentraciones y sobrestima el NO_2 en 0.044 ppm en promedio, porque la relación real es cóncava y se aplana en los valores altos, como se observó en la Tarea 1.4. El modelo 1.4, al estimarse con todas las horas, tiene una pendiente menor y se equivoca mucho menos en ese tramo. A partir de esto se probaron dos reglas. La primera combina ambos modelos: el 1.5 cuando el CO no rebasa la cerca y el 1.4 cuando la rebasa. La segunda usa solo el modelo 1.5 dentro del rango en el que fue estimado: cuando el CO supera la cerca, el NO_2 estimado se mantiene en el valor que el modelo da en la cerca (0.0593 ppm), en lugar de prolongar la recta.

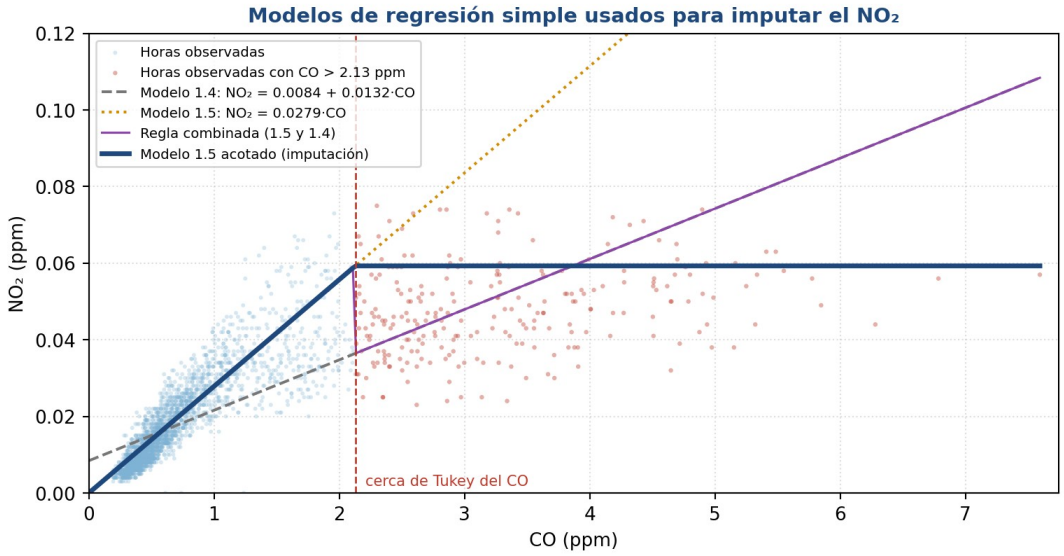


Figura 1. Modelos de regresión simple del NO_2 en función del CO y reglas de imputación evaluadas. La línea azul gruesa es la regla adoptada.

Con los mismos datos con los que se estimaron, la regla combinada obtiene el menor error (RMSE de 0.0074 ppm, frente a 0.0075 del modelo acotado), pero tiene un salto en la cerca: al pasar de un modelo a otro, el NO_2 estimado cae de 0.059 a 0.036 ppm, algo que no tiene sentido físico. La validación fuera de muestra, en la que los modelos se reestiman con septiembre y octubre y se aplican a noviembre y diciembre, resuelve la elección. Los tres esquemas que prolongan una recta

tienen errores parecidos y altos (RMSE cercano a 0.019 ppm), mientras que el modelo 1.5 acotado reduce el error a 0.0088 ppm, menos de la mitad. Cuando el CO alcanza valores que el modelo no conoce, es más seguro no extrapolar. Por eso se adoptó el modelo 1.5 acotado para la imputación. Aun así, la relación entre el NO_2 y el CO cambia de un mes a otro, por lo que los valores imputados deben tomarse como una aproximación y no como mediciones.

2.3 Serie completada

Se imputaron 5,711 horas; en 446 de ellas el CO superaba la cerca y el NO_2 se fijó en el valor del límite. La Figura 2 muestra la serie diaria resultante y la Tabla 2 los promedios mensuales.



Figura 2. Promedio diario de NO_2 observado (septiembre a diciembre) e imputado a partir del CO, estación Centro, 2024.

Mes	Horas observadas	Horas imputadas	NO_2 observado	NO_2 completado
Enero	0	711		0.0409
Febrero	0	692		0.0348
Marzo	0	741		0.0302
Abril	0	706		0.0269
Mayo	0	742		0.0263
Junio	0	720		0.0244
Julio	0	688		0.0264
Agosto	0	653		0.0156
Septiembre	535	32	0.0123	0.0122
Octubre	720	13	0.0185	0.0183
Noviembre	717	3	0.0227	0.0226
Diciembre	734	10	0.0261	0.0263

Tabla 2. Horas observadas e imputadas y promedio mensual de NO_2 (ppm).

En septiembre a diciembre los promedios casi no cambian, porque solo se completaron 222 horas sueltas. De enero a agosto toda la información proviene del CO. El patrón que resulta es razonable: el promedio más alto se da en enero (0.0409 ppm) y desciende hacia el verano, lo que coincide con la temporada seca e invernal, en la que las inversiones térmicas dificultan la dispersión de los contaminantes en Guadalajara, y con la temporada de lluvias, que la favorece. Aun así, ese comportamiento es heredado del CO y no puede verificarse, porque no existen mediciones de NO_2 en esos meses.

3. Relación del NO_2 con el PM10 y el PM2.5

3.1 Corpus de análisis

Para el análisis se tomaron las horas con NO_2 (observado o imputado), PM10 y PM2.5 al mismo tiempo (6,752) y, como en la Tarea 1.5, se excluyeron las horas atípicas en cualquiera de las tres variables según el criterio de Tukey, con lo que quedaron 6,260 horas, 3,878 de ellas con NO_2 imputado. Como control, todos los modelos se estimaron también con las horas de NO_2 observado únicamente (2,395 horas tras la misma depuración).

3.2 Dispersión entre las variables y colinealidad

La Figura 3 sigue la técnica de la sesión 8: se grafica la variable dependiente contra cada variable independiente y, además, las variables independientes entre sí. La Tabla 3 reúne los coeficientes de correlación.

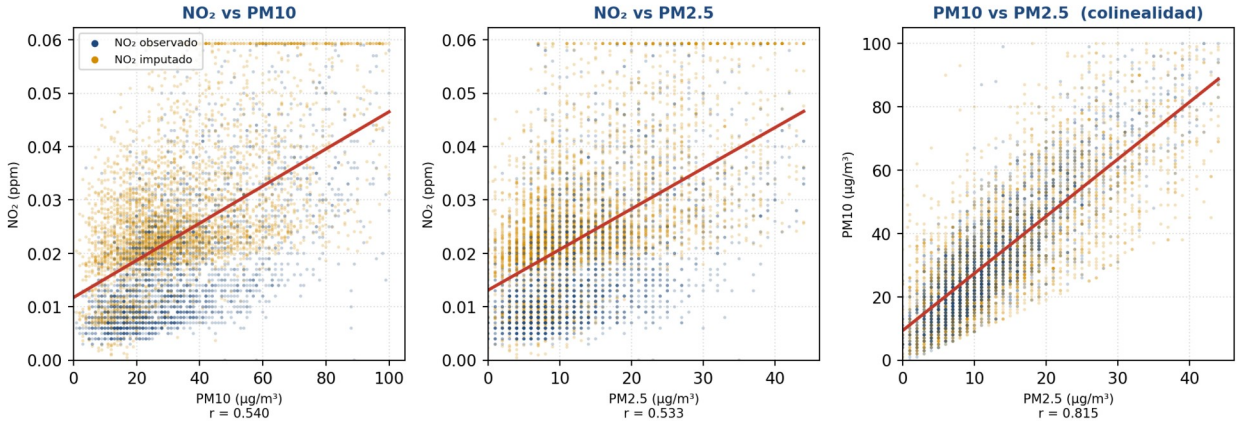


Figura 3. Dispersión del NO_2 frente al PM10 y al PM2.5, y del PM10 frente al PM2.5, serie completada sin atípicos. Los puntos ámbar son horas con NO_2 imputado.

Par de variables	r serie completada	r solo observadas
NO_2 – PM10	0.540	0.604
NO_2 – PM2.5	0.533	0.541
PM10 – PM2.5	**0.815**	**0.876**
VIF de PM10 y PM2.5	2.97	4.31

Tabla 3. Correlación de Pearson entre el NO_2 y las partículas, y entre las partículas, corpus sin atípicos.

El NO_2 se relaciona de forma positiva y moderada con ambas partículas, un poco más con el PM10. La relación más fuerte de la tabla, sin embargo, no es la del NO_2 sino la de las partículas entre sí (r = 0.815 en la serie completada y 0.876 con datos observados). No es casual: el PM10 incluye a todas las partículas menores de 10 µm y, por lo tanto, al PM2.5. Las dos variables independientes aportan en buena medida la misma información, que es justamente la colinealidad que la sesión 8 recomienda revisar antes de ajustar un modelo múltiple. El factor de inflación de la varianza (VIF = 1 / (1 − R^2_j)) es de 2.97 y 4.31: no llega al umbral de 5 o 10 que suele considerarse grave, pero indica que la varianza de cada coeficiente se multiplica por tres o cuatro por compartir información con la otra partícula.

3.3 Modelos de regresión lineal múltiple

Se ajustaron cuatro modelos por mínimos cuadrados: los dos simples, el lineal múltiple $NO_2 = b_0 + b_1 \cdot PM10 + b_2 \cdot PM2.5$ y un modelo cuadrático en el PM10, $NO_2 = b_0 + b_1 \cdot PM10 + b_2 \cdot PM10^2 + b_3 \cdot PM2.5$, como el de la sesión 8. Los resultados se presentan en la Tabla 4 y los planos de regresión en la Figura 4.

Serie y modelo	b PM10	b PM10²	b PM2.5	R^2	R^2 ajustado
Completada: simple PM10	0.348	–	–	0.291	0.291
Completada: simple PM2.5	–	–	0.761	0.284	0.284
Completada: múltiple lineal	**0.202**	**–**	**0.396**	**0.317**	**0.317**
Completada: múltiple cuadrático	0.193	0.00011 (p = 0.70)	0.397	0.317	0.317
Observada: simple PM10	0.349	–	–	0.365	0.364
Observada: simple PM2.5	–	–	0.721	0.293	0.293
Observada: múltiple lineal	0.323	–	0.069 (p = 0.12)	0.365	0.365
Observada: múltiple cuadrático	0.321	0.00002 (p = 0.95)	0.069 (p = 0.13)	0.365	0.365

Tabla 4. Coeficientes (ppb de NO_2 por µg/m³; por (µg/m³)² en el término cuadrático) y ajuste de los modelos. Salvo donde se indica el valor p, los coeficientes son significativos al 5 %.

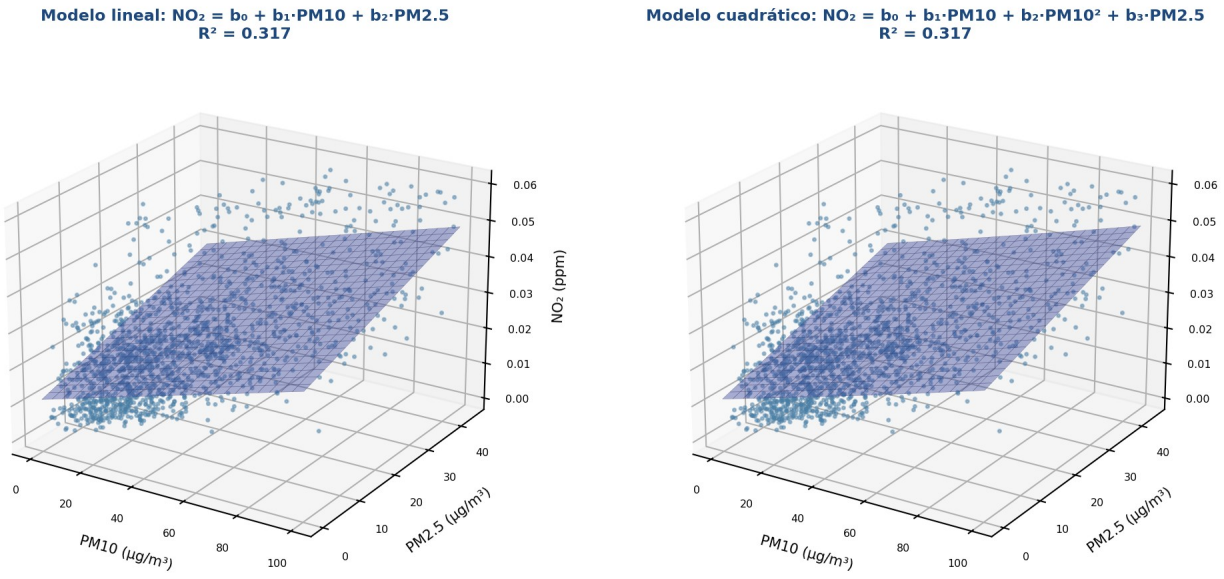


Figura 4. Plano de regresión lineal múltiple y superficie del modelo cuadrático del NO_2 en función del PM10 y el PM2.5, serie completada (muestra de 1,500 horas).

Con los datos observados, agregar el PM2.5 a un modelo que ya contiene al PM10 no mejora el ajuste (R^2 de 0.365 en ambos casos) y el coeficiente del PM2.5 se vuelve no significativo ($p = 0.12$), aunque en el modelo simple sí lo era. Es el síntoma típico de la colinealidad: una vez que el PM10 está en el modelo, el PM2.5 ya no aporta información propia sobre el NO_2. La Figura 5 lo muestra con claridad: el coeficiente del PM2.5 pasa de 0.721 a 0.069 ppb por µg/m³ y su intervalo de confianza incluye el cero.

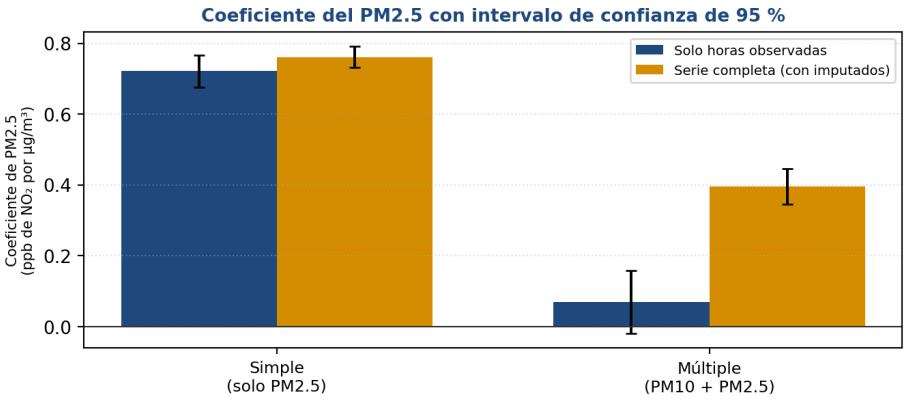


Figura 5. Coeficiente del PM2.5 en el modelo simple y en el múltiple, con su intervalo de confianza de 95 %, para la serie observada y la completada.

En la serie completada ambos coeficientes son significativos y el R^2 sube de 0.291 a 0.317. Esta diferencia debe interpretarse con cuidado. Las horas imputadas no contienen mediciones de NO_2, sino una función lineal del CO, de modo que en esos meses el modelo mide en realidad la relación entre el CO y las partículas, que es más pareja entre el PM10 y el PM2.5 porque ambos comparten la combustión como fuente. Parte de la información que el PM2.5 parece aportar proviene, entonces, de la imputación y no de los datos observados.

Por último, el término cuadrático no mejora el ajuste en ninguna de las dos series ($p = 0.70$ y 0.95), y la superficie de la Figura 4 es prácticamente un plano. A diferencia de lo que ocurría con el NOx y el CO, la relación del NO_2 con las partículas no muestra una curvatura relevante una vez excluidos los atípicos. Lo que limita el ajuste es la dispersión de los puntos: las dos partículas juntas explican apenas 31.7 % de la variabilidad del NO_2 en la serie completada.

4. Conclusiones

La imputación permitió completar 94.0 % de las horas sin NO_2 a partir del CO. Ninguno de los modelos de las tareas anteriores funcionó bien en todo el rango: la recta por el origen de la Tarea 1.5 es la más precisa en las concentraciones habituales, pero sobrestima el NO_2 cuando el CO es alto, porque prolonga una recta fuera del rango con el que fue estimada. Limitarla a ese rango fue la opción que mejor resistió la validación fuera de muestra, con menos de la mitad del error de las alternativas. Aun así, la relación entre ambos contaminantes cambia de un mes a otro, por lo que los ocho meses imputados son una aproximación que no puede contrastarse con mediciones.

El NO_2 mantiene una relación positiva y moderada con las partículas, algo mayor con el PM10. La relación más fuerte entre las variables analizadas es la del PM10 con el PM2.5, y esa colinealidad condiciona el modelo múltiple: con los datos observados, el PM2.5 deja de ser significativo cuando se incluye el PM10 y no mejora el ajuste. Para explicar el NO_2 con partículas basta con el PM10, y un modelo con ambas no aporta información adicional. La aparente contribución del PM2.5 en la serie completada se explica en buena parte por la imputación con CO.

En términos generales, las partículas explican una fracción mucho menor del NO_2 que el CO o el NOx, lo que concuerda con que tienen fuentes más diversas (polvo, construcción, combustión, formación secundaria), mientras que el NO_2 depende sobre todo del tránsito vehicular. Como en las tareas anteriores, se trata de asociaciones estadísticas que no establecen relaciones de causalidad.

Referencias

Little, R. J. A., & Rubin, D. B. (2019). Statistical analysis with missing data (3.ª ed.). Wiley.

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to linear regression analysis (6.ª ed.). Wiley.

Ruiz Chávez, C. F. (2026). Visualización de grandes bases de datos: Sesión 8 [Diapositivas de clase]. Maestría en Ciencia de los Datos, Centro Universitario de Ciencias Económico Administrativas, Universidad de Guadalajara.

Secretaría de Medio Ambiente y Desarrollo Territorial. (2024). Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ): base de datos de calidad del aire 2024. Gobierno del Estado de Jalisco. https://siga.jalisco.gob.mx/aire/

Seinfeld, J. H., & Pandis, S. N. (2016). Atmospheric chemistry and physics: From air pollution to climate change (3.ª ed.). Wiley.