Universidad de Guadalajara
Centro Universitario de Ciencias Económico-Administrativas
Maestría en Ciencias de los Datos | 3er Semestre
Materia: Visualización de Grandes Bases de Datos

Tarea 1.7. Modelo refinado del NO_2 con PM10 y PM2.5
Estación de monitoreo Centro, Zona Metropolitana de Guadalajara, 2024

Alumno:	Carlos Pulido Rosas
Fecha:	21 de octubre de 2026
Actividad:	Tarea 1.7. Modelado de NO_2 y PM2.5/PM10 refinado
Herramienta:	Python 3.13 (pandas, NumPy, Matplotlib, statsmodels, scikit-learn)
Versión:	SIMAJ, base de calidad del aire 2024 (BD_2024)
Entorno:	Equipo personal, entorno conda MCD
Dataset:	Calidad del aire ZMG 2024, estación Centro (CEN)

1. Introducción

En la tarea anterior completé el NO_2 de la estación Centro con el CO y armé modelos de regresión múltiple con el PM10 y el PM2.5. En esta tarea refino ese modelo. Le quité el intercepto para que el plano pase por el origen, $NO_2 = b_1 \cdot PM10 + b_2 \cdot PM2.5$, quité los atípicos de las tres variables y comparé el resultado contra los modelos de la 1.6.

Trabajé con las mismas dos series de la 1.6. La completada tiene el NO_2 imputado y suma 6,752 horas con las tres variables. La observada solo tiene NO_2 medido (2,611 horas) y la uso para comprobar que lo que veo no sea efecto de la imputación.

2. Metodología

2.1 Exclusión de atípicos

Seguí el mismo criterio de Tukey de las tareas pasadas. Si en una hora el NO_2, el PM10 o el PM2.5 quedan fuera de [Q1 − 1.5·RIC, Q3 + 1.5·RIC], quito esa hora completa. Me quedaron 6,260 horas en la serie completada y 2,395 en la observada. También calculé las correlaciones con los datos sin depurar para ver qué cambiaba.

2.2 Modelo por el origen

El modelo de la 1.6 era $NO_2 = b_0 + b_1 \cdot PM10 + b_2 \cdot PM2.5$. Al quitarle b_0, el modelo supone que si no hay partículas tampoco hay NO_2. Para compararlos no me quise quedar solo con el R^2 que da cada modelo. Como vimos en la Tarea 1.5, cuando no hay intercepto el R^2 se mide contra cero y no contra el promedio, y sale alto aunque el modelo ajuste mal. Así que además calculé el R^2 contra el promedio en los dos casos, el RMSE y el promedio de los residuales.

2.3 Relación entre las partículas y K-medias

Para ver cómo se relacionan el PM10 y el PM2.5 usé su correlación y una recta por el origen $PM2.5 = b \cdot PM10$. También probé K-medias, que vimos en la sesión 9. El algoritmo junta las horas en k grupos buscando que la suma $J = \Sigma \Sigma \|x_i - c_j\|^2$ de las distancias al centroide sea la menor posible. Estandaricé las dos variables antes de agrupar para que ninguna pesara más y escogí k con la gráfica del codo.

3. Resultados

3.1 ¿Mejoró la correlación?

En la Tabla 1 están las correlaciones antes y después de quitar los atípicos.

Par	Completada sin depurar	Completada depurada	Observada sin depurar	Observada depurada
NO_2 – PM10	0.641	0.540	0.694	0.604
NO_2 – PM2.5	0.602	0.533	0.570	0.541
PM10 – PM2.5	0.883	0.815	0.899	0.876

Tabla 1. Correlación de Pearson antes y después de excluir los atípicos de NO_2, PM10 y PM2.5.

La correlación no mejoró. Bajó en todos los pares. Con los datos observados, la del NO_2 con el PM10 pasó de 0.694 a 0.604. Ya me había pasado algo parecido con las partículas en la Tarea 1.5. Las horas atípicas son episodios de mucha contaminación donde todo sube al mismo tiempo, y como quedan muy lejos del resto, jalan la correlación hacia arriba. Sin ellas la relación es más débil, pero se parece más a lo que pasa normalmente. El origen aquí no influye, porque la correlación no depende del modelo.

3.2 ¿Mejoraron el R^2 y los residuales?

La Tabla 2 pone lado a lado el modelo de la 1.6 y el refinado.

Serie y modelo	b_0 (ppb)	b PM10	b PM2.5	R^2 del modelo	R^2 vs. promedio	RMSE (ppb)	Residual medio (ppb)
Completada: 1.6 con intercepto	11.22	0.202	0.396	0.317	0.317	10.90	-0.00
Completada: 1.7 por el origen	**0 (forzado)**	**0.392**	**0.524**	**0.796**	**0.133**	**12.29**	**+2.86**
Observada: 1.6 con intercepto	6.03	0.323	0.069	0.365	0.365	9.63	+0.00
Observada: 1.7 por el origen	0 (forzado)	0.435	0.106	0.788	0.301	10.11	+1.57

Tabla 2. Modelo de la Tarea 1.6 contra el modelo refinado, datos depurados. Los coeficientes están en ppb de NO_2 por µg/m³. El R^2 del modelo es el que reporta statsmodels; en el modelo por el origen se calcula contra cero.

Cuando vi el R^2 del modelo refinado pensé que había mejorado mucho, porque en la serie completada subió de 0.317 a 0.796. Luego recordé lo de la Tarea 1.5. Ese R^2 se mide contra cero, y como el NO_2 casi nunca vale cero, cualquier plano más o menos cercano a los puntos da un número alto. Con el R^2 medido contra el promedio, que es el que sí se puede comparar, el refinado cae a 0.133 en la serie completada y a 0.301 en la observada. Los dos quedan por debajo de los de la 1.6. El RMSE también empeora, de 10.9 a 12.3 ppb en la serie completada.

Los residuales tampoco mejoraron. En la 1.6 su promedio es cero, que es lo normal cuando el modelo tiene intercepto. En el refinado el promedio es de +2.9 ppb, o sea que en general el modelo se queda corto. Las Figuras 1 y 2 lo muestran.

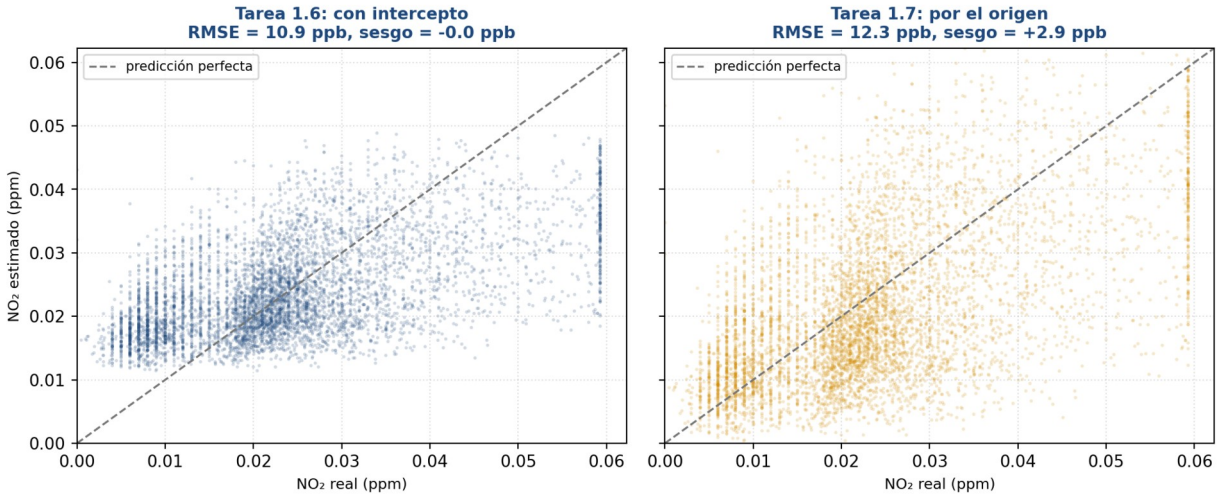


Figura 1. NO_2 real contra NO_2 estimado por el modelo de la Tarea 1.6 y por el modelo refinado, serie completada depurada. La línea punteada es la predicción perfecta.

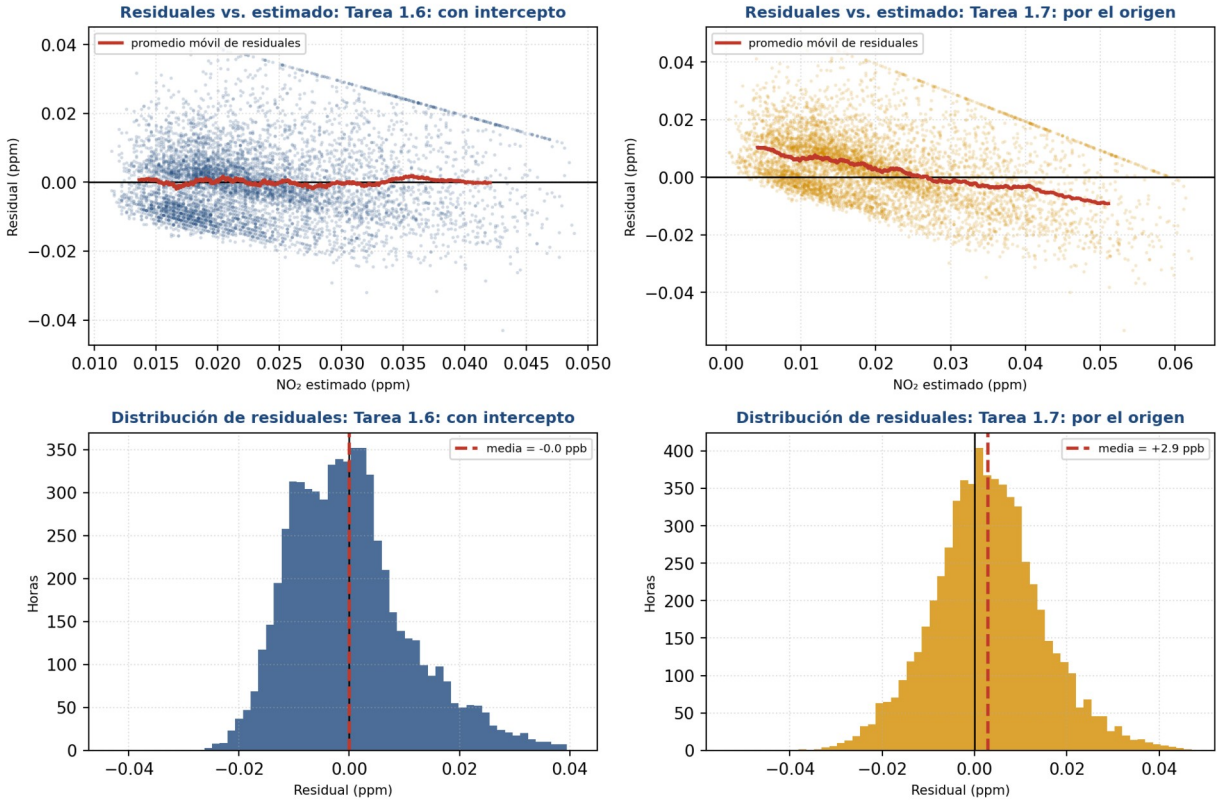


Figura 2. Residuales de los dos modelos, serie completada depurada. Arriba, residuales contra valor estimado con su promedio móvil; abajo, su distribución.

Lo más claro está en la parte de arriba de la Figura 2. En la 1.6 la línea roja, que es el promedio móvil de los residuales, se mantiene casi pegada al cero. En el refinado va bajando. Cuando el modelo estima poco NO_2 los residuales son positivos, y cuando estima mucho son negativos. Eso quiere decir que en horas con pocas partículas el modelo predice muy poco NO_2 cuando sí lo hay, y en horas con muchas partículas se pasa. Si los residuales tienen una tendencia así, al modelo le falta algo, y

aquí lo que le falta es la constante. En el histograma de abajo también se nota, porque los residuales del refinado están corridos a la derecha del cero.

Hay dos detalles más en la figura. La línea recta de puntos que se ve en la parte de arriba son horas imputadas que en la 1.6 quedaron fijas en el valor límite de 0.059 ppm. Y la correlación entre el NO_2 real y el estimado casi no cambia (0.563 y 0.562). Los dos modelos ordenan las horas casi igual de más a menos contaminadas; el refinado lo que pierde es el nivel.

3.3 ¿Cómo se relacionan las partículas entre sí?

El PM10 y el PM2.5 son el par con la correlación más alta de todo el análisis, 0.876 con los datos observados y 0.815 en la serie completada. Era de esperarse, porque el PM2.5 forma parte del PM10. Con una recta por el origen me salió PM2.5 ≈ 0.39·PM10 (R^2_o = 0.930), es decir, cerca del 39 % del PM10 son partículas finas. El VIF de 4.31 indica colinealidad moderada entre las dos.

Con K-medias quería ver si había distintos tipos de horas según sus partículas. En la gráfica del codo (Figura 3, derecha) la J baja mucho hasta k = 3 y después casi no cambia, así que me quedé con tres grupos. Sus promedios están en la Tabla 3.

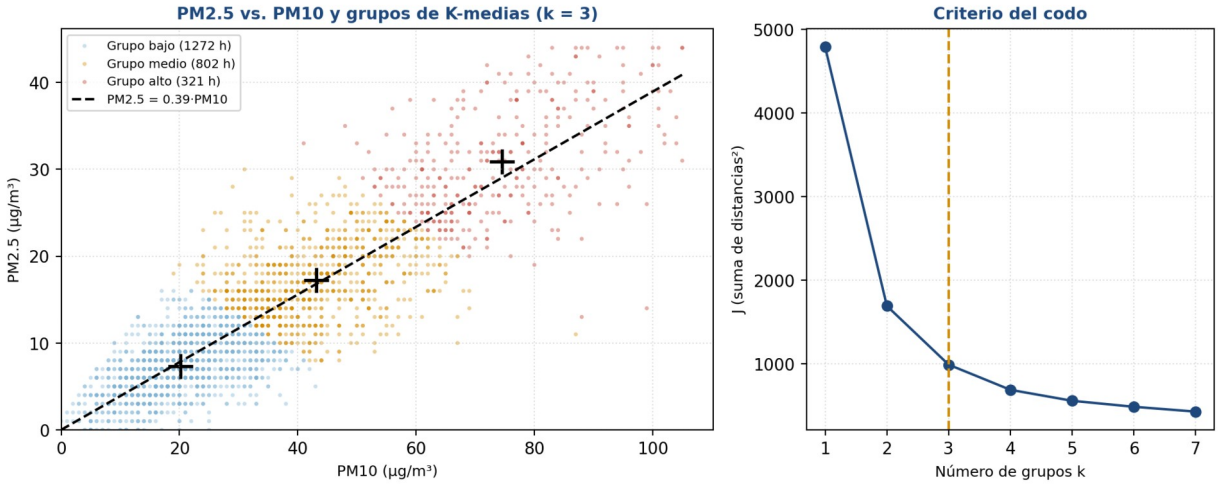


Figura 3. Izquierda: PM2.5 contra PM10 con los tres grupos de K-medias (las cruces son los centroides) y la recta por el origen. Derecha: J para k de 1 a 7. Horas con NO_2 observado, sin atípicos.

Grupo	Horas	PM10 (µg/m³)	PM2.5 (µg/m³)	PM2.5 / PM10	NO_2 (ppb)
Bajo	1,272	20.2	7.3	0.36	13.2
Medio	802	43.1	17.2	0.40	20.7
Alto	321	74.6	30.9	0.41	32.8

Tabla 3. Promedio de cada grupo de K-medias (k = 3), horas con NO_2 observado.

No salieron tipos de partículas distintos. Los tres grupos están sobre la misma diagonal y lo que los separa es qué tanta contaminación hay, poca, media o mucha. La proporción de finas cambia poco, de 0.36 en el grupo bajo a 0.41 en el alto. Esto me confirma que el PM10 y el PM2.5 se mueven casi como si fueran una sola variable.

Lo que sí me llamó la atención es el NO_2. No lo usé para formar los grupos y aun así sube de uno a otro, de 13.2 a 32.8 ppb. Además, en el grupo con menos partículas el NO_2 sigue en 13.2 ppb, que está lejos de cero. Ahí se ve por qué el modelo por el origen no funciona con estos datos.

4. ¿Qué nos dice este modelo?

En el modelo refinado de la serie completada, cada µg/m³ de PM10 va con 0.39 ppb de NO_2 y cada µg/m³ de PM2.5 con 0.52 ppb. En la 1.6 eran 0.20 y 0.40. Las pendientes crecieron porque, al quitar la constante, tienen que cargar con el NO_2 que antes explicaba ella. Esa constante valía 11.2 ppb en la serie completada y 6.0 ppb en la observada, y en los dos casos era significativa.

Creo que la razón es física. Con el CO funcionó forzar el origen porque el CO y el NO_2 salen del mismo escape. Las partículas, en cambio, también vienen del polvo, de la construcción y de otras cosas que no producen NO_2. Hay horas con pocas partículas en las que sigue habiendo NO_2 por el tráfico, y horas con mucho polvo y no tanto NO_2. Por eso no tiene sentido que el NO_2 sea cero cuando las partículas son cero, y el modelo refinado lo confirma, porque al quitar la constante ajusta peor y los residuales quedan sesgados.

5. Conclusiones

Al quitar los atípicos la correlación bajó, porque esas horas extremas la estaban inflando. Forzar el plano por el origen hizo que el R^2 del modelo subiera de 0.317 a 0.796, pero eso es por la forma en que se calcula sin intercepto. Comparado de forma justa bajó a 0.133, el RMSE subió y los residuales quedaron sesgados. En resumen, el modelo refinado es peor que el de la 1.6.

El PM10 y el PM2.5 están muy relacionados y el PM2.5 es más o menos el 39 % del PM10. K-medias no encontró tipos de horas distintos, solo niveles de contaminación, y el NO_2 sube junto con ellos. Si tuviera que describir el NO_2 con partículas usaría el modelo con intercepto de la 1.6 o el de fracción fina y gruesa. La recta por el origen la dejaría para casos como el NO_2 con el CO, que sí vienen de la misma fuente.

Referencias

Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). Introduction to linear regression analysis (6.ª ed.). Wiley.

Ruiz Chávez, C. F. (2026). Visualización de grandes bases de datos: Sesión 9 [Diapositivas de clase]. Maestría en Ciencia de los Datos, Centro Universitario de Ciencias Económico Administrativas, Universidad de Guadalajara.

Secretaría de Medio Ambiente y Desarrollo Territorial. (2024). Sistema de Monitoreo Atmosférico de Jalisco (SIMAJ): base de datos de calidad del aire 2024. Gobierno del Estado de Jalisco. https://siga.jalisco.gob.mx/aire/

Seinfeld, J. H., & Pandis, S. N. (2016). Atmospheric chemistry and physics: From air pollution to climate change (3.ª ed.). Wiley.